

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



Ninh Hải Đăng

**ỨNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG
GIÁM SÁT BIẾN ĐỘNG RỪNG TỈNH CÀ MAU**

TÓM TẮT ĐỒ ÁN TỐT NGHIỆP

Ngành: Công nghệ Hàng không Vũ trụ

Cán bộ hướng dẫn: TS. Hà Minh Cường

Cán bộ đồng hướng dẫn: ThS. Hoàng Tích Phúc

HÀ NỘI - 2025

CHƯƠNG 1. BÀI TOÁN

1.1. Đặt vấn đề

Rừng đóng vai trò thiết yếu trong việc duy trì sự cân bằng sinh thái toàn cầu, điều hòa khí hậu thông qua hấp thụ CO₂, bảo tồn đa dạng sinh học và cung cấp sinh kế cho hàng triệu người. Tuy nhiên, tình trạng mất rừng đang diễn ra với tốc độ báo động trên toàn cầu, đặc biệt tại các quốc gia đang phát triển. Theo báo cáo “Global Forest Resources Assessment 2020” của FAO, thế giới đã mất khoảng 178 triệu ha rừng trong giai đoạn 1990–2020, tương đương với diện tích của Libya.

Các nguyên nhân chính dẫn đến mất rừng bao gồm: chuyển đổi đất rừng sang nông nghiệp và chăn nuôi, khai thác gỗ bất hợp pháp, cháy rừng do biến đổi khí hậu và hoạt động của con người, cũng như mở rộng đô thị hóa. Hậu quả của việc mất rừng không chỉ dừng lại ở mất đi nguồn tài nguyên, mà còn gây ra biến đổi khí hậu nghiêm trọng do giảm khả năng hấp thụ CO₂, suy giảm đa dạng sinh học khi môi trường sống của nhiều loài bị phá hủy, gia tăng rủi ro thiên tai như lũ lụt và lở đất do mất lớp phủ thực vật, và ảnh hưởng trực tiếp đến sinh kế của cộng đồng địa phương phụ thuộc vào rừng.

Tại Việt Nam, mặc dù độ che phủ rừng đã tăng từ 37% (năm 2000) lên 42% (năm 2020) nhờ các chương trình trồng rừng, nhưng tình trạng suy thoái và mất rừng tự nhiên vẫn đáng báo động, đặc biệt tại các tỉnh ven biển và đồng bằng sông Cửu Long. Tỉnh Cà Mau, nằm ở cực Nam Tổ Quốc, sở hữu hệ sinh thái rừng ngập mặn có giá trị cao về sinh thái và kinh tế. Rừng ngập mặn đóng vai trò quan trọng trong việc chống xói mòn bờ biển, giảm thiểu tác động của bão và nước biển dâng, cung cấp nguồn sinh kế cho ngư dân địa phương, và là nơi cư trú, sinh sản của nhiều loài thủy sinh có giá trị kinh tế.

Tuy nhiên, rừng ngập mặn Cà Mau đang phải đối mặt với nhiều áp lực: chuyển đổi đất rừng sang ao nuôi tôm là nguyên nhân chính gây mất rừng do lợi nhuận kinh tế cao từ nuôi trồng thủy sản; xâm nhập mặn ngày càng gia tăng do biến đổi khí hậu và nước biển dâng; khai thác gỗ và sản phẩm rừng không bền vững; và tác động của các cơn bão nhiệt đới ngày càng mạnh.

Phương pháp giám sát rừng truyền thống dựa trên điều tra thực địa có nhiều hạn chế: tốn kém về thời gian và chi phí khi khảo sát diện tích lớn, khó tiếp cận các vùng rừng xa xôi hoặc địa hình phức tạp, tần suất cập nhật thông tin thấp (thường 3–5 năm/lần), và khó phát hiện kịp thời các biến động nhỏ lẻ nhưng tích lũy dần theo thời gian.

Công nghệ viễn thám vệ tinh cung cấp giải pháp hiệu quả, cho phép giám sát liên tục, diện rộng với chi phí hợp lý. Chương trình Copernicus của Liên minh Châu Âu cung cấp dữ liệu miễn phí từ hai vệ tinh bổ sung nhau: Sentinel-1 với ra-đa khẩu độ tổng hợp (SAR) băng C hoạt động trong mọi điều kiện thời tiết, ngày đêm, không bị ảnh hưởng bởi mây; và Sentinel-2 với ảnh quang học đa phổ 13 kênh ở độ phân giải 10–60m, cung cấp thông tin chi tiết về đặc tính phổ của thực vật. Cả hai vệ tinh đều có chu kỳ quay trở lại ngắn (5–6 ngày) và độ phân giải không gian cao (10m), phù hợp cho giám sát rừng nhiệt đới.

Trong những năm gần đây, trí tuệ nhân tạo và học sâu đã đạt được những bước tiến vượt bậc trong xử lý ảnh và nhận dạng mẫu. Mạng nơ-ron tích chập (CNN) đặc biệt hiệu quả trong phân loại ảnh nhờ khả năng tự động học đặc trưng không gian từ dữ liệu thô, không cần trích xuất đặc trưng thủ công như các phương pháp học máy truyền thống. CNN đã được ứng dụng thành công trong nhiều lĩnh vực viễn thám như phân loại lớp phủ đất, phát hiện đối tượng, và giám sát biến động.

Xuất phát từ nhu cầu thực tiễn về giám sát rừng hiệu quả tại tỉnh Cà Mau và xu hướng ứng dụng công nghệ trí tuệ nhân tạo tiên tiến, đề án này lựa chọn đề tài “**Ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau**” nhằm phát triển mô hình phát hiện mất rừng với độ chính xác cao, góp phần hỗ trợ công tác quản lý và bảo vệ rừng bền vững.

1.2. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề án là biến động rừng tại khu vực ranh giới lâm nghiệp tỉnh Cà Mau. Các trạng thái biến động rừng được phân loại thành bốn nhóm chính:

(1) Rừng ổn định: Các vùng có lớp phủ rừng ổn định, không có biến đổi đáng kể giữa hai thời kỳ quan sát. Đây là những khu vực rừng tự nhiên hoặc rừng trồng được bảo vệ tốt, duy trì độ che phủ và sức khỏe thực vật qua thời gian.

(2) Mất rừng: Các vùng chuyển từ trạng thái có rừng sang không có rừng trong giai đoạn nghiên cứu. Nguyên nhân có thể do chuyển đổi sang nuôi trồng thủy sản, khai thác gỗ, hoặc các hoạt động phát triển hạ tầng.

(3) Phi rừng: Các vùng không phải rừng ở cả hai thời kỳ, bao gồm khu dân cư, đất nông nghiệp, mặt nước (sông, hồ, ao nuôi), và các loại hình sử dụng đất khác.

(4) Phục hồi rừng: Các vùng chuyển từ trạng thái không có rừng sang có rừng,

thường là kết quả của các chương trình trồng rừng, tái sinh tự nhiên, hoặc phục hồi sinh thái.

Về không gian, nghiên cứu được thực hiện trên khu vực ranh giới lâm nghiệp tỉnh Cà Mau (theo địa giới hành chính mới có hiệu lực từ ngày 01/07/2025, sau khi sáp nhập tỉnh Cà Mau cũ và tỉnh Bạc Liêu) với tổng diện tích 170,179 ha (tương đương 1,701.79 km²). Khu vực này bao gồm các loại hình rừng tự nhiên và rừng trồng, trong đó chủ yếu là rừng ngập mặn và rừng phòng hộ ven biển.

Về thời gian, dữ liệu sử dụng bao gồm ảnh vệ tinh Sentinel-1 và Sentinel-2 trong giai đoạn từ tháng 01/2024 đến tháng 02/2025, cho phép phát hiện các biến động xảy ra trong khoảng thời gian khoảng 13 tháng. Việc lựa chọn hai thời điểm này dựa trên các tiêu chí: cả hai đều nằm trong mùa khô (tháng 1–3) để giảm thiểu ảnh hưởng của mây và đảm bảo tính so sánh; và khoảng cách thời gian đủ dài để phát hiện các biến động có ý nghĩa nhưng không quá dài dẫn đến biến đổi tích lũy phức tạp.

Diện tích thực tế được phân loại là 162,469 ha (khoảng 95.5% diện tích ranh giới). Phần còn lại (4.5%) bị loại trừ do các lý do: bị mây che phủ ở một hoặc cả hai thời điểm mặc dù đã áp dụng lọc mây, dữ liệu không hợp lệ hoặc thiếu dữ liệu tại một số vùng biên, và các vùng nằm ngoài ranh giới lâm nghiệp chính thức.

1.3. Cơ sở lý thuyết

1.3.1. Công nghệ viễn thám

Viễn thám là khoa học và nghệ thuật thu nhận thông tin về một đối tượng, khu vực hoặc hiện tượng thông qua phân tích dữ liệu được thu thập bởi một thiết bị không tiếp xúc trực tiếp với đối tượng đó. Trong giám sát rừng, công nghệ viễn thám cung cấp hai loại dữ liệu bổ sung nhau:

Viễn thám bị động (Sentinel-2): Ảnh quang học đa phổ với 13 kênh phổ từ vùng nhìn thấy đến hồng ngoại sóng ngắn, độ phân giải không gian 10–60m tùy kênh, phụ thuộc vào ánh sáng mặt trời và bị ảnh hưởng bởi mây. Ưu điểm chính là cung cấp thông tin chi tiết về đặc tính phổ của thực vật, cho phép tính toán các chỉ số thực vật, và dễ hiểu, trực quan với con người. Hạn chế là không hoạt động ban đêm, bị ảnh hưởng nghiêm trọng bởi mây và bóng mây, và phụ thuộc vào điều kiện khí quyển.

Viễn thám chủ động (Sentinel-1): Ra-đa khẩu độ tổng hợp (SAR) băng C với hai

kênh phân cực VV và VH, độ phân giải 10m, hoạt động độc lập với ánh sáng và điều kiện thời tiết. Ưu điểm là hoạt động trong mọi điều kiện thời tiết (qua mây, mưa), hoạt động cả ngày lẫn đêm, và nhạy cảm với cấu trúc và độ ẩm bề mặt. Hạn chế là dữ liệu phức tạp, khó hiểu hơn ảnh quang học, bị ảnh hưởng bởi độ nhám bề mặt và địa hình, và có hiện tượng nhiễu đốm (speckle noise).

Các chỉ số thực vật được tính từ ảnh quang học đóng vai trò quan trọng trong giám sát rừng:

NDVI (Normalized Difference Vegetation Index) đo lường mật độ và sức khỏe thực vật dựa trên sự khác biệt giữa phản xạ cận hồng ngoại (thực vật khỏe phản xạ cao) và ánh sáng đỏ (thực vật hấp thụ mạnh). Công thức: $NDVI = (NIR - Red) / (NIR + Red)$, với giá trị từ -1 đến +1; giá trị cao (0.6–0.9) chỉ thị thực vật dày đặc, khỏe mạnh.

NBR (Normalized Burn Ratio) được thiết kế để phát hiện vùng cháy rừng, nhưng cũng rất nhạy với biến động rừng do khai thác. Công thức: $NBR = (NIR - SWIR2) / (NIR + SWIR2)$; sự giảm mạnh giá trị NBR chỉ ra mất rừng hoặc suy thoái.

NDMI (Normalized Difference Moisture Index) phản ánh hàm lượng nước trong tán lá và độ ẩm thực vật, hữu ích trong phát hiện stress thực vật sớm. Công thức: $NDMI = (NIR - SWIR1) / (NIR + SWIR1)$; giá trị cao chỉ thị thực vật có độ ẩm tốt.

Việc tích hợp dữ liệu đa nguồn (SAR + quang học) đã được chứng minh trong nhiều nghiên cứu là có khả năng tăng độ chính xác phân loại 5–15% so với sử dụng đơn nguồn, do hai loại dữ liệu cung cấp thông tin bổ sung nhau về cả đặc tính quang phổ và cấu trúc của thực vật.

1.3.2. Mạng nơ-ron tích chập (CNN)

Mạng nơ-ron tích chập là một kiến trúc học sâu được thiết kế đặc biệt cho xử lý dữ liệu dạng lưới như ảnh. CNN có khả năng tự động học các đặc trưng phân cấp từ dữ liệu thô, từ các đặc trưng cơ bản (cạnh, góc) ở các lớp đầu đến các đặc trưng phức tạp hơn (kết cấu, hình dạng) ở các lớp sau.

Các thành phần chính của CNN bao gồm:

Lớp tích chập (Convolutional Layer) thực hiện phép tích chập giữa đầu vào và các bộ lọc học được, trích xuất đặc trưng không gian cục bộ. Mỗi bộ lọc tìm kiếm một loại đặc trưng cụ thể (ví dụ: cạnh ngang, cạnh dọc, kết cấu).

Lớp gộp (Pooling Layer) giảm chiều không gian của dữ liệu, làm giảm số lượng tham số và tính toán, đồng thời tăng tính bất biến đối với phép dịch chuyển nhỏ. Phương pháp phổ biến là Max Pooling (lấy giá trị lớn nhất) hoặc Average Pooling (lấy giá trị trung bình).

Chuẩn hóa theo lô (Batch Normalization) chuẩn hóa đầu ra của mỗi lớp về phân phối chuẩn, giúp ổn định và tăng tốc quá trình huấn luyện, cho phép sử dụng tốc độ học cao hơn, và có tác dụng điều chuẩn nhẹ.

Dropout là kỹ thuật điều chuẩn tắt ngẫu nhiên một tỷ lệ các nơ-ron trong quá trình huấn luyện, giúp ngăn ngừa quá khớp bằng cách buộc mạng học các đặc trưng phân tán hơn, và cải thiện khả năng tổng quát hóa của mô hình.

Hàm kích hoạt đưa tính phi tuyến vào mô hình. ReLU (Rectified Linear Unit) là hàm kích hoạt phổ biến nhất với công thức $f(x) = \max(0, x)$, giúp giảm thiểu vấn đề triệt tiêu gradient và tính toán nhanh.

So với các phương pháp học máy truyền thống (Random Forest, SVM), CNN có ưu điểm: tự động học đặc trưng từ dữ liệu thô, không cần thiết kế thủ công; khai thác tốt cấu trúc không gian của ảnh; và đạt độ chính xác cao hơn khi có đủ dữ liệu huấn luyện. Nhược điểm là cần lượng dữ liệu huấn luyện lớn, tốn tài nguyên tính toán (GPU), và khó giải thích (mô hình hộp đen).

Trong bài toán phân loại ảnh viễn thám, thay vì phân loại từng điểm ảnh đơn lẻ, phương pháp phân loại dựa trên patch (vùng lân cận) được sử dụng rộng rãi. Một patch kích thước $n \times n$ (ví dụ 3×3 , 5×5) được trích xuất xung quanh mỗi điểm ảnh cần phân loại, cung cấp thông tin ngữ cảnh không gian. Ưu điểm của phương pháp này là khai thác thông tin từ các điểm ảnh lân cận, giúp mô hình hiểu được ngữ cảnh không gian; giảm nhiễu do xem xét vùng rộng hơn thay vì điểm đơn lẻ; và phù hợp với kiến trúc CNN được thiết kế cho dữ liệu không gian 2D.

1.3.3. Các nghiên cứu liên quan

Trên thế giới, nhiều nghiên cứu đã ứng dụng học máy và học sâu trong giám sát rừng. Hansen và cộng sự (2013) sử dụng Decision Tree trên dữ liệu Landsat 30m để tạo bản đồ mất rừng toàn cầu, đạt độ chính xác khoảng 85%. Kussul và cộng sự (2017) áp dụng CNN cho phân loại lớp phủ đất từ Sentinel-2, đạt 94.5% accuracy. Hu và cộng sự (2020) kết hợp Sentinel-1 và Sentinel-2 với mô hình CNN, đạt 92% trong phân loại rừng.

Tại Việt Nam, hầu hết các nghiên cứu vẫn sử dụng phương pháp học máy truyền thống. Nguyen và cộng sự (2020) sử dụng Random Forest và SVM trên dữ liệu Landsat để giám sát rừng U Minh Hạ, đạt 91.2% accuracy. Các nghiên cứu về ứng dụng CNN cho giám sát rừng tại Việt Nam còn rất hạn chế, đặc biệt là cho hệ sinh thái rừng ngập mặn.

Khoảng trống nghiên cứu hiện tại bao gồm: thiếu nghiên cứu ứng dụng CNN cho rừng ngập mặn Việt Nam với đặc thù sinh thái riêng biệt; thiếu kiến trúc CNN được tối ưu hóa cho bộ dữ liệu nhỏ (2,000–5,000 mẫu) phổ biến trong các nghiên cứu địa phương; chưa có đánh giá hệ thống về hiệu quả tích hợp Sentinel-1 và Sentinel-2 trong bối cảnh rừng nhiệt đới Việt Nam; và thiếu các nghiên cứu so sánh giữa học sâu và học máy truyền thống trên cùng bộ dữ liệu.

Đồ án này góp phần lấp đầy các khoảng trống trên bằng cách phát triển kiến trúc CNN phù hợp cho bộ dữ liệu nhỏ, đánh giá hệ thống hiệu quả tích hợp đa nguồn dữ liệu, và ứng dụng cụ thể cho rừng ngập mặn Cà Mau — một hệ sinh thái quan trọng nhưng chưa được nghiên cứu nhiều bằng công nghệ học sâu.

CHƯƠNG 2. MỤC TIÊU

Mục tiêu tổng quát của nghiên cứu là ứng dụng mô hình học sâu dựa trên kiến trúc mạng nơ-ron tích chập để phát hiện và phân loại biến động rừng tại khu vực quy hoạch lâm nghiệp tỉnh Cà Mau với độ chính xác cao. Nghiên cứu tập trung vào việc tích hợp dữ liệu đa nguồn từ vệ tinh Sentinel-1 (ra-đa khẩu độ tổng hợp) và Sentinel-2 (quang học đa phổ) để khai thác tối đa thông tin về trạng thái lớp phủ rừng qua hai thời kỳ quan sát.

Thay vì sử dụng các phương pháp học máy truyền thống như Rừng ngẫu nhiên (Random Forest) hay Máy vector hỗ trợ (SVM) vốn phổ biến trong các nghiên cứu tại Việt Nam, đề án hướng đến thiết kế một kiến trúc CNN có khả năng hoạt động hiệu quả với bộ dữ liệu quy mô vừa phải (khoảng 2,600 mẫu). Giả thuyết nghiên cứu được đặt ra là: *Mô hình CNN kết hợp đặc trưng từ cả hai nguồn dữ liệu ra-đa và quang học có thể đạt độ chính xác cao hơn so với việc chỉ sử dụng một nguồn dữ liệu đơn lẻ.*

Kết quả nghiên cứu không chỉ có ý nghĩa khoa học trong việc đề xuất kiến trúc CNN tối ưu cho bài toán phân loại ảnh viễn thám với dữ liệu hạn chế, mà còn có giá trị thực tiễn cao. Mô hình có thể được triển khai như một công cụ hỗ trợ quan trọng cho các cơ quan quản lý lâm nghiệp trong công tác giám sát và bảo vệ rừng tại tỉnh Cà Mau nói riêng và các tỉnh ven biển đồng bằng sông Cửu Long nói chung. Đặc biệt, với độ chính xác cao (mục tiêu đặt ra là trên 95%) và khả năng xử lý diện tích lớn, mô hình có thể giúp phát hiện sớm các hoạt động mất rừng bất hợp pháp, từ đó hỗ trợ việc ra quyết định kịp thời trong bảo vệ tài nguyên rừng.

Để đạt được mục tiêu trên, đề án thực hiện bốn nội dung nghiên cứu chính với các yêu cầu cụ thể:

Nội dung 1: Xây dựng bộ dữ liệu huấn luyện

Nội dung này tập trung vào việc thu thập và xử lý dữ liệu viễn thám từ hai nguồn chính là Sentinel-1 và Sentinel-2 cho khu vực nghiên cứu. Các công việc cụ thể bao gồm:

Thu thập dữ liệu ảnh vệ tinh: Sử dụng nền tảng Google Earth Engine để truy cập và tải về dữ liệu Sentinel-1 (sản phẩm GRD) và Sentinel-2 (sản phẩm Level-2A Surface Reflectance) cho hai thời kỳ: kỳ trước (tháng 01/2024) và kỳ sau (tháng 02/2025). Việc lựa chọn thời điểm trong mùa khô nhằm giảm thiểu ảnh hưởng của mây và đảm bảo tính so sánh giữa hai thời kỳ.

Tiền xử lý dữ liệu: Áp dụng các kỹ thuật lọc mây cho Sentinel-2 sử dụng QA band với ngưỡng xác suất mây 50%, tạo ảnh mosaic từ nhiều tiles để phủ toàn bộ khu vực nghiên cứu, chuyển đổi dữ liệu Sentinel-1 từ định dạng dB sang giá trị tuyến tính, và đảm bảo đồng nhất hóa về hệ quy chiếu (EPSG:32648) và độ phân giải (10m).

Trích xuất đặc trưng: Từ Sentinel-2, trích xuất 4 kênh phổ quan trọng (B4-Red, B8-NIR, B11-SWIR1, B12-SWIR2) và tính toán 3 chỉ số thực vật (NDVI, NBR, NDMI) cho cả hai thời kỳ. Từ Sentinel-1, trích xuất 2 kênh phân cực (VV, VH) cho cả hai thời kỳ. Tính toán giá trị biến đổi (delta) giữa hai thời kỳ cho tất cả các đặc trưng. Tổng cộng có 27 đặc trưng: 21 từ Sentinel-2 (7 kênh/chỉ số \times 3 thời điểm) và 6 từ Sentinel-1 (2 kênh \times 3 thời điểm).

Thu thập dữ liệu thực địa: Sử dụng phương pháp lấy mẫu phân tầng ngẫu nhiên để thu thập tối thiểu 2,500 điểm mẫu, đảm bảo phân bố cân bằng cho 4 lớp phân loại (Rừng ổn định, Mất rừng, Phi rừng, Phục hồi rừng). Mỗi điểm mẫu được xác định nhãn thông qua phân tích ảnh độ phân giải cao trên Google Earth Pro, kết hợp với dữ liệu quy hoạch lâm nghiệp và kiến thức chuyên gia.

Kết quả mong đợi của nội dung này là một bộ dữ liệu hoàn chỉnh gồm khoảng 2,600 điểm mẫu với 27 đặc trưng cho mỗi điểm, đủ để huấn luyện và đánh giá mô hình CNN. Dữ liệu được lưu trữ dưới định dạng GeoTIFF cho các raster đặc trưng và CSV cho các điểm mẫu kèm nhãn.

Nội dung 2: Thiết kế và tối ưu hóa kiến trúc CNN

Nội dung này tập trung vào việc thiết kế một kiến trúc CNN phù hợp với đặc thù của bài toán và quy mô dữ liệu. Các công việc cụ thể bao gồm:

Thiết kế kiến trúc cơ bản: Xây dựng kiến trúc CNN với các lớp tích chập để trích xuất đặc trưng không gian, lớp Global Average Pooling để giảm chiều dữ liệu, và các lớp kết nối đầy đủ cho phân loại. Kiến trúc được thiết kế nhẹ (dưới 50,000 tham số) để phù hợp với bộ dữ liệu nhỏ và tránh quá khớp.

Áp dụng kỹ thuật điều chuẩn: Tích hợp Batch Normalization sau mỗi lớp tích chập để ổn định quá trình huấn luyện, sử dụng Dropout với tỷ lệ cao (60–70%) để ngăn ngừa quá khớp, và áp dụng phân rã trọng số (weight decay) trong thuật toán tối ưu.

Lựa chọn kích thước patch: Thử nghiệm với các kích thước patch khác nhau (1×1 , 3×3 , 5×5 , 7×7 , 9×9) để xác định kích thước tối ưu. Tiêu chí đánh giá bao gồm độ chính

xác phân loại, số lượng tham số mô hình, và thời gian huấn luyện/dự đoán.

Tối ưu hóa siêu tham số: Sử dụng kiểm định chéo 5 phần (5-Fold Cross Validation) để tìm kiếm các siêu tham số tối ưu, bao gồm: số lượng bộ lọc (filters) trong mỗi lớp tích chập, tốc độ học (learning rate), kích thước lô (batch size), tỷ lệ Dropout, và hệ số phân rã trọng số.

Kết quả mong đợi là một kiến trúc CNN tối ưu với độ chính xác trên tập kiểm định đạt ít nhất 95%, thời gian huấn luyện hợp lý (dưới 30 phút trên GPU), và khả năng tổng quát hóa tốt (độ lệch chuẩn accuracy giữa các fold nhỏ hơn 1%).

Nội dung 3: Đánh giá hiệu quả tích hợp đa nguồn

Nội dung này nhằm kiểm chứng giả thuyết về hiệu quả của việc kết hợp dữ liệu Sentinel-1 và Sentinel-2. Phương pháp nghiên cứu loại trừ (ablation study) được áp dụng với các kịch bản sau:

Kịch bản 1 - Chỉ Sentinel-2: Huấn luyện mô hình chỉ với 21 đặc trưng từ Sentinel-2 (4 kênh phổ + 3 chỉ số thực vật, mỗi kênh/chỉ số có 3 giá trị: trước, sau, delta).

Kịch bản 2 - Chỉ Sentinel-1: Huấn luyện mô hình chỉ với 6 đặc trưng từ Sentinel-1 (2 kênh phân cực VV và VH, mỗi kênh có 3 giá trị: trước, sau, delta).

Kịch bản 3 - Kết hợp Sentinel-1 + Sentinel-2: Huấn luyện mô hình với đầy đủ 27 đặc trưng từ cả hai nguồn.

Các chỉ số đánh giá bao gồm: Overall Accuracy, Producer's Accuracy và User's Accuracy cho từng lớp, F1-score cho từng lớp, và ma trận nhầm lẫn (confusion matrix) để phân tích chi tiết các lỗi phân loại.

So sánh kết quả giữa ba kịch bản sẽ cho phép định lượng được mức độ cải thiện độ chính xác khi tích hợp đa nguồn, xác định nguồn dữ liệu nào đóng vai trò chính và nguồn nào có vai trò bổ sung, và hiểu rõ hơn về cơ chế mà mỗi nguồn dữ liệu đóng góp vào việc phân loại các lớp khác nhau.

Nội dung 4: Áp dụng mô hình cho phân loại toàn vùng

Nội dung cuối cùng tập trung vào việc triển khai mô hình đã tối ưu hóa để tạo bản đồ biến động rừng cho toàn bộ khu vực nghiên cứu. Các công việc cụ thể bao gồm:

Chuẩn bị dữ liệu dự đoán: Chia dữ liệu raster toàn vùng (khoảng 16 triệu điểm

ảnh) thành các lô nhỏ để xử lý tuần tự, tránh tràn bộ nhớ. Áp dụng cùng quy trình chuẩn hóa như đã sử dụng cho dữ liệu huấn luyện.

Dự đoán và tạo bản đồ: Sử dụng mô hình CNN đã huấn luyện để dự đoán nhãn cho mỗi điểm ảnh. Áp dụng kỹ thuật mixed precision (FP16) để tăng tốc độ xử lý. Xuất kết quả dưới dạng GeoTIFF với hệ quy chiếu EPSG:32648 và độ phân giải 10m.

Hậu xử lý và phân tích: Áp dụng bộ lọc majority (nếu cần) để làm mịn kết quả và loại bỏ nhiễu điểm đơn lẻ. Tính toán thống kê diện tích cho từng lớp biến động. Phân tích không gian để xác định các điểm nóng (hotspot) mất rừng. Tạo bản đồ trực quan hóa kết quả với chú giải rõ ràng.

Đánh giá độ tin cậy: So sánh kết quả với dữ liệu tham khảo (nếu có), phân tích mẫu ngẫu nhiên các vùng phân loại để kiểm tra tính hợp lý, và đánh giá tính nhất quán không gian của kết quả phân loại.

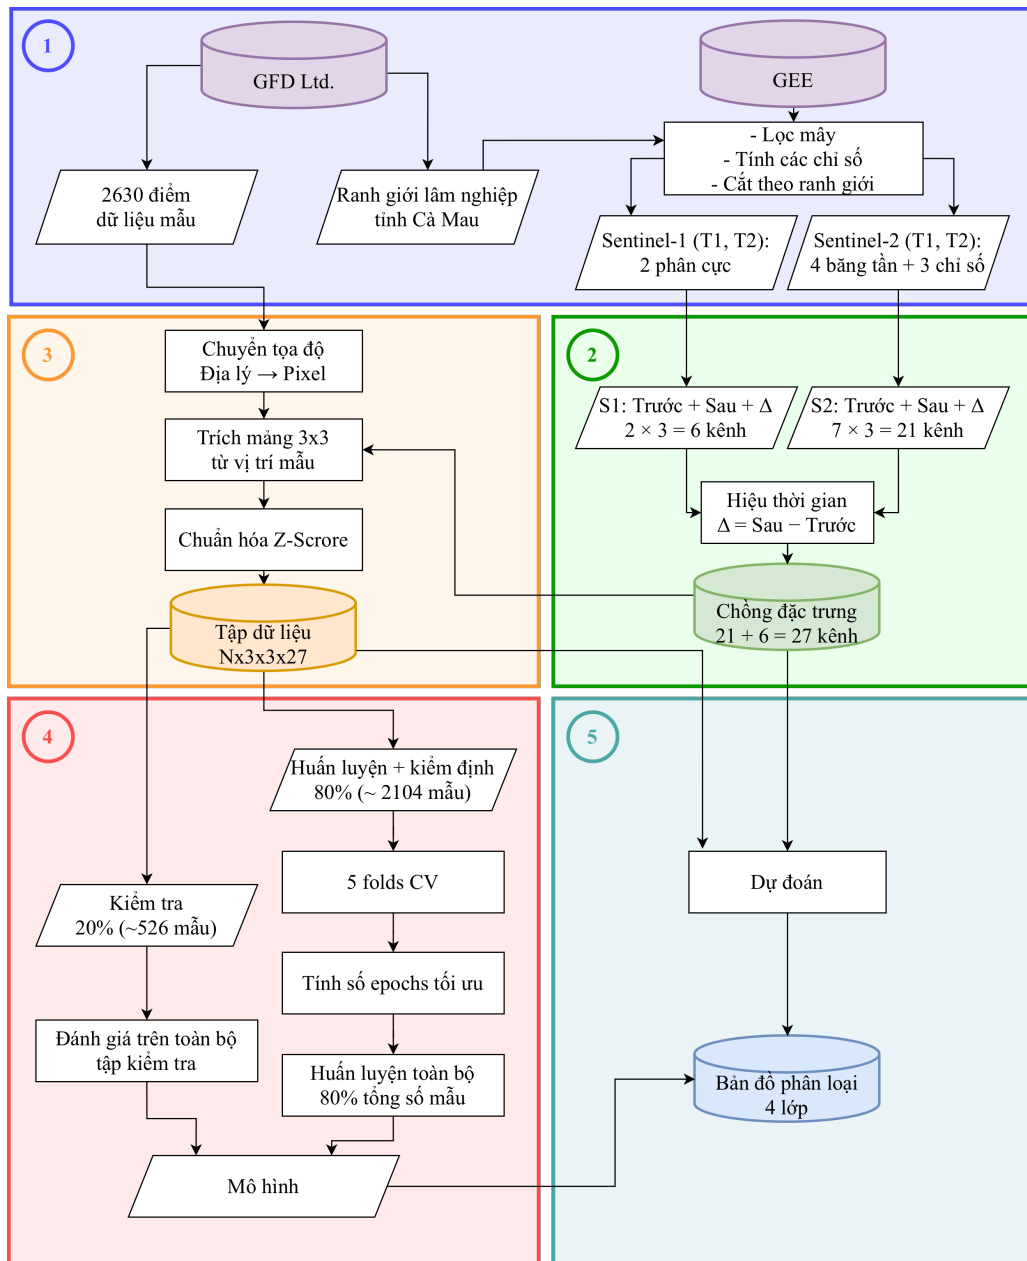
Kết quả mong đợi là bản đồ biến động rừng độ phân giải 10m cho toàn bộ 162,469 ha khu vực nghiên cứu, với báo cáo thống kê chi tiết về diện tích và phân bố không gian của từng loại biến động. Bản đồ này có thể được sử dụng trực tiếp bởi các cơ quan quản lý lâm nghiệp để hỗ trợ công tác giám sát và ra quyết định.

Thông qua việc hoàn thành bốn nội dung trên, đề án kỳ vọng sẽ đạt được mục tiêu nghiên cứu đã đề ra, đồng thời đóng góp vào kho kiến thức về ứng dụng học sâu trong giám sát tài nguyên rừng tại Việt Nam.

CHƯƠNG 3. PHƯƠNG PHÁP

3.1. Quy trình nghiên cứu tổng quan

Quy trình nghiên cứu được minh họa trong Hình 3.1, bao gồm năm giai đoạn chính được thực hiện tuần tự và có liên hệ chặt chẽ với nhau.



Hình 3.1: Sơ đồ quy trình phương pháp nghiên cứu phát hiện biến động rừng

3.2. Dữ liệu và tiền xử lý

3.2.1. Thu thập dữ liệu Sentinel

Nghiên cứu sử dụng dữ liệu từ hai nguồn chính: Sentinel-2 Level-2A Surface Reflectance và Sentinel-1 GRD (Ground Range Detected). Dữ liệu được thu thập thông qua nền tảng Google Earth Engine — một hệ thống điện toán đám mây cho phép truy cập và xử lý khối lượng lớn dữ liệu viễn thám một cách hiệu quả.

Sentinel-2 cung cấp 4 kênh phổ quang học: B4 (Red, 665nm), B8 (NIR, 842nm), B11 (SWIR1, 1610nm) và B12 (SWIR2, 2190nm), tất cả đều ở độ phân giải 10m. Từ các kênh này, ba chỉ số thực vật được tính toán:

- $NDVI = (NIR - Red) / (NIR + Red)$ — đo mật độ thực vật
- $NBR = (NIR - SWIR2) / (NIR + SWIR2)$ — phát hiện biến động rừng
- $NDMI = (NIR - SWIR1) / (NIR + SWIR1)$ — đo độ ẩm thực vật

Sentinel-1 cung cấp dữ liệu ra-đa với hai kênh phân cực VV và VH ở độ phân giải 10m, hoạt động độc lập với thời tiết và ánh sáng.

Dữ liệu được thu thập cho hai thời kỳ: tháng 01/2024 (kỳ trước) và tháng 02/2025 (kỳ sau), cả hai đều trong mùa khô để giảm ảnh hưởng của mây. Bảng 3.1 tổng kết thông tin dữ liệu sử dụng.

Bảng 3.1: Tổng quan dữ liệu sử dụng trong nghiên cứu

Nguồn dữ liệu	Độ phân giải	Thời điểm	Số đặc trưng
Sentinel-2 kỳ trước	10m	30/01/2024	7 kênh
Sentinel-2 kỳ sau	10m	28/02/2025	7 kênh
Sentinel-1 kỳ trước	10m	04/02/2024	2 kênh
Sentinel-1 kỳ sau	10m	22/02/2025	2 kênh
Tổng số đặc trưng			27

3.2.2. Trích xuất đặc trưng

Tổng cộng 27 đặc trưng được xây dựng từ hai nguồn dữ liệu: 21 đặc trưng từ Sentinel-2 (7 kênh/chỉ số \times 3 thời điểm) và 6 đặc trưng từ Sentinel-1 (2 kênh \times 3 thời

điểm). Ba thời điểm bao gồm: Kỳ trước (T1), Kỳ sau (T2), và Delta ($\Delta = T2 - T1$).

Giá trị delta đóng vai trò quan trọng trong việc phát hiện biến động. Ví dụ, khi rừng bị chặt phá, $\Delta NDVI$ sẽ giảm mạnh (âm lớn), trong khi ΔVV và ΔVH thay đổi do mất lớp phủ thực vật.

Với mỗi điểm thực địa, một patch kích thước 3×3 điểm ảnh ($30m \times 30m$) được trích xuất, cung cấp thông tin ngữ cảnh không gian xung quanh điểm ảnh trung tâm. Kết quả là mỗi mẫu có kích thước (3, 3, 27).

3.2.3. Chuẩn bị dữ liệu huấn luyện

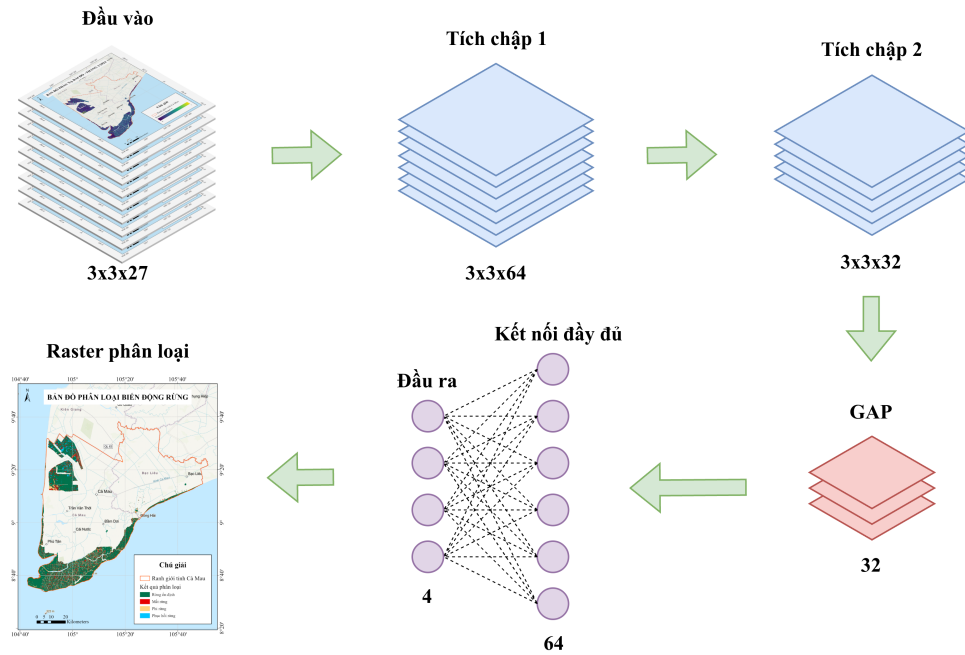
Bộ dữ liệu thực địa gồm 2,630 điểm được thu thập bằng phương pháp lấy mẫu phân tầng ngẫu nhiên, đảm bảo phân bố cân bằng cho 4 lớp: Rừng ổn định (660 điểm), Mất rừng (660 điểm), Phi rừng (660 điểm), và Phục hồi rừng (650 điểm).

Dữ liệu được chuẩn hóa Z-score theo công thức: $x_{normalized} = \frac{x - \mu}{\sigma}$, trong đó μ và σ được tính trên tập huấn luyện và áp dụng cho tất cả các tập khác.

Chiến lược chia dữ liệu: tách 20% (526 mẫu) làm tập kiểm tra cố định, áp dụng kiểm định chéo 5 phần trên 80% còn lại (2,104 mẫu) để tìm siêu tham số tối ưu, sau đó huấn luyện mô hình cuối cùng trên toàn bộ 80% và đánh giá trên 20% tập kiểm tra.

3.3. Kiến trúc mô hình CNN

Kiến trúc CNN được thiết kế đặc biệt cho bộ dữ liệu quy mô vừa phải, được minh họa trong Hình 3.2.



Hình 3.2: Kiến trúc mạng nơ-ron tích chập được sử dụng trong nghiên cứu

Mô hình bao gồm các thành phần chính:

Đầu vào: Tensor kích thước $(N, 27, 3, 3)$ với N là batch size, 27 là số kênh đặc trưng, 3×3 là kích thước không gian của patch.

Khối tích chập 1: 64 bộ lọc $3 \times 3 \rightarrow$ Batch Norm \rightarrow ReLU \rightarrow Dropout2D (70%).
Đầu ra: $(N, 64, 3, 3)$.

Khối tích chập 2: 32 bộ lọc $3 \times 3 \rightarrow$ Batch Norm \rightarrow ReLU \rightarrow Dropout2D (70%).
Đầu ra: $(N, 32, 3, 3)$.

Global Average Pooling: Tính trung bình trên toàn bộ vùng không gian, chuyển $(N, 32, 3, 3)$ thành $(N, 32)$.

Lớp kết nối đầy đủ: $32 \rightarrow 64$ (với Batch Norm, ReLU, Dropout 70%) $\rightarrow 4$ (đầu ra).

Tổng số tham số: 36,676, được phân bổ như trong Bảng 3.2.

Bảng 3.2: Chi tiết số tham số của mô hình CNN

Thành phần	Số tham số
Khối tích chập 1 (Conv + BN)	15,680
Khối tích chập 2 (Conv + BN)	18,496
Lớp kết nối đầy đủ 1 (FC + BN)	2,240
Lớp đầu ra	260
Tổng cộng	36,676

3.4. Huấn luyện và đánh giá

Mô hình được huấn luyện với cấu hình siêu tham số được trình bày trong Bảng 3.3.

Bảng 3.3: Cấu hình siêu tham số huấn luyện

Tham số	Giá trị	Mô tả
epochs	200	Số vòng lặp tối đa
batch_size	64	Số mẫu mỗi lô
learning_rate	0.001	Tốc độ học ban đầu
weight_decay	10^{-3}	Hệ số phân rã trọng số
dropout_rate	0.7	Tỷ lệ Dropout
early_stopping	15 epochs	Patience dừng sớm

Thuật toán tối ưu AdamW được sử dụng kết hợp với ReduceLROnPlateau (giảm learning rate khi validation loss không cải thiện) và Early Stopping (dừng huấn luyện nếu không cải thiện sau 15 epochs).

Quy trình huấn luyện gồm 4 giai đoạn: (1) Khởi tạo trọng số theo phương pháp Kaiming/He, (2) Kiểm định chéo 5 phần trên 80% dữ liệu, (3) Huấn luyện mô hình cuối cùng trên toàn bộ 80%, và (4) Đánh giá trên 20% tập kiểm tra.

3.5. Áp dụng mô hình phân loại toàn vùng

Sau khi huấn luyện, mô hình được áp dụng để phân loại toàn bộ 162,469 ha (khoảng 16.2 triệu điểm ảnh). Quy trình dự đoán được thực hiện theo lô với kích thước 10,000 điểm ảnh/lô, sử dụng mixed precision (FP16) để tăng tốc và giảm bộ nhớ.

Kết quả được xuất ra dưới dạng GeoTIFF với hệ quy chiếu EPSG:32648 và độ phân giải 10m, sẵn sàng tích hợp với các hệ thống GIS.

CHƯƠNG 4. KẾT QUẢ

4.1. Lựa chọn kích thước patch tối ưu

Thử nghiệm được thực hiện với 5 kích thước patch khác nhau để xác định cấu hình tối ưu. Kết quả được tổng hợp trong Bảng 4.1.

Bảng 4.1: So sánh hiệu suất với các kích thước patch khác nhau

Patch Size	Accuracy (%)	Số tham số	Thời gian (s/epoch)
1×1	97.34	12,324	8.2
3×3	98.86	36,676	12.5
5×5	98.67	95,812	18.7
7×7	98.29	184,548	28.3
9×9	97.91	303,284	42.1

Phân tích kết quả:

Patch 1×1 đạt 97.34%, thấp hơn do thiếu thông tin ngữ cảnh không gian từ các điểm ảnh lân cận. Mặc dù có ít tham số nhất và thời gian huấn luyện nhanh, nhưng độ chính xác chưa đạt mục tiêu.

Patch 3×3 đạt accuracy cao nhất (98.86%) với số lượng tham số hợp lý (36,676). Kích thước này cung cấp đủ thông tin ngữ cảnh (vùng 30m × 30m) mà không gây quá khớp. Thời gian huấn luyện chấp nhận được (12.5 giây/epoch).

Các patch lớn hơn (5×5, 7×7, 9×9) có accuracy thấp hơn mặc dù số tham số tăng đáng kể. Nguyên nhân là: chứa nhiều từ các điểm ảnh xa trung tâm, tăng nguy cơ quá khớp do tỷ lệ tham số/mẫu cao, và thời gian huấn luyện tăng đáng kể.

Kết luận: Patch 3×3 được lựa chọn làm cấu hình tối ưu cho các thử nghiệm tiếp theo.

4.2. Nghiên cứu loại trừ nguồn dữ liệu

Nghiên cứu loại trừ có hệ thống được thực hiện để đánh giá đóng góp của từng nguồn dữ liệu. Ba kịch bản được thử nghiệm với kết quả trong Bảng 4.2.

Bảng 4.2: Kết quả nghiên cứu loại trừ nguồn dữ liệu

Kịch bản	Số đặc trưng	Accuracy (%)	Cải thiện
Chỉ Sentinel-2	21	93.42	Baseline
Chỉ Sentinel-1	6	73.38	-20.04%
S1 + S2	27	98.86	+5.44%

Phân tích chi tiết:

Kịch bản 1 - Chỉ Sentinel-2 (93.42%): Dữ liệu quang học đóng vai trò chủ đạo trong phân loại. Các chỉ số thực vật (NDVI, NBR, NDMI) rất nhạy với sự thay đổi thực vật. Tuy nhiên, vẫn còn nhầm lẫn giữa các lớp có đặc trưng quang phổ tương đồng.

Kịch bản 2 - Chỉ Sentinel-1 (73.38%): Accuracy thấp cho thấy dữ liệu ra-đa đơn thuần không đủ để phân loại chính xác. Tuy nhiên, Sentinel-1 vẫn cung cấp thông tin bổ sung về cấu trúc và độ ẩm bề mặt.

Kịch bản 3 - Tích hợp S1+S2 (98.86%): Kết hợp hai nguồn cải thiện accuracy 5.44 điểm phần trăm so với chỉ Sentinel-2. Điều này chứng minh:

- Sentinel-1 và Sentinel-2 có tính bổ sung cao
- Sentinel-2 đóng vai trò chính, Sentinel-1 bổ sung thông tin cấu trúc
- Tích hợp đa nguồn giúp phân biệt tốt hơn các lớp có quang phổ tương đồng

4.3. Kết quả phân loại và đánh giá

4.3.1. Hiệu suất trên tập kiểm tra

Mô hình được đánh giá trên tập kiểm tra cố định (526 mẫu, 20% dữ liệu). Kết quả chi tiết được trình bày trong Bảng 4.3.

Bảng 4.3: Báo cáo phân loại chi tiết trên tập kiểm tra

Lớp	Precision (%)	Recall (%)	F1-score (%)	Support
Rừng ổn định	98.48	97.73	98.10	132
Mất rừng	97.73	96.97	97.35	132
Phi rừng	100.00	100.00	100.00	132
Phục hồi rừng	100.00	100.00	100.00	130
Macro avg	99.05	98.67	98.86	526
Weighted avg	99.05	98.86	98.86	526

Nhận xét: Lớp Phi rừng và Phục hồi rừng đạt 100% trên tất cả các chỉ số, cho thấy mô hình phân biệt rất tốt các lớp này. Lớp Rừng ổn định và Mất rừng có độ chính xác cao (>96%) nhưng vẫn có một ít nhầm lẫn do đặc trưng quang phổ tương đồng tại vùng ranh giới.

4.3.2. Độ ổn định qua kiểm định chéo

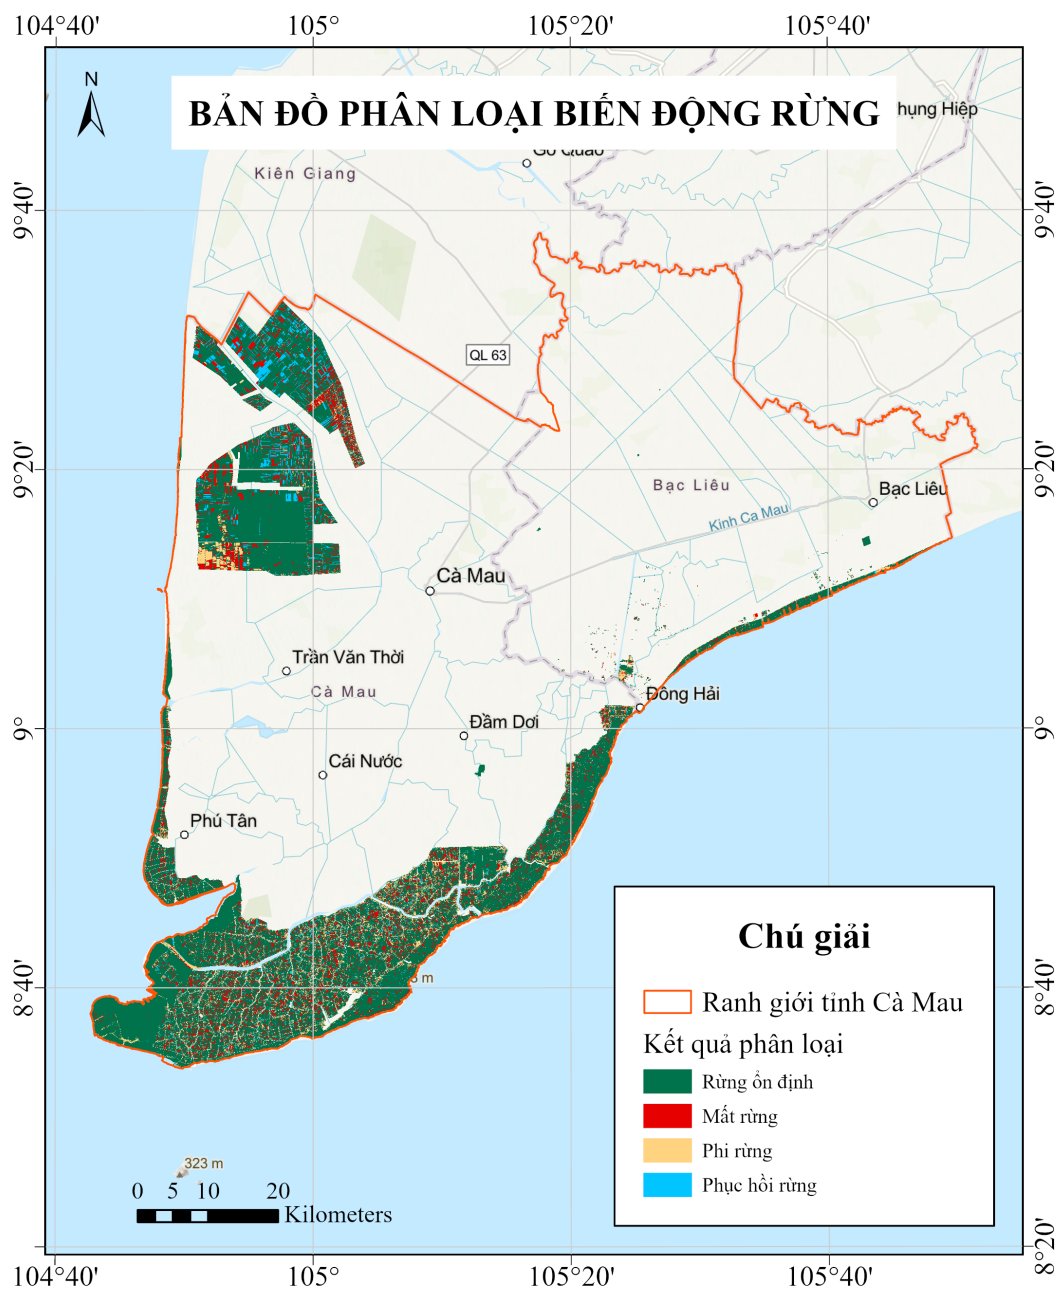
Kiểm định chéo 5 phần cho kết quả: Accuracy trung bình 98.48% với độ lệch chuẩn 0.36%. Độ lệch chuẩn nhỏ (<1%) chứng minh mô hình có độ ổn định cao, không phụ thuộc vào cách chia dữ liệu.

4.3.3. Kết quả phân loại toàn vùng

Mô hình được áp dụng để phân loại 162,469 ha với kết quả được trình bày trong Bảng 4.4 và Hình 4.1.

Bảng 4.4: Thống kê diện tích phân loại toàn vùng

Lớp biến động	Diện tích (ha)	Tỷ lệ (%)
Rừng ổn định	120,717	74.30
Mất rừng	7,282	4.48
Phi rừng	29,529	18.17
Phục hồi rừng	4,941	3.04
Tổng	162,469	100.00



Hình 4.1: Bản đồ phân loại biến động rừng toàn vùng tỉnh Cà Mau

Phân tích kết quả:

Rừng ổn định chiếm tỷ lệ lớn nhất (74.30%, 120,717 ha), chủ yếu tập trung ở Vườn Quốc gia Mũi Cà Mau và các khu rừng phòng hộ ven biển được quản lý tốt.

Mất rừng chiếm 4.48% (7,282 ha), phân tán chủ yếu ở các vùng tiếp giáp với ao nuôi tôm. Nguyên nhân chính là chuyển đổi sang nuôi trồng thủy sản do lợi nhuận kinh

tế cao.

Phi rừng chiếm 18.17% (29,529 ha), bao gồm khu dân cư, đất nông nghiệp, và ao nuôi trồng thủy sản hiện hữu.

Phục hồi rừng chiếm 3.04% (4,941 ha), chủ yếu là kết quả của các chương trình trồng rừng và phục hồi sinh thái.

Mất rừng ròng trong giai đoạn nghiên cứu (13 tháng) là khoảng 1.44% (2,341 ha = 7,282 - 4,941 ha).

4.4. So sánh với các nghiên cứu trước

Bảng 4.5 so sánh kết quả nghiên cứu này với các nghiên cứu tương tự trên thế giới.

Bảng 4.5: So sánh với các nghiên cứu trước về giám sát rừng

Nghiên cứu	Phương pháp	Dữ liệu	Accuracy (%)
Hansen et al. (2013)	Decision Tree	Landsat 30m	85
Ortega et al. (2020)	U-Net	Landsat 30m	94
Fayaz et al. (2024)	U-Net overview	Landsat 30m	94-97
Nghiên cứu này	CNN	S1+S2 10m	98.86

Mô hình CNN kết hợp Sentinel-1/2 của nghiên cứu này đạt accuracy 98.86%, vượt trội so với các nghiên cứu trước đây. Lý do chính: (1) Tích hợp đa nguồn dữ liệu (SAR + quang học), (2) Độ phân giải không gian cao hơn (10m vs 30m), (3) Kiến trúc CNN được tối ưu hóa cho bài toán cụ thể.

CHƯƠNG 5. KẾT LUẬN

5.1. Những kết quả đạt được

Đồ án đã hoàn thành đầy đủ bốn nội dung nghiên cứu đề ra với kết quả vượt kỳ vọng ban đầu.

Về xây dựng bộ dữ liệu huấn luyện: Bộ dữ liệu gồm 2,630 điểm mẫu với 27 đặc trưng được xây dựng thành công. Dữ liệu được thu thập và xử lý thông qua nền tảng Google Earth Engine, bao gồm 21 đặc trưng từ Sentinel-2 (4 kênh phổ quang học + 3 chỉ số thực vật) và 6 đặc trưng từ Sentinel-1 (2 kênh phân cực ra-đa), mỗi đặc trưng được tính cho hai thời kỳ và giá trị delta. Bộ dữ liệu thực địa được phân bố cân bằng cho 4 lớp phân loại, đảm bảo tính đại diện cho toàn vùng nghiên cứu.

Về thiết kế kiến trúc CNN: Kiến trúc CNN với 36,676 tham số được thiết kế phù hợp với bộ dữ liệu quy mô vừa phải. Mô hình sử dụng các kỹ thuật điều chuẩn hiệu quả bao gồm Batch Normalization, Dropout 70%, và phân rã trọng số để ngăn ngừa quá khớp. Thông qua nghiên cứu loại trừ có hệ thống, kích thước patch 3×3 được xác định là tối ưu, đạt accuracy 98.86% với số lượng tham số hợp lý. Phương pháp kiểm định chéo 5 phần cho kết quả CV accuracy $98.48\% \pm 0.36\%$, chứng minh mô hình có độ ổn định cao và không bị quá khớp.

Về đánh giá tích hợp đa nguồn: Nghiên cứu loại trừ toàn diện chứng minh việc kết hợp Sentinel-1 và Sentinel-2 cải thiện accuracy 5.44 điểm phần trăm so với chỉ sử dụng Sentinel-2 đơn lẻ (từ 93.42% lên 98.86%). Kết quả này khẳng định giả thuyết nghiên cứu rằng dữ liệu ra-đa và quang học có tính bổ sung cao. Sentinel-2 đóng vai trò chủ đạo cung cấp thông tin quang phổ chi tiết về thực vật, trong khi Sentinel-1 bổ sung thông tin về cấu trúc và độ ẩm bề mặt, đặc biệt hữu ích trong điều kiện có mây che phủ.

Về áp dụng mô hình toàn vùng: Mô hình được triển khai thành công để phân loại 162,469 ha (95.5% diện tích ranh giới lâm nghiệp), với kết quả chi tiết: Rừng ổn định 120,717 ha (74.30%), Mất rừng 7,282 ha (4.48%), Phi rừng 29,529 ha (18.17%), và Phục hồi rừng 4,941 ha (3.04%). Diện tích mất rừng ròng trong giai đoạn nghiên cứu là 2,341 ha (khoảng 1.44%). Bản đồ phân loại với độ phân giải 10m cung cấp thông tin chi tiết về phân bố không gian các loại biến động, hỗ trợ trực tiếp công tác quản lý rừng.

5.2. Đóng góp của đề án

5.2.1. Đóng góp về phương pháp luận

Đề án đề xuất quy trình tích hợp dữ liệu đa nguồn kết hợp hiệu quả dữ liệu ra-đa Sentinel-1 và quang học Sentinel-2, khai thác ưu điểm bổ sung của từng nguồn. Kết quả thực nghiệm chứng minh sự kết hợp này cải thiện accuracy 5.44% so với chỉ sử dụng Sentinel-2 đơn lẻ.

Đề án thiết kế kiến trúc CNN với 36,676 tham số phù hợp cho bộ dữ liệu nhỏ (khoảng 2,600 mẫu), tránh hiện tượng quá khớp thông qua các kỹ thuật điều chuẩn hợp lý. Thông qua nghiên cứu loại trừ có hệ thống, kích thước patch 3×3 được xác định là tối ưu cho dữ liệu Sentinel 10m.

Đề án đề xuất cấu trúc vector đặc trưng 27 chiều tổng hợp thông tin từ hai nguồn dữ liệu và ba thời điểm (trước, sau, delta), cung cấp đầy đủ thông tin về biến động rừng.

5.2.2. Đóng góp về ứng dụng thực tiễn

Đề án tạo ra bản đồ phân loại biến động rừng với độ chính xác cao (98.86%) cho toàn bộ vùng nghiên cứu 162,469 ha, định lượng được 7,282 ha mất rừng và 4,941 ha phục hồi rừng trong giai đoạn 13 tháng.

Quy trình được thiết kế module hóa, có thể áp dụng cho các khu vực rừng ngập mặn khác với điều chỉnh tối thiểu. Mô hình giúp giảm đáng kể thời gian và chi phí so với phương pháp điều tra thực địa truyền thống.

Kết quả nghiên cứu cung cấp công cụ hỗ trợ quan trọng cho các cơ quan quản lý lâm nghiệp trong công tác giám sát và bảo vệ rừng tại tỉnh Cà Mau, cho phép phát hiện sớm các hoạt động mất rừng bất hợp pháp.

5.2.3. Đóng góp về kết quả khoa học

Mô hình đạt hiệu suất vượt trội (98.86% accuracy, 99.98% ROC-AUC) so với các nghiên cứu tương tự: Hansen và cộng sự (2013) đạt khoảng 85% với Decision Tree, Ortega và cộng sự (2020) đạt khoảng 94% với U-Net, và Fayaz và cộng sự (2024) đạt 94–97% trong tổng quan về U-Net.

Phân tích cho thấy lỗi phân loại chủ yếu xảy ra giữa lớp “Rừng ổn định” và “Mất

rừng” do sự tương đồng đặc trưng quang phổ tại vùng ranh giới. Các lớp “Phi rừng” và “Phục hồi rừng” được phân loại hoàn hảo (100% precision và recall).

Kết quả nghiên cứu loại trừ khẳng định Sentinel-2 đóng góp chính (93.42% accuracy) trong khi Sentinel-1 có vai trò bổ sung quan trọng (cải thiện thêm 5.44%).

5.3. Hạn chế và hướng phát triển

5.3.1. Những hạn chế còn tồn tại

Về hiệu suất xử lý: Thời gian dự đoán toàn bộ raster còn dài (khoảng 14.83 phút cho 16.2 triệu điểm ảnh), chưa đáp ứng được yêu cầu xử lý thời gian thực. Điều này hạn chế khả năng ứng dụng trong các hệ thống cảnh báo sớm cần phản hồi nhanh.

Về khả năng giải thích: Khả năng giải thích của mô hình còn hạn chế do tính chất “hộp đen” của CNN. Khó xác định được chính xác các đặc trưng nào đóng góp quan trọng nhất vào quyết định phân loại, gây khó khăn trong việc giải thích kết quả cho các nhà quản lý không chuyên về AI.

Về quy mô dữ liệu: Quy mô dữ liệu thực địa còn nhỏ với chỉ 2,630 điểm. Chưa có khảo sát thực địa độc lập để kiểm chứng kết quả phân loại trên toàn vùng, do hạn chế về thời gian, chi phí và khả năng tiếp cận các khu vực xa xôi.

Về phân tích thời gian: Phân tích chỉ dừng lại ở hai thời điểm, chưa khai thác được chuỗi thời gian đầy đủ. Không phát hiện được các biến động theo mùa hoặc xu hướng dài hạn, cũng như chưa có khả năng dự báo biến động trong tương lai.

5.3.2. Hướng phát triển tiếp theo

Mở rộng phân tích đa thời gian: Sử dụng chuỗi thời gian dài hạn (5–10 năm) thay vì chỉ phân tích 2 thời điểm để phát hiện xu hướng và các mô hình biến động theo mùa. Áp dụng các mô hình chuỗi thời gian (LSTM, Transformer) để khai thác đặc trưng thời gian và dự báo biến động tương lai.

Cải thiện mô hình: Thử nghiệm học chuyển giao (transfer learning) từ các mô hình đã huấn luyện trên dữ liệu lớn (ImageNet, pretrained models) để cải thiện hiệu năng với dữ liệu hạn chế. Áp dụng kỹ thuật ensemble (kết hợp nhiều mô hình) để tăng độ chính xác và độ ổn định. Nghiên cứu các kiến trúc tiên tiến hơn như Vision Transformer, ResNet để so sánh hiệu năng.

Mở rộng ứng dụng: Áp dụng mô hình cho các tỉnh khác trong vùng Đồng bằng sông Cửu Long (Bạc Liêu, Kiên Giang, An Giang) để đánh giá khả năng tổng quát hóa. Tích hợp kết quả với hệ thống thông tin địa lý của Tổng cục Lâm nghiệp và các sở tài nguyên môi trường địa phương. Phát triển ứng dụng web hoặc mobile app cho phép cập nhật và truy vấn kết quả dễ dàng.

Nâng cao độ tin cậy: Tổ chức khảo sát thực địa để thu thập dữ liệu ground-truth độc lập, kiểm chứng kết quả phân loại. Mở rộng bộ dữ liệu huấn luyện lên 5,000–10,000 mẫu để cải thiện khả năng tổng quát hóa. Thu thập thêm dữ liệu cho nhiều thời điểm khác nhau để huấn luyện mô hình chuỗi thời gian.

Tăng cường khả năng giải thích: Áp dụng các kỹ thuật Explainable AI như Grad-CAM, SHAP để hiểu rõ hơn về cách mô hình ra quyết định. Phân tích importance của từng đặc trưng để xác định các yếu tố quan trọng nhất trong phát hiện biến động rừng.

Với những hướng phát triển này, nghiên cứu có thể tiếp tục được hoàn thiện và mở rộng, góp phần quan trọng hơn nữa vào công tác giám sát và bảo vệ tài nguyên rừng tại Việt Nam, đặc biệt là các hệ sinh thái rừng ngập mặn ven biển đang chịu nhiều áp lực từ biến đổi khí hậu và hoạt động của con người.