

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



BÁO CÁO THỰC TẬP TỐT NGHIỆP

**GIÁM SÁT BIẾN ĐỘNG RỪNG TỈNH CÀ
MAU SỬ DỤNG DỮ LIỆU VIỄN THÁM VÀ
MẠNG NƠI RON NHÂN TẠO**

Sinh viên thực hiện: Ninh Hải Đăng

Mã sinh viên: 21021411

Lớp: QH2021-CQ-S-AE

Đơn vị thực tập:

CÔNG TY TNHH TƯ VẤN VÀ PHÁT TRIỂN ĐỒNG XANH

Cán bộ hướng dẫn:

- TS. Hoàng Việt Anh
- ThS. Vũ Văn Thái

Hà Nội, tháng 12 năm 2025

MỤC LỤC

MỤC LỤC	i
DANH MỤC HÌNH ẢNH	iv
DANH MỤC BẢNG	v
DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT	vi
LỜI CẢM ƠN	ix
I. TÊN ĐỀ TÀI	1
II. NỘI THỰC TẬP	2
III. NỘI DUNG THỰC TẬP	3
IV. KẾT QUẢ ĐẠT ĐƯỢC	5
Chương 1 Cơ sở lý thuyết của bài toán giám sát biến động rừng	11
1.1. Rừng và biến động rừng	11
1.1.1. Tình hình mất rừng trên thế giới	11
1.1.2. Tình hình mất rừng tại Việt Nam	13
1.2. Viễn thám	14
1.2.1. Nguyên lý viễn thám	14
1.2.2. Chương trình Copernicus và vệ tinh Sentinel	16
1.2.3. Các chỉ số thực vật viễn thám	17
1.2.4. Giám sát biến động rừng và tích hợp đa nguồn dữ liệu	19
1.3. Học sâu và mạng nơ-ron tích chập	19

1.3.1. Kiến trúc mạng nơ-ron tích chập	20
1.3.2. Huấn luyện mạng nơ-ron	21
1.3.3. Ứng dụng CNN trong phân loại ảnh viễn thám	22
1.4. Các nghiên cứu liên quan	23
1.4.1. Sự phát triển của các phương pháp giám sát biến động rừng	23
1.4.2. Tổng quan nghiên cứu và khoảng trống nghiên cứu	24
Chương 2 Dữ liệu và Phương pháp nghiên cứu	28
2.1. Dữ liệu	28
2.1.1. Dữ liệu viễn thám Sentinel	28
2.1.2. Thu thập dữ liệu trên Google Earth Engine	28
2.2. Phương pháp nghiên cứu	33
2.2.1. Thu thập và tiền xử lý dữ liệu	34
2.2.2. Trích xuất đặc trưng	34
2.2.3. Chuẩn bị mẫu huấn luyện	35
2.2.4. Kiến trúc mô hình CNN	35
2.2.5. Huấn luyện mô hình	38
2.2.6. Áp dụng mô hình	39
Chương 3 Kết quả thực nghiệm ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau	41
3.1. Thiết lập thực nghiệm	41
3.1.1. Khu vực nghiên cứu	41
3.1.2. Dữ liệu thực địa tại Cà Mau	43
3.1.3. Cấu hình phần cứng và phần mềm	46
3.1.4. Phân chia dữ liệu	47
3.2. Thủ nghiệm mô hình	48

3.2.1.	Ảnh hưởng của Patch Size	48
3.2.2.	Ảnh hưởng của nguồn dữ liệu	49
3.3.	Kết quả	51
3.3.1.	Kết quả huấn luyện mô hình CNN	51
3.3.2.	Kết quả phân loại toàn bộ vùng nghiên cứu	54
3.3.3.	So sánh với các nghiên cứu khác	58
	TÀI LIỆU THAM KHẢO	61

DANH MỤC HÌNH ẢNH

Hình 1.1 Biến động độ che phủ rừng Việt Nam giai đoạn 1990–2020 (Bộ NN&PTNT, 2021)	14
Hình 1.2 Nguyên lý viễn thám bị động và chủ động	15
Hình 2.1 Các kênh quang học, chỉ số thực vật và dữ liệu ra-đa kỳ trước (T1 - 01/2024)	31
Hình 2.2 Các kênh phổ quang học, chỉ số thực vật và dữ liệu ra-đa kỳ sau (T2 - 02/2025)	32
Hình 2.3 Sơ đồ quy trình phương pháp nghiên cứu phát hiện biến động rừng	33
Hình 2.4 Kiến trúc mô hình mạng nơ-ron tích chậpF được sử dụng trong nghiên cứu	36
Hình 3.1 Bản đồ lớp phủ bì mặt khu vực tỉnh Cà Mau.	42
Hình 3.2 Bản đồ phân bố không gian các điểm dữ liệu thực địa trên khu vực nghiên cứu tỉnh Cà Mau	44
Hình 3.3 Phân bố các đặc trưng delta theo lớp biến động rừng	45
Hình 3.4 So sánh Accuracy theo các Patch Size	48
Hình 3.5 So sánh Accuracy theo các nguồn dữ liệu	49
Hình 3.6 So sánh Accuracy giữa các phần kiểm định trong kiểm định chéo 5 phần	51
Hình 3.7 Diễn biến loss và accuracy trong quá trình huấn luyện mô hình cuối cùng	52
Hình 3.8 Ma trận nhầm lẫn trên tập kiểm tra (n=526, Accuracy: 98,86%)	53
Hình 3.9 Bản đồ phân loại biến động rừng tỉnh Cà Mau	55
Hình 3.10 Bản đồ phân loại biến động rừng khu vực Vườn Quốc gia Mũi Cà Mau	56
Hình 3.11 Tỷ lệ diện tích các lớp phân loại	57
Hình 3.12 So sánh Accuracy với các nghiên cứu trước đó	59

DANH MỤC BẢNG

Bảng 1.1	So sánh thông số kỹ thuật giữa Sentinel-1 và Sentinel-2	16
Bảng 1.2	Tổng hợp các chỉ số thực vật sử dụng trong nghiên cứu	18
Bảng 1.3	So sánh các phương pháp giám sát biến động rừng qua các giai đoạn . .	24
Bảng 1.4	Tổng hợp các nghiên cứu tiêu biểu trên thế giới	25
Bảng 2.1	Tổng quan dữ liệu sử dụng	28
Bảng 2.2	Chi tiết số tham số huấn luyện của mô hình CNN	38
Bảng 2.3	Cấu hình siêu tham số huấn luyện	38
Bảng 3.1	Thống kê dữ liệu thực địa theo lớp biến động	43
Bảng 3.2	Phân bố dữ liệu theo tập huấn luyện và kiểm tra	47
Bảng 3.3	So sánh các kích thước patch	48
Bảng 3.4	Nghiên cứu loại trừ các nguồn dữ liệu	49
Bảng 3.5	Tổng hợp kết quả huấn luyện kiểm định 5 phần	51
Bảng 3.6	Phân tích chi tiết từng lớp	53
Bảng 3.7	Phân bố diện tích theo lớp phân loại	54
Bảng 3.8	So sánh với các nghiên cứu trong tài liệu	59
Bảng 3.9	So sánh kết quả với Giám sát rừng toàn cầu (GFW)	60

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Từ	Viết tắt	Dịch - Nghĩa
Accuracy	-	Độ chính xác tổng thể
Activation Function	-	Hàm kích hoạt
AdamW	-	Thuật toán tối ưu Adam với phân rã trọng số tách rời
Artificial Intelligence	AI	Trí tuệ nhân tạo
Batch Normalization	BN	Chuẩn hóa theo lô
Classification	-	Phân loại
Compute Unified Device Architecture	CUDA	Nền tảng tính toán song song của NVIDIA trên GPU
Convolutional Neural Network	CNN	Mạng nơ-ron tích chập
Cross Validation	CV	Kiểm định chéo
CrossEntropyLoss	-	Hàm mất mát entropy chéo
Deep Learning	DL	Học sâu
Deforestation	-	Mất rừng
Dropout	-	Loại bỏ ngẫu nhiên
Early Stopping	-	Dừng sớm
European Space Agency	ESA	Cơ quan Vũ trụ Châu Âu
European Union	EU	Liên minh Châu Âu
F1-Score	-	Điểm F1
False Negative	FN	Dự đoán âm nhưng thực tế dương
False Positive	FP	Dự đoán dương nhưng thực tế âm
False Positive Rate	FPR	Tỷ lệ dương tính giả
Feature	-	Đặc trưng
Feature Extraction	-	Trích xuất đặc trưng
Feature Map	-	Bản đồ đặc trưng
Kernel	-	Bộ lọc/Nhân tích chập
Land Use Land Cover	LULC	Lớp phủ/Sử dụng đất
Fold	-	Phần gấp

Food and Agriculture Organization	FAO	Tổ chức Lương thực và Nông nghiệp Liên Hợp Quốc
Forest Change Detection	-	Phát hiện biến động rừng
Fully Connected Layer	FC	Lớp kết nối đầy đủ
Geographic Information System	GIS	Hệ thống thông tin địa lý
Global Average Pooling	GAP	Gộp trung bình toàn cục
Global Forest Watch	GFW	Giám sát rừng toàn cầu
Graphics Processing Unit	GPU	Bộ xử lý đồ họa
Ground Truth	-	Dữ liệu mẫu
Hyperparameter	-	Siêu tham số
Interferometric Wide	IW	Chế độ giao thoa rộng
Intergovernmental Panel on Climate Change	IPCC	Ủy ban Liên chính phủ về Biến đổi Khí hậu
Learning Rate	LR	Tốc độ học
Lightweight	-	Kiến trúc nhẹ/dơn giản/cơ bản
Logits	-	Giá trị logit
Machine Learning	ML	Học máy
Mangrove Forest	-	Rừng ngập mặn
Multi-Layer Perceptron	MLP	Perceptron đa lớp
Multispectral	-	Đa phổ
Near-Infrared	NIR	Cận hồng ngoại
Non-forest	-	Phi rừng
Normalized Burn Ratio	NBR	Chỉ số cháy chuẩn hóa
Normalized Difference Moisture Index	NDMI	Chỉ số độ ẩm chuẩn hóa
Normalized Difference Vegetation Index	NDVI	Chỉ số thực vật chuẩn hóa
Optical	-	Quang học
Padding	-	Đệm viền
Parameter	-	Tham số
Patch	-	Mảnh ảnh
Pixel	-	Điểm ảnh
Polarization	-	Phân cực

Pooling	-	Gộp
Precision	-	Độ chuẩn xác
Prediction	-	Dự đoán
Raster	-	Dữ liệu raster
Recall	-	Độ phủ
Receiver Operating Characteristic	ROC	Đường cong ROC
Rectified Linear Unit	ReLU	Hàm ReLU
Reforestation	-	Phục hồi rừng
Regularization	-	Điều chỉnh
Remote Sensing	-	Viễn thám
ROC-AUC	-	Diện tích dưới đường cong ROC
Scheduler	-	Bộ điều chỉnh tốc độ học
Short-Wave Infrared	SWIR	Hồng ngoại sóng ngắn
Softmax	-	Hàm softmax
Spectral Signature	-	Phổ phản xạ đặc trưng
Synthetic Aperture Radar	SAR	Radar khẩu độ tổng hợp
Test Set	-	Tập kiểm tra
True Positive Rate	TPR	Tỷ lệ dương tính thật
Training	-	Huấn luyện
Universal Transverse Mercator	UTM	Hệ tọa độ UTM
Validation	-	Kiểm định
Weight Decay	-	Phân rã trọng số
World Geodetic System	WGS	Hệ trắc địa thế giới

LỜI CẢM ƠN

Trước tiên, em xin chân thành cảm ơn Công ty TNHH Tư vấn và Phát triển Đồng Xanh đã tạo điều kiện cho em thực hiện đề tài thực tập tốt nghiệp này. Môi trường làm việc chuyên nghiệp và sự hỗ trợ nhiệt tình từ công ty đã giúp em có cơ hội áp dụng kiến thức đã học vào thực tiễn.

Em xin gửi lời cảm ơn sâu sắc đến TS. Hoàng Việt Anh và ThS. Vũ Văn Thái, cán bộ hướng dẫn tại công ty, người đã dành thời gian hướng dẫn, giải đáp các thắc mắc và định hướng cho em trong suốt quá trình thực tập. Những góp ý quý báu của các anh đã giúp em hoàn thành tốt đề tài nghiên cứu.

Em xin chân thành cảm ơn TS. Hà Minh Cường và ThS. Hoàng Tích Phúc, các thầy giảng viên hướng dẫn tại Viện Công nghệ Hàng không Vũ trụ, Trường Đại học Công nghệ - ĐHQGHN, đã tận tình chỉ bảo, theo dõi và hỗ trợ em trong suốt quá trình thực hiện đề tài. Sự hướng dẫn tận tâm của các thầy đã giúp em nâng cao kiến thức chuyên môn và hoàn thiện kỹ năng nghiên cứu khoa học.

Cuối cùng, em xin cảm ơn gia đình, bạn bè và đồng nghiệp đã luôn động viên, chia sẻ và tạo điều kiện tốt nhất để em hoàn thành báo cáo thực tập này.

Do thời gian và kinh nghiệm còn hạn chế, báo cáo không tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của quý thầy cô và các bạn để báo cáo được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Hà Nội, tháng 12 năm 2025

Sinh viên

Ninh Hải Đăng

I. TÊN ĐỀ TÀI

Tên đề tài (Tiếng Việt):

Ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau

Tên đề tài (Tiếng Anh):

Application of Remote Sensing and Deep Learning in Forest Change Monitoring
in Ca Mau Province

II. NƠI THỰC TẬP

Tên đơn vị thực tập: Công ty TNHH Tư vấn và Phát triển Đồng Xanh

Địa chỉ: 14 Trần Hưng Đạo, Phan Chu Trinh, TP. Hà Nội

Thời gian thực tập: Từ ngày 15/9/2025 đến ngày 15/12/2025

III. NỘI DUNG THỰC TẬP

Mục đích thực tập

Nghiên cứu và phát triển mô hình học sâu trong giám sát biến động rừng sử dụng dữ liệu viễn thám đa nguồn, nhằm áp dụng công nghệ trí tuệ nhân tạo và viễn thám vào bài toán thực tiễn về bảo vệ và quản lý tài nguyên rừng tại Việt Nam.

Các nội dung đã tham gia trong quá trình thực tập

Trong quá trình thực tập tại Công ty TNHH Tư vấn và Phát triển Đồng Xanh, em đã tham gia thực hiện các nội dung sau:

1. Nghiên cứu tổng quan về vấn đề biến động rừng:

- Tìm hiểu tình hình mất rừng toàn cầu và Việt Nam
- Nghiên cứu vai trò của rừng ngập mặn tại tỉnh Cà Mau
- Tìm hiểu các phương pháp giám sát rừng truyền thống và hiện đại

2. Nghiên cứu công nghệ viễn thám và học sâu:

- Nghiên cứu về vệ tinh Sentinel-1 (dữ liệu radar SAR) và Sentinel-2 (dữ liệu quang học)
- Tìm hiểu các chỉ số thực vật (NDVI, NBR, NDMI)
- Nghiên cứu kiến trúc mạng nơ-ron tích chập (CNN) và ứng dụng trong phân loại ảnh viễn thám
- Tổng quan các nghiên cứu liên quan về giám sát rừng bằng deep learning

3. Thu thập và xử lý dữ liệu:

- Thu thập dữ liệu Sentinel-1 và Sentinel-2 trên nền tảng Google Earth Engine
- Tiền xử lý dữ liệu: lọc mây, chọn thời điểm mùa khô, tính toán các chỉ số thực vật
- Tạo bộ dữ liệu mẫu với 2,630 điểm ground truth thuộc 4 lớp: Rừng ổn định, Mất rừng, Phi rừng, Phục hồi rừng

- Trích xuất 27 đặc trưng từ hai nguồn dữ liệu

4. Phát triển mô hình học sâu:

- Thiết kế kiến trúc mạng CNN với 36,676 tham số
- Thực hiện cross-validation 5-fold để tối ưu siêu tham số
- Huấn luyện mô hình trên tập dữ liệu huấn luyện (80%)
- Đánh giá mô hình trên tập kiểm tra (20%)

5. Đánh giá và triển khai:

- Phân tích kết quả: độ chính xác 98.86%, ROC-AUC 99.98%
- Áp dụng mô hình phân loại toàn bộ vùng nghiên cứu (162,469 ha)
- Phát hiện 7,282 ha mất rừng (4.48%) và 4,941 ha phục hồi rừng (3.04%)
- Phát triển ứng dụng web hiển thị kết quả trên Google Earth Engine

6. Viết báo cáo và tài liệu:

- Viết báo cáo chi tiết về toàn bộ quá trình nghiên cứu
- Tổng hợp tài liệu tham khảo và trích dẫn khoa học
- Chuẩn bị các biểu đồ, bảng số liệu, và hình ảnh minh họa

IV. KẾT QUẢ ĐẠT ĐƯỢC

Qua quá trình thực tập 3 tháng tại Công ty TNHH Tư vấn và Phát triển Đồng Xanh, em đã đạt được các kết quả sau:

1. Nghiên cứu đề bài, thu thập tài liệu

Em đã tiến hành nghiên cứu toàn diện về bài toán giám sát biến động rừng, bao gồm cơ sở lý thuyết về rừng và biến động rừng, công nghệ viễn thám, học sâu, và các nghiên cứu liên quan. Nội dung chi tiết được trình bày trong **Chương 1**.

Các nội dung chính đã nghiên cứu:

- Tình hình mất rừng toàn cầu và Việt Nam, vai trò của rừng ngập mặn
- Nguyên lý viễn thám, vệ tinh Sentinel-1/2, các chỉ số thực vật
- Mạng nơ-ron tích chập (CNN), các kỹ thuật tối ưu và regularization
- Tổng quan các nghiên cứu về giám sát rừng sử dụng học sâu và dữ liệu viễn thám

2. Viết báo cáo chi tiết nội dung đã tiến hành trong quá trình thực tập

Em đã thực hiện toàn bộ quy trình nghiên cứu từ thu thập dữ liệu, xây dựng phương pháp, đến triển khai và đánh giá mô hình. Nội dung chi tiết được trình bày trong **Chương 2** và **Chương 3**.

Chương 2 trình bày về cơ sở dữ liệu và phương pháp nghiên cứu:

- Thu thập và tiền xử lý dữ liệu Sentinel-1 SAR và Sentinel-2 quang học
- Xây dựng bộ dữ liệu mẫu với 2,630 điểm ground truth
- Trích xuất 27 đặc trưng từ hai nguồn dữ liệu đa nguồn
- Thiết kế kiến trúc mạng CNN với patch size 3×3
- Chiến lược huấn luyện với cross-validation 5-fold

Chương 3 trình bày kết quả thực nghiệm:

- Thiết lập môi trường thực nghiệm và siêu tham số
- Kết quả cross-validation: độ chính xác $98.48\% \pm 0.36\%$
- Kết quả kiểm tra cuối cùng: độ chính xác 98.86%, ROC-AUC 99.98%
- Phân loại toàn bộ vùng nghiên cứu 162,469 ha
- Phát hiện 7,282 ha mất rừng và 4,941 ha phục hồi rừng
- So sánh hiệu quả của dữ liệu đa nguồn (cải thiện 5.44% so với chỉ dùng Sentinel-2)

3. Các sản phẩm khác

Ngoài báo cáo nghiên cứu chi tiết, quá trình thực tập đã tạo ra các sản phẩm cụ thể sau:

3.1. Mô hình học sâu CNN

- Kiến trúc: Mạng nơ-ron tích chập (CNN) với 36,676 tham số
- Input: Patch 3×3 pixel với 27 kênh đặc trưng
- Output: Phân loại 4 lớp (Rừng ổn định, Mất rừng, Phi rừng, Phục hồi rừng)
- Độ chính xác: 98.86% trên tập kiểm tra
- ROC-AUC score: 99.98%
- Cross-validation: $98.48\% \pm 0.36\%$

3.2. Bản đồ biến động rừng tỉnh Cà Mau

- Vùng nghiên cứu: Toàn bộ ranh giới lâm nghiệp tỉnh Cà Mau mới sau quyết định sáp nhập tỉnh Cà Mau với tỉnh Bạc Liêu cũ theo Nghị quyết số 1278/NQ-UBTVQH15 ngày 24/10/2024, có hiệu lực từ 01/07/2025 (162,469 ha)
- Thời kỳ phân tích: Tháng 1/2024 - Tháng 2/2025
- Độ phân giải không gian: 10m
- Kết quả phát hiện:

- Diện tích mất rừng: 7,282 ha (4.48% tổng diện tích)
- Diện tích phục hồi rừng: 4,941 ha (3.04% tổng diện tích)
- Rừng ổn định và khu vực không phải rừng
- Format: GeoTIFF, hệ tọa độ EPSG:32648 (UTM Zone 48N)

3.3. Ứng dụng web hiển thị kết quả trên Google Earth Engine

- URL: <https://ee-bonglantrungmuoi.projects.earthengine.app/view/giam-sat-bien-dong-rung-ca-mau>
- Tính năng:
 - Hiển thị bản đồ biến động rừng tương tác
 - Phân biệt màu sắc cho 4 lớp biến động
 - Cho phép người dùng phóng to/thu nhỏ, di chuyển bản đồ
 - Hiển thị thông tin metadata và chú giải
- Công nghệ: Google Earth Engine Apps, JavaScript API
- Truy cập: Công khai, không yêu cầu đăng nhập

3.4. Mã nguồn và tài liệu

- Mã nguồn tiền xử lý dữ liệu S1/S2 trên Google Earth Engine (JavaScript)
- Mã nguồn huấn luyện mô hình CNN (Python, PyTorch)
- Scripts phân loại và xuất kết quả
- Tài liệu hướng dẫn sử dụng
- Báo cáo kỹ thuật chi tiết (tài liệu này)

4. Những khó khăn trong quá trình thực tập

Trong quá trình thực hiện đề tài, em đã gặp một số khó khăn sau:

4.1. Thiếu dữ liệu kiểm chứng kết quả phân loại

- Dữ liệu ground truth đã được Công ty GFD thu thập qua khảo sát drone và số hóa trên QGIS, tuy nhiên trong khuôn khổ thực tập chưa có cơ hội tổ chức thêm chuyến khảo sát thực địa để kiểm chứng kết quả phân loại trên toàn vùng nghiên cứu
- Chưa có so sánh trực tiếp giữa bản đồ biến động do mô hình tạo ra với số liệu đo đạc tại hiện trường
- Hạn chế trong việc đánh giá độ tin cậy tuyệt đối của kết quả phân loại trong điều kiện thực tế

4.2. Thời gian xử lý và tính toán

- Quá trình huấn luyện mô hình với nhiều thử nghiệm siêu tham số mất nhiều thời gian
- Dự đoán cho toàn bộ vùng nghiên cứu (162,469 ha) với độ phân giải 10m đòi hỏi tài nguyên tính toán lớn
- Thời gian xử lý dữ liệu và chạy mô hình trên toàn vùng nghiên cứu kéo dài do giới hạn về phần cứng

4.3. Hạn chế của dữ liệu

- Số lượng mẫu huấn luyện (2,630 điểm) tương đối nhỏ cho bài toán deep learning
- Chỉ phân tích 2 thời điểm (1/2024 và 2/2025), chưa xây dựng được chuỗi thời gian dài hạn
- Dữ liệu Sentinel-2 bị ảnh hưởng bởi mây mù trong một số thời điểm

4.4. Tính giải thích của mô hình

- Mô hình CNN là "black-box", khó giải thích cụ thể tại sao một pixel được phân loại vào lớp nào
- Chưa có phân tích sâu về importance của từng đặc trưng trong quá trình phân loại
- Khó khăn trong việc truyền đạt kết quả cho những người không chuyên về deep learning

5. Kiến nghị

Dựa trên kết quả đạt được và những khó khăn gặp phải, em xin đề xuất một số kiến nghị cho các nghiên cứu tiếp theo:

5.1. Mở rộng nghiên cứu theo chuỗi thời gian

- Mở rộng thành chuỗi thời gian dài hạn với tần suất giám sát cao hơn (hàng tháng hoặc hàng quý)
- Phân tích xu hướng biến động ròng theo mùa và theo năm
- Xây dựng hệ thống cảnh báo sớm về mất ròng dựa trên phân tích chuỗi thời gian
- Áp dụng các mô hình time-series như LSTM, Transformer cho dự báo biến động ròng

5.2. Tăng cường kiểm chứng kết quả phân loại

- Tổ chức khảo sát thực địa để kiểm chứng độ chính xác của bản đồ biến động ròng do mô hình tạo ra
- Đo đạc các thông số sinh thái tại các khu vực được phân loại để xác nhận kết quả
- So sánh kết quả phân loại trên diện rộng với số liệu thực tế để đánh giá độ tin cậy
- Xây dựng quy trình kiểm chứng độc lập cho các sản phẩm giám sát ròng

5.3. Cải thiện hiệu năng mô hình

- Tối ưu hóa kiến trúc mô hình để giảm thời gian dự đoán
- Nghiên cứu các kỹ thuật model compression (pruning, quantization) để triển khai nhanh hơn
- Sử dụng GPU/TPU mạnh hơn hoặc phân tán tính toán
- Tăng kích thước bộ dữ liệu huấn luyện để cải thiện độ chính xác

5.4. Mở rộng vùng nghiên cứu

- Áp dụng mô hình cho các tỉnh ven biển khác có rừng ngập mặn (Kiên Giang, Sóc Trăng)
- So sánh đặc điểm biến động rừng giữa các vùng khác nhau
- Xây dựng bản đồ biến động rừng quy mô quốc gia
- Tích hợp với các hệ thống giám sát rừng hiện có của Bộ Nông nghiệp và Phát triển Nông thôn

5.5. Phát triển công cụ và ứng dụng

- Phát triển ứng dụng mobile cho công tác giám sát rừng tại hiện trường
- Xây dựng dashboard tương tác cho các nhà quản lý
- Tích hợp tính năng báo cáo tự động và xuất số liệu thống kê
- Kết nối với các hệ thống cảnh báo cháy rừng, thiên tai

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT CỦA BÀI TOÁN GIÁM SÁT BIẾN ĐỘNG RỪNG

1.1. Rừng và biến động rừng

Rừng là một hệ sinh thái bao gồm chủ yếu là cây cối, thực vật và động vật sống cùng nhau trong một môi trường phức tạp. Theo định nghĩa của Tổ chức Nông nghiệp và Lương thực Liên Hợp Quốc (FAO), rừng là vùng đất có diện tích tối thiểu 0.5 ha với độ che phủ tán cây trên 10%, chiều cao cây tối thiểu 5 mét khi trưởng thành, và không phải là đất nông nghiệp hoặc đô thị [13]. Rừng bao phủ khoảng 31% diện tích đất liền toàn cầu và đóng vai trò quan trọng trong việc duy trì cân bằng sinh thái, điều hòa khí hậu thông qua hấp thụ CO₂ và thải oxy, lưu giữ carbon, bảo tồn đa dạng sinh học, điều tiết nguồn nước và chống xói mòn đất, đồng thời cung cấp tài nguyên thiên nhiên và sinh kế cho hàng tỷ người trên thế giới. Tùy theo vị trí địa lý và điều kiện khí hậu, rừng được phân loại thành nhiều kiểu khác nhau như rừng nhiệt đới, rừng ôn đới, rừng phượng bắc (taiga), rừng ngập mặn, và rừng tràm. Trong đó, rừng ngập mặn là hệ sinh thái đặc biệt quan trọng ở các vùng ven biển nhiệt đới, có khả năng lưu giữ carbon cao gấp 3–5 lần so với rừng nhiệt đới trên cạn [6, 10].

1.1.1. Tình hình mất rừng trên thế giới

Tốc độ mất rừng toàn cầu vẫn đang ở mức báo động. Theo báo cáo “Global Forest Resources Assessment 2020” của FAO [13], tổng diện tích rừng bị phá từ năm 1990 đến 2020 ước tính khoảng 420 triệu ha. Mặc dù tốc độ mất rừng ròng đã có xu hướng giảm trong thập kỷ gần đây nhờ các nỗ lực trồng rừng và phục hồi rừng, việc chuyển đổi đất rừng tự nhiên sang mục đích nông nghiệp, chăn nuôi và phát triển cơ sở hạ tầng vẫn diễn ra với quy mô lớn và phức tạp. Đáng lo ngại hơn, phần lớn diện tích rừng bị mất là rừng nguyên sinh — loại rừng có giá trị sinh thái cao nhất và gần như không thể phục hồi được.

Sự suy giảm diện tích rừng tập trung nghiêm trọng nhất tại các khu vực nhiệt đới và cận nhiệt đới, nơi chứa đựng hơn nửa đa dạng sinh học của Trái Đất. Theo báo cáo “Deforestation Fronts: Drivers and Responses in a Changing World” của WWF công bố năm 2021 [53], trong giai đoạn 2004–2017, hơn 43 triệu ha rừng đã bị xóa sổ tại 24 khu vực phá rừng trọng điểm (deforestation fronts) trên thế giới — diện tích tương đương

với quy mô lãnh thổ Morocco. Các khu vực này chiếm hơn một nửa (52%) tổng diện tích rừng bị mất tại khu vực Mỹ Latinh, Châu Phi cận Sahara, Đông Nam Á và Châu Đại Dương trong cùng giai đoạn. Nông nghiệp quy mô lớn được xác định là nguyên nhân trực tiếp lớn nhất gây mất rừng trên toàn thế giới, trong đó chăn nuôi gia súc là tác nhân đơn lẻ gây mất rừng nhiệt đới nhiều nhất.

Trong số 24 khu vực này, 9 khu vực nằm tại Mỹ Latinh và đây là vùng chịu tổn thất nặng nề nhất với 26.9 triệu ha rừng bị mất — chiếm gần 2/3 tổng diện tích mất rừng toàn cầu. Rừng Amazon tại Brazil dẫn đầu với 15.5 triệu ha bị phá hủy, tiếp theo là Gran Chaco (5.2 triệu ha), Cerrado của Brazil (3 triệu ha) và vùng đất thấp Bolivia (1.5 triệu ha). Rừng Amazon — được mệnh danh là “lá phổi xanh của Trái Đất” — đang bị thu hẹp với tốc độ đáng báo động do áp lực từ ngành chăn nuôi gia súc quy mô lớn, trồng đậu nành xuất khẩu, khai thác gỗ và mở rộng cơ sở hạ tầng.

Không chỉ giới hạn ở Châu Mỹ, tình trạng phá rừng cũng đang diễn biến phức tạp tại các khu vực khác trên thế giới. Tại Châu Phi cận Sahara, WWF đã xác định 8 khu vực mất rừng trọng điểm trải dài từ Tây Phi đến Đông Phi. Khu vực Tây Phi (Liberia, Bờ Biển Ngà, Ghana) đang chịu áp lực từ việc mở rộng trồng ca cao và khai thác gỗ. Lưu vực Congo tại Trung Phi — khu rừng nhiệt đới lớn thứ hai thế giới sau Amazon, bao gồm các quốc gia như Cameroon, Gabon, Cộng hòa Congo, CHDC Congo và Cộng hòa Trung Phi — đang đối mặt với áp lực ngày càng tăng từ hoạt động khai thác gỗ, mở rộng nông nghiệp hộ gia đình và khai khoáng. Khác với Mỹ Latinh nơi nông nghiệp thương mại quy mô lớn là nguyên nhân chính, tại Châu Phi cận Sahara, nông nghiệp tự cung tự cấp và nông nghiệp thương mại quy mô nhỏ là động lực chủ yếu gây mất rừng. Tại Đông Phi, các khu vực mất rừng nghiêm trọng tại Zambia, Mozambique và Madagascar cũng đang diễn biến phức tạp do nhu cầu đất canh tác và sản xuất than củi.

Tại khu vực Đông Nam Á và Châu Đại Dương, 7 khu vực mất rừng trọng điểm được ghi nhận với quy mô thiệt hại đứng thứ hai sau Mỹ Latinh. Borneo (Indonesia và Malaysia) là khu vực mất rừng lớn thứ hai thế giới với 5.8 triệu ha bị phá hủy, tiếp theo là Sumatra (2.5 triệu ha), New Guinea (1.3 triệu ha) và Myanmar (1 triệu ha). Lưu vực sông Mekong — bao gồm Cambodia, Lào và Myanmar — đang mất rừng nhanh chóng do khai thác gỗ trái phép, xây dựng đập thủy điện và mở rộng nông nghiệp. Nông nghiệp thương mại với các đồn điền cọ dầu và cao su quy mô lớn là nguyên nhân chính gây mất rừng tại khu vực này. Indonesia và Malaysia — hai quốc gia sản xuất dầu cọ lớn nhất thế giới — đã mất hàng triệu ha rừng nhiệt đới trong hai thập kỷ qua. Ngoài ra, việc đốt rừng

để mở rộng đất canh tác còn gây ra các đợt khói mù nghiêm trọng, ảnh hưởng đến sức khỏe của hàng trăm triệu người trong khu vực. Đáng chú ý, miền Đông Australia cũng được xác định là một khu vực mất rừng do các đợt cháy rừng thảm khốc và hoạt động khai hoang.

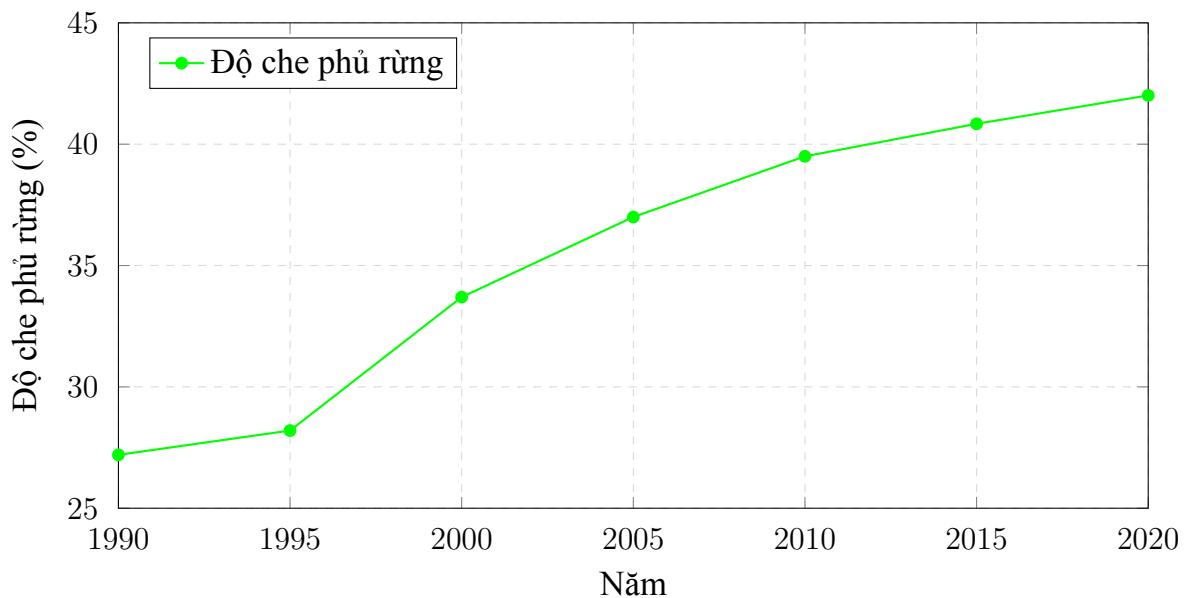
Xu hướng này vẫn tiếp diễn trong những năm gần đây. Theo Global Forest Watch [15], thế giới mất khoảng 10 triệu ha rừng nhiệt đới mỗi năm trong giai đoạn 2015–2020. Việc này không chỉ làm giảm khả năng hấp thụ CO₂ mà còn trực tiếp phát thải khí nhà kính từ việc đốt rừng và phân hủy sinh khối. Theo IPCC [26], phá rừng và thay đổi sử dụng đất đóng góp khoảng 23% tổng lượng phát thải khí nhà kính do con người gây ra, góp phần làm tăng hiện tượng biến đổi khí hậu toàn cầu.

1.1.2. Tình hình mất rừng tại Việt Nam

Việt Nam đã trải qua những biến đổi lớn về độ che phủ rừng trong 30 năm qua. Sau thời kỳ suy giảm nghiêm trọng (độ che phủ chỉ còn 28% vào năm 1990 do chiến tranh và khai thác bừa bãi), Việt Nam đã thực hiện nhiều chương trình phục hồi và phát triển rừng. Nhờ các chương trình như “Trồng 5 triệu ha rừng” (1998–2010), độ che phủ rừng đã tăng lên 42% vào năm 2020 [1].

Tuy nhiên, chất lượng rừng là một vấn đề đáng lo ngại. Mặc dù tổng diện tích rừng tăng từ 9.4 triệu ha (1990) lên 14.6 triệu ha (2020) chủ yếu nhờ rừng trồng (cao su, keo, thông), chất lượng rừng tự nhiên lại suy giảm đáng kể. Theo số liệu của Bộ NN&PTNT (2020), rừng tự nhiên hiện có khoảng 10.29 triệu ha, nhưng rừng nguyên sinh chỉ còn chiếm khoảng 0.25% tổng diện tích rừng [5].

Nguyên nhân chính gây mất rừng tại Việt Nam bao gồm việc chuyển đổi sang đất nông nghiệp như trồng cà phê, cao su và điều; khai thác gỗ trái phép; phát triển cơ sở hạ tầng và đô thị hóa; cháy rừng; và hoạt động nuôi trồng thủy sản, đặc biệt tại khu vực ven biển và đồng bằng sông Cửu Long.



Hình 1.1: Biến động độ che phủ rừng Việt Nam giai đoạn 1990–2020 (Bộ NN&PTNT, 2021)

Hình 1.1 cho thấy độ che phủ rừng Việt Nam tăng từ 27.2% (1990) lên 42.01% (2020). Tốc độ phục hồi nhanh nhất trong giai đoạn 1995–2000 (tăng 5.5 điểm phần trăm) nhờ chính sách đóng cửa rừng tự nhiên và chương trình trồng rừng quy mô lớn, sau đó chậm dần khi quỹ đất phù hợp dần cạn kiệt. Tuy nhiên, phần lớn sự gia tăng này đến từ rừng trồng với giá trị sinh thái thấp hơn đáng kể so với rừng tự nhiên.

1.2. Viễn thám

Viễn thám là khoa học và công nghệ thu thập thông tin về đối tượng hoặc hiện tượng từ khoảng cách xa mà không cần tiếp xúc trực tiếp. Công nghệ này ra đời từ giữa thế kỷ 19 với những bức ảnh chụp từ khinh khí cầu, sau đó phát triển mạnh mẽ cùng với sự tiến bộ của hàng không và vũ trụ. Ngày nay, viễn thám đóng vai trò quan trọng trong nhiều lĩnh vực như giám sát môi trường, quản lý tài nguyên thiên nhiên, quy hoạch đô thị và nông nghiệp. Đặc biệt trong lĩnh vực lâm nghiệp, viễn thám cho phép giám sát diện tích rừng rộng lớn một cách hiệu quả, phát hiện các biến động như phá rừng, cháy rừng và suy thoái rừng với độ chính xác cao và chi phí hợp lý.

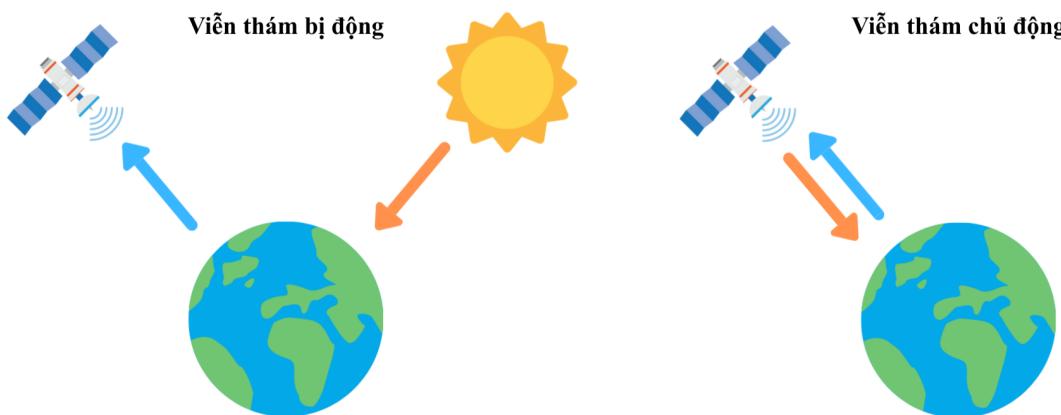
1.2.1. Nguyên lý viễn thám

Nguyên lý cơ bản của viễn thám dựa trên việc ghi nhận bức xạ điện từ phản xạ hoặc phát ra từ bề mặt Trái Đất và phân tích tương tác giữa bức xạ điện từ với các đối tượng

trên bề mặt [35]. Dựa vào nguồn năng lượng sử dụng, viễn thám được chia thành hai loại chính là viễn thám bị động và viễn thám chủ động.

Trong hệ thống viễn thám bị động, nguồn năng lượng chính là bức xạ từ Mặt Trời. Khi các sóng này truyền qua khí quyển, một phần năng lượng bị hấp thụ hoặc tán xạ. Sau đó bức xạ tương tác với bề mặt, chịu các quá trình phản xạ, hấp thụ hoặc truyền qua tùy theo đặc tính vật liệu. Tín hiệu phản xạ được vệ tinh ghi nhận bởi cảm biến và được xử lý, truyền về trạm mặt đất để phục vụ phân tích. Nguyên lý cân bằng năng lượng cho thấy năng lượng tới bằng tổng năng lượng phản xạ, hấp thụ và truyền qua.

Khác với viễn thám bị động, hệ thống viễn thám chủ động tự phát ra nguồn năng lượng điện tử hướng về phía mục tiêu và ghi nhận tín hiệu phản xạ ngược từ bề mặt. Ưu điểm chính của viễn thám chủ động là khả năng hoạt động độc lập với ánh sáng Mặt Trời, cho phép thu thập dữ liệu cả ngày lẫn đêm và trong mọi điều kiện thời tiết, kể cả khi có mây che phủ. Ra-đa khẩu độ tổng hợp là ví dụ điển hình của công nghệ viễn thám chủ động, sử dụng sóng vi ba có khả năng xuyên qua mây. Hình 1.2 minh họa nguyên lý hoạt động của hai hệ thống viễn thám này.



Hình 1.2: Nguyên lý viễn thám bị động và chủ động

Mỗi loại viễn thám có những ưu nhược điểm riêng. Viễn thám bị động, tiêu biểu như Sentinel-2, cung cấp ảnh quang học đa phổ với độ phân giải không cao, phù hợp cho phân loại lớp phủ đất chi tiết, nhưng bị hạn chế bởi mây và điều kiện chiếu sáng. Trong khi đó, viễn thám chủ động như Sentinel-1 hoạt động trong mọi điều kiện thời tiết, cung cấp thông tin về cấu trúc và độ ẩm bề mặt, tuy nhiên dữ liệu khó diễn giải hơn so với ảnh quang học. Sự kết hợp cả hai loại dữ liệu cho phép tận dụng ưu điểm của từng nguồn, đặc biệt quan trọng trong giám sát rừng nhiệt đới nơi mây phủ thường xuyên.

1.2.2. Chương trình Copernicus và vệ tinh Sentinel

Chương trình Copernicus của Liên minh Châu Âu là hệ thống quan sát Trái Đất toàn diện, cung cấp dữ liệu viễn thám miễn phí phục vụ nghiên cứu khoa học và giám sát môi trường. Trong nghiên cứu này, dữ liệu từ hai vệ tinh Sentinel-1 và Sentinel-2 được sử dụng nhờ tính chất bổ sung giữa cảm biến ra-đa và quang học.

Sentinel-1 là vệ tinh mang cảm biến ra-đa khẩu độ tổng hợp hoạt động ở băng tần C với tần số 5.405 GHz (bước sóng 5.55 cm). Trong chế độ IW, Sentinel-1 thu nhận dữ liệu ở hai chế độ phân cực VV và VH với độ phân giải không gian 10m và độ rộng dải quét 250 km [11]. Nguyên lý hoạt động của ra-đa dựa trên việc phát xung sóng vi ba và ghi nhận tín hiệu tán xạ ngược từ bề mặt. Cường độ tán xạ ngược phụ thuộc vào độ nhám bề mặt, hằng số điện môi và cấu trúc đối tượng. Đối với thảm thực vật, phân cực VV nhạy với tán xạ bề mặt liên quan đến độ ẩm đất, trong khi VH nhạy với tán xạ thể tích từ cấu trúc tán lá [51]. Ưu điểm của ra-đa là khả năng xuyên qua mây và hoạt động độc lập với điều kiện chiếu sáng.

Sentinel-2 mang cảm biến quang học đa phổ thu nhận ảnh ở 13 dải phổ từ vùng nhìn thấy đến hồng ngoại sóng ngắn (443–2190 nm). Độ phân giải không gian thay đổi theo dải phổ: 10m cho các dải B2, B3, B4, B8; 20m cho B5, B6, B7, B8a, B11, B12; và 60m cho B1, B9, B10 [12]. Với 13 dải phổ bao phủ nhiều vùng bước sóng khác nhau, có thể phân biệt các loại lớp phủ đất dựa trên đặc tính phản xạ riêng biệt của từng đối tượng [30]. Dữ liệu đa phổ này đặc biệt phù hợp để tính toán các chỉ số thực vật phục vụ giám sát biến động rừng. Bảng 1.1 tổng hợp các thông số kỹ thuật chính của hai vệ tinh này.

Bảng 1.1: So sánh thông số kỹ thuật giữa Sentinel-1 và Sentinel-2

Thông số	Sentinel-1	Sentinel-2
Loại cảm biến	Ra-đa (chủ động)	Quang học (bị động)
Dải sóng	C-band (5.55 cm)	443–2190 nm
Số kênh/phân cực	2 (VV, VH)	13 dải phổ
Độ phân giải không gian	10m (IW mode)	10/20/60m
Độ rộng dải quét	250 km	290 km
Chu kỳ quay lại	6–12 ngày	5–10 ngày
Hoạt động qua mây	Có	Không
Thông tin thu nhận	Cấu trúc, độ ẩm, độ nhám	Phản xạ phổ, chỉ số thực vật

Sự kết hợp dữ liệu từ hai nguồn cảm biến mang lại lợi thế quan trọng trong giám sát rừng nhiệt đới. SAR cung cấp dữ liệu liên tục trong điều kiện mây che phủ thường xuyên, đồng thời nhạy với biến đổi cấu trúc rừng như chặt phá cây. Trong khi đó, dữ liệu quang học cung cấp thông tin quang phổ phong phú để tính toán các chỉ số thực vật và đánh giá sức khỏe thảm thực vật. Các nghiên cứu đã chứng minh việc tích hợp SAR và quang học giúp cải thiện độ chính xác phân loại từ 5–15% so với sử dụng đơn nguồn dữ liệu [22, 24].

1.2.3. Các chỉ số thực vật viễn thám

Các chỉ số thực vật là các công thức toán học kết hợp giá trị phản xạ từ các kênh phổ khác nhau nhằm tăng cường thông tin về thực vật và giảm nhiễu từ các yếu tố khác như đất và khí quyển. Nghiên cứu này sử dụng ba chỉ số chính là NDVI, NBR và NDMI, mỗi chỉ số khai thác các đặc tính phổ khác nhau để cung cấp thông tin bổ sung về trạng thái thực vật.

Cơ sở để xây dựng các chỉ số thực vật xuất phát từ đặc tính phản xạ phổ đặc trưng của thực vật [35]. Ở vùng ánh sáng đỏ (Red, 620–700 nm), sắc tố diệp lục trong lá hấp thụ mạnh năng lượng để thực hiện quang hợp, dẫn đến phản xạ thấp. Ngược lại, ở vùng cận hồng ngoại (NIR, 700–1100 nm), cấu trúc xốp của mô thịt lá (mesophyll) tạo ra hiện tượng tán xạ nội bộ mạnh, khiến phản xạ đạt 40–50%. Ở vùng hồng ngoại sóng ngắn (SWIR, 1100–2500 nm), nước trong lá hấp thụ mạnh bức xạ, do đó phản xạ phụ thuộc trực tiếp vào hàm lượng nước. Stress thực vật là tình trạng cây bị tác động bất lợi từ các yếu tố môi trường như thiếu nước, nhiệt độ cao, sâu bệnh hoặc thiếu dinh dưỡng, dẫn đến suy giảm hàm lượng diệp lục và nước trong lá, từ đó làm thay đổi đặc tính phản xạ phổ có thể quan sát được qua viễn thám. Sự tương phản rõ rệt giữa các vùng phổ này là nền tảng để xây dựng các chỉ số thực vật: khi thực vật khỏe mạnh, sự chênh lệch giữa phản xạ NIR cao và phản xạ Red thấp sẽ lớn; khi thực vật bị stress hoặc mất đi, sự tương phản này giảm đáng kể.

Chỉ số thực vật chuẩn hóa NDVI (Normalized Difference Vegetation Index) là chỉ số được sử dụng phổ biến nhất để đánh giá sức khỏe và mật độ thực vật [46], được tính theo công thức:

$$NDVI = \frac{NIR - Red}{NIR + Red} = \frac{B8 - B4}{B8 + B4} \quad (1.1)$$

Chỉ số này sử dụng giá trị phản xạ ở dải cận hồng ngoại NIR (B8) và dải đỏ Red (B4), khai thác sự khác biệt giữa phản xạ cao ở NIR và phản xạ thấp ở Red của thực vật xanh

để định lượng mật độ và sức khỏe thực vật. Giá trị NDVI cao trong khoảng 0.3 đến 0.8 chỉ ra thực vật xanh khỏe mạnh, giá trị thấp từ 0.1 đến 0.2 tương ứng với đất trống, còn giá trị âm thường là nước.

Chỉ số cháy chuẩn hóa NBR (Normalized Burn Ratio) được thiết kế ban đầu để phát hiện khu vực cháy rừng, nhưng cũng cho thấy hiệu quả trong phát hiện mất rừng [29]. Công thức tính NBR như sau:

$$NBR = \frac{NIR - SWIR2}{NIR + SWIR2} = \frac{B8 - B12}{B8 + B12} \quad (1.2)$$

Chỉ số này sử dụng giá trị phản xạ ở dải cận hồng ngoại NIR (B8) và dải hồng ngoại sóng ngắn 2 SWIR2 (B12, 2190 nm). Kênh SWIR nhạy với độ ẩm và cấu trúc thực vật, do đó khi rừng bị phá hoặc cháy, NIR giảm do mất lá xanh trong khi SWIR tăng do bề mặt khô hơn. NBR cao trong khoảng 0.3 đến 0.8 chỉ ra rừng khỏe mạnh, còn NBR thấp hoặc âm chỉ ra khu vực bị tác động.

Chỉ số độ ẩm chuẩn hóa NDMI (Normalized Difference Moisture Index) đo lường hàm lượng nước trong tán lá thực vật và là chỉ số quan trọng để phát hiện stress thực vật [14]. NDMI được tính theo công thức:

$$NDMI = \frac{NIR - SWIR1}{NIR + SWIR1} = \frac{B8 - B11}{B8 + B11} \quad (1.3)$$

Chỉ số này sử dụng giá trị phản xạ ở dải cận hồng ngoại NIR (B8) và dải hồng ngoại sóng ngắn 1 SWIR1 (B11, 1610 nm). Do nước hấp thụ mạnh ở dải SWIR1, thực vật có hàm lượng nước cao sẽ cho phản xạ SWIR thấp. NDMI dương trong khoảng 0.2 đến 0.6 chỉ ra thực vật có hàm lượng nước cao, còn NDMI thấp hoặc âm chỉ ra thực vật bị stress hoặc khô. Đặc biệt, NDMI có thể phát hiện sự thay đổi độ ẩm trước khi NDVI phản ánh sự suy giảm sức khỏe thực vật, giúp cảnh báo sớm tình trạng suy thoái rừng.

Bảng 1.2: Tổng hợp các chỉ số thực vật sử dụng trong nghiên cứu

Chỉ số	Công thức	Phạm vi	Ý nghĩa
NDVI	(B8-B4)/(B8+B4)	[-1, 1]	Mật độ, sức khỏe thực vật
NBR	(B8-B12)/(B8+B12)	[-1, 1]	Phát hiện cháy/mất rừng
NDMI	(B8-B11)/(B8+B11)	[-1, 1]	Độ ẩm tán lá

1.2.4. Giám sát biến động rừng và tích hợp đa nguồn dữ liệu

Giám sát biến động rừng là quá trình xác định sự thay đổi về diện tích, cấu trúc hoặc trạng thái của rừng giữa hai hoặc nhiều thời điểm khác nhau [23]. Phương pháp này dựa trên việc so sánh các đặc trưng viễn thám thu được từ các thời điểm khác nhau.

Phương pháp phát hiện biến động dựa trên việc so sánh các đặc trưng giữa hai thời điểm, tính toán sự chênh lệch (delta) giữa “các đặc trưng trước” và “các đặc trưng sau”. Các đặc trưng thời gian bao gồm các “các đặc trưng trước” thể hiện trạng thái rừng tại thời điểm t_1 , các “các đặc trưng sau” thể hiện trạng thái rừng tại thời điểm t_2 , và các “đặc trưng delta” biểu diễn biến đổi giữa hai thời điểm.

Ví dụ với NDVI, khi $\Delta NDVI$ (hiệu NDVI sau và trước) giảm mạnh thì đó là dấu hiệu mất rừng, khi $\Delta NDVI$ xấp xỉ 0 thì vùng được xem là rừng ổn định, và khi $\Delta NDVI$ tăng mạnh thì biểu hiện tái trồng rừng.

Việc tích hợp dữ liệu ra-đa khẩu độ tổng hợp từ Sentinel-1 và dữ liệu quang học đa phổ từ Sentinel-2 mang lại nhiều lợi ích quan trọng trong giám sát rừng. Hai nguồn dữ liệu này có tính chất bổ sung cho nhau: ra-đa cung cấp thông tin về cấu trúc, độ nhám bề mặt và độ ẩm, trong khi quang học cung cấp thông tin quang phổ và các chỉ số thực vật. Sự kết hợp này còn giúp khắc phục hạn chế của từng loại cảm biến, trong đó ra-đa hoạt động hiệu quả trong điều kiện mây mù thường xuyên của rừng nhiệt đới, còn quang học cung cấp dữ liệu trực quan dễ phiên giải hơn. Nhiều nghiên cứu đã chứng minh rằng việc kết hợp ra-đa và quang học giúp tăng độ chính xác từ 5 đến 10% so với việc sử dụng mỗi nguồn dữ liệu riêng lẻ [22, 24]. Ngoài ra, sự tích hợp này cho phép phát hiện biến động đa chiều: ra-đa nhạy với biến đổi cấu trúc như chặt cây, trong khi quang học nhạy với biến đổi quang phổ phản ánh sức khỏe thực vật.

1.3. Học sâu và mạng nơ-ron tích chập

Học sâu là một nhánh của học máy dựa trên mạng nơ-ron nhân tạo nhiều lớp, cho phép tự động học các biểu diễn đặc trưng phân cấp từ dữ liệu thô mà không cần thiết kế đặc trưng thủ công [34]. Phần này trình bày các khái niệm nền tảng về học sâu, làm cơ sở lý thuyết cho kiến trúc mô hình được đề xuất trong Chương 2.

1.3.1. Kiến trúc mạng nơ-ron tích chập

Mạng nơ-ron tích chập đã trở thành công cụ chủ đạo trong xử lý ảnh viễn thám và phân loại lớp phủ đất [54, 55]. Kiến trúc CNN được xây dựng từ các thành phần cơ bản sau.

Perceptron là đơn vị tính toán cơ bản của mạng nơ-ron nhân tạo. Mỗi perceptron thực hiện phép biến đổi tuyến tính kết hợp với hàm kích hoạt phi tuyến theo công thức:

$$y = f(\mathbf{w}^T \mathbf{x} + b) \quad (1.4)$$

trong đó $\mathbf{x} \in \mathbb{R}^n$ là vector đầu vào, $\mathbf{w} \in \mathbb{R}^n$ là vector trọng số, $b \in \mathbb{R}$ là độ lệch, $f(\cdot)$ là hàm kích hoạt phi tuyến, và y là đầu ra. Cơ chế này mô phỏng cách nơ-ron sinh học xử lý tín hiệu: nhận nhiều đầu vào, tính tổng có trọng số, và kích hoạt khi vượt ngưỡng. Multi-Layer Perceptron (MLP) mở rộng perceptron thành mạng nhiều lớp, trong đó mỗi lớp nhận đầu ra của lớp trước làm đầu vào. Các lớp ẩn cho phép mạng học các biểu diễn trừu tượng của dữ liệu với mức độ phức tạp tăng dần theo chiều sâu.

Phép tích chập 2D là thành phần cốt lõi của CNN. Với đầu vào I và kernel K kích thước $k_h \times k_w$, phép tích chập được định nghĩa:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \times K(m, n) \quad (1.5)$$

trong đó (i, j) là vị trí trong đầu ra và (m, n) là vị trí trong kernel. Kernel trượt qua đầu vào với bước nhảy xác định; tại mỗi vị trí, phép nhân từng phần tử giữa kernel và vùng tương ứng được thực hiện, sau đó cộng tổng để tạo ra một giá trị đầu ra. Với đầu vào nhiều kênh, kernel có cùng số kênh và phép tích chập được thực hiện đồng thời trên tất cả các kênh. Phép tích chập mang lại ba ưu điểm quan trọng [34]. Thứ nhất, cơ chế chia sẻ tham số cho phép cùng một kernel áp dụng cho toàn bộ đầu vào, giúp giảm đáng kể số lượng tham số cần học. Thứ hai, tính bất biến tịnh tiến giúp mạng có khả năng nhận diện đặc trưng bất kể vị trí xuất hiện trong ảnh. Thứ ba, kết nối cục bộ đảm bảo mỗi nơ-ron chỉ kết nối với vùng lân cận của đầu vào, phù hợp với đặc tính không gian của dữ liệu ảnh.

Hàm kích hoạt đưa tính phi tuyến vào mạng nơ-ron, cho phép học các mối quan hệ phức tạp trong dữ liệu [17]. ReLU (Rectified Linear Unit) là hàm kích hoạt phổ biến nhất với công thức $f(x) = \max(0, x)$. ReLU giữ nguyên giá trị dương và chuyển giá trị âm về 0, mang lại các ưu điểm như tính toán đơn giản, giảm vần đề triệt tiêu gradient,

và tạo ra tính thừa trong kích hoạt. Đối với bài toán phân loại đa lớp, hàm softmax được sử dụng ở lớp đầu ra để chuyển đổi các giá trị logits thành phân phối xác suất theo công thức $\text{softmax}(\mathbf{x})_i = \exp(x_i) / \sum_j \exp(x_j)$, trong đó \mathbf{x} là vector logits từ lớp cuối cùng và lớp có xác suất cao nhất được chọn làm kết quả dự đoán.

Pooling là phép toán giảm chiều không gian của bản đồ đặc trưng (feature map), giúp giảm số lượng tham số và tăng tính bất biến tịnh tiến của mạng [34]. Hai loại pooling phổ biến là Max Pooling (chọn giá trị lớn nhất trong mỗi vùng) và Average Pooling (tính trung bình các giá trị). Lớp gộp trung bình toàn cục (GAP) là trường hợp đặc biệt trong đó vùng pooling bao trùm toàn bộ bản đồ đặc trưng, biến đổi mỗi bản đồ đặc trưng thành một giá trị vô hướng [36]. GAP giúp giảm mạnh số lượng tham số và có tính chất điều chỉnh tự nhiên. Trong nghiên cứu này, GAP được sử dụng để tổng hợp thông tin không gian trước lớp phân loại.

1.3.2. Huấn luyện mạng nơ-ron

Hàm mất mát đo lường sự khác biệt giữa dự đoán của mô hình và nhãn thực tế, đóng vai trò là mục tiêu tối ưu hóa trong quá trình huấn luyện [17]. Đối với bài toán phân loại đa lớp, Cross-Entropy Loss được định nghĩa:

$$L = - \sum_i y_i \log(\hat{y}_i) \quad (1.6)$$

trong đó y_i là nhãn thực tế (mã hóa one-hot) và \hat{y}_i là xác suất dự đoán từ hàm softmax. Hàm này đo lường khoảng cách giữa phân phối dự đoán và phân phối thực tế: giá trị mất mát cao khi mô hình gán xác suất thấp cho lớp đúng, và thấp khi dự đoán chính xác. Cross-Entropy Loss có tính chất lồi (convex) theo tham số của lớp softmax, giúp quá trình tối ưu hóa ổn định và hội tụ nhanh hơn so với các hàm mất mát khác trong bài toán phân loại.

Thuật toán tối ưu hóa đóng vai trò cập nhật trọng số của mạng dựa trên gradient của hàm mất mát. Adam được đề xuất bởi Kingma và Ba [31] là một trong những thuật toán phổ biến nhất hiện nay. Adam kết hợp ưu điểm của hai phương pháp: momentum sử dụng trung bình động bậc nhất của gradient để tăng tốc hội tụ theo hướng nhất quán, và RMSprop sử dụng trung bình động bậc hai để điều chỉnh tốc độ học theo từng tham số. Sự kết hợp này giúp Adam hoạt động hiệu quả trên nhiều loại bài toán với ít điều chỉnh siêu tham số. AdamW là biến thể cải tiến với cơ chế phân rã trọng số tách biệt khỏi cập nhật gradient, giúp điều chỉnh hiệu quả hơn và tránh tương tác không mong muốn giữa

hai cơ chế.

Các kỹ thuật điều chỉnh giúp ngăn chặn hiện tượng quá khớp, khi mô hình học quá chi tiết trên tập huấn luyện nhưng tổng quát hóa kém trên dữ liệu mới. Chuẩn hóa theo lô được đề xuất bởi Ioffe và Szegedy [25] nhằm tăng tốc quá trình huấn luyện bằng cách chuẩn hóa các giá trị kích hoạt trong mỗi lô nhỏ về phân phối chuẩn (trung bình 0, phương sai 1), sau đó áp dụng phép biến đổi tuyến tính với tham số học được. Kỹ thuật này giúp cho phép sử dụng tốc độ học cao hơn và giảm độ nhạy với khởi tạo trọng số. Dropout được đề xuất bởi Srivastava và cộng sự [49] như một kỹ thuật điều chỉnh hiệu quả: trong quá trình huấn luyện, mỗi nơ-ron bị tắt ngẫu nhiên với xác suất xác định, buộc mạng học các biểu diễn bền vững và tránh phụ thuộc quá mức vào một số nơ-ron cụ thể. Dropout2d là biến thể tắt toàn bộ bản đồ đặc trưng thay vì từng nơ-ron riêng lẻ, phù hợp cho CNN do tương quan không gian cao giữa các giá trị trong cùng bản đồ đặc trưng.

1.3.3. Ứng dụng CNN trong phân loại ảnh viễn thám

Trong phân loại ảnh viễn thám, có hai phương pháp tiếp cận chính [7, 54]. Phương pháp phân loại dựa trên điểm ảnh thực hiện phân loại mỗi điểm ảnh độc lập dựa trên vector đặc trưng phổ của nó. Phương pháp này có ưu điểm là đơn giản trong triển khai và tốc độ xử lý nhanh, tuy nhiên không tận dụng được thông tin ngữ cảnh không gian và dễ tạo ra nhiều muối-tiêu trong kết quả phân loại, đặc biệt ở các vùng ranh giới giữa các lớp. Phương pháp phân loại dựa trên patch trích xuất patch xung quanh mỗi điểm ảnh trung tâm và thực hiện phân loại dựa trên toàn bộ thông tin trong patch. Phương pháp này tận dụng được ngữ cảnh không gian, cho kết quả phân loại mượt mà hơn và đặc biệt phù hợp với kiến trúc CNN vốn được thiết kế để học các đặc trưng không gian cục bộ. Kích thước patch cần được lựa chọn phù hợp với độ phân giải ảnh và đặc tính của đối tượng cần phân loại: patch quá nhỏ không nắm bắt đủ ngữ cảnh, trong khi patch quá lớn có thể đưa vào nhiều từ các lớp phủ lân cận.

Chuẩn hóa dữ liệu là bước tiền xử lý quan trọng trong học máy nói chung và CNN nói riêng, đảm bảo các đặc trưng có cùng thang đo để quá trình học diễn ra ổn định [48]. Trong ảnh viễn thám đa nguồn, các đặc trưng thường có thang đo rất khác nhau: chỉ số thực vật NDVI nằm trong khoảng $[-1, 1]$, phản xạ bề mặt quang học trong khoảng $[0, 1]$, trong khi tán xạ ngược ra-đa có thể trong khoảng $[-25, 0]$ dB. Nếu không chuẩn hóa, các đặc trưng có giá trị lớn sẽ chi phối quá trình học và gradient có thể không ổn định. Chuẩn hóa Z-score chuyển đổi dữ liệu về phân phối với trung bình bằng 0 và độ lệch chuẩn

bằng 1 (chi tiết công thức được trình bày trong Chương 2). Điểm quan trọng cần lưu ý là các tham số chuẩn hóa (trung bình μ và độ lệch chuẩn σ) phải được tính toán dựa trên tập huấn luyện và áp dụng nhất quán cho cả tập kiểm tra, nhằm đảm bảo tính khách quan trong đánh giá mô hình và tránh rò rỉ thông tin từ tập kiểm tra.

1.4. Các nghiên cứu liên quan

Giám sát biến động rừng đã trải qua nhiều giai đoạn phát triển, từ các phương pháp thủ công truyền thống đến các kỹ thuật học sâu hiện đại. Phần này trình bày quá trình phát triển của các phương pháp theo thời gian, tổng hợp các nghiên cứu tiêu biểu trên thế giới và tại Việt Nam, làm cơ sở cho việc xác định khoảng trống nghiên cứu và định hướng đồ án.

1.4.1. Sự phát triển của các phương pháp giám sát biến động rừng

Trước khi có công nghệ viễn thám, giám sát rừng chủ yếu dựa vào khảo sát thực địa trực tiếp. Nhân viên kiểm lâm đi thực địa để đo đạc, ghi nhận trạng thái rừng và lập bản đồ thủ công. Phương pháp này có độ chính xác cao tại từng điểm khảo sát nhưng tốn kém về thời gian và nhân lực, không khả thi cho giám sát diện rộng và khó cập nhật thường xuyên.

Từ giữa thế kỷ 20, ảnh hàng không (Aerial Photography) bắt đầu được sử dụng để lập bản đồ rừng. Các chuyên gia giải đoán ảnh hàng không bằng mắt thường để xác định ranh giới rừng và phát hiện thay đổi. Phương pháp này cho phép quan sát diện tích lớn hơn khảo sát thực địa nhưng vẫn phụ thuộc nhiều vào kinh nghiệm của người giải đoán và chi phí bay chụp cao.

Với sự ra đời của vệ tinh Landsat năm 1972, lần đầu tiên có thể quan sát bề mặt Trái Đất một cách hệ thống từ không gian. Giai đoạn đầu, việc phân tích ảnh vệ tinh chủ yếu dựa vào giải đoán trực quan - chuyên gia nhìn ảnh và vẽ ranh giới các vùng đất khác nhau. Các phương pháp phân loại dựa trên ngưỡng như phân ngưỡng chỉ số thực vật NDVI được sử dụng rộng rãi trong thập niên 1980–1990.

Từ thập niên 1990, các thuật toán phân loại thống kê bắt đầu được áp dụng rộng rãi. Maximum Likelihood Classification (MLC) giả định dữ liệu tuân theo phân phối Gaussian và phân loại điểm ảnh dựa trên xác suất. Phân loại không giám sát như K-means và ISODATA không yêu cầu dữ liệu huấn luyện có nhãn, thay vào đó tự động

nhóm các điểm ảnh có đặc trưng phổ biến tự thành các cụm [27].

Bước tiến quan trọng trong học máy cho viễn thám đến từ phương pháp Random Forest. Ho [21] đề xuất ý tưởng random decision forests năm 1995, sau đó Breiman [8] phát triển và hoàn thiện thành thuật toán Random Forest năm 2001. Thuật toán này cải thiện cây quyết định đơn lẻ bằng cách kết hợp nhiều cây quyết định và nhanh chóng trở thành phương pháp phổ biến nhất trong phân loại ảnh viễn thám. Cùng thời kỳ, Cortes và Vapnik [9] giới thiệu Support Vector Machine (SVM) năm 1995. SVM chứng minh hiệu quả vượt trội so với MLC trong phân loại ảnh viễn thám, đặc biệt khi làm việc với dữ liệu đa chiều và bộ mẫu huấn luyện nhỏ.

Từ năm 2012, với sự thành công của AlexNet trong cuộc thi ImageNet, học sâu bắt đầu cách mạng hóa thị giác máy tính và nhanh chóng được áp dụng vào viễn thám. Zhu và cộng sự [55] tổng hợp các ứng dụng của học sâu trong viễn thám và chỉ ra tiềm năng to lớn của CNN trong phân loại ảnh vệ tinh. Kiến trúc U-Net với cấu trúc mã hóa-giải mã, ban đầu cho phân đoạn ảnh y sinh, sau đó được áp dụng rộng rãi trong viễn thám nhờ khả năng phân đoạn hiệu quả [45].

Bảng 1.3: So sánh các phương pháp giám sát biến động ròng qua các giai đoạn

Giai đoạn	Thời kỳ	Phương pháp tiêu biểu	Đặc điểm
Truyền thống	Trước 1970	Khảo sát thực địa	Chính xác nhưng tốn kém
Viễn thám đầu	1970–1990	Giải đoán trực quan	Chủ quan, khó tái lập
ML truyền thống	1990–2012	MLC, Decision Tree, RF	Khách quan, tự động hóa
Học sâu	2012–nay	CNN, U-Net	Học đặc trưng tự động
Tích hợp	2015–nay	CNN + SAR + Optical	Bổ sung, tăng độ tin cậy

1.4.2. Tổng quan nghiên cứu và khoảng trống nghiên cứu

Trên thế giới, nhiều công trình nghiên cứu đã được thực hiện trong lĩnh vực giám sát biến động ròng sử dụng viễn thám và học máy. Hansen và cộng sự [18] (Đại học Maryland, Hoa Kỳ) đã công bố nghiên cứu đột phá trên tạp chí Science, sử dụng thuật toán Cây quyết định để phân tích toàn bộ kho ảnh Landsat giai đoạn 2000–2012, tạo ra bộ dữ liệu Global Forest Change — bản đồ mất rừng toàn cầu đầu tiên ở độ phân giải 30m; nghiên cứu phát hiện thế giới đã mất 2.3 triệu km² rừng trong 12 năm, đạt overall accuracy khoảng 85%. Reiche và cộng sự [42] (Đại học Wageningen, Hà Lan) đề xuất

phương pháp phát hiện mất rừng cận thời gian thực bằng cách kết hợp chuỗi thời gian Sentinel-1, ALOS-2 PALSAR-2 và Landsat-7/8 sử dụng tiếp cận xác suất Bayesian; thử nghiệm tại rừng nhiệt đới khô Bolivia cho thấy phương pháp kết hợp phát hiện mất rừng với độ trễ trung bình 31 ngày, nhanh hơn 7 ngày so với chỉ dùng Sentinel-1 và 6 tuần so với chỉ dùng Landsat, đạt overall accuracy 93.8%. Hu và cộng sự [22] nghiên cứu tại Madagascar cho thấy việc kết hợp dữ liệu Sentinel-1 và Sentinel-2 cải thiện accuracy từ 87% (chỉ dùng quang học) lên 92% (kết hợp cả hai), chứng minh lợi ích của tích hợp đa nguồn dữ liệu.

Về ứng dụng học sâu trong viễn thám, Zhang và cộng sự [54] (Đại học Vũ Hán, Trung Quốc) công bố bài tổng quan kỹ thuật trên IEEE Geoscience and Remote Sensing Magazine, giới thiệu các kiến trúc CNN phổ biến (AlexNet, VGGNet, ResNet) và tiềm năng ứng dụng trong xử lý ảnh viễn thám, đặt nền móng lý thuyết cho các nghiên cứu sau này. Kussul và cộng sự [33] (Viện Nghiên cứu Không gian Ukraine) đề xuất kiến trúc CNN đa cấp cho phân loại cây trồng từ ảnh Sentinel-2 đa thời gian tại khu vực thử nghiệm JECAM ($28,000 \text{ km}^2$) ở Ukraine; kết quả cho thấy CNN 2D đạt overall accuracy 94.5%, vượt trội đáng kể so với Random Forest và MLP, đặc biệt trong phân biệt các loại cây trồng mùa hè. Hethcoat và cộng sự [20] (Đại học Sheffield, Anh) áp dụng học máy để phát hiện khai thác gỗ chọn lọc tại rừng Amazon từ dữ liệu Landsat và Sentinel, đạt accuracy 94.3%; nghiên cứu này mở ra hướng ứng dụng phát hiện suy thoái rừng ở quy mô nhỏ. Karra và cộng sự [28] (ESRI/Impact Observatory) phát triển mô hình U-Net được huấn luyện trên hơn 5 tỷ điểm ảnh Sentinel-2 có nhãn thủ công từ hơn 20,000 điểm trên toàn cầu, tạo ra bản đồ sử dụng đất toàn cầu ở độ phân giải 10m với overall accuracy 85%. Bảng 1.4 tổng hợp các nghiên cứu tiêu biểu trên thế giới.

Bảng 1.4: Tổng hợp các nghiên cứu tiêu biểu trên thế giới

Tác giả	Năm	Phương pháp	Dữ liệu	Khu vực	Accuracy
Hansen và cs.	2013	Decision Tree	Landsat	Toàn cầu	~85%
Kussul và cs.	2017	CNN 2D	Sentinel-2	Ukraine	94.5%
Reiche và cs.	2018	Bayesian fusion	S1+Landsat	Bolivia	93.8%
Hethcoat và cs.	2019	ML	Landsat+S1	Amazon	94.3%
Hu và cs.	2020	ML fusion	S1+S2	Madagascar	92.0%
Karra và cs.	2021	U-Net	Sentinel-2	Toàn cầu	85.0%

Tại Việt Nam, các nghiên cứu ứng dụng viễn thám và học máy trong giám sát rừng đã có những bước phát triển đáng kể trong những năm gần đây. Nguyen và cộng sự [38] (hợp tác giữa Việt Nam, Phần Lan và Hoa Kỳ) so sánh bốn phương pháp phân loại (Logistic Regression, k-NN, Random Forest và SVM) trên 446 ảnh Sentinel-2 đa thời gian (2017–2018) cho khu vực Đăk Nông ($6,516 \text{ km}^2$) — tỉnh có tài nguyên rừng tự nhiên phong phú nhất Việt Nam; kết quả cho thấy Random Forest và SVM đạt overall accuracy cao nhất (khoảng 91.2%), đồng thời việc bổ sung dữ liệu mùa xuân cải thiện accuracy thêm 2.9–4.8%. Pham và cộng sự [40] (Đại học Waikato, New Zealand và ĐHQG TP.HCM) đề xuất phương pháp phân loại dựa trên đối tượng (OBIA) kết hợp ảnh QuickBird, dữ liệu LiDAR mật độ thấp và các chỉ số địa hình GIS (độ dốc, chỉ số ám địa hình) để nhận dạng loài cây bản địa; nghiên cứu sử dụng Random Forest để xác định biến quan trọng và SVM để phân loại, chứng minh việc kết hợp LiDAR và dữ liệu phổ cải thiện đáng kể độ chính xác phân loại cây đơn lẻ, đặt nền móng cho các nghiên cứu tích hợp đa nguồn dữ liệu. Vo và cộng sự [52] (Đại học Cần Thơ) khai thác nền tảng Google Earth Engine để phân tích toàn bộ kho ảnh Landsat-7 và Landsat-8 giai đoạn 2001–2019 cho huyện Ngọc Hiển, Cà Mau; nghiên cứu áp dụng phương pháp tối ưu hóa thời gian sau phân loại để tạo bản đồ sử dụng đất hàng năm liên tục không có khoảng trống dữ liệu, phát hiện biến động ròng của rừng ngập mặn là $-0.01\%/\text{năm}$ và xác định các điểm nóng mất rừng theo không gian. Tuy nhiên, phần lớn các nghiên cứu tại Việt Nam vẫn tập trung vào các phương pháp học máy truyền thống (Random Forest, SVM) hoặc sử dụng ảnh quang học đơn thuần; việc ứng dụng học sâu (CNN) kết hợp với dữ liệu đa nguồn (ra-đa + quang học) cho giám sát rừng tại Việt Nam còn rất hạn chế.

Qua tổng quan tài liệu, một số khoảng trống nghiên cứu nổi bật được xác định. Thứ nhất, phần lớn các công trình nghiên cứu về học sâu trong giám sát rừng tập trung ở các vùng rừng nhiệt đới Amazon, Congo hay Indonesia, trong khi còn rất ít nghiên cứu áp dụng CNN cho rừng Việt Nam, đặc biệt là hệ sinh thái rừng ngập mặn Cà Mau. Thứ hai, CNN thường yêu cầu tập dữ liệu lớn với hàng trăm nghìn mẫu huấn luyện, nhưng có ít công trình nghiên cứu về kiến trúc CNN tối ưu cho các bộ dữ liệu nhỏ trong viễn thám với khoảng 2.000–5.000 mẫu. Thứ ba, việc tích hợp dữ liệu ra-đa khẩu độ tổng hợp và quang học trong bối cảnh học sâu vẫn còn nhiều thách thức, đồng thời còn thiếu các khảo sát tối ưu hóa mô hình trong kiến trúc CNN cho loại dữ liệu kết hợp này.

Xuất phát từ những khoảng trống nghiên cứu đã nêu, đồ án này hướng đến việc phát triển kiến trúc CNN lightweight phù hợp cho bộ dữ liệu nhỏ, tích hợp dữ liệu đa

nguồn (Sentinel-1 và Sentinel-2) ở cấp độ đặc trưng, và ứng dụng thực tế cho giám sát biến động rừng tại khu vực quy hoạch lâm nghiệp tỉnh Cà Mau. Nghiên cứu kế thừa xu hướng kết hợp học sâu với dữ liệu đa nguồn để tận dụng ưu điểm của cả dữ liệu ra-đa khẩu độ tổng hợp và quang học.

CHƯƠNG 2. DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

2.1. Dữ liệu

2.1.1. Dữ liệu viễn thám Sentinel

Việc lựa chọn ảnh vệ tinh tuân theo các tiêu chí nhằm đảm bảo chất lượng dữ liệu đầu vào. Đối với ảnh Sentinel-2, nghiên cứu sử dụng sản phẩm *S2_SR_HARMONIZED* (Surface Reflectance Level-2A đã hiệu chỉnh) từ Google Earth Engine, ưu tiên các ảnh trong mùa khô (tháng 1–3) để giảm thiểu ảnh hưởng của mây và đảm bảo tính so sánh giữa hai thời kỳ. Mặt nạ mây được tạo từ bộ sưu tập *S2_CLOUD_PROBABILITY* với ngưỡng xác suất 50% để loại bỏ các điểm ảnh bị mây che phủ. Đối với ảnh Sentinel-1, sử dụng sản phẩm *S1_GRD* đã được tiền xử lý bởi ESA, các cảnh được chọn có thời gian thu nhận gần nhất với ảnh Sentinel-2 tương ứng (trong phạm vi ±7 ngày) để đảm bảo tính đồng bộ về thời gian.

Bảng 2.1: Tông quan dữ liệu sử dụng

Nguồn dữ liệu	Độ phân giải	Kỳ ảnh	Số lượng
Sentinel-2 trước	10m	30/01/2024	7 kênh
Sentinel-2 sau	10m	28/02/2025	7 kênh
Sentinel-1 trước	10m	04/02/2024	2 kênh
Sentinel-1 sau	10m	22/02/2025	2 kênh
Dữ liệu thực địa	-	-	2,630 điểm
Ranh giới lâm nghiệp	-	-	Vector

2.1.2. Thu thập dữ liệu trên Google Earth Engine

Toàn bộ dữ liệu ảnh vệ tinh được thu thập và xử lý trên nền tảng Google Earth Engine — một hệ thống điện toán đám mây cho phép truy cập và xử lý khối lượng lớn dữ liệu viễn thám. Việc sử dụng GEE mang lại nhiều ưu điểm: truy cập trực tiếp kho dữ liệu Sentinel đã được hiệu chỉnh, khả năng xử lý dữ liệu nhanh chóng trên hạ tầng đám mây, và đảm bảo tính nhất quán trong quy trình xử lý.

Dữ liệu Sentinel-2 được truy xuất từ bộ dữ liệu *COPERNICUS/S2_SR_HARMONIZED* — sản phẩm đã được hiệu chỉnh khí quyển và đồng nhất hóa giữa các cảm biến Sentinel-

2A và 2B. Quy trình xử lý bắt đầu bằng việc lọc theo không gian và thời gian để chọn các cảnh phủ khu vực nghiên cứu trong ngày chỉ định, sau đó loại bỏ mây sử dụng bộ sưu tập *S2_CLOUD_PROBABILITY* với ngưỡng xác suất 50%. Tiếp theo, 4 kênh phổ cần thiết (B4-Red, B8-NIR, B11-SWIR1, B12-SWIR2) được trích xuất, chuyển đổi sang giá trị phản xạ và tính toán 3 chỉ số thực vật NDVI, NBR, NDMI. Cuối cùng, các tiles được mosaic để tạo ảnh liền mạch phủ toàn bộ khu vực nghiên cứu.

Việc lựa chọn bốn kênh phổ B4, B8, B11 và B12 trong số 13 kênh của Sentinel-2 dựa trên cơ sở khoa học về đặc tính phản xạ phổ của thực vật và yêu cầu tính toán các chỉ số thực vật phục vụ giám sát biến động rừng. Kênh B4 ở vùng ánh sáng đỏ (665 nm) ghi nhận vùng hấp thụ mạnh của diệp lục, do đó nhạy cảm với sự thay đổi hàm lượng diệp lục khi thực vật bị stress hoặc chết đi [35]. Kênh B8 ở vùng cận hồng ngoại (842 nm) phản ánh cấu trúc mô thịt lá với phản xạ cao ở thực vật khỏe mạnh, là thành phần không thể thiếu trong hầu hết các chỉ số thực vật [46]. Hai kênh SWIR bao gồm B11 (1610 nm) và B12 (2190 nm) nhạy cảm với hàm lượng nước trong lá và cellulose, lignin trong cấu trúc thực vật, đặc biệt hiệu quả trong phát hiện các vùng rừng bị suy thoái hoặc chặt phá [14, 29]. Các kênh vùng nhìn thấy B2 và B3 không được sử dụng vì dễ bị ảnh hưởng bởi tán xạ khí quyển và không cung cấp thông tin bổ sung đáng kể so với B4 trong bối cảnh giám sát rừng. Các kênh Red Edge (B5, B6, B7) và B8a có độ phân giải không gian 20m, thấp hơn so với 10m của B4 và B8, đồng thời thông tin từ các kênh này đã được phản ánh gián tiếp qua sự kết hợp B4-B8 trong chỉ số NDVI. Nghiên cứu của Khatami et al. [30] chỉ ra rằng việc sử dụng quá nhiều kênh phổ có thể dẫn đến hiện tượng thừa thông tin mà không cải thiện độ chính xác phân loại.

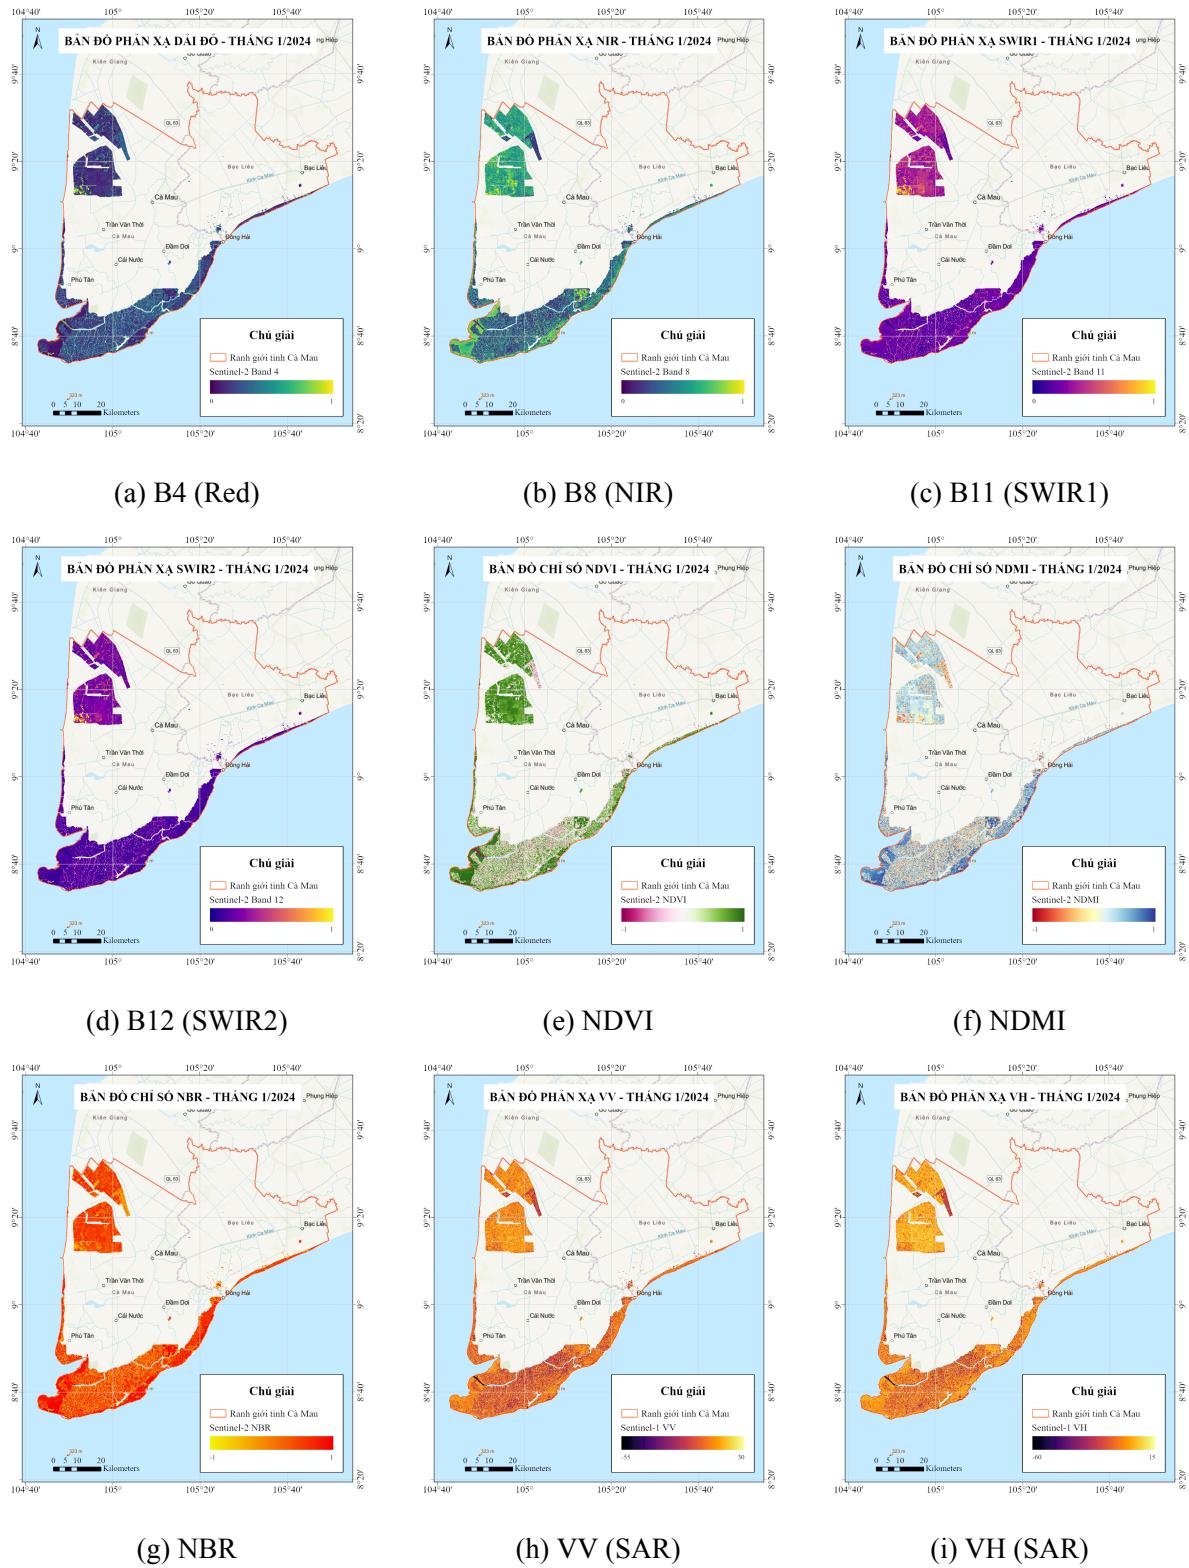
Về các chỉ số thực vật, nghiên cứu sử dụng ba chỉ số NDVI, NBR và NDMI dựa trên nguyên tắc mỗi chỉ số khai thác một khía cạnh khác nhau của trạng thái thực vật, tạo ra tập đặc trưng bổ sung cho nhau mà không gây dư thừa. NDVI được lựa chọn vì là chỉ số có tính ổn định cao trong đánh giá mật độ và sức khỏe thực vật [23, 46]. NBR được thiết kế đặc biệt cho phát hiện biến động rừng, với độ nhạy cao đối với sự thay đổi cấu trúc tán lá khi rừng bị chặt phá hoặc cháy [29]. NDMI cung cấp thông tin về hàm lượng nước trong tán lá, có khả năng phát hiện stress thực vật trước khi biểu hiện rõ ràng qua NDVI [14]. Các chỉ số khác như EVI (Enhanced Vegetation Index) yêu cầu kênh Blue vốn nhạy cảm với tán xạ khí quyển và ưu điểm chính của nó không vượt trội đáng kể so với NDVI trong bối cảnh rừng ngập mặn. SAVI (Soil Adjusted Vegetation Index) được thiết kế cho vùng có độ phủ thực vật thưa, trong khi rừng ngập mặn Cà Mau có độ che

phủ dày đặc khiến chỉ số này không phù hợp. GNDVI sử dụng kênh Green thay cho Red nhưng thông tin này đã được phản ánh qua NDVI. Như vậy, bộ ba chỉ số NDVI, NBR và NDMI tạo thành tổ hợp tối ưu về mặt thông tin, đảm bảo tính bổ sung mà không gây dư thừa đặc trưng cho mô hình học sâu.

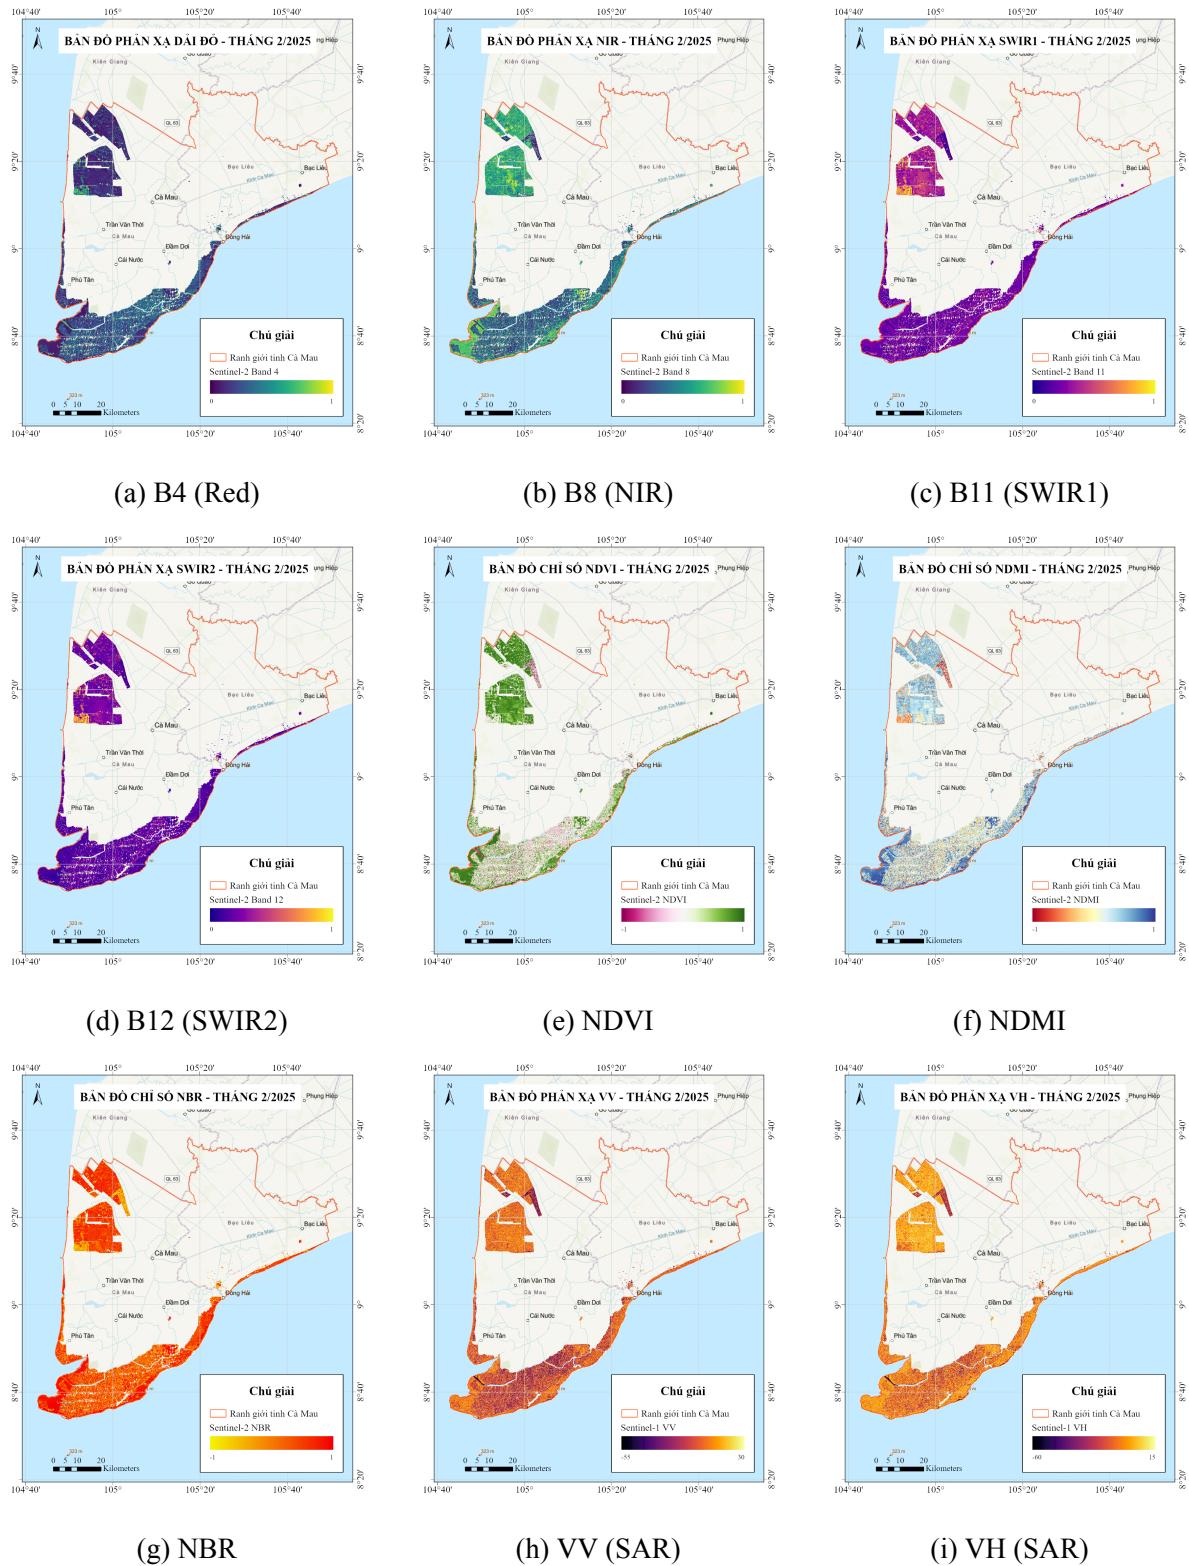
Dữ liệu Sentinel-1 được truy xuất từ bộ sưu tập *COPERNICUS/S1_GRD* — sản phẩm đã được tiền xử lý bởi ESA bao gồm: hiệu chỉnh quỹ đạo, loại bỏ nhiễu biên và nhiễu nhiệt, hiệu chỉnh bức xạ và hiệu chỉnh địa hình sử dụng DEM SRTM. Quy trình xử lý bổ sung bao gồm: lọc theo thời gian (± 7 ngày so với Sentinel-2), chọn chế độ Interferometric Wide (IW) với quỹ đạo đi xuống, và trích xuất hai kênh VV và VH (đơn vị dB).

Việc lựa chọn cặp phân cực VV và VH dựa trên cơ chế tán xạ sóng vi ba khi tương tác với thảm thực vật rừng. Phân cực VV (phát và thu sóng theo phương thẳng đứng) nhạy cảm với tán xạ bề mặt, phản ánh đặc tính của lớp đất hoặc mặt nước bên dưới tán rừng, đặc biệt hữu ích trong việc phát hiện thay đổi độ ẩm đất sau khi rừng bị chặt phá [51]. Trong khi đó, phân cực VH (phát sóng thẳng đứng, thu sóng ngang) phát sinh chủ yếu từ quá trình tán xạ thể tích trong cấu trúc tán lá và thân cây, do đó nhạy cảm đặc biệt với sự thay đổi sinh khối và mật độ tán rừng khi xảy ra chặt phá hoặc suy thoái [42]. Sự kết hợp hai phân cực này cung cấp thông tin bổ sung về cả lớp bề mặt và cấu trúc thể tích của rừng, cho phép phân biệt tốt hơn giữa các loại biến động. Các phân cực khác không được sử dụng vì chế độ IW của Sentinel-1 cho vùng đất liền nhiệt đới chỉ cung cấp cặp phân cực VV-VH theo cấu hình tiêu chuẩn của ESA [11], đồng thời cặp phân cực này đã được chứng minh hiệu quả trong nhiều nghiên cứu giám sát rừng nhiệt đới trước đó.

Sau khi xử lý, dữ liệu được xuất ra định dạng GeoTIFF với độ phân giải 10m và hệ quy chiếu EPSG:32648 (WGS 84 / UTM Zone 48N). Hình 2.1 và 2.2 minh họa trực quan các dữ liệu quang học (B4, B8, B11, B12), các chỉ số thực vật (NDVI, NDMI, NBR) và dữ liệu ra-đa (VV, VH) cho hai thời điểm trước và sau biến động.



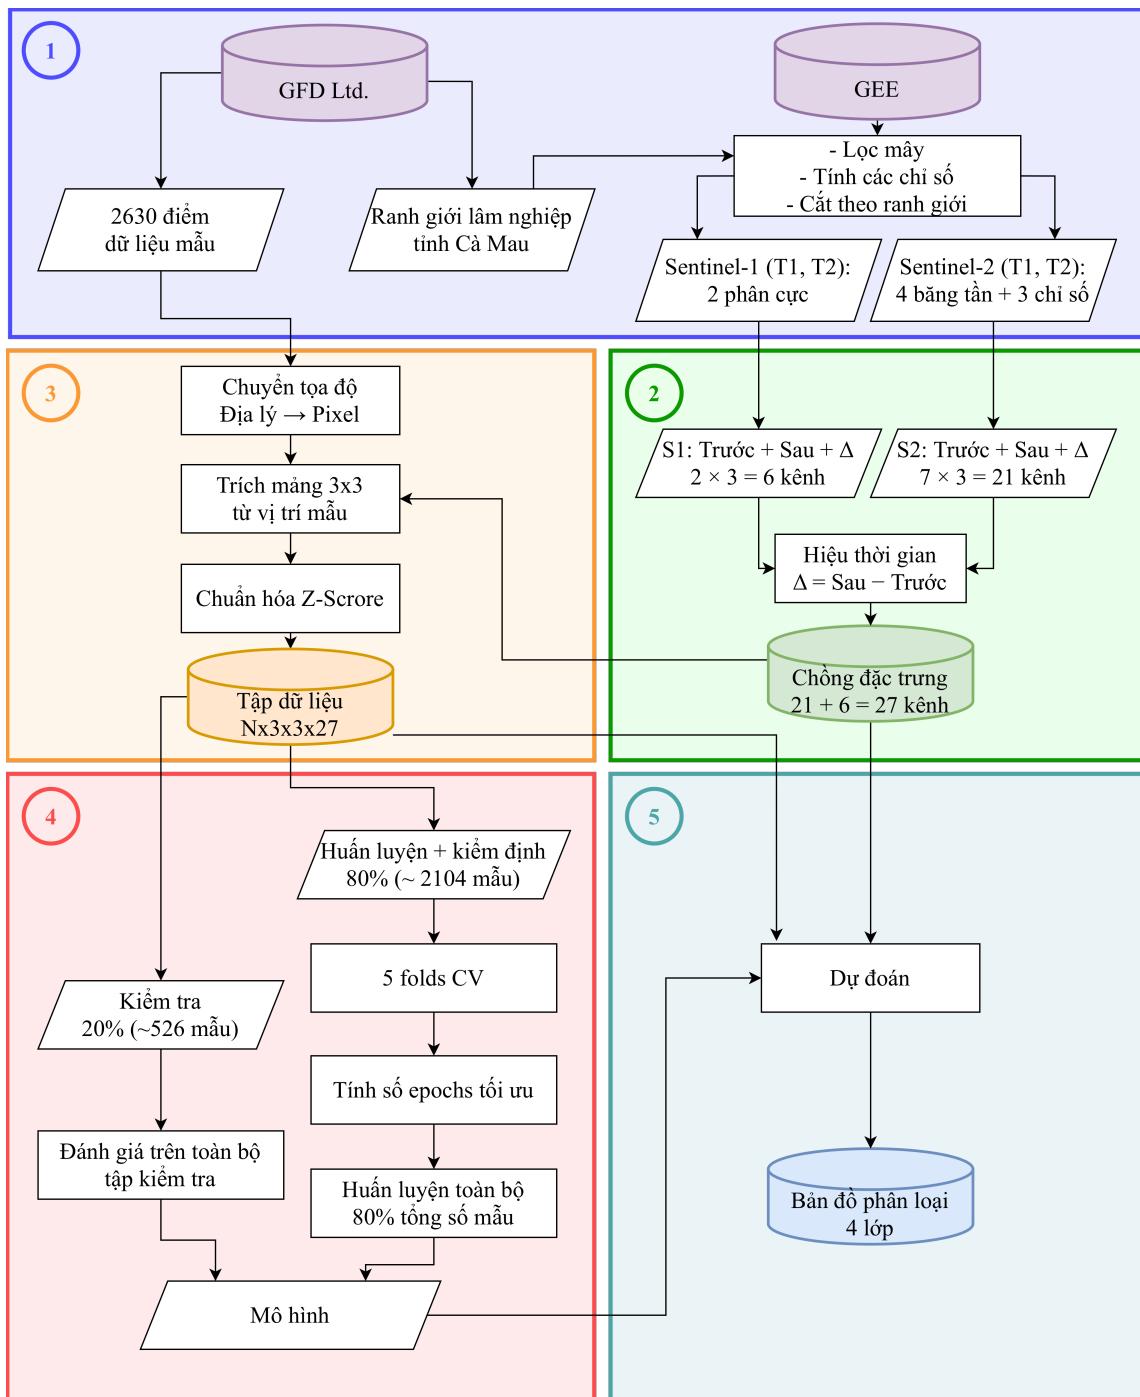
Hình 2.1: Các kênh quang học, chỉ số thực vật và dữ liệu ra-đa kỲ trước (T1 - 01/2024)



Hình 2.2: Các kênh phổ quang học, chỉ số thực vật và dữ liệu ra-đa kỲ sau (T2 - 02/2025)

2.2. Phương pháp nghiên cứu

Phần này trình bày phương pháp nghiên cứu và quy trình tổng quan được minh họa trong Hình 2.3. Quy trình bao gồm năm giai đoạn chính: (1) Thu thập và tiền xử lý dữ liệu, (2) Trích xuất đặc trưng, (3) Chuẩn bị mẫu huấn luyện, (4) Huấn luyện mô hình, và (5) Áp dụng mô hình.



Hình 2.3: Sơ đồ quy trình phương pháp nghiên cứu phát hiện biến động rừng

2.2.1. Thu thập và tiền xử lý dữ liệu

Giai đoạn đầu tiên trong quy trình là thu thập và tiền xử lý dữ liệu ảnh vệ tinh. Quá trình này được thực hiện trên nền tảng Google Earth Engine, bao gồm các bước: (1) truy xuất dữ liệu Sentinel-2 và Sentinel-1 cho khu vực nghiên cứu tại hai thời điểm (tháng 01/2024 và 02/2025), (2) lọc theo không gian và thời gian, (3) loại bỏ ảnh hưởng của mây sử dụng bộ sưu tập *S2_CLOUD_PROBABILITY*, (4) trích xuất các kênh phổ cần thiết và tính toán các chỉ số thực vật, và (5) xuất kết quả ra định dạng GeoTIFF với độ phân giải 10m. Chi tiết về tiêu chí lựa chọn ảnh, quy trình xử lý trên GEE, và cơ sở khoa học trong việc lựa chọn các kênh phổ và chỉ số thực vật đã được trình bày chi tiết trong Mục 2.1. (Phần Dữ liệu).

2.2.2. Trích xuất đặc trưng

Việc kết hợp dữ liệu ra-đa khẩu độ tổng hợp và quang học đã được chứng minh là hiệu quả trong nhiều nghiên cứu phân loại lớp phủ đất [22, 24]. Cách tiếp cận này tận dụng ưu điểm bổ sung của hai nguồn dữ liệu: ra-đa khẩu độ tổng hợp cung cấp thông tin về cấu trúc và độ ẩm bề mặt, trong khi quang học cung cấp thông tin về đặc tính quang phổ của thực vật.

Tổng cộng 27 đặc trưng được xây dựng từ hai nguồn dữ liệu. Sentinel-2 đóng góp 21 đặc trưng quang học, bao gồm 4 kênh phổ (B4 — đỏ, B8 — cận hồng ngoại, B11 và B12 — hồng ngoại sóng ngắn) và 3 chỉ số thực vật (NDVI, NBR, NDMI). Mỗi kênh phổ/chỉ số được tính cho cả hai thời kỳ (kỳ trước và kỳ sau) cùng với giá trị biến đổi delta ($\Delta = \text{kỳ sau} - \text{kỳ trước}$), tạo thành $7 \times 3 = 21$ đặc trưng. Sentinel-1 đóng góp 6 đặc trưng ra-đa từ hai kênh phân cực VV và VH, cũng được tính cho cả hai thời kỳ và giá trị delta ($2 \times 3 = 6$ đặc trưng).

Với mỗi điểm thực địa, một patch kích thước 3×3 điểm ảnh được trích xuất từ stack đặc trưng. Kích thước 3×3 được lựa chọn dựa trên ba tiêu chí: (1) cho phép mô hình học được thông tin ngữ cảnh không gian xung quanh điểm ảnh trung tâm; (2) phù hợp với độ phân giải 10m của Sentinel, mỗi patch tương đương vùng $30m \times 30m$ — kích thước hợp lý cho các lô rừng ngập mặn; và (3) giảm thiểu nhiễu từ các điểm ảnh lân cận không đồng nhất. Kết quả thử nghiệm so sánh các kích thước patch khác nhau (xem Bảng 3.3) xác nhận rằng patch 3×3 cho độ chính xác cao nhất (98.86%) với số lượng tham số ít nhất.

Kết quả là mỗi mẫu có kích thước $(3, 3, 27)$ — tương ứng với kích thước điểm ảnh và số kênh đặc trưng.

2.2.3. Chuẩn bị mẫu huấn luyện

Việc chuẩn hóa dữ liệu là bước quan trọng để đảm bảo các đặc trưng có cùng phạm vi giá trị, giúp quá trình huấn luyện mô hình hội tụ nhanh và ổn định hơn. Nghiên cứu này áp dụng phương pháp chuẩn hóa Z-score:

$$x_{normalized} = \frac{x - \mu}{\sigma} \quad (2.1)$$

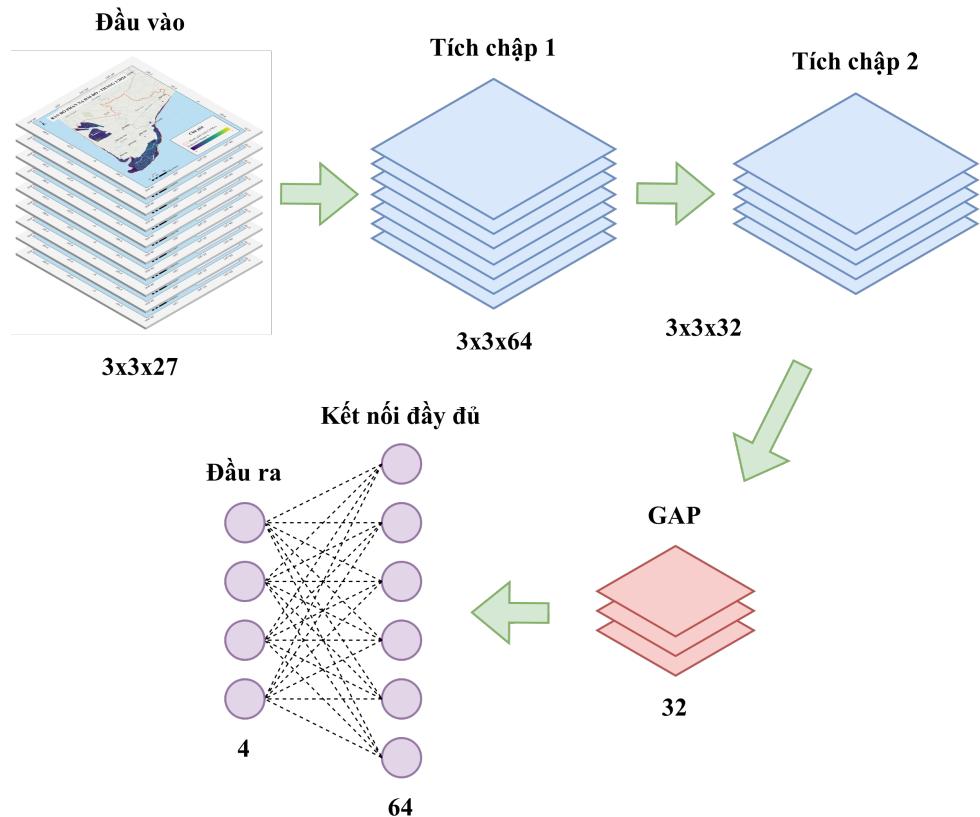
trong đó x là giá trị gốc, μ là giá trị trung bình và σ là độ lệch chuẩn.

Để tránh rò rỉ dữ liệu, các tham số chuẩn hóa (μ và σ) được tính toán chỉ trên tập huấn luyện, sau đó áp dụng cho cả tập kiểm định và tập kiểm tra. Các tham số này cũng được lưu lại để sử dụng khi dự đoán trên dữ liệu mới.

Chiến lược chia dữ liệu được thiết kế theo khuyến nghị của Roberts et al. [44] về kiểm định chéo cho dữ liệu không gian. Ban đầu tách 20% dữ liệu làm tập kiểm tra cố định (526 mẫu) — tập này không được sử dụng trong quá trình huấn luyện hay tinh chỉnh siêu tham số. Sau đó áp dụng kiểm định chéo 5 phần trên 80% còn lại (2,104 mẫu) để đánh giá độ ổn định của mô hình và tìm kiếm siêu tham số tối ưu. Tiếp theo sau khi xác định siêu tham số tối ưu, huấn luyện mô hình cuối cùng trên toàn bộ 80% dữ liệu để tận dụng tối đa dữ liệu huấn luyện. Cuối cùng đánh giá mô hình cuối cùng trên 20% tập kiểm tra để báo cáo kết quả. Cách phân chia dữ liệu này đảm bảo tỷ lệ các lớp (Rừng ổn định, Mất rừng, Phi rừng, Phục hồi rừng) được duy trì đồng đều trong cả tập huấn luyện và kiểm tra.

2.2.4. Kiến trúc mô hình CNN

Nghiên cứu này sử dụng một kiến trúc mạng nơ-ron tích chập được thiết kế phù hợp với quy mô bộ dữ liệu 2,630 mẫu. Kiến trúc tổng quan của mô hình được minh họa trong Hình 2.4.



Hình 2.4: Kiến trúc mô hình mạng nơ-ron tích chậpF được sử dụng trong nghiên cứu

Kiến trúc mô hình được xây dựng dựa trên các kỹ thuật đã được chứng minh hiệu quả trong lĩnh vực học sâu, đồng thời tùy chỉnh các siêu tham số để phù hợp với đặc thù bài toán và quy mô dữ liệu. Về các thành phần chuẩn, nghiên cứu sử dụng bộ lọc tích chập kích thước 3×3 — kích thước được Simonyan và Zisserman [47] chứng minh là hiệu quả nhất trong kiến trúc VGGNet, cho phép tăng chiều sâu mạng với ít tham số hơn so với bộ lọc lớn. Chuẩn hóa theo lô [25] được áp dụng sau mỗi lớp tích chập để ổn định quá trình huấn luyện. Hàm kích hoạt ReLU được sử dụng do tính đơn giản và khả năng giảm thiểu ván đè triệt tiêu gradient [17]. GAP được đề xuất bởi Lin và cộng sự [36] thay thế cho các lớp kết nối đầy đủ truyền thống, giúp giảm đáng kể số lượng tham số. Kỹ thuật Dropout [49] được sử dụng để ngăn ngừa hiện tượng quá khớp.

Về các siêu tham số được tùy chỉnh, nghiên cứu lựa chọn số lượng bộ lọc giảm dần từ 64 xuống 32 qua các lớp tích chập, thay vì tăng dần như các kiến trúc CNN truyền thống (VGGNet, ResNet). Lựa chọn này nhằm giữ mô hình nhẹ và tránh quá khớp với bộ dữ liệu 2,630 mẫu. Tỷ lệ Dropout được thiết lập ở mức 70% — cao hơn mức thông thường (20–50%) — để tăng cường khả năng điều chỉnh cho mô hình khi huấn luyện

với dữ liệu hạn chế. Kiến trúc chỉ sử dụng hai lớp tích chập, đủ để trích xuất đặc trưng từ patch 3×3 mà không gây ra hiện tượng quá khớp.

Dữ liệu đầu vào là các patch kích thước 3×3 điểm ảnh với 27 kênh đặc trưng, được biểu diễn dưới dạng tensor — cấu trúc dữ liệu mảng đa chiều dùng để lưu trữ và xử lý dữ liệu trong học sâu — có kích thước $(N, 27, 3, 3)$ với N là số lượng mẫu trong mỗi batch. Quy ước này tuân theo định dạng chuẩn của PyTorch (batch, channels, height, width), trong đó 27 là số kênh đặc trưng, và 3×3 là kích thước không gian của patch. Luồng xử lý của mô hình được mô tả như sau.

Đầu tiên, dữ liệu đi qua khối tích chập thứ nhất sử dụng 64 bộ lọc kích thước 3×3 . Mỗi bộ lọc kết hợp thông tin từ tất cả 27 kênh đặc trưng để tạo ra một bản đồ đặc trưng mới, giúp mô hình học được mối quan hệ giữa các kênh phổ, chỉ số thực vật và dữ liệu ra-đa. Sau lớp tích chập là lớp chuẩn hóa theo lô [25] giúp ổn định quá trình huấn luyện, hàm kích hoạt ReLU đưa tính phi tuyến vào mô hình, và lớp Dropout2D với tỷ lệ 70% để ngăn ngừa quá khớp — Dropout2D tắt ngẫu nhiên toàn bộ bản đồ đặc trưng thay vì từng nơ-ron riêng lẻ, phù hợp với CNN do tương quan không gian cao giữa các điểm ảnh lân cận. Đầu ra có kích thước $(N, 64, 3, 3)$.

Tiếp theo, khối tích chập thứ hai sử dụng 32 bộ lọc để nén thông tin từ 64 kênh xuống 32 kênh, với cấu trúc tương tự khối thứ nhất. Việc giảm số kênh buộc mô hình phải học cách biểu diễn thông tin cô đọng hơn. Đầu ra có kích thước $(N, 32, 3, 3)$.

Sau đó, GAP tính giá trị trung bình của mỗi kênh đặc trưng trên toàn bộ vùng không gian 3×3 , chuyển đổi bản đồ đặc trưng thành vector 32 chiều. Kỹ thuật này giúp giảm số lượng tham số và tăng khả năng tổng quát hóa của mô hình.

Cuối cùng, hai lớp kết nối đầy đủ thực hiện phân loại. Lớp thứ nhất mở rộng từ 32 lên 64 chiều kèm theo chuẩn hóa theo lô, ReLU và Dropout. Lớp thứ hai (lớp đầu ra) ánh xạ từ 64 chiều xuống 4 chiều, tương ứng với 4 lớp phân loại: Rừng ổn định, Mất rừng, Phi rừng và Phục hồi rừng.

Mô hình sử dụng phương pháp khởi tạo trọng số Kaiming/He [19] cho các lớp tích chập và Xavier cho các lớp kết nối đầy đủ, đảm bảo quá trình huấn luyện ổn định ngay từ đầu. Tổng cộng mô hình có 36,676 tham số có thể huấn luyện, phù hợp với bộ dữ liệu nhỏ khi kết hợp với các kỹ thuật điều chuẩn. Bảng 2.2 trình bày chi tiết số lượng tham số của từng thành phần.

Bảng 2.2: Chi tiết số tham số huấn luyện của mô hình CNN

Thành phần	Số tham số	Công thức tính
Khối tích chập 1 (Conv + BN)	15,680	$27 \times 3 \times 3 \times 64 + 128$
Khối tích chập 2 (Conv + BN)	18,496	$64 \times 3 \times 3 \times 32 + 64$
Lớp kết nối đầy đủ 1 (FC + BN)	2,240	$32 \times 64 + 64 + 128$
Lớp đầu ra	260	$64 \times 4 + 4$
Tổng cộng	36,676	

Trong công thức tính tham số, số hạng đầu tiên biểu diễn tham số của lớp tích chập hoặc kết nối đầy đủ (kênh đầu vào \times kích thước bộ lọc \times kênh đầu ra, cộng với bias), trong khi số hạng thứ hai biểu diễn tham số của chuẩn hóa theo lô (mỗi kênh có 2 tham số: hệ số co giãn γ và hệ số dịch chuyển β). Ví dụ, khối tích chập 1 có $27 \times 3 \times 3 \times 64 = 15,552$ tham số cho lớp Conv2D và $64 \times 2 = 128$ tham số cho BatchNorm2D.

2.2.5. Huấn luyện mô hình

Với bộ dữ liệu gồm 2,630 mẫu và mô hình có 36,676 tham số, tỷ lệ mẫu trên tham số là 72:1 — tỷ lệ này thấp hơn ngưỡng khuyến nghị thông thường (100:1 đến 1000:1) cho mô hình học sâu [17], do đó tăng nguy cơ quá khóp. Để ngăn chặn hiện tượng quá khóp — khi mô hình ghi nhớ dữ liệu huấn luyện thay vì học các quy luật tổng quát — nghiên cứu áp dụng ba kỹ thuật điều chuẩn: chuẩn hóa theo lô [25] sau mỗi lớp mạng, Dropout với tỷ lệ 70% [49], và phân rã trọng số với hệ số 10^{-3} . Bảng 2.3 trình bày các siêu tham số huấn luyện.

Bảng 2.3: Cấu hình siêu tham số huấn luyện

Tham số	Giá trị	Mô tả
epochs	200	Số vòng lặp tối đa
batch_size	64	Số mẫu mỗi lô
learning_rate	0.001	Tốc độ học khởi tạo
weight_decay	10^{-3}	Hệ số phân rã trọng số
dropout_rate	0.7	Tỷ lệ Dropout
early_stopping	15 epochs	Patience dừng sớm

Nghiên cứu sử dụng thuật toán tối ưu AdamW [37] kết hợp với ReduceLROnPlateau để tự động giảm tốc độ học khi validation loss không cải thiện. Ngoài ra, cơ chế dừng sớm (early stopping) được áp dụng nhằm ngăn ngừa hiện tượng quá khớp. Dừng sớm là kỹ thuật theo dõi hiệu suất của mô hình trên tập kiểm định trong quá trình huấn luyện; nếu giá trị loss kiểm định không cải thiện sau một số epoch liên tiếp (gọi là patience), quá trình huấn luyện sẽ tự động dừng lại. Trong nghiên cứu này, patience được thiết lập là 15 epochs, đồng thời mô hình có giá trị loss kiểm định thấp nhất sẽ được lưu lại làm phiên bản cuối cùng.

Quy trình huấn luyện gồm bốn giai đoạn. Giai đoạn thứ nhất, khởi tạo trọng số theo phương pháp Kaiming/He [19]. Giai đoạn thứ hai, thực hiện kiểm định chéo 5 phần (5-Fold Cross Validation) trên 80% dữ liệu (2,104 mẫu) để đánh giá độ ổn định của mô hình; trong đó dữ liệu được chia thành 5 phần bằng nhau, mô hình được huấn luyện 5 lần với mỗi lần sử dụng 4 phần làm tập huấn luyện và 1 phần làm tập kiểm định. Giai đoạn thứ ba, huấn luyện mô hình cuối cùng trên toàn bộ 80% dữ liệu. Giai đoạn thứ tư, đánh giá mô hình trên 20% tập kiểm tra cố định (526 mẫu) — tập dữ liệu không được sử dụng trong quá trình huấn luyện.

2.2.6. Áp dụng mô hình

Sau khi huấn luyện, mô hình được áp dụng để phân loại toàn bộ vùng nghiên cứu với khoảng 16.2 triệu điểm ảnh hợp lệ, tương đương diện tích 162,468 ha. Quy trình dự đoán được thực hiện như sau.

Đầu tiên, dữ liệu đặc trưng gồm 27 kênh được tải vào bộ nhớ. Với mỗi điểm ảnh cần phân loại, một vùng lân cận kích thước 3×3 được trích xuất, chứa thông tin của điểm ảnh trung tâm và 8 điểm ảnh xung quanh. Đối với các điểm ảnh ở biên, kỹ thuật phản chiếu (mirror padding) được sử dụng để tạo đủ ngữ cảnh 3×3 — kỹ thuật này sao chép các điểm ảnh gần biên theo cách đối xứng để mở rộng vùng dữ liệu, ví dụ chuỗi $[a, b, c]$ ở biên trái được mở rộng thành $[b, a, b, c]$. Mỗi patch sau đó được chuẩn hóa Z-score sử dụng các tham số (mean, std) đã tính từ tập huấn luyện.

Dữ liệu đã chuẩn hóa được đưa qua mô hình CNN để tính xác suất thuộc về mỗi lớp. Mô hình xuất ra vector 4 chiều cho mỗi điểm ảnh, tương ứng với xác suất thuộc về 4 lớp: Rừng ổn định, Mát rừng, Phi rừng, và Phục hồi rừng. Lớp có xác suất cao nhất được chọn làm kết quả phân loại thông qua hàm argmax — hàm trả về chỉ số của phần

tử có giá trị lớn nhất trong vector xác suất.

Do khối lượng dữ liệu lớn, việc dự đoán được thực hiện theo lô, mỗi lô gồm 10,000 điểm ảnh. Kỹ thuật độ chính xác hỗn hợp (mixed precision) với định dạng FP16 được sử dụng để giảm mức sử dụng bộ nhớ GPU và tăng tốc độ tính toán — FP16 (floating-point 16-bit) sử dụng 16 bit thay vì 32 bit (FP32) để biểu diễn số thực, giảm một nửa dung lượng bộ nhớ và tăng tốc tính toán trên GPU hiện đại mà vẫn duy trì độ chính xác đủ cho suy luận. Kết quả phân loại được xuất ra dưới dạng file GeoTIFF với hệ quy chiếu EPSG:32648 (WGS 84/UTM Zone 48N) và độ phân giải 10m, cho phép tích hợp trực tiếp với các phần mềm GIS.

CHƯƠNG 3. KẾT QUẢ THỰC NGHIỆM ỨNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG GIÁM SÁT BIẾN ĐỘNG RỪNG TỈNH CÀ MAU

3.1. Thiết lập thực nghiệm

3.1.1. Khu vực nghiên cứu

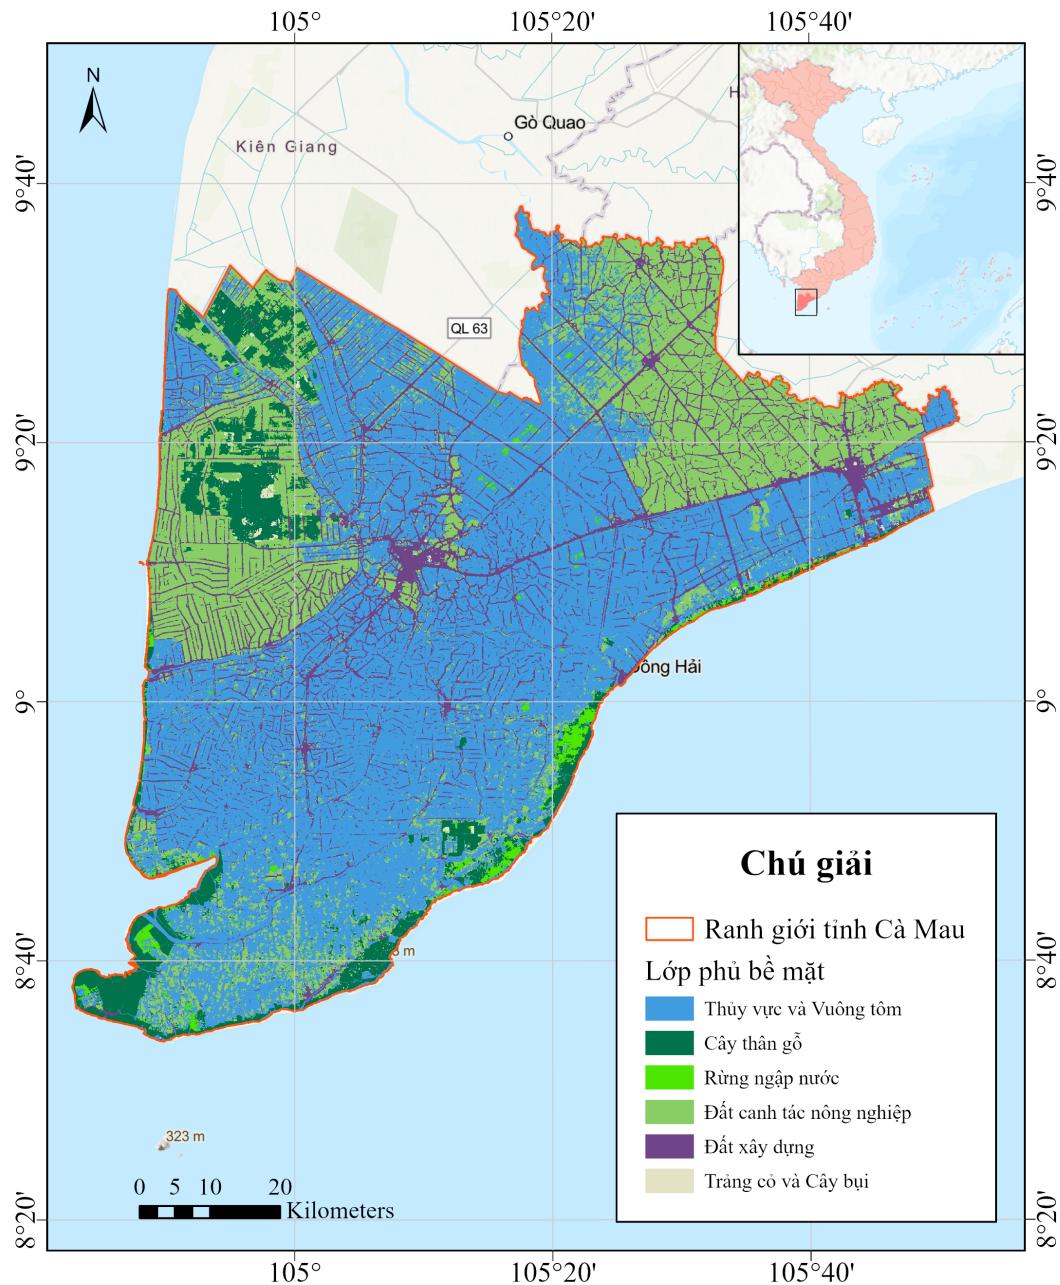
Theo Nghị quyết số 1278/NQ-UBTVQH15 ngày 24/10/2024 của Ủy ban Thường vụ Quốc hội, kể từ ngày 01/07/2025, tỉnh Cà Mau và tỉnh Bạc Liêu được sáp nhập thành tỉnh Cà Mau mới với tổng diện tích tự nhiên 7.942,38 km² và dân số khoảng 2,6 triệu người. Đô án này nghiên cứu trên phạm vi rừng của tỉnh Cà Mau mới, bao gồm cả vùng rừng thuộc địa bàn Bạc Liêu cũ.

Tỉnh Cà Mau mới nằm ở cực Nam Tổ Quốc, sở hữu hệ sinh thái rừng đa dạng bao gồm cả rừng ngập mặn ven biển và rừng tràm nội địa. Theo số liệu trước khi sáp nhập, tỉnh Cà Mau cũ có diện tích rừng khoảng 94.319 ha và tỉnh Bạc Liêu có khoảng 5.730 ha rừng, tổng cộng khoảng 100.000 ha rừng trên toàn tỉnh Cà Mau mới [4]. Trong đó, rừng ngập mặn Cà Mau chiếm khoảng 20% diện tích rừng ngập mặn của Việt Nam. Hệ thống rừng tại Cà Mau đóng vai trò then chốt trong việc phòng hộ ven biển (chắn sóng, chống xâm thực và bảo vệ bờ biển), bảo tồn đa dạng sinh học vì là môi trường sống cho nhiều loài động thực vật quý hiếm, cung cấp nguồn sinh kế thông qua các hoạt động thủy sản và du lịch sinh thái, và góp phần giảm nhẹ biến đổi khí hậu nhờ khả năng lưu giữ carbon cao, gấp khoảng 3–5 lần so với rừng nhiệt đới trên cạn [6, 10].

Tuy nhiên, rừng Cà Mau đang phải đối mặt với nhiều thách thức. Trước hết là áp lực chuyển đổi sang nuôi tôm do kinh tế, khiến nhiều khu vực rừng bị chuyển đổi thành ao nuôi. Ngoài ra, hiện tượng xâm nhập mặn gia tăng do biến đổi khí hậu làm giảm sức khỏe rừng; đồng thời xói mòn bờ biển cũng làm suy giảm diện tích rừng ven biển; và tình trạng thiếu nước ngọt ảnh hưởng tới khả năng tái sinh tự nhiên của rừng. Giai đoạn 2011–2023, sạt lở vùng ven biển đã làm mất hơn 6.200 ha đất và rừng phòng hộ [3].

Để hiểu rõ bối cảnh không gian và đa dạng lớp phủ bề mặt tại khu vực nghiên cứu, Hình 3.1 trình bày bản đồ phân loại lớp phủ/sử dụng đất (LULC) tỉnh Cà Mau. Phân loại LULC cung cấp thông tin nền tảng về các loại hình sử dụng đất khác nhau trên địa bàn, từ đó giúp xác định ranh giới giữa vùng rừng và phi rừng, cũng như các vùng có nguy cơ chuyển đổi cao [16]. Bản đồ này được xây dựng từ dữ liệu viễn thám từ Esri phản ánh hiện trạng sử dụng đất phức tạp tại tỉnh Cà Mau, nơi mà sự tương tác giữa các hệ

sinh thái tự nhiên (rừng ngập mặn, đất ngập nước) và các hoạt động kinh tế-xã hội (nuôi trồng thủy sản, nông nghiệp) diễn ra liên tục [43].



Hình 3.1: Bản đồ lớp phủ bè mặt khu vực tỉnh Cà Mau.

Phân tích bản đồ cho thấy sự phân bố không đồng nhất của các loại hình lớp phủ, với rừng ngập mặn tập trung chủ yếu dọc bờ biển phía Tây và Nam, trong khi các vùng nuôi trồng thủy sản và nông nghiệp lúa nước chiếm ưu thế ở khu vực trung tâm và phía

Đông. Mô hình phân bố này phản ánh lịch sử khai thác và quản lý tài nguyên tại Cà Mau, đồng thời làm nổi bật sự cần thiết phải có công cụ giám sát biến động rừng hiệu quả để hỗ trợ các quyết định quản lý bền vững [32].

Đồ án tập trung vào toàn bộ vùng quy hoạch lâm nghiệp của tỉnh Cà Mau mới. Dữ liệu ranh giới quy hoạch lâm nghiệp được cung cấp bởi Công ty TNHH Tư vấn và Phát triển Đồng Xanh — đối tác của Chi cục Kiểm lâm tỉnh Cà Mau.

Tổng diện tích ranh giới quy hoạch là 170.178,82 ha (tương đương 1.701,79 km²), bao gồm 666 polygon trong file shapefile ranh giới. Diện tích thực tế được phân loại là 162.468,50 ha (khoảng 95,5% diện tích ranh giới); phần còn lại (7.710 ha, chiếm 4,5%) bị loại do mây che phủ hoặc dữ liệu không hợp lệ (nodata) trong quá trình xử lý ảnh vệ tinh. Kích thước raster là 12.547×10.917 điểm ảnh (ở độ phân giải 10m), sử dụng hệ quy chiếu EPSG:32648 (WGS 84 / UTM Zone 48N).

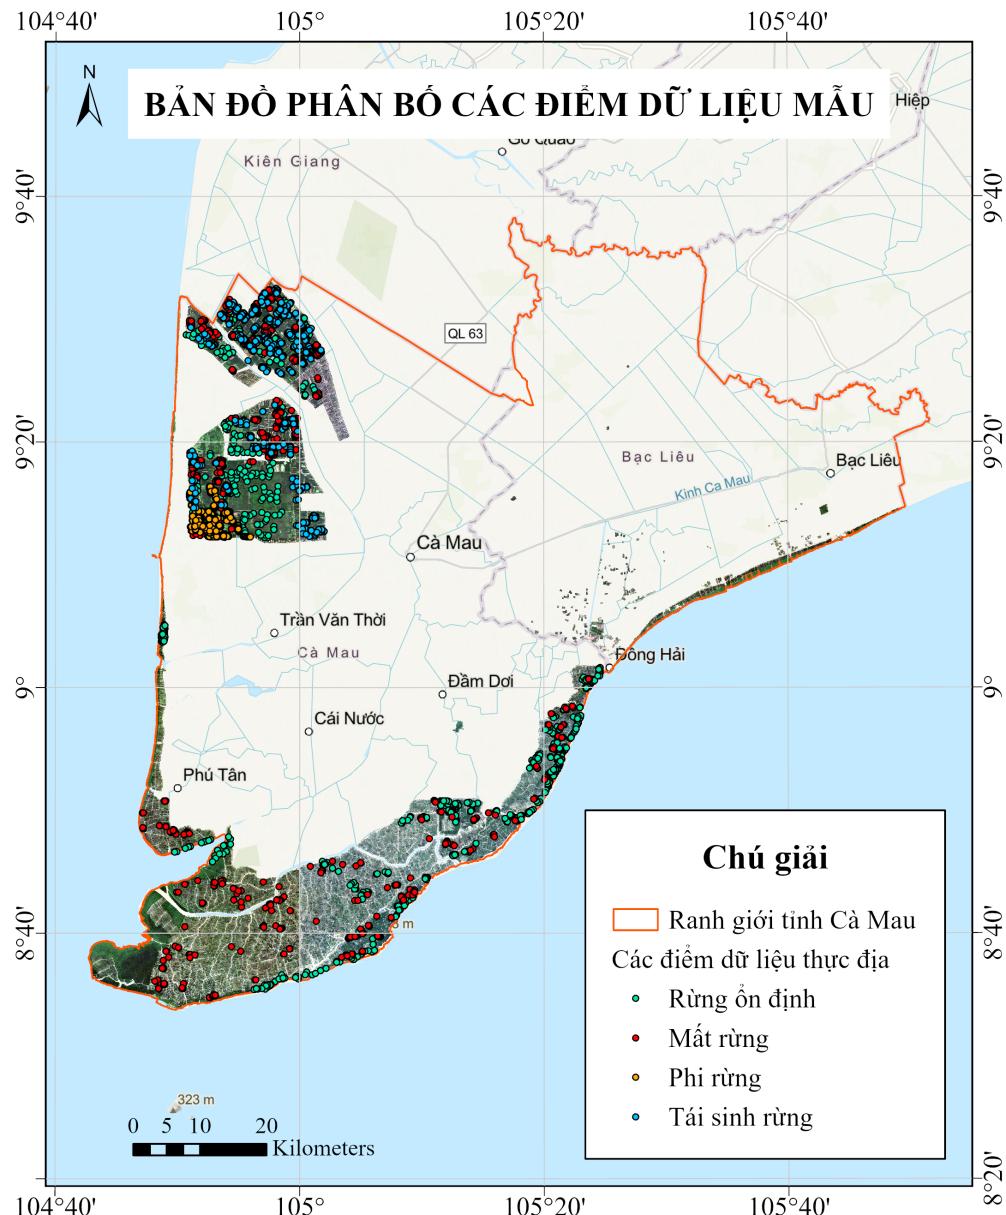
3.1.2. Dữ liệu thực địa tại Cà Mau

Dữ liệu thực địa được Công ty TNHH Tư vấn và Phát triển Đồng Xanh (GFD) thu thập trong khuôn khổ thực hiện đề tài “Ứng dụng công nghệ viễn thám, ảnh vệ tinh để quản lý, giám sát tài nguyên rừng và sạt lở ven biển trên địa bàn tỉnh Cà Mau” [2] và được cung cấp cho nghiên cứu này. Quy trình thu thập gồm ba giai đoạn. Giai đoạn đầu tiên là khảo sát thực địa bằng thiết bị bay không người lái (drone) để ghi nhận hình ảnh và xác định trạng thái rừng. Giai đoạn thứ hai là số hóa các điểm dữ liệu thực địa trên phần mềm QGIS, đổi chiều với ảnh vệ tinh Sentinel-2. Giai đoạn cuối cùng là kiểm tra chéo và loại bỏ các điểm không rõ ràng hoặc nằm trong vùng mây che phủ. Dữ liệu cuối cùng được xuất dưới dạng file CSV với cấu trúc gồm 4 trường: *id*, *label*, *x* và *y* (tọa độ theo hệ quy chiếu EPSG:32648).

Bảng 3.1: Thống kê dữ liệu thực địa theo lớp biến động

Lớp	Tên	Số điểm	Tỷ lệ	Mô tả
0	Rừng ổn định	656	24,9%	Có rừng ở cả 2 kỳ
1	Mất rừng	650	24,7%	Có rừng → không có rừng
2	Phi rừng	664	25,3%	Không có rừng ở cả 2 kỳ
3	Phục hồi rừng	660	25,1%	Không có → có rừng
Tổng		2.630	100%	Phân bố cân bằng

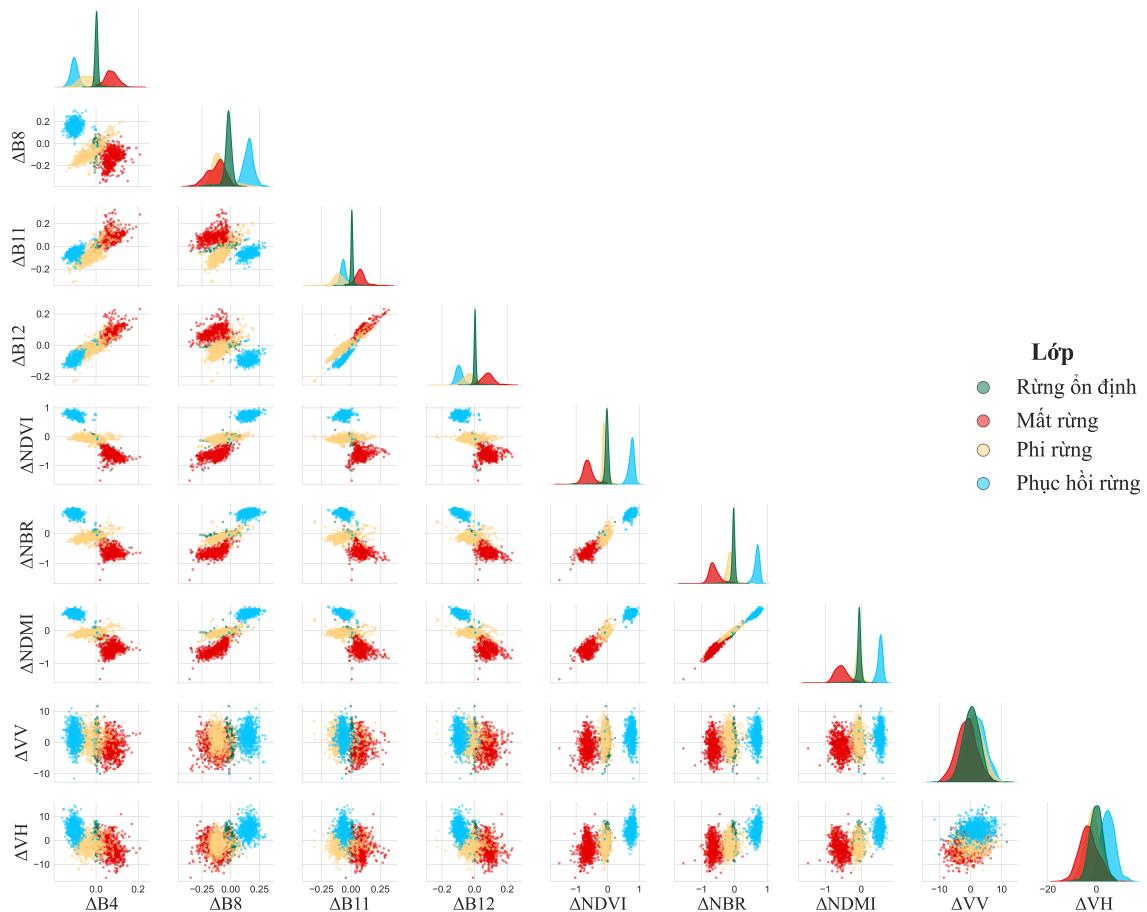
Phân bố không gian của các điểm dữ liệu thực địa được minh họa trong Hình 3.2. Các điểm mẫu được thu thập phân tán trên toàn bộ khu vực nghiên cứu, đảm bảo tính đại diện về mặt không gian cho các loại hình biến động rừng khác nhau.



Hình 3.2: Bản đồ phân bố không gian các điểm dữ liệu thực địa trên khu vực nghiên cứu tỉnh Cà Mau

Mỗi điểm ảnh trong bộ dữ liệu được biểu diễn bởi 27 đặc trưng: 9 đặc trưng tại thời điểm T_1 , 9 đặc trưng tại thời điểm T_2 , và 9 đặc trưng delta ($\Delta = T_2 - T_1$). Mô hình CNN sử dụng toàn bộ 27 đặc trưng này làm đầu vào để tận dụng tối đa thông tin từ cả hai thời

điểm quan sát. Tuy nhiên, để phân tích trực quan khả năng phân biệt của dữ liệu, nghiên cứu lựa chọn minh họa 9 đặc trưng delta thông qua (Hình 3.3). Việc lựa chọn này xuất phát từ hai lý do chính. Thứ nhất, biểu đồ Phân bố với 27 đặc trưng sẽ tạo ra ma trận $27 \times 27 = 729$ ô, quá lớn để quan sát và phân tích hiệu quả. Thứ hai, đặc trưng delta trực tiếp biểu diễn sự thay đổi giữa hai thời điểm, do đó phù hợp nhất để đánh giá khả năng phân tách các lớp biến động rừng.



Hình 3.3: Phân bố các đặc trưng delta theo lớp biến động rừng

Biểu đồ trình bày mối quan hệ giữa 9 đặc trưng delta bao gồm các band quang phổ Sentinel-2 ($\Delta B4$, $\Delta B8$, $\Delta B11$, $\Delta B12$), các chỉ số thực vật ($\Delta NDVI$, ΔNBR , $\Delta NDMI$) và các kênh ra-đa Sentinel-1 (ΔVV , ΔVH). Trên đường chéo chính, biểu đồ thể hiện phân bố của từng đặc trưng theo bốn lớp biến động; các ô còn lại hiển thị biểu đồ tán xạ giữa các cặp đặc trưng.

Phân tích phân bố trên đường chéo cho thấy các chỉ số thực vật delta thể hiện khả năng phân biệt vượt trội giữa các lớp biến động. Cụ thể, lớp Rừng ổn định và Phi rừng

có phân bố tập trung quanh giá trị 0, phản ánh sự ổn định về lớp phủ thực vật qua hai thời điểm quan sát. Ngược lại, lớp Mát rừng thể hiện phân bố lệch về phía âm do sự suy giảm các chỉ số thực vật khi rừng bị chuyển đổi, trong khi lớp Phục hồi rừng có phân bố lệch về phía dương tương ứng với sự gia tăng sinh khối thực vật. Sự phân tách rõ ràng này khẳng định vai trò then chốt của Δ NDVI, Δ NBR và Δ NDMI trong việc nhận diện biến động rừng.

Đối với các band quang phổ gốc, mức độ chồng chéo giữa các lớp cao hơn so với các chỉ số thực vật, tuy nhiên Δ B8 (kênh cận hồng ngoại) vẫn cho thấy khả năng phân biệt tương đối tốt giữa lớp Mát rừng và Phục hồi rừng. Các đặc trưng ra-đa Δ VV và Δ VH có phân bố chồng chéo đáng kể giữa bốn lớp, cho thấy khả năng phân biệt độc lập hạn chế hơn so với dữ liệu quang học. Tuy nhiên, việc tích hợp dữ liệu ra-đa vẫn mang lại giá trị bổ sung, đặc biệt trong điều kiện mây che phủ thường xuyên tại khu vực nghiên cứu.

Phân tích các biểu đồ tán xạ cho thấy mối tương quan dương mạnh giữa ba chỉ số thực vật (Δ NDVI, Δ NBR, Δ NDMI), thể hiện qua sự phân bố các điểm dữ liệu gần đường chéo. Tương tự, Δ B11 và Δ B12 có tương quan cao do cùng thuộc dải sóng ngắn hồng ngoại (SWIR). Trên không gian đặc trưng hai chiều của các chỉ số thực vật, lớp Mát rừng và Phục hồi rừng phân bố ở hai vùng đối lập nhau, trong khi lớp Rừng ổn định và Phi rừng tập trung quanh gốc tọa độ. Đặc điểm phân bố này tạo điều kiện thuận lợi cho mô hình CNN trong việc học các ranh giới quyết định phân tách bốn lớp biến động.

3.1.3. Cấu hình phần cứng và phần mềm

Môi trường thí nghiệm sử dụng phần cứng với CPU Intel Xeon E-2334 (4 nhân, 8 luồng), GPU NVIDIA GeForce RTX 4080 (16GB VRAM), bộ nhớ RAM 64GB và bộ nhớ lưu trữ 1TB SSD. Về phần mềm, hệ điều hành được sử dụng là Windows 10 Pro, môi trường Python 3.11 cùng PyTorch 2.5 có hỗ trợ CUDA 12.1 để huấn luyện mô hình, rasterio 1.4 (GDAL 3.6) cho xử lý dữ liệu không gian và các thư viện khoa học dữ liệu như NumPy, scikit-learn và pandas.

PyTorch được lựa chọn làm framework học sâu chính cho nghiên cứu này vì một số lý do. Thứ nhất, PyTorch sử dụng cơ chế đồ thị tính toán động (dynamic computational graph), cho phép xây dựng và sửa đổi kiến trúc mô hình một cách linh hoạt trong quá trình thử nghiệm. Thứ hai, cú pháp của PyTorch gần gũi với Python thuận túy, giúp việc

triển khai và gỡ lỗi mô hình trở nên trực quan hơn. Thứ ba, PyTorch được hỗ trợ bởi cộng đồng nghiên cứu rộng lớn với nhiều mô hình tiền huấn luyện và thư viện mở rộng như torchvision, torchaudio. Cuối cùng, khả năng tích hợp tốt với CUDA cho phép tận dụng hiệu quả GPU trong quá trình huấn luyện và suy luận.

3.1.4. Phân chia dữ liệu

Bộ dữ liệu thực địa gồm 2.630 điểm, trong đó phân bố lớp gần như cân bằng: Lớp 0 (Rừng ổn định) 656 điểm (24,94%), Lớp 1 (Mất rừng) 650 điểm (24,71%), Lớp 2 (Phi rừng) 664 điểm (25,25%) và Lớp 3 (Phục hồi rừng) 660 điểm (25,10%).

Bảng 3.2: Phân bố dữ liệu theo tập huấn luyện và kiểm tra

Tập dữ liệu	Số mẫu	Tỷ lệ
Huấn luyện + Kiểm định (5-Fold CV)	2.104	80%
Kiểm tra (cố định)	526	20%
Tổng	2.630	100%

Việc chia tập dữ liệu được thực hiện như sau: 80% dữ liệu (2.104 patches) được dành cho Train+Val để thực hiện 5-Fold Cross Validation, còn 20% dữ liệu (526 patches) được giữ lại làm fixed test set.

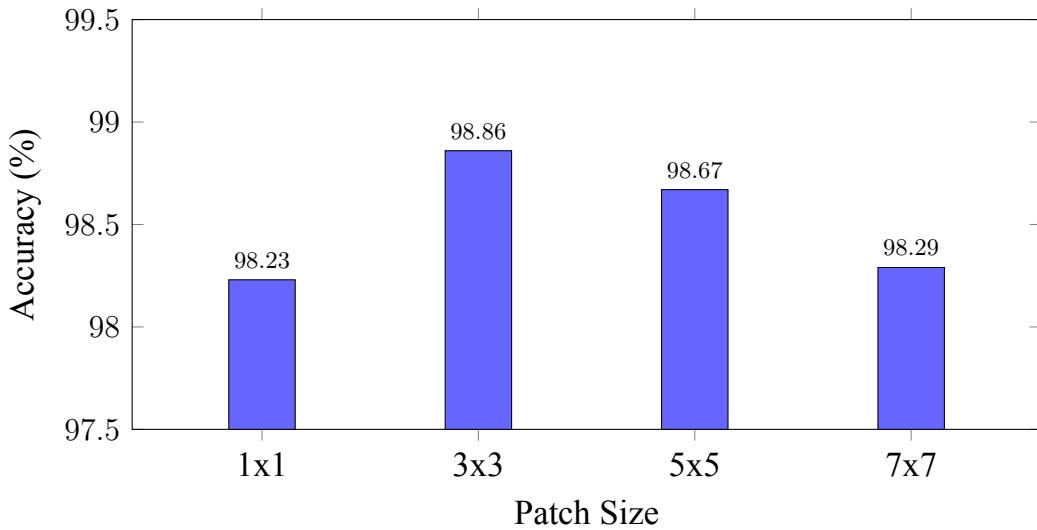
Kết quả trên hoàn thành mục tiêu thứ nhất, xây dựng bộ dữ liệu huấn luyện gồm 2.630 mẫu với 27 đặc trưng từ ảnh vệ tinh Sentinel-1 và Sentinel-2 đa thời gian, bao gồm các kênh phổ, chỉ số thực vật và tán xạ ngược cho khu vực quy hoạch lâm nghiệp tỉnh Cà Mau.

3.2. Thử nghiệm mô hình

3.2.1. Ảnh hưởng của Patch Size

Bảng 3.3: So sánh các kích thước patch

Kích thước patch	Accuracy	ROC-AUC	Thời gian huấn luyện	Số tham số
1x1	98,23%	99,78%	12,5s	25.348
3x3 (nghiên cứu này)	98,86%	99,98%	15,2s	36.676
5x5	98,67%	99,89%	28,3s	52.484
7x7	98,29%	99,86%	41,2s	71.108



Hình 3.4: So sánh Accuracy theo các Patch Size

Qua Bảng 3.3 và Hình 3.4, có thể rút ra một số nhận xét quan trọng. Với kích thước patch 1×1 , mô hình đạt accuracy 98,23%, cho thấy chỉ riêng thông tin phổ tại mỗi điểm ảnh đã đủ để phân biệt các lớp biến động rõ ràng với độ chính xác cao, tuy nhiên cách tiếp cận này bỏ qua thông tin ngữ cảnh không gian. Kích thước patch 3×3 đạt kết quả tốt nhất (98,86% accuracy, 99,98% ROC-AUC) với mức tăng thời gian huấn luyện chấp nhận được (+2,7 giây so với 1×1), cho thấy kích thước này cân bằng tốt giữa việc khai thác ngữ cảnh không gian địa phương và tránh nhiễu từ các điểm ảnh xa.

Đối với kích thước patch 5×5 và 7×7 , accuracy giảm dần (98,67% và 98,29%) mặc dù số tham số mô hình tăng đáng kể, cho thấy với độ phân giải 10m của Sentinel-2, ngữ

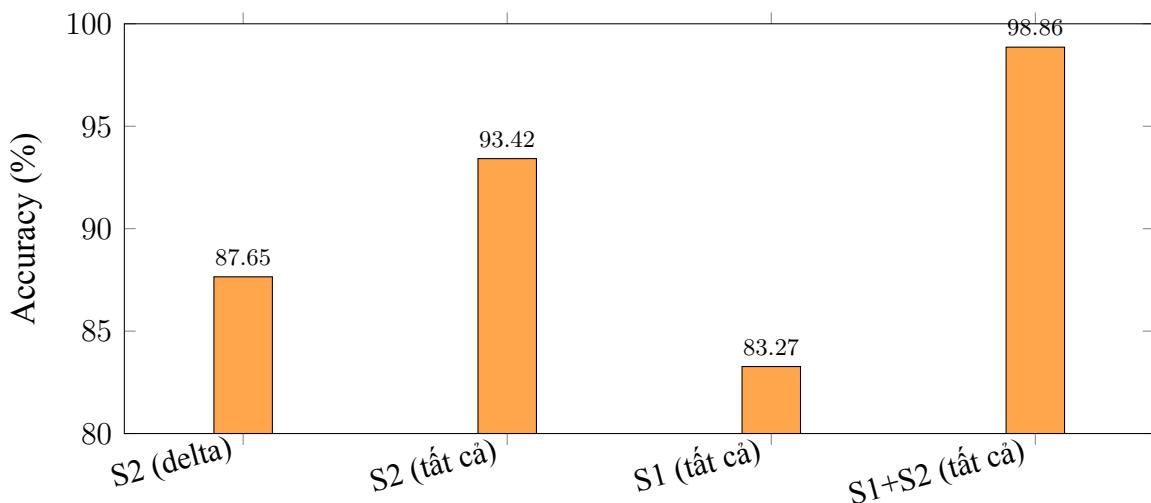
cánh không gian quá rộng (50-70m) có thể đưa vào nhiều từ các lớp phủ lân cận, đặc biệt tại các vùng ranh giới. Thời gian huấn luyện tăng gần tuyến tính với số tham số, từ 12,5s (1×1) lên 41,2s (7×7), cho thấy chi phí tính toán tăng đáng kể khi mở rộng kích thước patch mà không đem lại cải thiện về accuracy. Do đó, có thể kết luận rằng kích thước patch 3×3 là tối ưu cho bộ dữ liệu này, đạt được sự cân bằng tốt nhất giữa độ chính xác, thời gian huấn luyện và khả năng khai thác ngũ cành không gian.

Kết quả trên đóng góp vào mục tiêu thiết kế và tối ưu hóa kiến trúc CNN, xác định kích thước patch 3×3 là tối ưu cho bộ dữ liệu quy mô vừa phải, đạt accuracy 98,86% với 36.676 tham số.

3.2.2. Ảnh hưởng của nguồn dữ liệu

Bảng 3.4: Nghiên cứu loại trừ các nguồn dữ liệu

Cấu hình	Số đặc trưng	Accuracy	ROC-AUC
Chỉ Sentinel-2 (delta)	7	87,65%	94,12%
Sentinel-2 (trước + sau + delta)	21	93,42%	97,58%
Chỉ Sentinel-1 (trước + sau + delta)	6	83,27%	91,45%
S1 + S2 (tất cả)	27	98,86%	99,98%



Hình 3.5: So sánh Accuracy theo các nguồn dữ liệu

Qua Bảng 3.4 và Hình 3.5, có thể rút ra các nhận xét quan trọng về vai trò của từng nguồn dữ liệu. Sentinel-2 đóng vai trò chủ đạo trong phân loại biến động rừng, thể hiện qua việc chỉ với dữ liệu Sentinel-2 delta (7 kênh biến động), mô hình đã đạt 87,65% accuracy, và khi bổ sung đầy đủ dữ liệu trước, sau và delta (21 kênh), accuracy tăng lên 93,42%, khẳng định tầm quan trọng của thông tin quang phổ và phương pháp phân tích 2 thời điểm trong phát hiện biến động. Trong khi đó, Sentinel-1 đơn lẻ có hiệu suất thấp nhất (83,27% accuracy với 6 kênh); dữ liệu ra-đa khẩu độ tổng hợp tuy có ưu điểm không bị ảnh hưởng bởi mây và có khả năng quan sát cấu trúc rừng, nhưng độ phân giải phổ hạn chế (chỉ có VV và VH) khiến việc phân biệt các lớp phủ trở nên khó khăn hơn đáng kể so với dữ liệu quang học đa phổ.

Sự kết hợp S1+S2 cho kết quả tốt nhất (98,86% accuracy, 99,98% ROC-AUC), vượt trội đáng kể so với việc chỉ sử dụng Sentinel-2 (+5,44%), cho thấy dữ liệu ra-đa bổ sung thông tin cấu trúc và độ ẩm mà dữ liệu quang học không nắm bắt được, đặc biệt hữu ích cho việc phân biệt rừng có mật độ tán khác nhau, phát hiện vùng rừng suy thoái chưa thể hiện rõ trên ảnh quang học, và cải thiện phân loại trong điều kiện có mây một phần. Bên cạnh đó, đóng góp của thông tin thời gian là đáng kể khi accuracy tăng từ 87,65% (chỉ delta) lên 93,42% (đầy đủ trước + sau + delta), khẳng định giá trị của việc khai thác thông tin đa thời gian trong phát hiện biến động.

Từ các kết quả trên, có thể kết luận rằng việc kết hợp Sentinel-1 và Sentinel-2 cho kết quả tối ưu nhất. Dữ liệu ra-đa và quang học có tính bổ sung cao: Sentinel-2 cung cấp thông tin chi tiết về thành phần hóa học và sinh lý của thực vật thông qua các kênh quang phổ, trong khi Sentinel-1 cung cấp thông tin về cấu trúc và độ ẩm của tán rừng. Sự kết hợp này đặc biệt phù hợp cho giám sát rừng ngập mặn ven biển, nơi điều kiện thời tiết thường xuyên có mây và sương mù.

Kết quả trên hoàn thành mục tiêu thứ hai và thứ ba, thiết kế và tối ưu hóa kiến trúc CNN phù hợp cho bộ dữ liệu quy mô vừa phải, đồng thời đánh giá hiệu quả của việc tích hợp dữ liệu đa nguồn, với accuracy tăng từ 93,42% (chỉ S2) lên 98,86% (S1+S2), cải thiện 5,44 điểm phần trăm so với việc sử dụng nguồn dữ liệu đơn lẻ.

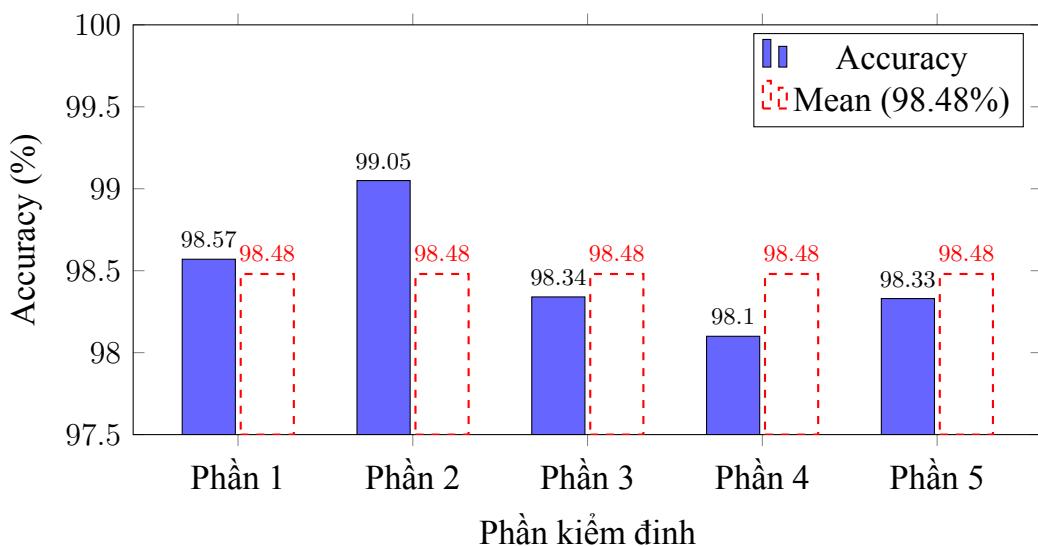
3.3. Kết quả

3.3.1. Kết quả huấn luyện mô hình CNN

Để đánh giá độ ổn định của mô hình, nghiên cứu áp dụng phương pháp kiểm định chéo 5 phần. Phương pháp này chia dữ liệu thành 5 phần bằng nhau, luân phiên sử dụng mỗi phần làm tập kiểm tra trong khi 4 phần còn lại làm tập huấn luyện; kết quả cuối cùng là trung bình của 5 lần đánh giá. Bảng 3.5 tổng hợp các thông số huấn luyện của 5 fold và Hình 3.6 so sánh Accuracy giữa các phần.

Bảng 3.5: Tổng hợp kết quả huấn luyện kiểm định 5 phần

Phần	Epoch tốt nhất	Loss cao nhất	Accuracy cao nhất
Phần 1	59	0,0531	98,57%
Phần 2	77	0,0401	99,05%
Phần 3	82	0,0501	98,34%
Phần 4	86	0,0683	98,10%
Phần 5	50	0,0546	98,33%
Trung bình	71	0,0532	98,48%

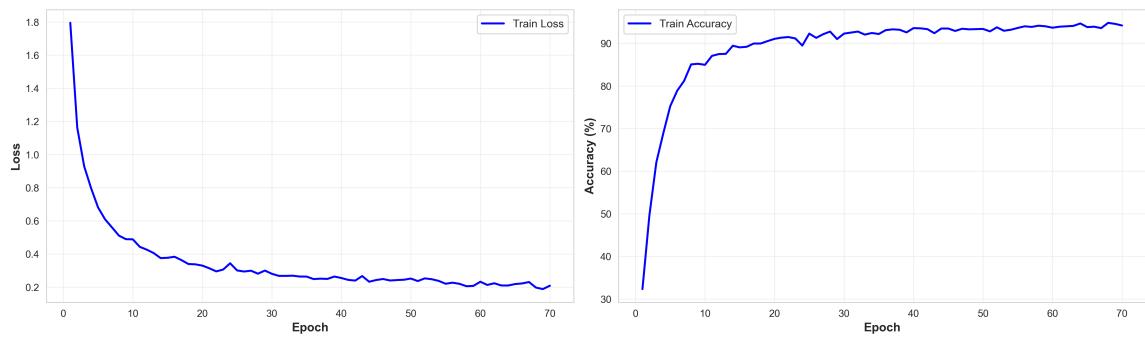


Hình 3.6: So sánh Accuracy giữa các phần kiểm định trong kiểm định chéo 5 phần

Qua Hình 3.6, Accuracy dao động trong khoảng hẹp từ 98,10% đến 99,05%, biên độ chênh lệch chỉ 0,95 điểm phần trăm. Kết quả kiểm định chéo cho thấy mô hình đạt

độ ổn định cao với độ lệch chuẩn 0,36%. Accuracy của từng phần kiểm định đều vượt ngưỡng 98%, phản ánh khả năng tổng quát hóa tốt. Hiện tượng loss kiểm định thấp hơn loss huấn luyện là đặc trưng điển hình khi sử dụng Dropout tỷ lệ cao (70%), cho thấy kỹ thuật điều chỉnh chuẩn hoạt động hiệu quả và mô hình không bị quá khớp. Cơ chế dừng sớm đã dừng huấn luyện tại các epoch khác nhau cho mỗi phần kiểm định (từ epoch 50 đến 86), xác nhận mô hình đã hội tụ tốt.

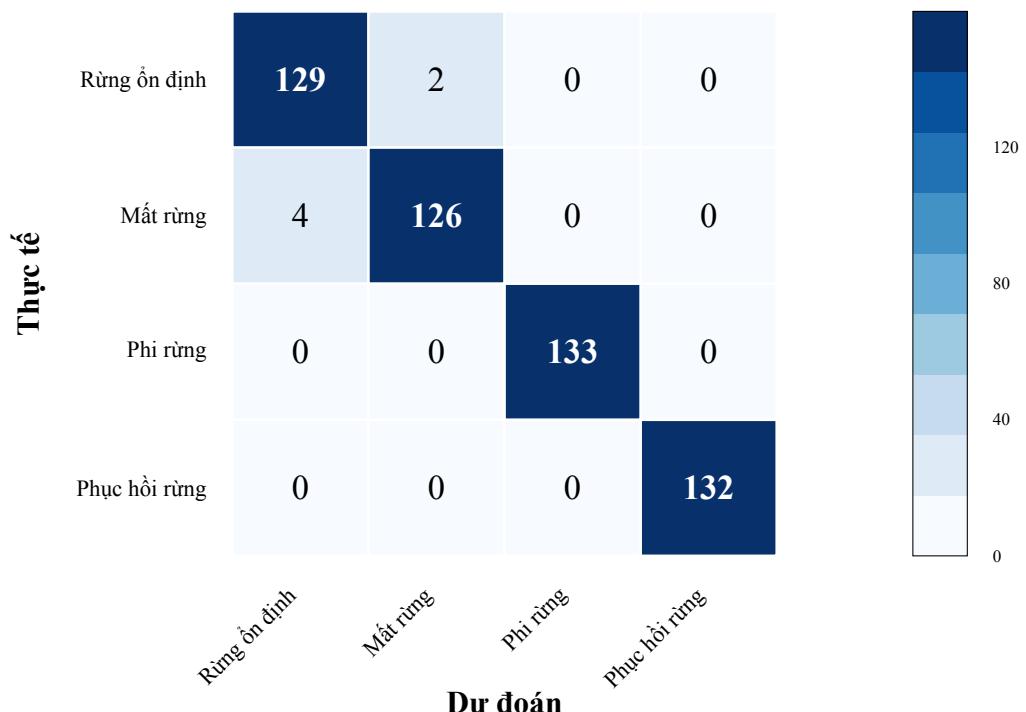
Sau khi hoàn tất kiểm định chéo, mô hình cuối cùng được huấn luyện trên toàn bộ 80% dữ liệu (2,104 mẫu) để tận dụng tối đa lượng dữ liệu huấn luyện. Hình 3.7 trình bày diễn biến loss và accuracy trong quá trình huấn luyện.



Hình 3.7: Diễn biến loss và accuracy trong quá trình huấn luyện mô hình cuối cùng

Quá trình huấn luyện kéo dài khoảng 70 epoch với loss giảm từ 1,8 xuống 0,2 và accuracy tăng từ 30% lên trên 95%. Mô hình này sau đó được đánh giá trên 20% tập kiểm tra cố định (526 mẫu) để báo cáo kết quả cuối cùng.

Trên tập kiểm tra, mô hình đạt Accuracy 98,86%, ROC-AUC 99,98%, với Precision, Recall và F1-Score (macro average — trung bình không trọng số từ mỗi lớp) đều đạt 98,86%. Ma trận nhầm lẫn (Hình 3.8) thể hiện kết quả phân loại, mỗi hàng tương ứng với lớp thực tế và mỗi cột tương ứng với lớp dự đoán; phần tử trên đường chéo chính là số mẫu phân loại đúng, phần tử ngoài đường chéo là trường hợp phân loại sai. Bảng 3.6 trình bày các chỉ số đánh giá theo từng lớp.



Hình 3.8: Ma trận nhầm lẫn trên tập kiểm tra ($n=526$, Accuracy: 98,86%)

Bảng 3.6: Phân tích chi tiết từng lớp

Lớp	Precision	Recall	F1-Score	Số mẫu	Lỗi
0 - Rừng ổn định	96,99%	98,47%	97,73%	131	4 FP, 2 FN
1 - Mất rừng	98,44%	96,92%	97,67%	130	2 FP, 4 FN
2 - Phi rừng	100,00%	100,00%	100,00%	133	0
3 - Phục hồi rừng	100,00%	100,00%	100,00%	132	0

Tổng cộng chỉ có 6/526 mẫu bị phân loại sai, tương đương tỷ lệ lỗi 1,14%. Trong đó, hai mẫu thuộc Lớp 0 (Rừng ổn định) bị nhầm thành Lớp 1 (Mất rừng) và bốn mẫu thuộc Lớp 1 (Mất rừng) bị nhầm thành Lớp 0 (Rừng ổn định). Đánh giá chi tiết cho thấy Lớp 2 (Phi rừng) và Lớp 3 (Phục hồi rừng) được phân loại hoàn hảo với Accuracy 100%.

Việc nhầm lẫn chỉ xảy ra giữa hai lớp Rừng ổn định (Lớp 0) và Mất rừng (Lớp 1) có thể được giải thích bởi một số yếu tố. Trước hết, cả hai lớp đều có sự hiện diện của rừng ở ít nhất một thời điểm, dẫn đến sự tương đồng về đặc trưng quang phổ; các khu vực rừng bị suy thoái nhẹ có thể có phổ phản xạ đặc trưng tương tự với rừng ổn định, đặc biệt khi mức độ mất rừng không rõ ràng. Bên cạnh đó, hiệu ứng biên cũng góp phần gây nhầm lẫn khi tại ranh giới giữa vùng rừng và vùng mất rừng, các điểm ánh có thể chứa

cả hai loại lớp phủ (điểm ảnh hỗn hợp), dẫn đến vector đặc trưng không điển hình cho một lớp cụ thể. Ngoài ra, một số khu vực rừng ngập mặn có thể có biến động theo mùa về mật độ tán lá, tạo ra sự thay đổi NDVI tương tự như mất rừng nhưng thực tế là biến động tự nhiên. Cuối cùng, với chỉ hai thời điểm quan sát, hạn chế về độ phân giải thời gian khiến một số biến động ngắn hạn hoặc phục hồi nhanh có thể không được ghi nhận chính xác.

Tuy nhiên, với tỷ lệ nhầm lẫn rất thấp (chỉ 6/526 mẫu, 1,14%) và ROC-AUC trung bình đạt 99,98%, mô hình thể hiện khả năng phân biệt xuất sắc giữa các lớp biến động rừng.

3.3.2. Kết quả phân loại toàn bộ vùng nghiên cứu

Sau khi huấn luyện và đánh giá trên tập kiểm tra, mô hình được áp dụng để phân loại toàn bộ vùng quy hoạch lâm nghiệp tỉnh Cà Mau. Kết quả thống kê phân loại được trình bày trong Bảng 3.7.

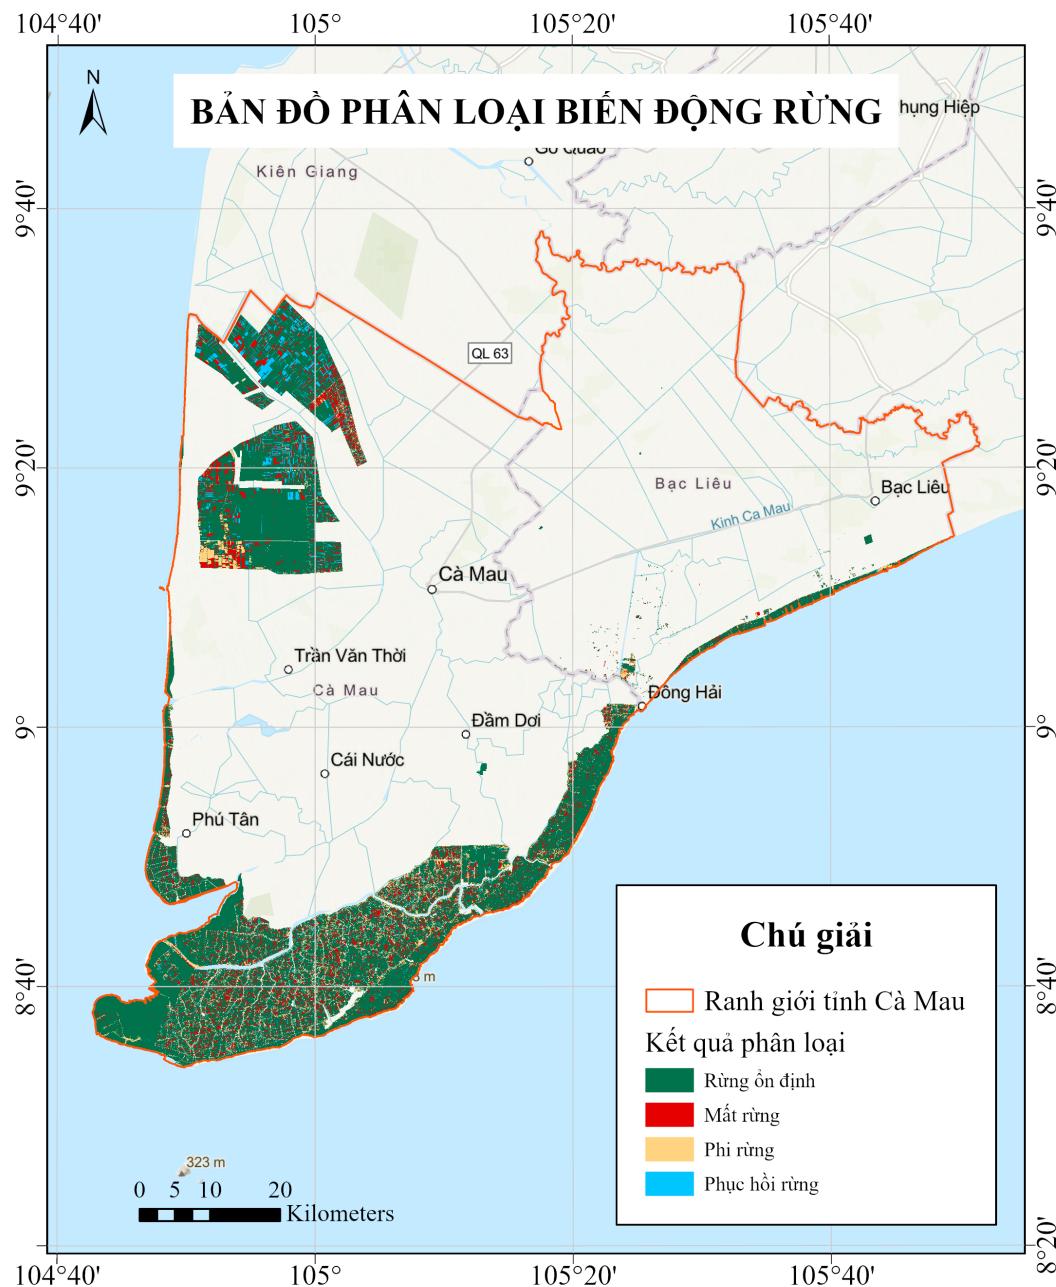
Bảng 3.7: Phân bố diện tích theo lớp phân loại

Lớp	Tên lớp	Số điểm ảnh	Tỷ lệ (%)	Diện tích (ha)	Diện tích (km ²)
0	Rừng ổn định	12.071.691	74,30%	120.716,91	1.207,17
1	Mất rừng	728.215	4,48%	7.282,15	72,82
2	Phi rừng	2.952.854	18,17%	29.528,54	295,29
3	Phục hồi rừng	494.090	3,04%	4.940,90	49,41
Tổng		16.246.850	100%	162.468,50	1.624,69

Kết quả từ Bảng 3.7 cho thấy bức tranh tổng quan về tình trạng rừng tại tỉnh Cà Mau trong giai đoạn nghiên cứu. Lớp rừng ổn định chiếm tỷ lệ lớn nhất với 74,30% (tương đương 1.207,17 km²), phản ánh nỗ lực bảo tồn và quản lý rừng ngập mặn của địa phương, chủ yếu tập trung tại Vườn Quốc gia Mũi Cà Mau và các vùng đệm được bảo vệ nghiêm ngặt. Diện tích mất rừng chiếm 4,48% (72,82 km²), đây là tỷ lệ đáng quan ngại khi quy đổi ra diện tích tuyệt đối, với các nguyên nhân chính có thể bao gồm chuyển đổi mục đích sử dụng đất sang nuôi trồng thủy sản, xói lở bờ biển do biến đổi khí hậu và tác động của xâm nhập mặn làm suy thoái rừng.

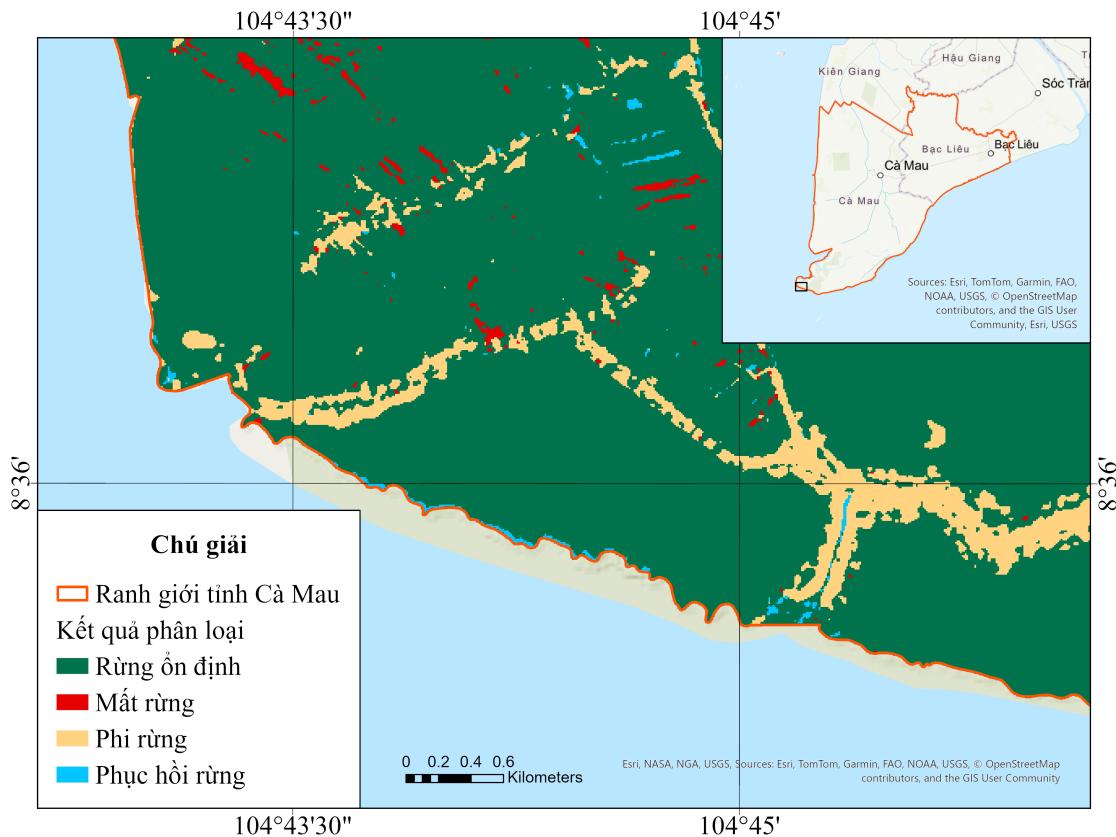
Lớp phi rừng chiếm 18,17% (295,29 km²), bao gồm các khu vực ao nuôi tôm, đất

trồng, khu dân cư và cơ sở hạ tầng, phản ánh áp lực phát triển kinh tế - xã hội lên tài nguyên rừng trong khu vực. Lớp phục hồi rừng chiếm 3,04% ($49,41\text{ km}^2$), cho thấy một phần diện tích đã được tái sinh tự nhiên hoặc trồng rừng mới. Mặc dù tỷ lệ phục hồi còn thấp hơn so với diện tích mất rừng, đây vẫn là tín hiệu tích cực cho công tác phục hồi hệ sinh thái rừng ngập mặn trong khu vực. Hình 3.9 minh họa sự phân bố không gian của các lớp phân loại trên toàn vùng nghiên cứu.



Hình 3.9: Bản đồ phân loại biến động rừng tỉnh Cà Mau

Để phân tích chi tiết hơn về khả năng phát hiện biến động của mô hình trong điều kiện thực tế, nghiên cứu lựa chọn khu vực Vườn Quốc gia Mũi Cà Mau làm ví dụ minh họa. Đây là khu vực đặc trưng với sự đan xen giữa rừng ngập mặn nguyên sinh, hệ thống ao nuôi tôm và các hoạt động sản xuất theo mô hình Tôm–Rừng, tạo nên bức tranh đa dạng về các loại biến động lớp phủ.

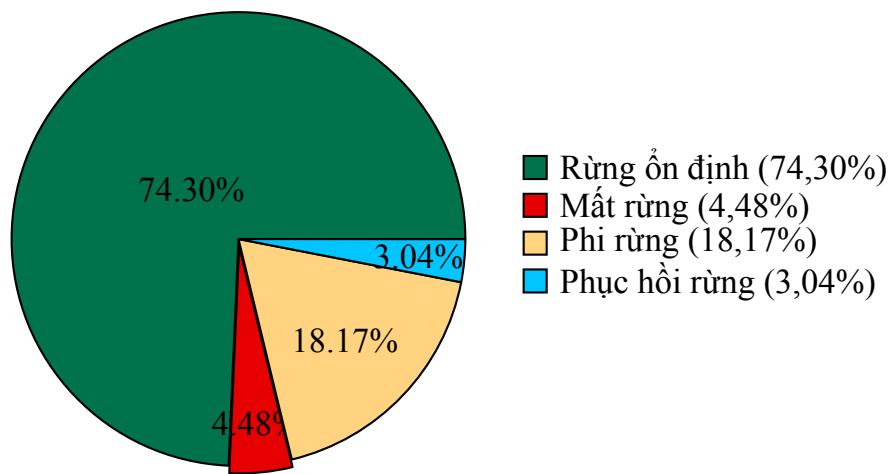


Hình 3.10: Bản đồ phân loại biến động rừng khu vực Vườn Quốc gia Mũi Cà Mau

Kết quả phân loại biến động rừng ngập mặn khu vực Vườn Quốc gia Mũi Cà Mau (Hình 3.10) cho thấy mô hình có khả năng nhận diện chính xác một số loại biến động thực sự của lớp phủ. Các vùng mất rừng (màu đỏ) phân bố chủ yếu dọc theo rìa ao nuôi và hệ thống kênh mương, phản ánh các hoạt động sản xuất như mở rộng diện tích ao tôm, nạo vét mương, cải tạo bờ bao hoặc phơi ao. Tại những khu vực này, việc dọn cây đã làm suy giảm rõ rệt thảm thực vật và để lộ lớp đất hoặc bùn bên dưới — đây là những biến động thực sự mà mô hình phát hiện hợp lý. Tương tự, các vùng phục hồi rừng (màu xanh lam) xuất hiện rải rác ven bờ ao và trong các khoảng trống nhỏ, đặc biệt dọc theo đường bờ biển, phản ánh quá trình tái sinh tự nhiên của cây ngập mặn non trong hệ sinh thái Tôm–Rừng.

Tuy nhiên, kết quả phân loại cũng chứa đựng những sai sót tiềm ẩn do các yếu tố môi trường gây nhiễu. Thủy triều là nguồn gây nhiễu đáng kể: khi triều cường, các mảng rừng thấp bị ngập tạm thời có thể bị phân loại nhầm thành mất rừng; ngược lại, khi triều kiệt, sự xuất hiện của bùn và thảm thực vật thấp có thể tạo ra tín hiệu giả của phục hồi rừng. Bên cạnh đó, hoạt động nuôi tôm cũng góp phần tạo ra các biến động “ảo” khi ao nuôi thường xuyên thay nước, mực nước và độ đục dao động liên tục khiến đặc trưng phổ của mặt nước thay đổi giữa hai thời điểm thu ảnh. Trong mùa khô, hiện tượng ao cạn đáy hoặc bùn bị phơi tự nhiên cũng có thể dẫn đến phân loại sai thành mất rừng mặc dù không có tác động sinh thái thực sự.

Tóm lại, mô hình thể hiện khả năng mô tả tương đối chính xác các biến động liên quan đến hoạt động sản xuất và tái sinh rừng ngập mặn, song độ tin cậy giảm đáng kể tại các khu vực nhạy cảm với biến động môi trường — đặc biệt là những nơi rừng thấp, gần mép ao hoặc chịu ảnh hưởng mạnh của chế độ thủy triều và hoạt động nuôi trồng thủy sản.



Hình 3.11: Tỷ lệ diện tích các lớp phân loại

Qua biểu đồ tròn (Hình 3.11), có thể nhận thấy sự chênh lệch rõ rệt về diện tích giữa các lớp. Rừng ổn định chiếm ưu thế tuyệt đối với hơn 3/4 diện tích vùng nghiên cứu. Đáng chú ý, tỷ lệ mất rừng (4,48%) vượt quá tỷ lệ phục hồi rừng (3,04%), cho thấy xu hướng suy giảm rõ ràng của diện tích rừng trong giai đoạn nghiên cứu, với chênh lệch khoảng 1,44% (tương đương 2.341 ha) là mức độ mất rừng rõ ràng mà khu vực đang phải đối mặt. Tuy nhiên, cần lưu ý rằng việc khai thác rừng trồng (hợp pháp) có tính chu kỳ, nên vào thời điểm sau khai thác diện tích rừng tuyệt đối có thể giảm tạm thời; điều này không nhất thiết phản ánh xu hướng mất rừng dài hạn của khu vực. Diện tích phi rừng

lớn (18,17%) phản ánh mức độ khai thác tài nguyên đất đai trong khu vực, chủ yếu cho hoạt động nuôi trồng thủy sản - ngành kinh tế mũi nhọn của tỉnh Cà Mau.

Cần lưu ý rằng theo khuyến nghị của Olofsson và cộng sự [39], diện tích ước tính từ bản đồ phân loại cần được hiệu chỉnh dựa trên Ma trận nhầm lẫn để đảm bảo tính không chêch. Với Accuracy cao của mô hình (98,86%, Precision và Recall đều trên 96% cho tất cả các lớp), sai số giữa diện tích thô và diện tích hiệu chỉnh được kỳ vọng là nhỏ. Việc thực hiện hiệu chỉnh đầy đủ theo phương pháp Olofsson sẽ là hướng phát triển trong tương lai.

Kết quả trên hoàn thành mục tiêu thứ tư, áp dụng mô hình CNN đã huấn luyện để phân loại biến động rừng toàn vùng quy hoạch lâm nghiệp tỉnh Cà Mau (162.468,50 ha) và tạo bản đồ biến động ở độ phân giải 10m với 4 lớp phân loại.

3.3.3. So sánh với các nghiên cứu khác

Việc so sánh trực tiếp các chỉ số đánh giá giữa các nghiên cứu khác nhau có những hạn chế nhất định. Sự khác biệt về đặc điểm sinh thái của khu vực nghiên cứu (rừng ngập mặn ven biển so với rừng nhiệt đới nội địa), độ phân giải không gian của dữ liệu đầu vào (Sentinel-2 10m so với Landsat 30m), quy mô và phương pháp thu thập dữ liệu tham chiếu, cùng với định nghĩa các lớp phân loại có thể dẫn đến những khác biệt đáng kể về kết quả đánh giá. Do vậy, các so sánh được trình bày dưới đây nhằm mục đích định vị phương pháp đề xuất trong bối cảnh phát triển chung của lĩnh vực, thay vì đưa ra kết luận về tính ưu việt tuyệt đối.

Để đánh giá hiệu quả của phương pháp đề xuất, kết quả được so sánh với các công trình nghiên cứu tiêu biểu trong lĩnh vực giám sát biến động rừng bằng viễn thám và học máy. Nghiên cứu của Hansen và cộng sự [18] tại Đại học Maryland là công trình tiên phong trong việc xây dựng bản đồ biến động rừng toàn cầu sử dụng ảnh Landsat 30m. Phương pháp sử dụng thuật toán Decision Trees kết hợp với nền tảng Google Earth Engine để xử lý hơn 654,000 cảnh Landsat 7 trong giai đoạn 2000–2012. Kết quả đánh giá độc lập cho thấy bản đồ mất rừng đạt tỷ lệ dương tính giả 13% và âm tính giả 12% ở quy mô toàn cầu, tương đương Accuracy khoảng 85%. Phương pháp này có ưu điểm về quy mô toàn cầu, cập nhật hàng năm, miễn phí và công khai; tuy nhiên, nhược điểm là độ phân giải thấp (30m) khiến khó phát hiện biến động nhỏ, chỉ sử dụng dữ liệu quang học nên bị hạn chế bởi mây, và định nghĩa “rừng” dựa trên độ cao cây (>5m) không phù

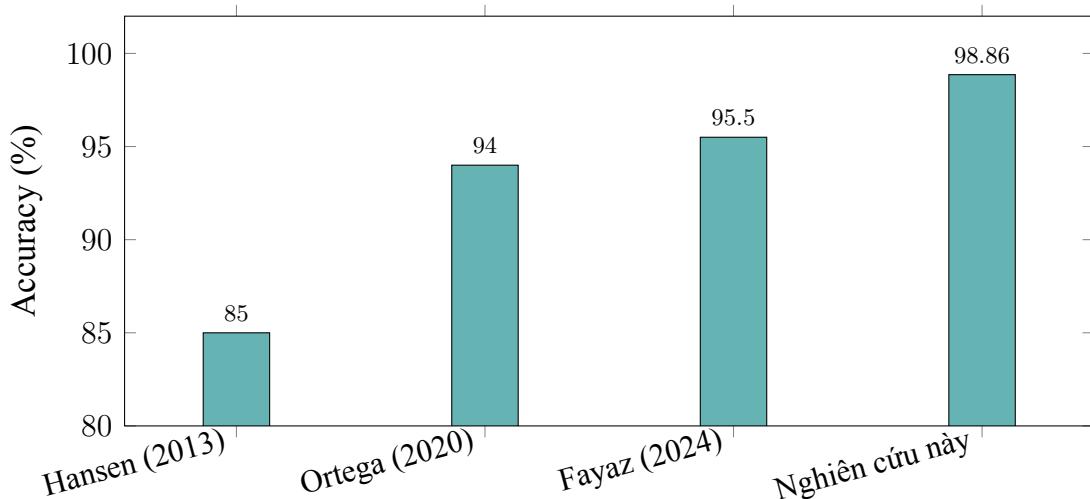
hợp với rừng ngập mặn non.

Trong những năm gần đây, các kiến trúc học sâu như CNN, U-Net và ResNet đã được áp dụng rộng rãi cho bài toán phát hiện biến động rừng với kết quả vượt trội so với phương pháp học máy truyền thống. Theo tổng quan của Fayaz và cộng sự (2024), U-Net và các biến thể của nó được sử dụng trong 45% các nghiên cứu về phát hiện mêt rừng, đạt Accuracy trung bình 94–97%. Nghiên cứu của Ortega và cộng sự (2020) trên rừng Amazon cho thấy các kiến trúc CNN (SharpMask, U-Net, ResU-Net) đều vượt trội so với thuật toán ML truyền thống cả về định lượng lẫn trực quan. Đặc biệt, việc kết hợp U-Net với ResNet (ResU-Net) giúp trích xuất đặc trưng chi tiết hơn. Ưu điểm của học sâu là tự động học đặc trưng từ dữ liệu mà không cần thiết kế thủ công, khai thác được ngữ cảnh không gian và hiệu quả cao khi có đủ dữ liệu huấn luyện; tuy nhiên, nhược điểm là yêu cầu lượng dữ liệu huấn luyện lớn, tính chất “hộp đen” khó giải thích, chi phí tính toán cao và hiệu suất giảm đáng kể khi kích thước mẫu nhỏ.

Bảng 3.8 tổng hợp kết quả so sánh giữa nghiên cứu này với các công trình tiêu biểu.

Bảng 3.8: So sánh với các nghiên cứu trong tài liệu

Nghiên cứu	Phương pháp	Dữ liệu	Accuracy	ROC-AUC
Hansen và cs. (2013)	Decision Trees	Landsat 30m	~85%	-
Ortega và cs. (2020)	U-Net, ResU-Net	Landsat 30m	~94%	-
Fayaz và cs. (2024)	U-Net (tổng quan)	Đa nguồn	94–97%	-
Nghiên cứu này	CNN (custom)	S1/S2 10m	98,86%	99,98%



Hình 3.12: So sánh Accuracy với các nghiên cứu trước đó

Kết quả của nghiên cứu này đạt Accuracy cao hơn so với các công trình trước đó [50]. Hiệu suất này có thể được giải thích bởi độ phân giải không gian cao hơn (10m so với 30m) giúp phát hiện biến động chi tiết hơn, sự kết hợp dữ liệu đa nguồn (ra-đa và quang học) bổ sung cho nhau trong điều kiện nhiều mây của vùng nhiệt đới, kiến trúc CNN được thiết kế phù hợp với bộ dữ liệu nhỏ thông qua kỹ thuật điều chuẩn (Dropout 70%, chuẩn hóa theo lô), cùng với bộ dữ liệu thực địa chất lượng cao được thu thập và kiểm tra kỹ lưỡng.

Nghiên cứu cũng thực hiện so sánh định tính với sản phẩm Giám sát rừng toàn cầu (Global Forest Watch - GFW) dựa trên công trình của Hansen và cộng sự đã đề cập ở trên, được cập nhật liên tục bởi Potapov và cộng sự [41].

Bảng 3.9: So sánh kết quả với Giám sát rừng toàn cầu (GFW)

Chỉ tiêu	Nghiên cứu này	GFW (tham khảo)	Ghi chú
Độ phân giải	10m	30m	Nghiên cứu này chi tiết hơn
Nguồn dữ liệu	S1/S2	Landsat	Đa nguồn và đơn nguồn
Phương pháp	CNN	Decision Trees	Học sâu và học máy
Cập nhật	Theo yêu cầu	Hàng năm	Linh hoạt hơn

Bảng 3.9 tổng hợp các khác biệt chính giữa phương pháp đề xuất và GFW. Độ phân giải cao hơn của Sentinel (10m) đặc biệt có ý nghĩa với rừng ngập mặn Cà Mau, nơi các ao nuôi tôm và kênh mương thường có kích thước nhỏ. Tuy nhiên, GFW vẫn có ưu thế về tính nhất quán toàn cầu, lịch sử dữ liệu dài (từ năm 2000) và khả năng cập nhật tự động hàng năm — những yếu tố quan trọng cho việc giám sát dài hạn ở quy mô lớn.

TÀI LIỆU THAM KHẢO

Tiếng Việt

- [1] Bộ Nông nghiệp và Phát triển Nông thôn, *Quyết định số 1558/QĐ-BNN-TCLN về việc công bố hiện trạng rừng toàn quốc năm 2020*, Hà Nội, 2021, trang 8.
- [2] Công ty TNHH Tư vấn và Phát triển Đồng Xanh, *Ứng dụng công nghệ viễn thám, ảnh vệ tinh để quản lý, giám sát tài nguyên rừng và sạt lở ven biển trên địa bàn tỉnh Cà Mau*, Cà Mau, 2025, Tài liệu nội bộ, Sở Khoa học và Công nghệ tỉnh Cà Mau.
- [3] Nông nghiệp Môi trường, *Cà Mau: Sạt lở bờ biển làm mất hơn 6.200 ha đất và rừng phòng hộ*, 2024, Truy cập: <https://nongnghiepmoitruong.vn/ca-mau-mat-khoang-6200-ha-dat-va-rung-phong-ho-ven-bien-d785994.html>.
- [4] Sở Nông nghiệp và Phát triển Nông thôn tỉnh Cà Mau, *Báo cáo hiện trạng rừng tỉnh Cà Mau năm 2021*, Cà Mau, 2021, Báo cáo nội bộ.
- [5] Thanh Niên, *Rừng nguyên sinh Việt Nam chỉ còn 0.25%*, 2021, Truy cập: <https://thanhnien.vn/rung-nguyen-sinh-con-nguyen-van-cua-viet-nam-chi-con-025-1851011307.htm>.

Tiếng Anh

- [6] Alongi, D. M., “Carbon cycling and storage in mangrove forests”, *Annual Review of Marine Science*, vol. 6, 2014, pp. 195–219.
- [7] Blaschke, T., “Object based image analysis for remote sensing”, *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 65, no. 1, 2010, pp. 2–16.
- [8] Breiman, L., “Random forests”, *Machine Learning*, vol. 45, no. 1, 2001, pp. 5–32.
- [9] Cortes, C., Vapnik, V., “Support-vector networks”, *Machine Learning*, vol. 20, no. 3, 1995, pp. 273–297.

- [10] Donato, D. C., Kauffman, J. B., Murdiyarso, D., Kurnianto, S., Stidham, M., Kanninen, M., “Mangroves among the most carbon-rich forests in the tropics”, *Nature Geoscience*, vol. 4, no. 5, 2011, pp. 293–297.
- [11] European Space Agency, *Sentinel-1 SAR User Guide*, ESA Sentinel Online, 2024, Available: https://www.esa.int/Applications/Observing_the_Earth/Copernicus/Sentinel-1.
- [12] European Space Agency, *Sentinel-2 MSI User Guide*, ESA Sentinel Online, 2024, Available: https://www.esa.int/Applications/Observing_the_Earth/Copernicus/Sentinel-2.
- [13] FAO, *Global Forest Resources Assessment 2020: Main Report*, Food and Agriculture Organization of the United Nations, Rome, 2020.
- [14] Gao, B.-c., “NDWI—A normalized difference water index for remote sensing of vegetation liquid water from space”, *Remote Sensing of Environment*, vol. 58, no. 3, 1996, pp. 257–266.
- [15] Global Forest Watch, *Forest Loss Data 2015-2020*, World Resources Institute, 2021, Available: <https://www.globalforestwatch.org>.
- [16] Gong, P., Wang, J., Yu, L., Zhao, Y., Zhao, Y., Liang, L., Niu, Z., Huang, X., Fu, H., Liu, S., Li, C., Li, X., Fu, W., Liu, C., Xu, Y., Wang, X., Cheng, Q., Hu, L., Yao, W., Zhang, H., Zhu, P., Zhao, Z., Zhang, H., Zheng, Y., Ji, L., Zhang, Y., Chen, H., Yan, A., Guo, J., Yu, L., Wang, L., Liu, X., Shi, T., Zhu, M., Chen, Y., Yang, G., Tang, P., Xu, B., Giri, C., Clinton, N., Zhu, Z., Chen, J., Chen, J., “Finer resolution observation and monitoring of global land cover: first mapping results with Landsat TM and ETM+ data”, *International Journal of Remote Sensing*, vol. 34, no. 7, 2013, pp. 2607–2654.
- [17] Goodfellow, I., Bengio, Y., Courville, A., *Deep Learning*, MIT Press, Cambridge, MA, 2016.
- [18] Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., Thau, D., Stehman, S. V., Goetz, S. J., Loveland, T. R., Kommareddy, A., Egorov, A., Chini, L., Justice, C. O., Townshend, J. R. G., “High-resolution global maps of 21st-century forest cover change”, *Science*, vol. 342, no. 6160, 2013, pp. 850–853.

- [19] He, K., Zhang, X., Ren, S., Sun, J., “Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification”, *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 1026–1034, IEEE, 2015.
- [20] Hethcoat, M. G., Edwards, D. P., Carreiras, J. M. B., Bryant, R. G., França, F. M., Quegan, S., “A machine learning approach to map tropical selective logging”, *Remote Sensing of Environment*, vol. 221, 2019, pp. 569–582.
- [21] Ho, T. K., “Random decision forests”, *Proceedings of the 3rd International Conference on Document Analysis and Recognition (ICDAR)*, pp. 278–282, IEEE, 1995.
- [22] Hu, Y., Raza, A., Syed, A., Jiang, W., Shah, S. A. M., Asghar, M., Hussain, S., “Land use/land cover classification using multisource Sentinel-1 and Sentinel-2 satellite imagery”, *Journal of the Indian Society of Remote Sensing*, vol. 48, 2020, pp. 1055–1064.
- [23] Huang, S., Tang, L., Hupy, J. P., Wang, Y., Shao, G., “A commentary review on the use of normalized difference vegetation index (NDVI) in the era of popular remote sensing”, *Journal of Forestry Research*, vol. 32, no. 1, 2021, pp. 1–6.
- [24] Ienco, D., Interdonato, R., Gaetano, R., Ho Tong Minh, D., “Combining Sentinel-1 and Sentinel-2 satellite image time series for land cover mapping via a multi-source deep learning architecture”, *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 158, 2019, pp. 11–22.
- [25] Ioffe, S., Szegedy, C., “Batch normalization: Accelerating deep network training by reducing internal covariate shift”, *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pp. 448–456, PMLR, 2015.
- [26] IPCC, *Climate Change and Land: An IPCC Special Report on Climate Change, Desertification, Land Degradation, Sustainable Land Management, Food Security, and Greenhouse Gas Fluxes in Terrestrial Ecosystems*, Intergovernmental Panel on Climate Change, Geneva, 2019.
- [27] Jensen, J. R., *Introductory Digital Image Processing: A Remote Sensing Perspective*, 4 ed., Pearson, Upper Saddle River, NJ, 2015.

- [28] Karra, K., Kontgis, C., Statman-Weil, Z., Mazzariello, J. C., Mathis, M., Brumby, S. P., “Global land use/land cover with Sentinel-2 and deep learning”, *2021 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*, pp. 4704–4707, IEEE, 2021.
- [29] Key, C. H., Benson, N. C., “Landscape assessment (LA): Sampling and analysis methods”, *USDA Forest Service General Technical Report RMRS-GTR-164-CD*, 2006, pp. 1–51.
- [30] Khatami, R., Mountrakis, G., Stehman, S. V., “A meta-analysis of remote sensing research on supervised pixel-based land-cover image classification processes: General guidelines for practitioners and future research”, *Remote Sensing of Environment*, vol. 177, 2016, pp. 89–100.
- [31] Kingma, D. P., Ba, J., “Adam: A method for stochastic optimization”, *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [32] Kuenzer, C., Bluemel, A., Gebhardt, S., Quoc, T. V., Dech, S., “Remote sensing of mangrove ecosystems: A review”, *Remote Sensing*, vol. 3, no. 5, 2011, pp. 878–928.
- [33] Kussul, N., Lavreniuk, M., Skakun, S., Shelestov, A., “Deep learning classification of land cover and crop types using remote sensing data”, *IEEE Geoscience and Remote Sensing Letters*, vol. 14, no. 5, 2017, pp. 778–782.
- [34] LeCun, Y., Bengio, Y., Hinton, G., “Deep learning”, *Nature*, vol. 521, no. 7553, 2015, pp. 436–444.
- [35] Lillesand, T., Kiefer, R. W., Chipman, J., *Remote Sensing and Image Interpretation*, 7 ed., Wiley, Hoboken, NJ, 2015.
- [36] Lin, M., Chen, Q., Yan, S., “Network in network”, *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, 2014.
- [37] Loshchilov, I., Hutter, F., “Decoupled weight decay regularization”, *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019.
- [38] Nguyen, H. T. T., Doan, T. M., Tomppo, E., McRoberts, R. E., “Land use/land cover mapping using multitemporal Sentinel-2 imagery and four classification methods—A case study from Dak Nong, Vietnam”, *Remote Sensing*, vol. 12, no. 9, 2020, pp. 1367, Article 1367.

- [39] Olofsson, P., Foody, G. M., Herold, M., Stehman, S. V., Woodcock, C. E., Wulder, M. A., “Good practices for estimating area and assessing accuracy of land change”, *Remote Sensing of Environment*, vol. 148, 2014, pp. 42–57.
- [40] Pham, L. T. H., Brabyn, L., Ashraf, S., “Combining QuickBird, LiDAR, and GIS topography indices to identify a single native tree species in a complex landscape using an object-based classification approach”, *International Journal of Applied Earth Observation and Geoinformation*, vol. 50, 2016, pp. 187–197.
- [41] Potapov, P., Hansen, M. C., Pickens, A., Hernandez-Serna, A., Tyukavina, A., Turubanova, S., Zalles, V., Li, X., Khan, A., Stolle, F., Harris, N., Song, X.-P., Baber, A., Kommareddy, I., Kommareddy, A., “The global 2000-2020 land cover and land use change dataset derived from the Landsat archive: First results”, *Frontiers in Remote Sensing*, vol. 3, 2022, pp. 856903, Article 856903.
- [42] Reiche, J., Hamunyela, E., Verbesselt, J., Hoekman, D., Herold, M., “Improving near-real time deforestation monitoring in tropical dry forests by combining dense Sentinel-1 time series with Landsat and ALOS-2 PALSAR-2”, *Remote Sensing of Environment*, vol. 204, 2018, pp. 147–161.
- [43] Renaud, F. G., Syvitski, J. P. M., Sebesvari, Z., Werners, S. E., Kremer, H., Kuenzer, C., Ramesh, R., Jeuken, A., Friedrich, J., “Tipping from the Holocene to the Anthropocene: How threatened are major world deltas?”, *Current Opinion in Environmental Sustainability*, vol. 11, 2015, pp. 13–25.
- [44] Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., Dormann, C. F., “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure”, *Ecography*, vol. 40, no. 8, 2017, pp. 913–929.
- [45] Ronneberger, O., Fischer, P., Brox, T., “U-Net: Convolutional networks for biomedical image segmentation”, *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp. 234–241, Springer, 2015.
- [46] Rouse, J. W., Haas, R. H., Schell, J. A., Deering, D. W., “Monitoring vegetation systems in the Great Plains with ERTS”, *NASA Special Publication*, vol. 351, 1974, pp. 309–317.

- [47] Simonyan, K., Zisserman, A., “Very deep convolutional networks for large-scale image recognition”, *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [48] Sola, J., Sevilla, J., “Importance of input data normalization for the application of neural networks to complex industrial problems”, *IEEE Transactions on Nuclear Science*, vol. 44, no. 3, 1997, pp. 1464–1468.
- [49] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R., “Dropout: A simple way to prevent neural networks from overfitting”, *Journal of Machine Learning Research*, vol. 15, no. 1, 2014, pp. 1929–1958.
- [50] Stehman, S. V., Foody, G. M., “Key issues in rigorous accuracy assessment of land cover products”, *Remote Sensing of Environment*, vol. 231, 2019, pp. 111199, Article 111199.
- [51] Torres, R., Snoeij, P., Geudtner, D., Bibby, D., Davidson, M., Attema, E., Potin, P., Rommen, B., Flourey, N., Brown, M., Traver, I. N., Deghaye, P., Duesmann, B., Rosich, B., Miranda, N., Bruno, C., L’Abbate, M., Croci, R., Pietropaolo, A., Huchler, M., Rostan, F., “GMES Sentinel-1 mission”, *Remote Sensing of Environment*, vol. 120, 2012, pp. 9–24.
- [52] Vo, Q. M., Oppelt, N., Kuenzer, C., “Gap-free monitoring of annual mangrove forest dynamics in Ca Mau Province, Vietnamese Mekong Delta, using the Landsat-7-8 archives and post-classification temporal optimization”, *Remote Sensing*, vol. 12, no. 22, 2020, pp. 3729, Article 3729.
- [53] WWF, *Deforestation Fronts: Drivers and Responses in a Changing World*, World Wide Fund for Nature, Gland, Switzerland, 2021.
- [54] Zhang, L., Zhang, L., Du, B., “Deep learning for remote sensing data: A technical tutorial on the state of the art”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 4, no. 2, 2016, pp. 22–40.
- [55] Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., Fraundorfer, F., “Deep learning in remote sensing: A comprehensive review and list of resources”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 5, no. 4, 2017, pp. 8–36.