

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



Ninh Hải Đăng

**ỨNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG
GIÁM SÁT BIỂN ĐỘNG RỪNG TỈNH CÀ MAU**

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Công nghệ Hàng không Vũ trụ

HÀ NỘI - 2025

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



Ninh Hải Đăng

**ỨNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG GIÁM
SÁT BIỂN ĐỘNG RỪNG TỈNH CÀ MAU**

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Công nghệ Hàng không Vũ trụ

Cán bộ hướng dẫn: TS. Hà Minh Cường

Cán bộ đồng hướng dẫn: ThS. Hoàng Tích Phúc

HÀ NỘI - 2025

TÓM TẮT

Tóm tắt: Đồ án này nghiên cứu ứng dụng mạng nơ-ron tích chập (CNN) kết hợp với dữ liệu viễn thám đa nguồn từ vệ tinh Sentinel-1 và Sentinel-2 để phát hiện và phân loại biến động rừng tại tỉnh Cà Mau — khu vực rừng ngập mặn quan trọng bậc nhất tại Việt Nam. Nghiên cứu sử dụng 27 đặc trưng bao gồm các kênh phổ, chỉ số thực vật (NDVI, NBR, NDMI) và dữ liệu ra-đa khẩu độ tổng hợp từ hai thời kỳ (01/2024 và 02/2025) với độ phân giải 10m.

Kiến trúc CNN nhẹ với khoảng 36,000 tham số được thiết kế, sử dụng patches 3×3 để khai thác ngữ cảnh không gian, áp dụng các kỹ thuật điều chỉnh chuẩn gồm chuẩn hóa theo lô, Dropout và phân rã trọng số để tránh quá khớp trên bộ dữ liệu thực địa gồm 2,630 điểm với 4 lớp phân loại: Rừng ổn định, Mất rừng, Phi rừng và Phục hồi rừng. Quy trình đánh giá triển khai bằng cách chia mẫu ngẫu nhiên phân tầng kết hợp kiểm định chéo 5 lần, đảm bảo phân bố cân bằng các lớp và giữ lại 20% dữ liệu làm tập test cố định.

Kết quả cho thấy mô hình đạt độ chính xác 98.86% trên tập test với ROC-AUC 99.98%, kiểm định chéo cho kết quả trung bình $98.15\% \pm 0.28\%$ chứng tỏ mô hình ổn định và có khả năng tổng quát hóa tốt. Ứng dụng thực tế phân loại toàn vùng quy hoạch lâm nghiệp Cà Mau (170,179 ha ranh giới, 162,469 ha phân loại thực tế), phát hiện 7,282 ha mất rừng (4.48%) và 4,941 ha phục hồi rừng (3.04%) trong giai đoạn nghiên cứu, đóng góp phương pháp hiệu quả cho công tác giám sát tài nguyên rừng.

Từ khóa: CNN, viễn thám, biến động rừng, Cà Mau.

LỜI CAM ĐOAN

Tôi tên là Ninh Hải Đăng, sinh viên lớp QH-2021-I/CQ-S-AE, Viện Công nghệ Hàng không Vũ trụ, Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội. Tôi xin cam đoan rằng Đồ án tốt nghiệp với đề tài “Ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau” là kết quả nghiên cứu khoa học do chính tôi thực hiện dưới sự hướng dẫn của TS. Hà Minh Cường và ThS. Hoàng Tích Phúc.

Mọi sự hỗ trợ, hướng dẫn trong quá trình thực hiện đều đã được ghi nhận và cảm ơn; các thông tin, số liệu, tài liệu tham khảo trong đồ án đều được trích dẫn đầy đủ và được phép sử dụng. Tôi xin đảm bảo rằng tất cả dữ liệu nghiên cứu và kết quả trình bày trong đồ án là trung thực và chính xác. Nếu phát hiện bất kỳ sai sót nào, tôi xin hoàn toàn chịu trách nhiệm trước cơ quan nhà trường và các cơ quan liên quan.

Sinh viên

Ninh Hải Đăng

LỜI CẢM ƠN

Đối với mỗi sinh viên, đồ án tốt nghiệp là một cột mốc quan trọng, phản ánh kết quả học tập và quá trình rèn luyện suốt thời gian tại trường đại học. Trong quá trình thực hiện đồ án, bên cạnh những nỗ lực của bản thân, em đã nhận được rất nhiều sự giúp đỡ quý báu từ các thầy cô và những người xung quanh, nhờ đó công trình này mới có thể hoàn thành.

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc tới các thầy, cô là cán bộ, giảng viên trong trường Đại học Công nghệ nói chung và Viện Công nghệ Hàng không Vũ trụ nói riêng, những người đã tạo điều kiện và truyền đạt kiến thức quý báu trong suốt thời gian học tập.

Đặc biệt, em xin gửi lời cảm ơn chân thành tới TS. Hà Minh Cường và ThS. Hoàng Tích Phúc – giảng viên Viện Công nghệ Hàng không Vũ trụ, trường Đại học Công nghệ - Đại học Quốc gia Hà Nội, những người đã tận tình hướng dẫn, chỉ bảo và đồng hành cùng em trong suốt quá trình thực hiện đồ án.

Em cũng xin trân trọng cảm ơn TS. Hoàng Việt Anh và ThS. Vũ Văn Thái – Công ty TNHH Tư vấn và Phát triển Đồng Xanh (GFD), đã hỗ trợ em trong việc cung cấp dữ liệu, cơ sở vật chất và tạo điều kiện thuận lợi để hoàn thành nghiên cứu.

Cuối cùng, em xin gửi lời cảm ơn sâu sắc tới gia đình, bạn bè và các đồng nghiệp tại công ty đã luôn động viên, chia sẻ và đồng hành cùng em trong suốt quá trình học tập và thực hiện đồ án.

Mặc dù đã rất cố gắng, song do những hạn chế về mặt thời gian và kinh nghiệm, đồ án tốt nghiệp này chắc chắn sẽ không tránh khỏi những thiếu sót. Em kính mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô để bản thân có thể hoàn thiện hơn nữa trong tương lai.

Em xin trân trọng cảm ơn!

MỤC LỤC

TÓM TẮT	i
LỜI CAM ĐOAN	ii
LỜI CẢM ƠN	iii
MỤC LỤC	iv
DANH MỤC HÌNH ẢNH	vii
DANH MỤC BẢNG	ix
DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT	x
MỞ ĐẦU	1
1. Đặt vấn đề	1
2. Mục tiêu và nội dung nghiên cứu	2
3. Đối tượng và phạm vi nghiên cứu	2
4. Quan điểm và phương pháp nghiên cứu	3
5. Ý nghĩa khoa học và thực tiễn của đề tài	4
6. Cấu trúc của đồ án	4
Chương 1 Cơ sở lý thuyết của bài toán giám sát biến động rừng	5
1.1. Rừng và biến động rừng	5
1.1.1. Tình hình mất rừng trên thế giới	5
1.1.2. Tình hình mất rừng tại Việt Nam	8
1.2. Viễn thám	9
1.2.1. Nguyên lý viễn thám	9

1.2.2. Chương trình Copernicus và vệ tinh Sentinel	10
1.2.3. Các chỉ số thực vật viễn thám	12
1.2.4. Giám sát biến động rừng và tích hợp đa nguồn dữ liệu	13
1.3. Học sâu	14
1.3.1. Kiến trúc mạng nơ-ron tích chập	14
1.3.2. Huấn luyện mạng nơ-ron	15
1.3.3. Ứng dụng CNN trong phân loại ảnh viễn thám	17
1.4. Các nghiên cứu liên quan	17
1.4.1. Sự phát triển của các phương pháp giám sát biến động rừng	18
1.4.2. Nghiên cứu trên thế giới	19
1.4.3. Nghiên cứu tại Việt Nam	20
1.4.4. Khoảng trống nghiên cứu và điểm mới của đồ án	20
Chương 2 Cơ sở dữ liệu và Phương pháp nghiên cứu	22
2.1. Cơ sở dữ liệu	22
2.1.1. Dữ liệu viễn thám Sentinel	22
2.1.2. Thu thập dữ liệu trên Google Earth Engine	22
2.2. Phương pháp nghiên cứu	27
2.2.1. Trích xuất đặc trưng	28
2.2.2. Chuẩn bị mẫu huấn luyện	29
2.2.3. Kiến trúc mô hình CNN	29
2.2.4. Huấn luyện mô hình	31
2.2.5. Áp dụng mô hình	32
Chương 3 Kết quả thực nghiệm ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau	33
3.1. Thiết lập thực nghiệm	33
3.1.1. Khu vực nghiên cứu	33

3.1.2. Dữ liệu thực địa tại Cà Mau	35
3.1.3. Cấu hình phần cứng và phần mềm	38
3.1.4. Phân chia dữ liệu	38
3.2. Thủ nghiệm mô hình	39
3.2.1. Ảnh hưởng của Patch Size	39
3.2.2. Ảnh hưởng của nguồn dữ liệu	40
3.3. Kết quả	42
3.3.1. Kết quả huấn luyện mô hình CNN	42
3.3.2. Kết quả phân loại toàn bộ vùng nghiên cứu	49
3.3.3. So sánh với các nghiên cứu khác	53
3.3.4. Đánh giá tổng quan	55
KẾT LUẬN VÀ KIẾN NGHỊ	57
TÀI LIỆU THAM KHẢO	61

DANH MỤC HÌNH ẢNH

Hình 1.1 Các mặt trận mất rừng trọng điểm tại khu vực Mỹ Latinh. (Nguồn: WWF, 2021)	6
Hình 1.2 Các mặt trận mất rừng trọng điểm tại Châu Phi và Đông Nam Á. (Nguồn: WWF, 2021)	7
Hình 1.3 Biến động độ che phủ rừng Việt Nam giai đoạn 1990-2020	9
Hình 1.4 Nguyên lý viễn thám bị động và chủ động	10
Hình 2.1 Các băng quang học, chỉ số thực vật và dữ liệu ra-đa kỳ trước (T1 - 01/2024)	25
Hình 2.2 Các băng quang học, chỉ số thực vật và dữ liệu ra-đa kỳ sau (T2 - 02/2025)	26
Hình 2.3 Sơ đồ quy trình phương pháp nghiên cứu phát hiện biến động rừng . .	27
Hình 2.4 Kiến trúc mô hình mạng nơ-ron tích chập (CNN) được sử dụng trong nghiên cứu	30
Hình 3.1 Bản đồ lớp phủ bề mặt khu vực tỉnh Cà Mau.	34
Hình 3.2 Bản đồ phân bố không gian các điểm dữ liệu thực địa trên khu vực nghiên cứu tỉnh Cà Mau	36
Hình 3.3 Phân bố các đặc trưng delta theo lớp biến động rừng	37
Hình 3.4 So sánh Accuracy theo các Patch Size	39
Hình 3.5 So sánh Accuracy theo các nguồn dữ liệu	41
Hình 3.6 Diễm biến loss và accuracy trong quá trình huấn luyện Fold 1	42
Hình 3.7 Diễm biến loss và accuracy trong quá trình huấn luyện Fold 2	43
Hình 3.8 Diễm biến loss và accuracy trong quá trình huấn luyện Fold 3	43
Hình 3.9 Diễm biến loss và accuracy trong quá trình huấn luyện Fold 4	43
Hình 3.10 Diễm biến loss và accuracy trong quá trình huấn luyện Fold 5	44

Hình 3.11	Điễn biến loss và accuracy trong quá trình huấn luyện mô hình cuối cùng (80% dữ liệu)	45
Hình 3.12	So sánh Accuracy giữa các fold trong Cross Validation	46
Hình 3.13	Confusion Matrix dạng heatmap trên tập kiểm tra (n=526, Accuracy: 98.86%)	47
Hình 3.14	Đường cong ROC và điểm AUC cho các lớp phân loại (AUC trung bình macro: 0.9998)	48
Hình 3.15	Bản đồ phân loại biến động rừng tỉnh Cà Mau	50
Hình 3.16	Bản đồ phân loại biến động rừng khu vực Vườn Quốc gia Mũi Cà Mau	51
Hình 3.17	Tỷ lệ diện tích các lớp phân loại	52
Hình 3.18	So sánh Accuracy với các nghiên cứu trước đó	54
Hình 3.19	Giao diện ứng dụng web Google Earth Engine hiển thị kết quả phân loại biến động rừng tỉnh Cà Mau	58

DANH MỤC BẢNG

Bảng 1.1	So sánh thông số kỹ thuật giữa Sentinel-1 và Sentinel-2	11
Bảng 1.2	Tổng hợp các chỉ số thực vật sử dụng trong nghiên cứu	13
Bảng 1.3	So sánh các phương pháp giám sát biến động rừng qua các giai đoạn . .	19
Bảng 1.4	Tổng hợp các nghiên cứu tiêu biểu trên thế giới	20
Bảng 2.1	Tổng quan dữ liệu viễn thám sử dụng	22
Bảng 2.2	Chi tiết 27 đặc trưng sử dụng trong mô hình	28
Bảng 2.3	Chi tiết số tham số huấn luyện của mô hình CNN	31
Bảng 2.4	Cấu hình siêu tham số huấn luyện	31
Bảng 3.1	Thống kê dữ liệu thực địa theo lớp biến động	35
Bảng 3.2	Phân bố dữ liệu theo tập huấn luyện và kiểm tra	39
Bảng 3.3	So sánh các kích thước patch	39
Bảng 3.4	Nghiên cứu loại trừ các nguồn dữ liệu (Ablation Study)	40
Bảng 3.5	Tổng hợp kết quả huấn luyện 5-Fold Cross Validation	44
Bảng 3.6	Kết quả kiểm định chéo 5 phần (5-Fold Cross Validation)	45
Bảng 3.7	Các chỉ số đánh giá trên tập kiểm tra (526 mẫu)	46
Bảng 3.8	Phân tích chi tiết từng lớp	47
Bảng 3.9	Phân bố diện tích theo lớp phân loại	49
Bảng 3.10	So sánh với các nghiên cứu trong tài liệu	54
Bảng 3.11	So sánh kết quả với Giám sát rừng toàn cầu (GFW)	55

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Từ	Viết tắt	Dịch - Nghĩa
Ablation Study	-	Nghiên cứu loại trừ (phân tích ảnh hưởng từng thành phần)
Accuracy	-	Độ chính xác tổng thể (tỷ lệ dự đoán đúng trên tổng số mẫu)
Activation Function	-	Hàm kích hoạt (hàm phi tuyến trong mạng nơ-ron)
AdamW	-	Thuật toán tối ưu Adam với phân rã trọng số tách rời
Artificial Intelligence	AI	Trí tuệ nhân tạo
Backscatter	-	Tán xạ ngược (năng lượng radar phản hồi về cảm biến)
Batch Normalization	BN	Chuẩn hóa theo lô (chuẩn hóa đầu vào mỗi lớp theo mini-batch)
Bi-temporal	-	Hai thời điểm (phân tích so sánh hai thời kỳ)
C-band	-	Băng tần C (bước sóng radar 4-8 GHz, xuyên qua mây)
Classification	-	Phân loại (gán nhãn cho đối tượng)
Compute Unified Device Architecture	CUDA	Nền tảng tính toán song song của NVIDIA trên GPU
Confusion Matrix	-	Ma trận nhầm lẫn (bảng so sánh dự đoán và thực tế)
Convolutional Neural Network	CNN	Mạng nơ-ron tích chập
Cross Validation	CV	Kiểm định chéo (đánh giá mô hình trên nhiều phần dữ liệu)
CrossEntropyLoss	-	Hàm mất mát entropy chéo (độ sai khác phân phối xác suất)

Deep Learning	DL	Học sâu (học máy với nhiều lớp ẩn)
Deforestation	-	Mất rừng (chuyển đổi từ rừng sang phi rừng)
Dropout	-	Loại bỏ ngẫu nhiên (tắt ngẫu nhiên một số nơ-ron khi huấn luyện)
Early Stopping	-	Dừng sớm (ngừng huấn luyện khi validation loss không giảm)
European Space Agency	ESA	Cơ quan Vũ trụ Châu Âu
European Union	EU	Liên minh Châu Âu
F1-Score	-	Điểm F1 (trung bình điều hòa của độ chuẩn xác và độ phủ)
False Negative	FN	Âm tính giả (dự đoán âm nhưng thực tế dương)
False Positive	FP	Dương tính giả (dự đoán dương nhưng thực tế âm)
False Positive Rate	FPR	Tỷ lệ dương tính giả
Feature	-	Đặc trưng (thuộc tính đầu vào của mô hình)
Feature Extraction	-	Trích xuất đặc trưng (rút trích thông tin từ dữ liệu thô)
Feature Map	-	Bản đồ đặc trưng (đầu ra của lớp tích chập)
Kernel	-	Bộ lọc/Nhân tích chập (ma trận trọng số trượt qua ảnh)
Fold	-	Phần gập (một phần dữ liệu trong Cross Validation)
Food and Agriculture Organization	FAO	Tổ chức Lương thực và Nông nghiệp Liên Hợp Quốc
Forest Change Detection	-	Phát hiện biến động rừng
Fully Connected Layer	FC	Lớp kết nối đầy đủ (mỗi nơ-ron kết nối với tất cả nơ-ron lớp trước)

Geographic Information System	GIS	Hệ thống thông tin địa lý
Global Average Pooling	GAP	Gộp trung bình toàn cục (lấy trung bình toàn bộ bản đồ đặc trưng)
Global Forest Watch	GFW	Giám sát rừng toàn cầu
Graphics Processing Unit	GPU	Bộ xử lý đồ họa (phản ứng tính toán song song)
Ground Truth	-	Dữ liệu mẫu (nhân thực tế dùng để huấn luyện và đánh giá mô hình, thường thu thập từ khảo sát thực địa hoặc giải đoán ảnh)
Hyperparameter	-	Siêu tham số (tham số cấu hình trước khi huấn luyện)
Interferometric Wide	IW	Chế độ giao thoa rộng (chế độ chụp chính của Sentinel-1)
Intergovernmental Panel on Climate Change	IPCC	Ủy ban Liên chính phủ về Biến đổi Khí hậu
Learning Rate	LR	Tốc độ học (bước cập nhật trọng số mỗi lần lặp)
Lightweight	-	Kiến trúc nhẹ (mô hình có ít tham số, tính toán nhanh)
Logits	-	Giá trị logit (đầu ra thô của mạng trước khi áp dụng softmax)
Machine Learning	ML	Học máy
Mangrove Forest	-	Rừng ngập mặn
Multi-Layer Perceptron	MLP	Perceptron đa lớp (mạng nơ-ron nhiều lớp kết nối đầy đủ)
Multispectral	-	Đa phổ (ảnh chụp ở nhiều dải bước sóng)
Near-Infrared	NIR	Cận hồng ngoại (bước sóng 0.7–1.4 μm)
Non-forest	-	Phi rừng (vùng không có rừng che phủ)

Normalized Burn Ratio	NBR	Chỉ số cháy chuẩn hóa (phát hiện vùng cháy rừng)
Normalized Difference Moisture Index	NDMI	Chỉ số độ ẩm chuẩn hóa (đánh giá độ ẩm thực vật)
Normalized Difference Vegetation Index	NDVI	Chỉ số thực vật chuẩn hóa (đánh giá mức độ xanh tươi)
Optical	-	Quang học (ảnh vệ tinh dùng ánh sáng khả kiến và hồng ngoại)
Overfitting	-	Quá khớp (mô hình học thuộc dữ liệu huấn luyện, kém tổng quát)
Padding	-	Đệm viền (thêm pixel xung quanh ảnh khi tích chập)
Parameter	-	Tham số (trọng số học được trong quá trình huấn luyện)
Patch	-	Mảnh ảnh (vùng ảnh nhỏ trích xuất từ ảnh gốc)
Pixel	-	Điểm ảnh (đơn vị nhỏ nhất của ảnh số)
Polarization	-	Phân cực (hướng dao động của sóng radar: VV, VH)
Pooling	-	Gộp (giảm kích thước không gian của feature map)
Precision	-	Độ chuẩn xác (tỷ lệ dự đoán dương đúng trên tổng dự đoán dương)
Prediction	-	Dự đoán (kết quả đầu ra của mô hình)
Raster	-	Dữ liệu raster (ảnh dạng lưới điểm ảnh)
Recall	-	Độ phủ (tỷ lệ phát hiện đúng trên tổng số thực tế dương)
Receiver Operating Characteristic	ROC	Đường cong ROC (biểu đồ đánh giá khả năng phân loại)

Rectified Linear Unit	ReLU	Hàm ReLU (hàm kích hoạt: $f(x) = \max(0, x)$)
Reforestation	-	Phục hồi rừng (tái sinh hoặc trồng lại rừng)
Regularization	-	Điều chuẩn (kỹ thuật giảm overfitting)
Remote Sensing	-	Viễn thám (thu thập thông tin từ xa qua vệ tinh/máy bay)
ROC-AUC	-	Diện tích dưới đường cong ROC (đo khả năng phân biệt lớp)
Scheduler	-	Bộ điều chỉnh tốc độ học (thay đổi learning rate theo epoch)
Short-Wave Infrared	SWIR	Hồng ngoại sóng ngắn (bước sóng 1.4–3 μm)
Softmax	-	Hàm softmax (chuyển logits thành phân phối xác suất)
Spectral Signature	-	Phổ phản xạ đặc trưng (đặc điểm phản xạ theo bước sóng)
Stratified	-	Phân tầng (chia dữ liệu giữ nguyên tỷ lệ các lớp)
Synthetic Aperture Radar	SAR	Radar khẩu độ tổng hợp (cảm biến chủ động, hoạt động mọi thời tiết)
Test Set	-	Tập kiểm tra (dữ liệu đánh giá cuối cùng, không dùng khi huấn luyện)
True Positive Rate	TPR	Tỷ lệ dương tính thật (độ nhạy/độ phủ)
Training	-	Huấn luyện (quá trình học tham số từ dữ liệu)
Universal Mercator	Transverse UTM	Hệ tọa độ UTM (phép chiếu bắn đồ chia thành 60 múi)
Validation	-	Xác thực (đánh giá mô hình trong quá trình huấn luyện)

Weight Decay	-	Phân rã trọng số (thêm phạt L2 vào hàm mất mát)
World Geodetic System	WGS	Hệ trắc địa thế giới (hệ tọa độ toàn cầu, WGS84)

MỞ ĐẦU

1. Đặt vấn đề

Rừng là một hệ sinh thái bao gồm chủ yếu là cây cối, thực vật và động vật sống cùng nhau trong một môi trường phức tạp. Theo định nghĩa của Tổ chức Nông nghiệp và Lương thực Liên Hợp Quốc (FAO), rừng là vùng đất có diện tích tối thiểu 0.5 ha với độ che phủ tán cây trên 10%, chiều cao cây tối thiểu 5 mét khi trưởng thành, và không phải là đất nông nghiệp hoặc đô thị [12]. Rừng bao phủ khoảng 31% diện tích đất liền toàn cầu và đóng vai trò quan trọng trong việc duy trì cân bằng sinh thái, điều hòa khí hậu thông qua hấp thụ CO₂ và thải oxy, lưu giữ carbon, bảo tồn đa dạng sinh học, điều tiết nguồn nước và chống xói mòn đất, đồng thời cung cấp tài nguyên thiên nhiên và sinh kế cho hàng tỷ người trên thế giới. Tùy theo vị trí địa lý và điều kiện khí hậu, rừng được phân loại thành nhiều kiểu khác nhau như rừng nhiệt đới, rừng ôn đới, rừng phuong bắc (taiga), rừng ngập mặn, và rừng tràm. Trong đó, rừng ngập mặn là hệ sinh thái đặc biệt quan trọng ở các vùng ven biển nhiệt đới, có khả năng lưu giữ carbon cao gấp 3–5 lần so với rừng nhiệt đới trên cạn [5, 9].

Tuy nhiên, tình trạng mất rừng đang diễn ra nghiêm trọng trên toàn cầu, đặc biệt tại các quốc gia đang phát triển. Theo báo cáo “Global Forest Resources Assessment 2020” của FAO [12], thế giới đã mất khoảng 178 triệu ha rừng trong giai đoạn 1990–2020, tương đương diện tích của Libya.

Tại Việt Nam, mặc dù độ che phủ rừng đã tăng từ 37% (năm 2000) lên 42% (năm 2020) nhờ các chương trình trồng rừng, nhưng tình trạng suy thoái và mất rừng tự nhiên vẫn đáng báo động, đặc biệt tại các tỉnh ven biển và đồng bằng sông Cửu Long. Tỉnh Cà Mau, nằm ở cực Nam Tổ Quốc, sở hữu hệ sinh thái rừng ngập mặn quan trọng nhưng đang phải đối mặt với áp lực từ nuôi trồng thủy sản, xâm nhập mặn và biến đổi khí hậu.

Phương pháp giám sát rừng truyền thống dựa trên điều tra thực địa tốn kém thời gian, chi phí và khó áp dụng cho diện tích rộng. Công nghệ viễn thám vệ tinh cung cấp giải pháp hiệu quả, cho phép giám sát liên tục, diện rộng với chi phí hợp lý. Chương trình Copernicus của Liên minh Châu Âu cung cấp dữ liệu miễn phí từ các vệ tinh Sentinel-1 và Sentinel-2 phù hợp cho giám sát rừng nhiệt đới.

Trong những năm gần đây, trí tuệ nhân tạo và học sâu đã đạt được những bước tiến

vượt bậc trong xử lý ảnh và nhận dạng mẫu. Mạng nơ-ron tích chập đặc biệt hiệu quả trong phân loại ảnh nhờ khả năng tự động học đặc trưng không gian từ dữ liệu thô.

Xuất phát từ nhu cầu thực tiễn về giám sát rừng hiệu quả và xu hướng ứng dụng công nghệ AI tiên tiến, đồ án này lựa chọn đề tài “**Ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau**” nhằm phát triển mô hình phát hiện mất rừng với độ chính xác cao.

2. Mục tiêu và nội dung nghiên cứu

Mục tiêu tổng quát của đồ án là phát triển mô hình học sâu dựa trên kiến trúc CNN để phát hiện và phân loại các khu vực biến động rừng từ ảnh vệ tinh đa nguồn (Sentinel-1 và Sentinel-2) tại tỉnh Cà Mau.

Để đạt được mục tiêu tổng quát, đề tài tập trung vào năm mục tiêu cụ thể. Thứ nhất, xây dựng bộ dữ liệu huấn luyện thông qua thu thập và xử lý dữ liệu ảnh vệ tinh Sentinel-1/2 đa thời gian, kết hợp với dữ liệu thực địa để tạo bộ dữ liệu huấn luyện chất lượng cao. Thứ hai, thiết kế kiến trúc CNN phù hợp với bộ dữ liệu có quy mô vừa phải (khoảng 2,600 mẫu). Thứ ba, triển khai phương pháp phân chia dữ liệu khoa học bằng cách chia mẫu ngẫu nhiên phân tầng kết hợp với kiểm định chéo 5 lần. Thứ tư, huấn luyện và tối ưu hóa mô hình bằng các kỹ thuật huấn luyện tiên tiến. Thứ năm, áp dụng mô hình để phân loại biến động rừng toàn bộ khu vực nghiên cứu.

Đồ án thực hiện các nội dung chính sau: (1) Tổng quan tài liệu về biến động rừng, công nghệ viễn thám và các phương pháp học sâu trong giám sát rừng; (2) Thu thập và tiền xử lý dữ liệu ảnh vệ tinh Sentinel-1/2 cho khu vực nghiên cứu; (3) Trích xuất đặc trưng phổ và chỉ số thực vật từ dữ liệu đa thời gian; (4) Xây dựng bộ dữ liệu mẫu huấn luyện với 4 lớp biến động rừng; (5) Thiết kế và huấn luyện mô hình CNN cho bài toán phân loại; (6) Đánh giá hiệu năng mô hình và phân loại biến động rừng toàn vùng nghiên cứu.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đồ án là biến động rừng tại khu vực ranh giới lâm nghiệp tỉnh Cà Mau. Các trạng thái biến động rừng được phân loại thành bốn nhóm: Rừng ổn định (Forest Stable), Mất rừng (Deforestation), Phi rừng (Non-forest) và Phục hồi rừng (Reforestation).

Về không gian, nghiên cứu được thực hiện trên khu vực ranh giới lâm nghiệp tỉnh Cà Mau (theo địa giới hành chính mới có hiệu lực từ ngày 01/07/2025, sau khi sáp nhập tỉnh Cà Mau cũ và tỉnh Bạc Liêu) với tổng diện tích 170,179 ha (tương đương 1,701.79 km²). Khu vực này bao gồm các loại hình rừng tự nhiên và rừng trồng, trong đó chủ yếu là rừng ngập mặn và rừng phòng hộ ven biển. Về thời gian, dữ liệu sử dụng bao gồm ảnh vệ tinh Sentinel-1 và Sentinel-2 trong giai đoạn từ tháng 01/2024 đến tháng 02/2025. Diện tích thực tế được phân loại là 162,469 ha (khoảng 95.5% diện tích ranh giới, phần còn lại bị loại do mây che hoặc dữ liệu không hợp lệ).

4. Quan điểm và phương pháp nghiên cứu

Đồ án được thực hiện dựa trên quan điểm hệ thống, xem xét biến động rừng như một quá trình phức tạp chịu tác động của nhiều yếu tố tự nhiên và nhân sinh. Nghiên cứu tiếp cận theo hướng tích hợp đa nguồn dữ liệu viễn thám (ra-đa và quang học) để khai thác tối đa thông tin về trạng thái và biến động của lớp phủ rừng. Đồng thời, nghiên cứu áp dụng quan điểm thực tiễn, hướng đến phát triển giải pháp có khả năng ứng dụng trong công tác quản lý và giám sát rừng.

Đồ án áp dụng phương pháp nghiên cứu thực nghiệm, kết hợp giữa viễn thám và học sâu, bao gồm năm giai đoạn chính.

Giai đoạn thứ nhất là thu thập và tiền xử lý dữ liệu, trong đó ảnh vệ tinh Sentinel-1 và Sentinel-2 được thu thập từ nền tảng Google Earth Engine. Dữ liệu Sentinel-2 sử dụng sản phẩm đã hiệu chỉnh khí quyển (Level-2A) kết hợp loại bỏ pixel bị mây che phủ, còn dữ liệu Sentinel-1 đã được ESA tiền xử lý bao gồm hiệu chỉnh quỹ đạo và loại bỏ nhiễu.

Giai đoạn thứ hai là trích xuất đặc trưng, bao gồm việc tính toán các kênh phổ và chỉ số thực vật từ dữ liệu Sentinel-2 (B4, B8, B11, B12, NDVI, NBR, NDMI) và các kênh tán xạ ngược (backscatter) từ Sentinel-1 (VV, VH) cho hai thời kỳ cùng với giá trị delta, tổng hợp 27 đặc trưng cho mỗi điểm mẫu.

Giai đoạn thứ ba là chuẩn bị mẫu huấn luyện, trong đó bộ dữ liệu 2,630 mẫu với 4 lớp biến động rừng được xây dựng. Kỹ thuật chuẩn hóa dữ liệu được áp dụng và dữ liệu được phân chia theo tỷ lệ 80% huấn luyện (với kiểm định chéo 5 lần) và 20% kiểm tra.

Giai đoạn thứ tư là huấn luyện mô hình, bao gồm thiết kế kiến trúc CNN nhẹ với 2 lớp tích chập, sử dụng các kỹ thuật điều chỉnh (Dropout, chuẩn hóa theo lô, phân rã trọng số) và áp dụng kiểm định chéo 5 lần để đánh giá độ ổn định của mô hình.

Giai đoạn thứ năm là áp dụng mô hình để phân loại toàn vùng nghiên cứu bằng phương pháp sliding window, tổng hợp kết quả và đánh giá độ chính xác.

5. Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, đồ án đề xuất kiến trúc CNN nhẹ và hiệu quả cho bài toán phân loại ảnh viễn thám với bộ dữ liệu quy mô vừa phải. Nghiên cứu chứng minh hiệu quả của việc tích hợp đa nguồn dữ liệu (ra-đa khâu độ tổng hợp và quang học đa phô) trong phát hiện biến động rừng, đồng thời đóng góp vào hướng nghiên cứu ứng dụng học sâu trong lĩnh vực viễn thám và giám sát môi trường.

Về ý nghĩa thực tiễn, đồ án cung cấp mô hình giám sát biến động rừng với độ chính xác cao (trên 98%), giúp giảm đáng kể thời gian và chi phí so với phương pháp điều tra thực địa truyền thống. Kết quả nghiên cứu có thể hỗ trợ các cơ quan quản lý lâm nghiệp trong việc giám sát và bảo vệ rừng tại tỉnh Cà Mau. Ngoài ra, mô hình có thể mở rộng áp dụng cho các khu vực khác có điều kiện tương tự.

6. Cấu trúc của đồ án

Nội dung chính của đồ án gồm 3 chương như sau:

Chương 1: Cơ sở lý thuyết của bài toán giám sát biến động rừng

Chương 2: Cơ sở dữ liệu và Phương pháp nghiên cứu

Chương 3: Kết quả thực nghiệm ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT CỦA BÀI TOÁN GIÁM SÁT BIẾN ĐỘNG RỪNG

1.1. Rừng và biến động rừng

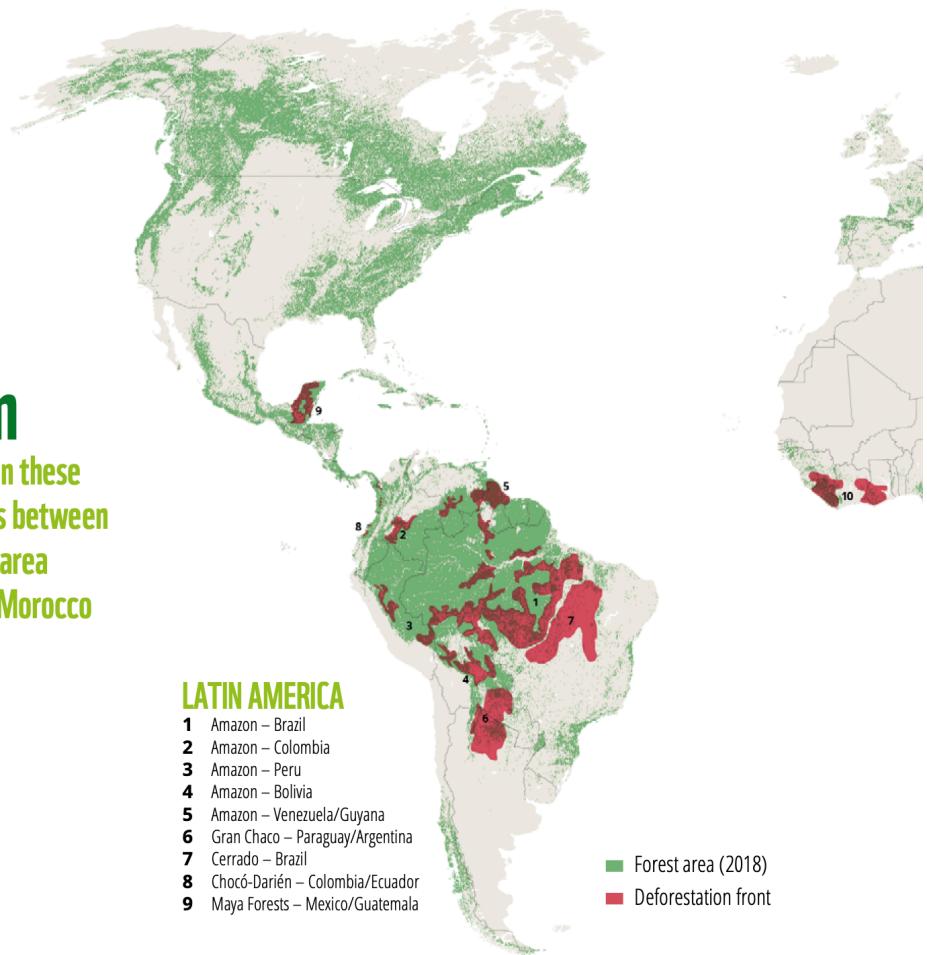
1.1.1. Tình hình mất rừng trên thế giới

Tốc độ mất rừng toàn cầu vẫn đang ở mức báo động. Theo báo cáo “Global Forest Resources Assessment 2020” của FAO [12], tổng diện tích rừng bị phá từ năm 1990 đến 2020 ước tính khoảng 420 triệu ha. Mặc dù tốc độ mất rừng ròng đã có xu hướng giảm trong thập kỷ gần đây nhờ các nỗ lực trồng rừng và phục hồi rừng, việc chuyển đổi đất rừng tự nhiên sang mục đích nông nghiệp, chăn nuôi và phát triển cơ sở hạ tầng vẫn diễn ra với quy mô lớn và phức tạp. Đáng lo ngại hơn, phần lớn diện tích rừng bị mất là rừng nguyên sinh — loại rừng có giá trị sinh thái cao nhất và gần như không thể phục hồi được.

Sự suy giảm diện tích rừng tập trung nghiêm trọng nhất tại các khu vực nhiệt đới và cận nhiệt đới, nơi chứa đựng hơn một nửa đa dạng sinh học của Trái Đất. Theo báo cáo “Deforestation Fronts: Drivers and Responses in a Changing World” của WWF công bố năm 2021 [53], trong giai đoạn 2004–2017, hơn 43 triệu ha rừng đã bị xóa sổ tại 24 “mặt trận phá rừng” (deforestation fronts) trên thế giới — diện tích tương đương với quy mô lãnh thổ Morocco. Các mặt trận này chiếm hơn một nửa (52%) tổng diện tích rừng bị mất tại khu vực Mỹ Latinh, Châu Phi cận Sahara, Đông Nam Á và Châu Đại Dương trong cùng giai đoạn. Nông nghiệp quy mô lớn được xác định là nguyên nhân trực tiếp lớn nhất gây mất rừng trên toàn thế giới, trong đó chăn nuôi gia súc là tác nhân đơn lẻ gây mất rừng nhiệt đới nhiều nhất.

Trong số 24 mặt trận, 9 mặt trận nằm tại Mỹ Latinh và đây là khu vực chịu tổn thất nặng nề nhất với 26.9 triệu ha rừng bị mất — chiếm gần 2/3 tổng diện tích mất rừng toàn cầu. Rừng Amazon tại Brazil dẫn đầu với 15.5 triệu ha bị phá hủy, tiếp theo là Gran Chaco (5.2 triệu ha), Cerrado của Brazil (3 triệu ha) và vùng đất thấp Bolivia (1.5 triệu ha). Rừng Amazon — được mệnh danh là “lá phổi xanh của Trái Đất” — đang bị thu hẹp với tốc độ đáng báo động do áp lực từ ngành chăn nuôi gia súc quy mô lớn, trồng đậu nành xuất khẩu, khai thác gỗ và mở rộng cơ sở hạ tầng. Hình 1.1 minh họa các mặt trận mất rừng trọng điểm tại khu vực này.

**Over
43 million**
hectares were lost in these
deforestation fronts between
2004 and 2017, an area
roughly the size of Morocco

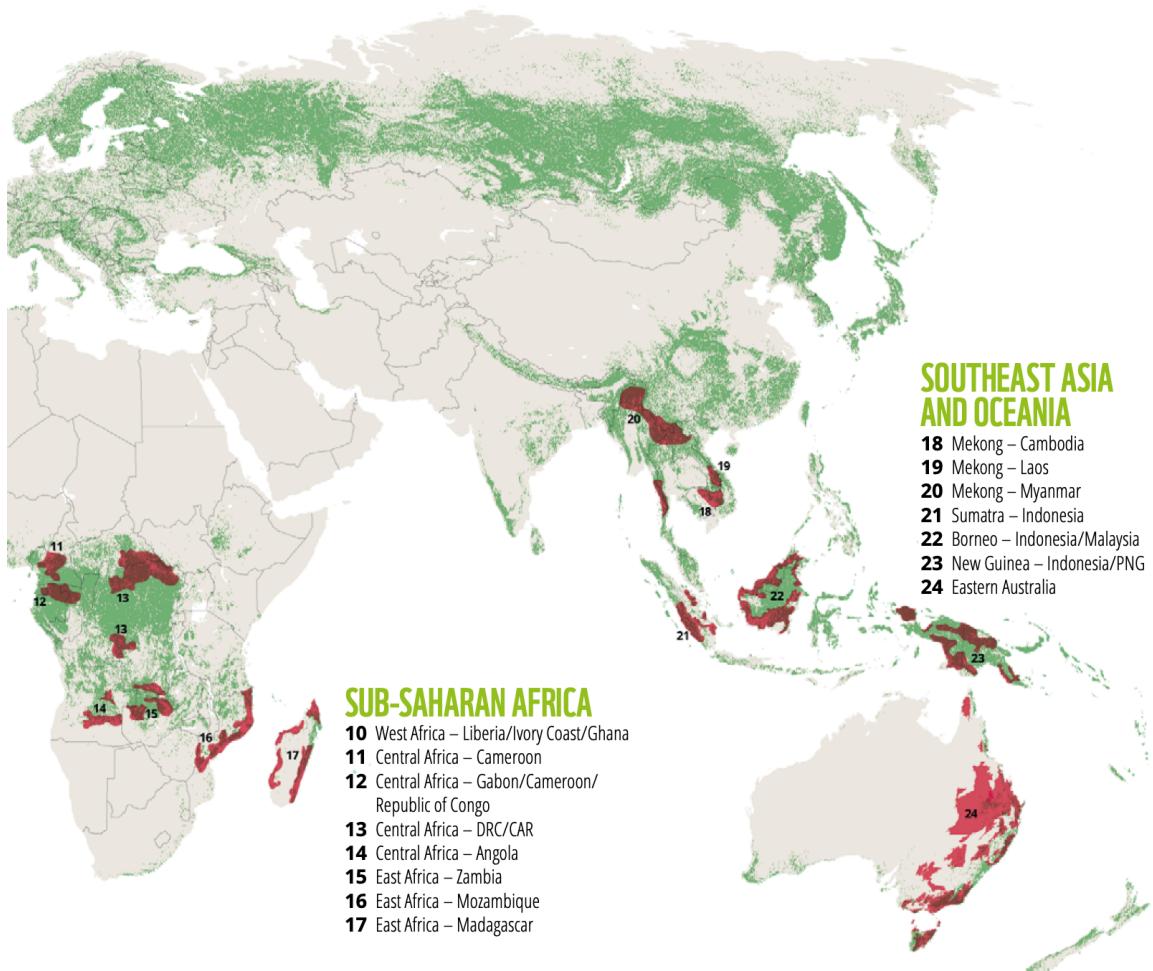


Hình 1.1: Các mặt trận mất rừng trọng điểm tại khu vực Mỹ Latinh. (Nguồn: WWF, 2021)

Không chỉ giới hạn ở Châu Mỹ, tình trạng phá rừng cũng đang diễn biến phức tạp tại các khu vực khác trên thế giới. Tại Châu Phi cận Sahara, WWF đã xác định 8 mặt trận mất rừng trọng điểm trải dài từ Tây Phi đến Đông Phi. Khu vực Tây Phi (Liberia, Bờ Biển Ngà, Ghana) đang chịu áp lực từ việc mở rộng trồng cao và khai thác gỗ. Lưu vực Congo tại Trung Phi — khu rừng nhiệt đới lớn thứ hai thế giới sau Amazon, bao gồm các quốc gia như Cameroon, Gabon, Cộng hòa Congo, CHDC Congo và Cộng hòa Trung Phi — đang đối mặt với áp lực ngày càng tăng từ hoạt động khai thác gỗ, mở rộng nông nghiệp hộ gia đình và khai khoáng. Khác với Mỹ Latinh nơi nông nghiệp thương mại quy mô lớn là nguyên nhân chính, tại Châu Phi cận Sahara, nông nghiệp tự cung tự cấp và nông nghiệp thương mại quy mô nhỏ là động lực chủ yếu gây mất rừng. Tại Đông Phi, các mặt trận mất rừng tại Zambia, Mozambique và Madagascar cũng đang diễn biến phức tạp do nhu cầu đất canh tác và sản xuất than củi.

Tại khu vực Đông Nam Á và Châu Đại Dương, 7 mặt trận mất rừng được ghi nhận

với quy mô thiệt hại đứng thứ hai sau Mỹ Latinh. Borneo (Indonesia và Malaysia) là mặt trận mất rừng lớn thứ hai thế giới với 5.8 triệu ha bị phá hủy, tiếp theo là Sumatra (2.5 triệu ha), New Guinea (1.3 triệu ha) và Myanmar (1 triệu ha). Lưu vực sông Mekong — bao gồm Cambodia, Lào và Myanmar — đang mất rừng nhanh chóng do khai thác gỗ trái phép, xây dựng đập thủy điện và mở rộng nông nghiệp. Nông nghiệp thương mại với các đồn điền cọ dầu và cao su quy mô lớn là nguyên nhân chính gây mất rừng tại khu vực này. Indonesia và Malaysia — hai quốc gia sản xuất cọ dầu lớn nhất thế giới — đã mất hàng triệu ha rừng nhiệt đới trong hai thập kỷ qua. Ngoài ra, việc đốt rừng để mở rộng đất canh tác còn gây ra các đợt khói mù nghiêm trọng, ảnh hưởng đến sức khỏe của hàng trăm triệu người trong khu vực. Đáng chú ý, miền Đông Australia cũng được xác định là một mặt trận mất rừng do các đợt cháy rừng thảm khốc và hoạt động khai hoang. Hình 1.2 thể hiện các mặt trận mất rừng trọng điểm tại hai khu vực này.



Hình 1.2: Các mặt trận mất rừng trọng điểm tại Châu Phi và Đông Nam Á. (Nguồn: WWF, 2021)

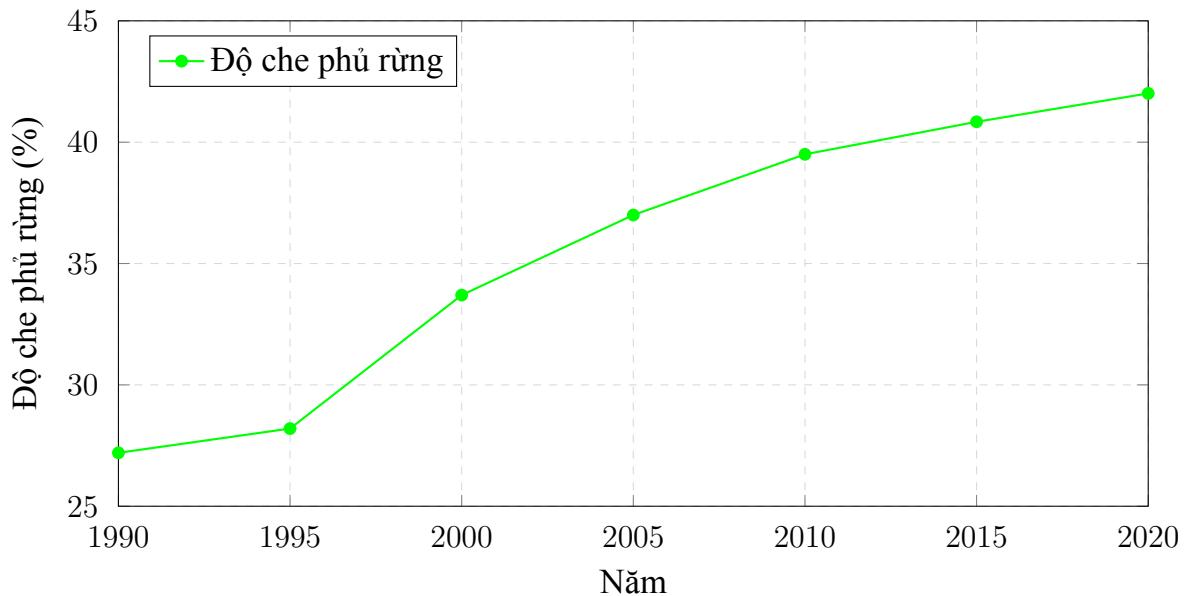
Xu hướng này vẫn tiếp diễn trong những năm gần đây. Theo Global Forest Watch [15], thế giới mất khoảng 10 triệu ha rừng nhiệt đới mỗi năm trong giai đoạn 2015–2020. Việc này không chỉ làm giảm khả năng hấp thụ CO₂ mà còn trực tiếp phát thải khí nhà kính từ việc đốt rừng và phân hủy sinh khối. Theo IPCC [26], phá rừng và thay đổi sử dụng đất đóng góp khoảng 23% tổng lượng phát thải khí nhà kính do con người gây ra, góp phần làm gia tăng hiện tượng biến đổi khí hậu toàn cầu.

1.1.2. Tình hình mất rừng tại Việt Nam

Việt Nam đã trải qua những biến đổi lớn về độ che phủ rừng trong 30 năm qua. Sau thời kỳ suy giảm nghiêm trọng (độ che phủ chỉ còn 28% vào năm 1990 do chiến tranh và khai thác bừa bãi), Việt Nam đã thực hiện nhiều chương trình phục hồi và phát triển rừng. Nhờ các chương trình như “Trồng 5 triệu ha rừng” (1998-2010), độ che phủ rừng đã tăng lên 42% vào năm 2020 [1].

Tuy nhiên, chất lượng rừng là một vấn đề đáng lo ngại. Mặc dù tổng diện tích rừng tăng từ 9.4 triệu ha (1990) lên 14.6 triệu ha (2020) chủ yếu nhờ rừng trồng (cao su, keo, thông), chất lượng rừng tự nhiên lại suy giảm đáng kể. Theo số liệu của Bộ NN&PTNT (2020), rừng tự nhiên hiện có khoảng 10.29 triệu ha, nhưng rừng nguyên sinh chỉ còn chiếm khoảng 0.25% tổng diện tích rừng [4].

Nguyên nhân chính gây mất rừng tại Việt Nam bao gồm việc chuyển đổi sang đất nông nghiệp như trồng cà phê, cao su và điều; khai thác gỗ trái phép; phát triển cơ sở hạ tầng và đô thị hóa; cháy rừng; và hoạt động nuôi trồng thủy sản, đặc biệt tại khu vực ven biển và đồng bằng sông Cửu Long.



Hình 1.3: Biến động độ che phủ rừng Việt Nam giai đoạn 1990-2020

1.2. Viễn thám

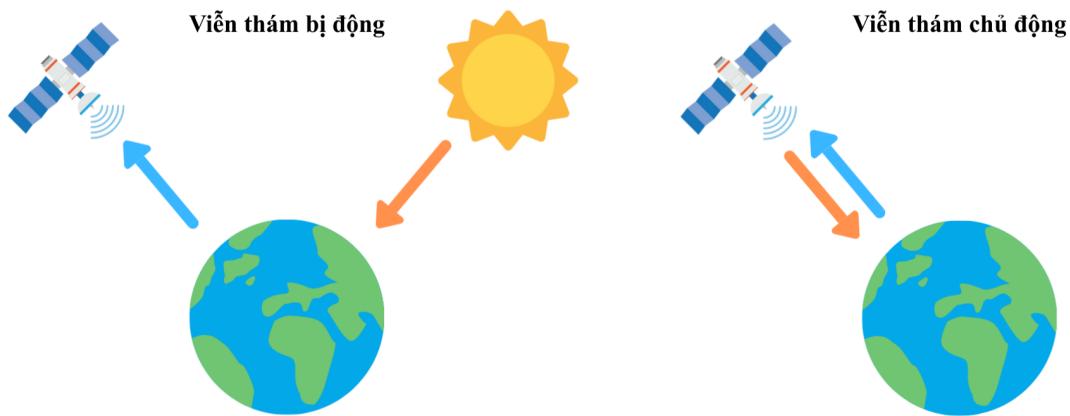
1.2.1. Nguyên lý viễn thám

Viễn thám là khoa học và kỹ thuật thu thập thông tin về một đối tượng hoặc khu vực từ xa, thường thông qua việc ghi nhận bức xạ điện từ phản xạ hoặc phát ra từ bề mặt Trái Đất [36]. Nguyên lý cơ bản của viễn thám dựa trên tương tác giữa bức xạ điện từ và các đối tượng trên bề mặt. Dựa vào nguồn năng lượng sử dụng, viễn thám được chia thành hai loại chính: viễn thám bị động (passive remote sensing) và viễn thám chủ động (active remote sensing).

Trong hệ thống viễn thám bị động, nguồn năng lượng chính là bức xạ từ Mặt Trời. Khi các sóng này truyền qua khí quyển, một phần năng lượng bị hấp thụ hoặc tán xạ. Sau đó bức xạ tương tác với bề mặt, chịu các quá trình phản xạ, hấp thụ hoặc truyền qua tùy theo đặc tính vật liệu. Tín hiệu phản xạ được vệ tinh ghi nhận bởi cảm biến và được xử lý, truyền về trạm mặt đất để phục vụ phân tích. Nguyên lý cân bằng năng lượng cho thấy năng lượng tới bằng tổng năng lượng phản xạ, hấp thụ và truyền qua.

Khác với viễn thám bị động, hệ thống viễn thám chủ động tự phát ra nguồn năng lượng điện từ hướng về phía mục tiêu và ghi nhận tín hiệu phản xạ ngược từ bề mặt. Ưu điểm chính của viễn thám chủ động là khả năng hoạt động độc lập với ánh sáng Mặt Trời, cho phép thu thập dữ liệu cả ngày lẫn đêm và trong mọi điều kiện thời tiết, kể cả khi có

mây che phủ. Radar khẩu độ tổng hợp là ví dụ điển hình của công nghệ viễn thám chủ động, sử dụng sóng vi ba có khả năng xuyên qua mây.



Hình 1.4: Nguyên lý viễn thám bị động và chủ động

Mỗi loại viễn thám có những ưu nhược điểm riêng. Viễn thám bị động, tiêu biểu như Sentinel-2, cung cấp ảnh quang học đa phổ với độ phân giải không gian và phổ cao, phù hợp cho phân loại lớp phủ đất chi tiết, nhưng bị hạn chế bởi mây và điều kiện chiếu sáng. Trong khi đó, viễn thám chủ động như Sentinel-1 hoạt động trong mọi điều kiện thời tiết, cung cấp thông tin về cấu trúc và độ ẩm bề mặt, tuy nhiên dữ liệu khó diễn giải hơn so với ảnh quang học. Sự kết hợp cả hai loại dữ liệu cho phép tận dụng ưu điểm của từng nguồn, đặc biệt quan trọng trong giám sát rừng nhiệt đới nơi mây phủ thường xuyên.

1.2.2. Chương trình Copernicus và vệ tinh Sentinel

Chương trình Copernicus của Liên minh Châu Âu là hệ thống quan sát Trái Đất toàn diện, cung cấp dữ liệu viễn thám miễn phí phục vụ nghiên cứu khoa học và giám sát môi trường. Trong nghiên cứu này, dữ liệu từ hai vệ tinh Sentinel-1 và Sentinel-2 được sử dụng nhờ tính chất bổ sung giữa cảm biến ra-đa và quang học.

Sentinel-1 là vệ tinh mang cảm biến ra-đa khẩu độ tổng hợp hoạt động ở dải sóng C-band với tần số 5.405 GHz (bước sóng 5.55 cm). Trong chế độ IW, Sentinel-1 thu nhận dữ liệu ở hai chế độ phân cực VV và VH với độ phân giải không gian 10m và độ rộng dải quét 250 km [10]. Nguyên lý hoạt động của ra-đa dựa trên việc phát xung sóng vi ba và ghi nhận tín hiệu tán xạ ngược từ bề mặt. Cường độ tán xạ ngược phụ thuộc vào độ

nhám bề mặt, hằng số điện môi và cấu trúc đối tượng. Đôi với thảm thực vật, phân cực VV nhạy với tán xạ bề mặt liên quan đến độ ẩm đất, trong khi VH nhạy với tán xạ thể tích (volume scattering) từ cấu trúc tán lá [51]. Ưu điểm của ra-đa là khả năng xuyên qua mây và hoạt động độc lập với điều kiện chiếu sáng.

Sentinel-2 mang cảm biến quang học đa phổ thu nhận ảnh ở 13 dải phổ từ vùng nhìn thấy đèn hồng ngoại sóng ngắn (443–2190 nm). Độ phân giải không gian thay đổi theo dải phổ: 10m cho các dải B2, B3, B4, B8; 20m cho B5, B6, B7, B8a, B11, B12; và 60m cho B1, B9, B10 [11]. Với 13 dải phổ bao phủ nhiều vùng bước sóng khác nhau, có thể phân biệt các loại lớp phủ đất dựa trên đặc tính phản xạ riêng biệt của từng đối tượng [31]. Dữ liệu đa phổ này đặc biệt phù hợp để tính toán các chỉ số thực vật phục vụ giám sát biến động rừng. Bảng 1.1 tổng hợp các thông số kỹ thuật chính của hai vệ tinh này.

Bảng 1.1: So sánh thông số kỹ thuật giữa Sentinel-1 và Sentinel-2

Thông số	Sentinel-1	Sentinel-2
Loại cảm biến	Ra-đa (chủ động)	Quang học (bị động)
Dải sóng	C-band (5.55 cm)	443–2190 nm
Số kênh/phân cực	2 (VV, VH)	13 dải phổ
Độ phân giải không gian	10m (IW mode)	10/20/60m
Độ rộng dải quét	250 km	290 km
Chu kỳ quay lại	6–12 ngày	5–10 ngày
Hoạt động qua mây	Có	Không
Thông tin thu nhận	Cấu trúc, độ ẩm, độ nhám	Phản xạ phổ, chỉ số thực vật

Sự kết hợp dữ liệu từ hai nguồn cảm biến mang lại lợi thế quan trọng trong giám sát rừng nhiệt đới. SAR cung cấp dữ liệu liên tục trong điều kiện mây che phủ thường xuyên, đồng thời nhạy với biến đổi cấu trúc rừng như chặt phá cây. Trong khi đó, dữ liệu quang học cung cấp thông tin quang phổ phong phú để tính toán các chỉ số thực vật và đánh giá sức khỏe thảm thực vật. Các nghiên cứu đã chứng minh việc tích hợp SAR và quang học giúp cải thiện độ chính xác phân loại từ 5–15% so với sử dụng đơn nguồn dữ liệu [22, 24].

1.2.3. Các chỉ số thực vật viễn thám

Các chỉ số thực vật (Vegetation Indices) là các công thức toán học kết hợp giá trị phản xạ từ các kênh phổ khác nhau nhằm tăng cường thông tin về thực vật và giảm nhiễu từ các yếu tố khác như đất và khí quyển. Nghiên cứu này sử dụng ba chỉ số chính là NDVI, NBR và NDMI, mỗi chỉ số khai thác các đặc tính phổ khác nhau để cung cấp thông tin bổ sung về trạng thái thực vật.

Cơ sở để xây dựng các chỉ số thực vật xuất phát từ đặc tính phản xạ phổ đặc trưng của thực vật [36]. Ở vùng ánh sáng đỏ (Red, 620–700 nm), sắc tố diệp lục trong lá hấp thụ mạnh năng lượng để thực hiện quang hợp, dẫn đến phản xạ thấp. Ngược lại, ở vùng cận hồng ngoại (NIR, 700–1100 nm), cấu trúc xôp của mô thịt lá (mesophyll) tạo ra hiện tượng tán xạ nội bộ mạnh, khiến phản xạ đạt 40–50%. Ở vùng hồng ngoại sóng ngắn (SWIR, 1100–2500 nm), nước trong lá hấp thụ mạnh bức xạ, do đó phản xạ phụ thuộc trực tiếp vào hàm lượng nước. Stress thực vật là tình trạng cây bị tác động bất lợi từ các yếu tố môi trường như thiếu nước, nhiệt độ cao, sâu bệnh hoặc thiếu dinh dưỡng, dẫn đến suy giảm hàm lượng diệp lục và nước trong lá, từ đó làm thay đổi đặc tính phản xạ phổ có thể quan sát được qua viễn thám. Sự tương phản rõ rệt giữa các vùng phổ này là nền tảng để xây dựng các chỉ số thực vật: khi thực vật khỏe mạnh, sự chênh lệch giữa phản xạ NIR cao và phản xạ Red thấp sẽ lớn; khi thực vật bị stress hoặc mất đi, sự tương phản này giảm đáng kể.

Chỉ số thực vật chuẩn hóa NDVI (Normalized Difference Vegetation Index) là chỉ số được sử dụng phổ biến nhất để đánh giá sức khỏe và mật độ thực vật [46], được tính theo công thức:

$$NDVI = \frac{NIR - Red}{NIR + Red} = \frac{B8 - B4}{B8 + B4} \quad (1.1)$$

Chỉ số này sử dụng giá trị phản xạ ở dải cận hồng ngoại NIR (B8) và dải đỏ Red (B4), khai thác sự khác biệt giữa phản xạ cao ở NIR và phản xạ thấp ở Red của thực vật xanh để định lượng mật độ và sức khỏe thực vật. Giá trị NDVI cao trong khoảng 0.3 đến 0.8 chỉ ra thực vật xanh khỏe mạnh, giá trị thấp từ 0.1 đến 0.2 tương ứng với đất trống, còn giá trị âm thường là nước.

Chỉ số cháy chuẩn hóa NBR (Normalized Burn Ratio) được thiết kế ban đầu để phát hiện khu vực cháy rừng, nhưng cũng cho thấy hiệu quả trong phát hiện mất rừng [30]. Công thức tính NBR như sau:

$$NBR = \frac{NIR - SWIR2}{NIR + SWIR2} = \frac{B8 - B12}{B8 + B12} \quad (1.2)$$

Chỉ số này sử dụng giá trị phản xạ ở dải cận hồng ngoại *NIR* (B8) và dải hồng ngoại sóng ngắn 2 *SWIR2* (B12, 2190 nm). Kênh SWIR nhạy với độ ẩm và cấu trúc thực vật, do đó khi rừng bị phá hoặc cháy, NIR giảm do mất lá xanh trong khi SWIR tăng do bề mặt khô hơn. NBR cao trong khoảng 0.3 đến 0.8 chỉ ra rừng khỏe mạnh, còn NBR thấp hoặc âm chỉ ra khu vực bị tác động.

Chỉ số độ ẩm chuẩn hóa NDMI (Normalized Difference Moisture Index) đo lường hàm lượng nước trong tán lá thực vật và là chỉ số quan trọng để phát hiện stress thực vật [14]. NDMI được tính theo công thức:

$$NDMI = \frac{NIR - SWIR1}{NIR + SWIR1} = \frac{B8 - B11}{B8 + B11} \quad (1.3)$$

Chỉ số này sử dụng giá trị phản xạ ở dải cận hồng ngoại *NIR* (B8) và dải hồng ngoại sóng ngắn 1 *SWIR1* (B11, 1610 nm). Do nước hấp thụ mạnh ở dải SWIR1, thực vật có hàm lượng nước cao sẽ cho phản xạ SWIR thấp. NDMI dương trong khoảng 0.2 đến 0.6 chỉ ra thực vật có hàm lượng nước cao, còn NDMI thấp hoặc âm chỉ ra thực vật bị stress hoặc khô. Đặc biệt, NDMI có thể phát hiện sự thay đổi độ ẩm trước khi NDVI phản ánh sự suy giảm sức khỏe thực vật, giúp cảnh báo sớm tình trạng suy thoái rừng.

Bảng 1.2: Tổng hợp các chỉ số thực vật sử dụng trong nghiên cứu

Chỉ số	Công thức	Phạm vi	Ý nghĩa
NDVI	(B8-B4)/(B8+B4)	[-1, 1]	Mật độ, sức khỏe thực vật
NBR	(B8-B12)/(B8+B12)	[-1, 1]	Phát hiện cháy/mất rừng
NDMI	(B8-B11)/(B8+B11)	[-1, 1]	Độ ẩm tán lá

1.2.4. Giám sát biến động rừng và tích hợp đa nguồn dữ liệu

Giám sát biến động rừng là quá trình xác định sự thay đổi về diện tích, cấu trúc hoặc trạng thái của rừng giữa hai hoặc nhiều thời điểm khác nhau [23]. Phương pháp này dựa trên việc so sánh các đặc trưng viễn thám thu được từ các thời điểm khác nhau.

Phương pháp phát hiện biến động dựa trên việc so sánh các đặc trưng giữa hai thời điểm, tính toán sự chênh lệch (delta) giữa “các đặc trưng trước” và “các đặc trưng sau”. Các đặc trưng thời gian bao gồm các “các đặc trưng trước” thể hiện trạng thái rừng tại thời điểm t_1 , các “các đặc trưng sau” thể hiện trạng thái rừng tại thời điểm t_2 , và các “đặc trưng delta” biểu diễn biến đổi giữa hai thời điểm.

Ví dụ với NDVI, khi $\Delta NDVI$ (hiệu NDVI sau và trước) giảm mạnh thì đó là dấu hiệu mất rừng, khi $\Delta NDVI$ xấp xỉ 0 thì vùng được xem là rừng ổn định, và khi $\Delta NDVI$ tăng mạnh thì biểu hiện tái trồng rừng.

Việc tích hợp dữ liệu ra-đa khẩu độ tổng hợp từ Sentinel-1 và dữ liệu quang học đa phổ từ Sentinel-2 mang lại nhiều lợi ích quan trọng trong giám sát rừng. Hai nguồn dữ liệu này có tính chất bổ sung cho nhau: ra-đa cung cấp thông tin về cấu trúc, độ nhám bề mặt và độ ẩm, trong khi quang học cung cấp thông tin quang phổ và các chỉ số thực vật. Sự kết hợp này còn giúp khắc phục hạn chế của từng loại cảm biến, trong đó ra-đa hoạt động hiệu quả trong điều kiện mây mù thường xuyên của rừng nhiệt đới, còn quang học cung cấp dữ liệu trực quan dễ phiên giải hơn. Nhiều nghiên cứu đã chứng minh rằng việc kết hợp ra-đa và quang học giúp tăng độ chính xác từ 5 đến 10% so với việc sử dụng mỗi nguồn dữ liệu riêng lẻ [22, 24]. Ngoài ra, sự tích hợp này cho phép phát hiện biến động đa chiều: ra-đa nhạy với biến đổi cấu trúc như chặt cây, trong khi quang học nhạy với biến đổi quang phổ phản ánh sức khỏe thực vật.

1.3. Học sâu

Mạng nơ-ron tích chập (CNN) đã trở thành công cụ chủ đạo trong xử lý ảnh viễn thám và phân loại lớp phủ đất [54, 55]. Phần này trình bày các khái niệm nền tảng về học sâu, làm cơ sở lý thuyết cho kiến trúc mô hình được đề xuất trong Chương 2.

1.3.1. Kiến trúc mạng nơ-ron tích chập

Perceptron là đơn vị tính toán cơ bản của mạng nơ-ron nhân tạo. Mỗi perceptron thực hiện phép biến đổi tuyến tính kết hợp với hàm kích hoạt phi tuyến theo công thức:

$$y = f(\mathbf{w}^T \mathbf{x} + b) \quad (1.4)$$

trong đó $\mathbf{x} \in \mathbb{R}^n$ là vector đầu vào, $\mathbf{w} \in \mathbb{R}^n$ là vector trọng số, $b \in \mathbb{R}$ là độ lệch, $f(\cdot)$ là hàm kích hoạt phi tuyến, và y là đầu ra. Cơ chế này mô phỏng cách nơ-ron sinh học xử lý tín hiệu: nhận nhiều đầu vào, tính tổng có trọng số, và kích hoạt khi vượt ngưỡng. Multi-Layer Perceptron (MLP) mở rộng perceptron thành mạng nhiều lớp, trong đó mỗi lớp nhận đầu ra của lớp trước làm đầu vào. Các lớp ẩn cho phép mạng học các biểu diễn trừu tượng của dữ liệu với mức độ phức tạp tăng dần theo chiều sâu.

Phép tích chập 2D là thành phần cốt lõi của CNN. Với đầu vào I và kernel K kích

thước $k_h \times k_w$, phép tích chập được định nghĩa:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \times K(m, n) \quad (1.5)$$

trong đó (i, j) là vị trí trong đầu ra và (m, n) là vị trí trong kernel. Kernel trượt qua đầu vào với bước nhảy (stride) xác định; tại mỗi vị trí, phép nhân từng phần tử giữa kernel và vùng tương ứng được thực hiện, sau đó cộng tổng để tạo ra một giá trị đầu ra. Với đầu vào nhiều kênh, kernel có cùng số kênh và phép tích chập được thực hiện đồng thời trên tất cả các kênh. Phép tích chập mang lại ba ưu điểm quan trọng [35]. Thứ nhất, cơ chế chia sẻ tham số cho phép cùng một kernel áp dụng cho toàn bộ đầu vào, giúp giảm đáng kể số lượng tham số cần học. Thứ hai, tính bất biến tịnh tiến giúp mạng có khả năng nhận diện đặc trưng bất kể vị trí xuất hiện trong ảnh. Thứ ba, kết nối cục bộ đảm bảo mỗi nơ-ron chỉ kết nối với vùng lân cận của đầu vào, phù hợp với đặc tính không gian của dữ liệu ảnh.

Hàm kích hoạt đưa tính phi tuyến vào mạng nơ-ron, cho phép học các mối quan hệ phức tạp trong dữ liệu [16]. ReLU (Rectified Linear Unit) là hàm kích hoạt phổ biến nhất với công thức $f(x) = \max(0, x)$. ReLU giữ nguyên giá trị dương và chuyển giá trị âm về 0, mang lại các ưu điểm như tính toán đơn giản, giảm vấn đề triệt tiêu gradient, và tạo ra tính thừa trong kích hoạt. Đối với bài toán phân loại đa lớp, hàm softmax được sử dụng ở lớp đầu ra để chuyển đổi các giá trị logits thành phân phối xác suất theo công thức $\text{softmax}(\mathbf{x})_i = \exp(x_i) / \sum_j \exp(x_j)$, trong đó \mathbf{x} là vector logits từ lớp cuối cùng và lớp có xác suất cao nhất được chọn làm kết quả dự đoán.

Pooling là phép toán giảm chiều không gian của bản đồ đặc trưng (feature map), giúp giảm số lượng tham số và tăng tính bất biến tịnh tiến của mạng [35]. Hai loại pooling phổ biến là Max Pooling (chọn giá trị lớn nhất trong mỗi vùng) và Average Pooling (tính trung bình các giá trị). Global Average Pooling (GAP) là trường hợp đặc biệt trong đó vùng pooling bao trùm toàn bộ bản đồ đặc trưng, biến đổi mỗi bản đồ đặc trưng thành một giá trị vô hướng [37]. GAP giúp giảm mạnh số lượng tham số và có tính chất điều chuẩn tự nhiên. Trong nghiên cứu này, GAP được sử dụng để tổng hợp thông tin không gian trước lớp phân loại.

1.3.2. Huấn luyện mạng nơ-ron

Hàm mất mát đo lường sự khác biệt giữa dự đoán của mô hình và nhãn thực tế, đóng vai trò là mục tiêu tối ưu hóa trong quá trình huấn luyện [16]. Đối với bài toán phân

loại đa lớp, Cross-Entropy Loss được định nghĩa:

$$L = - \sum_i y_i \log(\hat{y}_i) \quad (1.6)$$

trong đó y_i là nhãn thực tế (mã hóa one-hot) và \hat{y}_i là xác suất dự đoán từ hàm softmax. Hàm này đo lường khoảng cách giữa phân phối dự đoán và phân phối thực tế: giá trị măt măt cao khi mô hình gán xác suất thấp cho lớp đúng, và thấp khi dự đoán chính xác. Cross-Entropy Loss có tính chất lồi (convex) theo tham số của lớp softmax, giúp quá trình tối ưu hóa ổn định và hội tụ nhanh hơn so với các hàm măt măt khác trong bài toán phân loại.

Thuật toán tối ưu hóa đóng vai trò cập nhật trọng số của mạng dựa trên gradient của hàm măt măt. Adam (Adaptive Moment Estimation) được đề xuất bởi Kingma và Ba [32] là một trong những thuật toán phổ biến nhất hiện nay. Adam kết hợp ưu điểm của hai phương pháp: momentum sử dụng trung bình động bậc nhất của gradient để tăng tốc hội tụ theo hướng nhất quán, và RMSprop sử dụng trung bình động bậc hai để điều chỉnh tốc độ học theo từng tham số. Sự kết hợp này giúp Adam hoạt động hiệu quả trên nhiều loại bài toán với ít điều chỉnh siêu tham số. AdamW là biến thể cải tiến với cơ chế phân rã trọng số (weight decay) tách biệt khỏi cập nhật gradient, giúp điều chỉnh hiệu quả hơn và tránh tương tác không mong muốn giữa hai cơ chế.

Các kỹ thuật điều chỉnh (regularization) giúp ngăn chặn hiện tượng quá khớp (overfitting), khi mô hình học quá chi tiết trên tập huấn luyện nhưng tổng quát hóa kém trên dữ liệu mới. Chuẩn hóa theo lô (Batch Normalization) được đề xuất bởi Ioffe và Szegedy [25] nhằm tăng tốc quá trình huấn luyện bằng cách chuẩn hóa các giá trị kích hoạt trong mỗi lô nhỏ về phân phối chuẩn (trung bình 0, phương sai 1), sau đó áp dụng phép biến đổi tuyến tính với tham số học được. Kỹ thuật này giúp cho phép sử dụng tốc độ học cao hơn và giảm độ nhạy với khởi tạo trọng số. Dropout được đề xuất bởi Srivastava và cộng sự [49] như một kỹ thuật điều chỉnh hiệu quả: trong quá trình huấn luyện, mỗi nơ-ron bị tắt ngẫu nhiên với xác suất xác định, buộc mạng học các biểu diễn bền vững và tránh phụ thuộc quá mức vào một số nơ-ron cụ thể. Dropout2d là biến thể tắt toàn bộ bản đồ đặc trưng thay vì từng nơ-ron riêng lẻ, phù hợp cho CNN do tương quan không gian cao giữa các giá trị trong cùng bản đồ đặc trưng.

1.3.3. Ứng dụng CNN trong phân loại ảnh viễn thám

Trong phân loại ảnh viễn thám, có hai phương pháp tiếp cận chính [6, 54]. Phương pháp phân loại dựa trên điểm ảnh (pixel-based) thực hiện phân loại mỗi điểm ảnh độc lập dựa trên vector đặc trưng phổ của nó. Phương pháp này có ưu điểm là đơn giản trong triển khai và tốc độ xử lý nhanh, tuy nhiên không tận dụng được thông tin ngữ cảnh không gian và dễ tạo ra nhiễu muối-tiêu (salt-and-pepper noise) trong kết quả phân loại, đặc biệt ở các vùng ranh giới giữa các lớp. Phương pháp phân loại dựa trên patch trích xuất cửa sổ (patch) xung quanh mỗi điểm ảnh trung tâm và thực hiện phân loại dựa trên toàn bộ thông tin trong patch. Phương pháp này tận dụng được ngữ cảnh không gian, cho kết quả phân loại mượt mà hơn và đặc biệt phù hợp với kiến trúc CNN vốn được thiết kế để học các đặc trưng không gian cục bộ. Kích thước patch cần được lựa chọn phù hợp với độ phân giải ảnh và đặc tính của đối tượng cần phân loại: patch quá nhỏ không nắm bắt đủ ngữ cảnh, trong khi patch quá lớn có thể đưa vào nhiều từ các lớp phủ lân cận.

Chuẩn hóa dữ liệu là bước tiền xử lý quan trọng trong học máy nói chung và CNN nói riêng, đảm bảo các đặc trưng có cùng thang đo để quá trình học diễn ra ổn định [48]. Trong ảnh viễn thám đa nguồn, các đặc trưng thường có thang đo rất khác nhau: chỉ số thực vật NDVI nằm trong khoảng $[-1, 1]$, phản xạ bề mặt quang học trong khoảng $[0, 1]$, trong khi tán xạ ngược ra-đa có thể trong khoảng $[-25, 0]$ dB. Nếu không chuẩn hóa, các đặc trưng có giá trị lớn sẽ chi phối quá trình học và gradient có thể không ổn định. Chuẩn hóa Z-score chuyển đổi dữ liệu về phân phối với trung bình bằng 0 và độ lệch chuẩn bằng 1 (chi tiết công thức được trình bày trong Chương 2). Điểm quan trọng cần lưu ý là các tham số chuẩn hóa (trung bình μ và độ lệch chuẩn σ) phải được tính toán dựa trên tập huấn luyện và áp dụng nhất quán cho cả tập kiểm tra, nhằm đảm bảo tính khách quan trong đánh giá mô hình và tránh rò rỉ thông tin (data leakage) từ tập kiểm tra.

1.4. Các nghiên cứu liên quan

Giám sát biến động rừng đã trải qua nhiều giai đoạn phát triển, từ các phương pháp thủ công truyền thống đến các kỹ thuật học sâu hiện đại. Phần này trình bày quá trình phát triển của các phương pháp theo thời gian, tổng hợp các nghiên cứu tiêu biểu trên thế giới và tại Việt Nam, làm cơ sở cho việc xác định khoảng trống nghiên cứu và định hướng đồ án.

1.4.1. Sự phát triển của các phương pháp giám sát biến động rừng

Trước khi có công nghệ viễn thám, giám sát rừng chủ yếu dựa vào khảo sát thực địa trực tiếp. Nhân viên kiểm lâm đi thực địa để đo đạc, ghi nhận trạng thái rừng và lập bản đồ thủ công. Phương pháp này có độ chính xác cao tại từng điểm khảo sát nhưng tốn kém về thời gian và nhân lực, không khả thi cho giám sát diện rộng và khó cập nhật thường xuyên.

Từ giữa thế kỷ 20, ảnh hàng không (Aerial Photography) bắt đầu được sử dụng để lập bản đồ rừng. Các chuyên gia giải đoán ảnh hàng không bằng mắt thường để xác định ranh giới rừng và phát hiện thay đổi. Phương pháp này cho phép quan sát diện tích lớn hơn khảo sát thực địa nhưng vẫn phụ thuộc nhiều vào kinh nghiệm của người giải đoán và chi phí bay chụp cao.

Với sự ra đời của vệ tinh Landsat năm 1972, lần đầu tiên có thể quan sát bề mặt Trái Đất một cách hệ thống từ không gian. Giai đoạn đầu, việc phân tích ảnh vệ tinh chủ yếu dựa vào giải đoán trực quan (Visual Interpretation) - chuyên gia nhìn ảnh và vẽ ranh giới các vùng đất khác nhau. Các phương pháp phân loại dựa trên ngưỡng (Threshold-based Classification) như phân ngưỡng chỉ số thực vật NDVI được sử dụng rộng rãi trong thập niên 1980-1990.

Từ thập niên 1990, các thuật toán phân loại thống kê bắt đầu được áp dụng rộng rãi. Maximum Likelihood Classification (MLC) giả định dữ liệu tuân theo phân phối Gaussian và phân loại pixel dựa trên xác suất. Phân loại không giám sát như K-means và ISODATA không yêu cầu dữ liệu huấn luyện có nhãn, thay vào đó tự động nhóm các pixel có đặc trưng phổ tương tự thành các cụm [27].

Bước tiến quan trọng trong học máy cho viễn thám đến từ phương pháp Random Forest. Ho [20] đề xuất ý tưởng random decision forests năm 1995, sau đó Breiman [7] phát triển và hoàn thiện thành thuật toán Random Forest năm 2001. Thuật toán này cải thiện cây quyết định đơn lẻ bằng cách kết hợp nhiều cây quyết định và nhanh chóng trở thành phương pháp phổ biến nhất trong phân loại ảnh viễn thám. Cùng thời kỳ, Cortes và Vapnik [8] giới thiệu Support Vector Machine (SVM) năm 1995. SVM chứng minh hiệu quả vượt trội so với MLC trong phân loại ảnh viễn thám, đặc biệt khi làm việc với dữ liệu đa chiều và bộ mẫu huấn luyện nhỏ.

Từ năm 2012, với sự thành công của AlexNet trong cuộc thi ImageNet, học sâu bắt đầu cách mạng hóa thị giác máy tính và nhanh chóng được áp dụng vào viễn thám.

Zhu và cộng sự [55] tổng hợp các ứng dụng của deep learning trong viễn thám và chỉ ra tiềm năng to lớn của CNN trong phân loại ảnh vệ tinh. Kiến trúc U-Net với cấu trúc encoder-decoder, ban đầu cho phân đoạn ảnh y sinh, sau đó được áp dụng rộng rãi trong viễn thám nhờ khả năng phân đoạn ngữ nghĩa pixel-wise hiệu quả [45].

Bảng 1.3: So sánh các phương pháp giám sát biến động rừng qua các giai đoạn

Giai đoạn	Thời kỳ	Phương pháp tiêu biểu	Đặc điểm
Truyền thống	Trước 1970	Khảo sát thực địa	Chính xác nhưng tốn kém
Viễn thám đầu	1970-1990	Giải đoán trực quan	Chủ quan, khó tái lập
ML truyền thống	1990-2012	MLC, Decision Tree, RF	Khách quan, tự động hóa
Học sâu	2012-nay	CNN, U-Net	Học đặc trưng tự động
Tích hợp	2015-nay	CNN + SAR + Optical	Bổ sung, tăng độ tin cậy

1.4.2. Nghiên cứu trên thế giới

Hansen và cộng sự [17] đã sử dụng thuật toán Cây quyết định để phát triển Global Forest Change dataset — bộ dữ liệu mất rừng toàn cầu đầu tiên ở độ phân giải 30m từ chuỗi thời gian Landsat (2000-2012). Công trình này đánh dấu bước tiến quan trọng trong giám sát rừng quy mô lớn, đạt accuracy khoảng 85%.

Reiche và cộng sự [43] kết hợp Sentinel-1 và Landsat để phát hiện mất rừng tại rừng nhiệt đới khô và đạt accuracy 93.8%. Hu và cộng sự [22] kết hợp Sentinel-1 và Sentinel-2 để phân loại rừng ở Madagascar và ghi nhận accuracy tăng từ 87% (chỉ dùng optical) lên 92% (kết hợp cả hai).

Kussul và cộng sự [34] áp dụng CNN cho phân loại cây trồng từ Sentinel-2 và đạt độ chính xác 94.5%, cao hơn đáng kể so với Random Forest. Zhang và cộng sự [54] giới thiệu các kiến trúc CNN phổ biến (AlexNet, VGGNet, ResNet) và ứng dụng của chúng trong viễn thám.

Hethcoat và cộng sự [19] áp dụng CNN (kiến trúc ResNet) để phát hiện khai thác gỗ chọn lọc tại Amazon từ dữ liệu Sentinel-1 và Sentinel-2, đạt accuracy 94.3%. Karra và cộng sự [28] ứng dụng deep learning kết hợp Sentinel-2 để tạo bản đồ sử dụng đất toàn cầu ở độ phân giải 10m.

Bảng 1.4: Tổng hợp các nghiên cứu tiêu biểu trên thế giới

Tác giả	Năm	Phương pháp	Dữ liệu	Accuracy
Hansen và cs.	2013	Decision Tree	Landsat	~85%
Kussul và cs.	2017	CNN	Sentinel-2	94.5%
Reiche và cs.	2018	Bayesian fusion	S1+Landsat	93.8%
Hethcoat và cs.	2019	CNN (ResNet)	S1+S2	94.3%
Hu và cs.	2020	ML	S1+S2	92.0%

1.4.3. Nghiên cứu tại Việt Nam

Tại Việt Nam, các nghiên cứu ứng dụng viễn thám và học máy trong giám sát rừng đã có những bước phát triển đáng kể trong những năm gần đây.

Nguyen và cộng sự [39] áp dụng Random Forest với Sentinel-2 đa thời gian để lập bản đồ sử dụng đất tại Đăk Nông, Việt Nam và đạt accuracy 91.2%. Nghiên cứu này cho thấy tiềm năng của việc sử dụng dữ liệu đa thời gian từ Sentinel-2 cho các vùng rừng Tây Nguyên.

Pham và cộng sự [41] đã sử dụng kết hợp ảnh QuickBird, LiDAR và chỉ số địa hình GIS để nhận dạng loài cây bản địa trong cảnh quan phức tạp, đặt nền móng cho các nghiên cứu tích hợp đa nguồn dữ liệu tại Việt Nam.

Vo và cộng sự [52] đã xây dựng hệ thống giám sát biến động rừng ngập mặn hàng năm tại tỉnh Cà Mau sử dụng chuỗi thời gian Landsat-7 và Landsat-8, áp dụng phương pháp tối ưu hóa thời gian sau phân loại để tạo bản đồ rừng liên tục không có khoảng trống dữ liệu.

Tuy nhiên, phần lớn các nghiên cứu tại Việt Nam vẫn tập trung vào các phương pháp học máy truyền thống (Random Forest, SVM) hoặc sử dụng ảnh quang học đơn thuần. Việc ứng dụng học sâu (CNN) kết hợp với dữ liệu đa nguồn (ra-đa + quang học) cho giám sát rừng tại Việt Nam còn rất hạn chế.

1.4.4. Khoảng trống nghiên cứu và điểm mới của đồ án

Qua tổng quan tài liệu, một số khoảng trống nghiên cứu nổi bật được xác định. Thứ nhất, phần lớn các công trình nghiên cứu về học sâu trong giám sát rừng tập trung ở các vùng rừng nhiệt đới Amazon, Congo hay Indonesia, trong khi còn rất ít nghiên cứu áp

dụng CNN cho rừng Việt Nam, đặc biệt là hệ sinh thái rừng ngập mặn Cà Mau. Thứ hai, CNN thường yêu cầu tập dữ liệu lớn với hàng trăm nghìn mẫu huấn luyện, nhưng có ít công trình nghiên cứu về kiến trúc CNN tối ưu cho các bộ dữ liệu nhỏ trong viễn thám với khoảng 2.000–5.000 mẫu. Thứ ba, việc tích hợp dữ liệu ra-đa khẩu độ tổng hợp và quang học trong bối cảnh học sâu vẫn còn nhiều thách thức, đồng thời còn thiếu các khảo sát tối ưu hóa mô hình trong kiến trúc CNN cho loại dữ liệu kết hợp này.

Xuất phát từ những khoảng trống nghiên cứu đã nêu, đồ án này đặt ra bốn mục tiêu chính. Mục tiêu đầu tiên là phát triển kiến trúc CNN phù hợp cho bộ dữ liệu nhỏ thông qua việc thiết kế mô hình lightweight với xấp xỉ 36K tham số, áp dụng các kỹ thuật điều chuẩn mạnh như Batch Normalization, Dropout và Weight Decay. Mục tiêu thứ hai là triển khai quy trình đánh giá khoa học chặt chẽ, bao gồm chia mẫu ngẫu nhiên phân tầng, thực hiện kiểm định chéo 5 lần và giữ lại tập dữ liệu kiểm tra chiếm 20%. Mục tiêu thứ ba là tối ưu hóa phương pháp kết hợp dữ liệu bằng cách tích hợp Sentinel-1 và Sentinel-2 ở cấp độ đặc trưng, trích xuất tổng cộng 27 đặc trưng gồm 21 đặc trưng từ Sentinel-2 và 6 đặc trưng từ Sentinel-1. Mục tiêu cuối cùng là ứng dụng thực tế tại Cà Mau, phân loại toàn vùng quy hoạch lâm nghiệp với diện tích ranh giới 170.179 ha và diện tích phân loại thực tế 162.469 ha, từ đó ước tính diện tích mất rừng và tạo bản đồ phân loại ở độ phân giải 10m.

Qua quá trình phát triển, các phương pháp giám sát rừng ngày càng tự động hóa, khách quan và chính xác hơn. Xu hướng hiện tại là kết hợp học sâu với dữ liệu đa nguồn gồm ra-đa khẩu độ tổng hợp và quang học để tận dụng ưu điểm của cả hai loại dữ liệu. Nghiên cứu này kế thừa xu hướng đó, áp dụng CNN kết hợp dữ liệu Sentinel-1 (ra-đa khẩu độ tổng hợp) và Sentinel-2 (quang học) cho giám sát biến động rừng tại Cà Mau.

CHƯƠNG 2. CƠ SỞ DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

2.1. Cơ sở dữ liệu

2.1.1. Dữ liệu viễn thám Sentinel

Việc lựa chọn ảnh vệ tinh tuân theo các tiêu chí nhằm đảm bảo chất lượng dữ liệu đầu vào. Đối với ảnh Sentinel-2, nghiên cứu sử dụng sản phẩm S2_SR_HARMONIZED (Surface Reflectance Level-2A đã hiệu chỉnh) từ Google Earth Engine, ưu tiên các ảnh trong mùa khô (tháng 1-3) để giảm thiểu ảnh hưởng của mây và đảm bảo tính so sánh giữa hai thời kỳ. Mặt nạ mây được tạo từ bộ sưu tập S2_CLOUD_PROBABILITY với ngưỡng xác suất 50% để loại bỏ các pixel bị mây che phủ. Đối với ảnh Sentinel-1, sử dụng sản phẩm S1_GRD đã được tiền xử lý bởi ESA, các cảnh được chọn có thời gian thu nhận gần nhất với ảnh Sentinel-2 tương ứng (trong phạm vi ±7 ngày) để đảm bảo tính đồng bộ về thời gian.

Bảng 2.1: Tổng quan dữ liệu viễn thám sử dụng

Nguồn dữ liệu	Độ phân giải	Kỳ ảnh	Ghi chú
Sentinel-2 trước	10m	30/01/2024	7 băng
Sentinel-2 sau	10m	28/02/2025	7 băng
Sentinel-1 trước	10m	04/02/2024	2 băng
Sentinel-1 sau	10m	22/02/2025	2 băng
Dữ liệu thực địa	-	-	2,630 điểm
Ranh giới lâm nghiệp	-	-	Vector

2.1.2. Thu thập dữ liệu trên Google Earth Engine

Toàn bộ dữ liệu ảnh vệ tinh được thu thập và xử lý trên nền tảng Google Earth Engine (GEE) — một hệ thống điện toán đám mây cho phép truy cập và xử lý khối lượng lớn dữ liệu viễn thám. Việc sử dụng GEE mang lại nhiều ưu điểm: truy cập trực tiếp kho dữ liệu Sentinel đã được hiệu chỉnh, khả năng xử lý dữ liệu nhanh chóng trên hạ tầng đám mây, và đảm bảo tính nhất quán trong quy trình xử lý.

Dữ liệu Sentinel-2 được truy xuất từ bộ dữ liệu COPERNICUS/S2_SR_HARMONIZED — sản phẩm đã được hiệu chỉnh khí quyển và đồng nhất hóa giữa các cảm biến Sentinel-

2A và 2B. Quy trình xử lý bắt đầu bằng việc lọc theo không gian và thời gian để chọn các cảnh phủ khu vực nghiên cứu trong ngày chỉ định, sau đó loại bỏ mây sử dụng bộ sưu tập S2_CLOUD_PROBABILITY với ngưỡng xác suất 50%. Tiếp theo, 4 băng cần thiết (B4-Red, B8-NIR, B11-SWIR1, B12-SWIR2) được trích xuất, chuyển đổi sang giá trị phản xạ và tính toán 3 chỉ số thực vật NDVI, NBR, NDMI. Cuối cùng, các tiles được mosaic để tạo ảnh liên mạch phủ toàn bộ khu vực nghiên cứu.

Việc lựa chọn bốn kênh phổ B4, B8, B11 và B12 trong số 13 kênh của Sentinel-2 dựa trên cơ sở khoa học về đặc tính phản xạ phổ của thực vật và yêu cầu tính toán các chỉ số thực vật phục vụ giám sát biến động rừng. Kênh B4 ở vùng ánh sáng đỏ (665 nm) ghi nhận vùng hấp thụ mạnh của diệp lục, do đó nhạy cảm với sự thay đổi hàm lượng diệp lục khi thực vật bị stress hoặc chết đi [36]. Kênh B8 ở vùng cận hồng ngoại (842 nm) phản ánh cấu trúc mô thịt lá với phản xạ cao ở thực vật khỏe mạnh, là thành phần không thể thiếu trong hầu hết các chỉ số thực vật [46]. Hai kênh SWIR bao gồm B11 (1610 nm) và B12 (2190 nm) nhạy cảm với hàm lượng nước trong lá và cellulose, lignin trong cấu trúc thực vật, đặc biệt hiệu quả trong phát hiện các vùng rừng bị suy thoái hoặc chặt phá [14, 30]. Các kênh vùng nhìn thấy B2 và B3 không được sử dụng vì dễ bị ảnh hưởng bởi tán xạ khí quyển và không cung cấp thông tin bổ sung đáng kể so với B4 trong bối cảnh giám sát rừng. Các kênh Red Edge (B5, B6, B7) và B8a có độ phân giải không gian 20m, thấp hơn so với 10m của B4 và B8, đồng thời thông tin từ các kênh này đã được phản ánh gián tiếp qua sự kết hợp B4-B8 trong chỉ số NDVI. Nghiên cứu của Khatami et al. [31] chỉ ra rằng việc sử dụng quá nhiều kênh phổ có thể dẫn đến hiện tượng thừa thông tin mà không cải thiện độ chính xác phân loại.

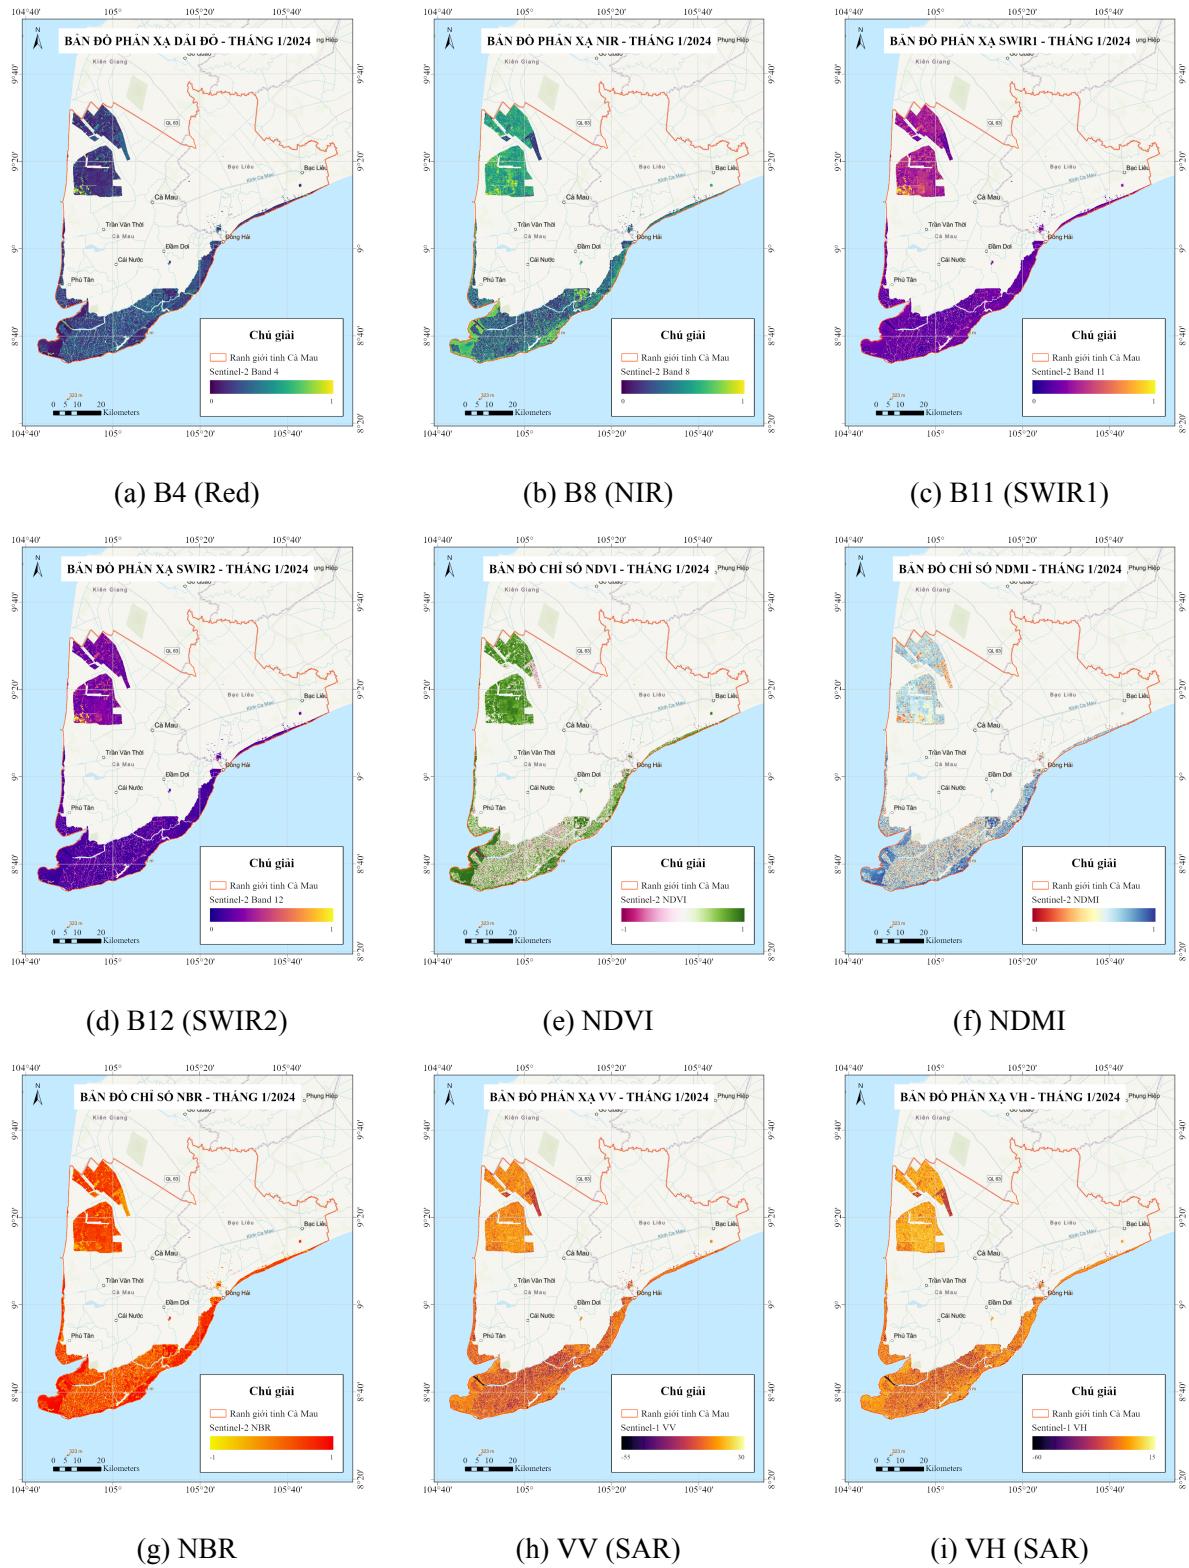
Về các chỉ số thực vật, nghiên cứu sử dụng ba chỉ số NDVI, NBR và NDMI dựa trên nguyên tắc mỗi chỉ số khai thác một khía cạnh khác nhau của trạng thái thực vật, tạo ra tập đặc trưng bổ sung cho nhau mà không gây dư thừa. NDVI được lựa chọn vì là chỉ số có tính ổn định cao trong đánh giá mật độ và sức khỏe thực vật [23, 46]. NBR được thiết kế đặc biệt cho phát hiện biến động rừng, với độ nhạy cao đối với sự thay đổi cấu trúc tán lá khi rừng bị chặt phá hoặc cháy [30]. NDMI cung cấp thông tin về hàm lượng nước trong tán lá, có khả năng phát hiện stress thực vật trước khi biểu hiện rõ ràng qua NDVI [14]. Các chỉ số khác như EVI (Enhanced Vegetation Index) yêu cầu kênh Blue vốn nhạy cảm với tán xạ khí quyển và ưu điểm chính của nó không vượt trội đáng kể so với NDVI trong bối cảnh rừng ngập mặn. SAVI (Soil Adjusted Vegetation Index) được thiết kế cho vùng có độ phủ thực vật thưa, trong khi rừng ngập mặn Cà Mau có độ che

phủ dày đặc khiến chỉ số này không phù hợp. GNDVI sử dụng kênh Green thay cho Red nhưng thông tin này đã được phản ánh qua NDVI. Như vậy, bộ ba chỉ số NDVI, NBR và NDMI tạo thành tổ hợp tối ưu về mặt thông tin, đảm bảo tính bổ sung mà không gây dư thừa đặc trưng cho mô hình học sâu.

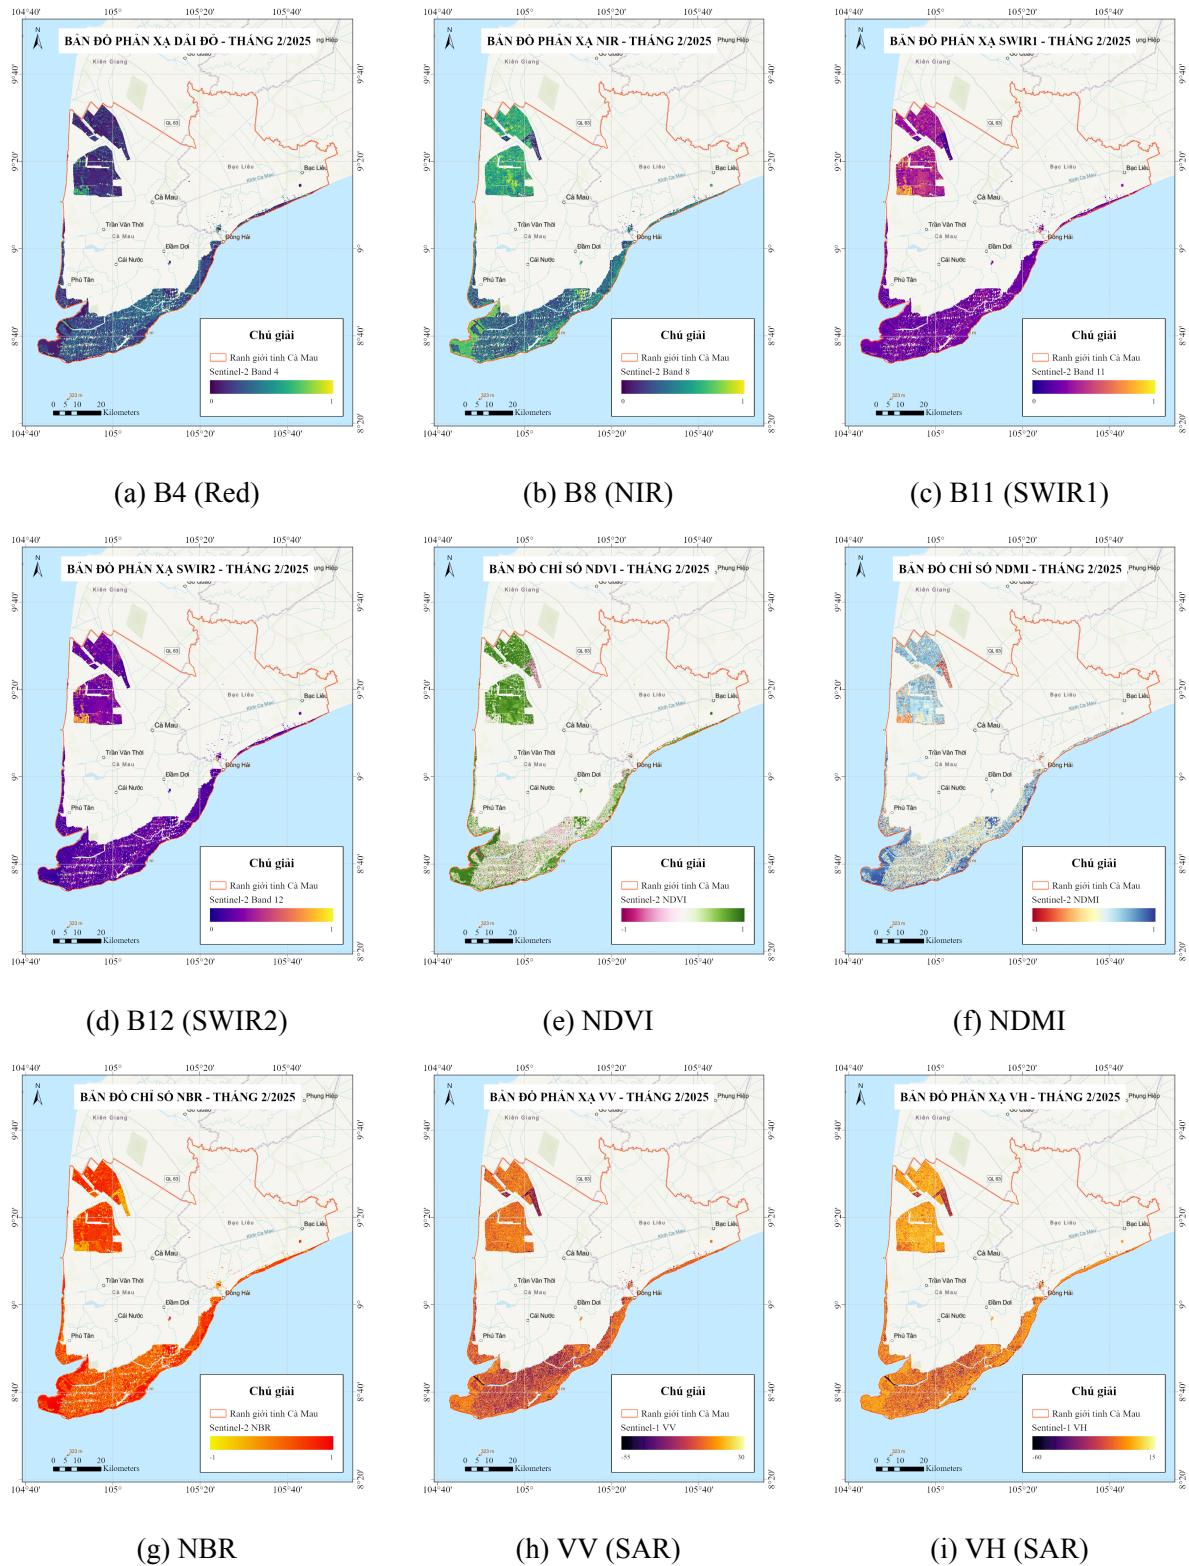
Dữ liệu Sentinel-1 được truy xuất từ bộ sưu tập COPERNICUS/S1_GRD — sản phẩm đã được tiền xử lý bởi ESA bao gồm: hiệu chỉnh quỹ đạo, loại bỏ nhiễu biên và nhiễu nhiệt, hiệu chỉnh bức xạ và hiệu chỉnh địa hình sử dụng DEM SRTM. Quy trình xử lý bổ sung bao gồm: lọc theo thời gian (± 7 ngày so với Sentinel-2), chọn chế độ Interferometric Wide (IW) với quỹ đạo đi xuống, và trích xuất hai băng VV và VH (đơn vị dB).

Việc lựa chọn cặp phân cực VV và VH dựa trên cơ chế tán xạ sóng vi ba khi tương tác với thảm thực vật rừng. Phân cực VV (phát và thu sóng theo phương thẳng đứng) nhạy cảm với tán xạ bề mặt, phản ánh đặc tính của lớp đất hoặc mặt nước bên dưới tán rừng, đặc biệt hữu ích trong việc phát hiện thay đổi độ ẩm đất sau khi rừng bị chặt phá [51]. Trong khi đó, phân cực VH (phát sóng thẳng đứng, thu sóng ngang) phát sinh chủ yếu từ quá trình tán xạ thể tích trong cấu trúc tán lá và thân cây, do đó nhạy cảm đặc biệt với sự thay đổi sinh khối và mật độ tán rừng khi xảy ra chặt phá hoặc suy thoái [43]. Sự kết hợp hai phân cực này cung cấp thông tin bổ sung về cả lớp bề mặt và cấu trúc thể tích của rừng, cho phép phân biệt tốt hơn giữa các loại biến động. Các phân cực khác không được sử dụng vì chế độ Interferometric Wide của Sentinel-1 cho vùng đất liền nhiệt đới chỉ cung cấp cặp phân cực VV-VH theo cấu hình tiêu chuẩn của ESA [10], đồng thời cặp phân cực này đã được chứng minh hiệu quả trong nhiều nghiên cứu giám sát rừng nhiệt đới trước đó.

Sau khi xử lý, dữ liệu được xuất ra định dạng GeoTIFF với độ phân giải 10m và hệ quy chiếu EPSG:32648 (WGS 84 / UTM Zone 48N). Hình 2.1 và 2.2 minh họa trực quan các dữ liệu quang học (B4, B8, B11, B12), các chỉ số thực vật (NDVI, NDMI, NBR) và dữ liệu ra-đa (VV, VH) cho hai thời điểm trước và sau biến động.



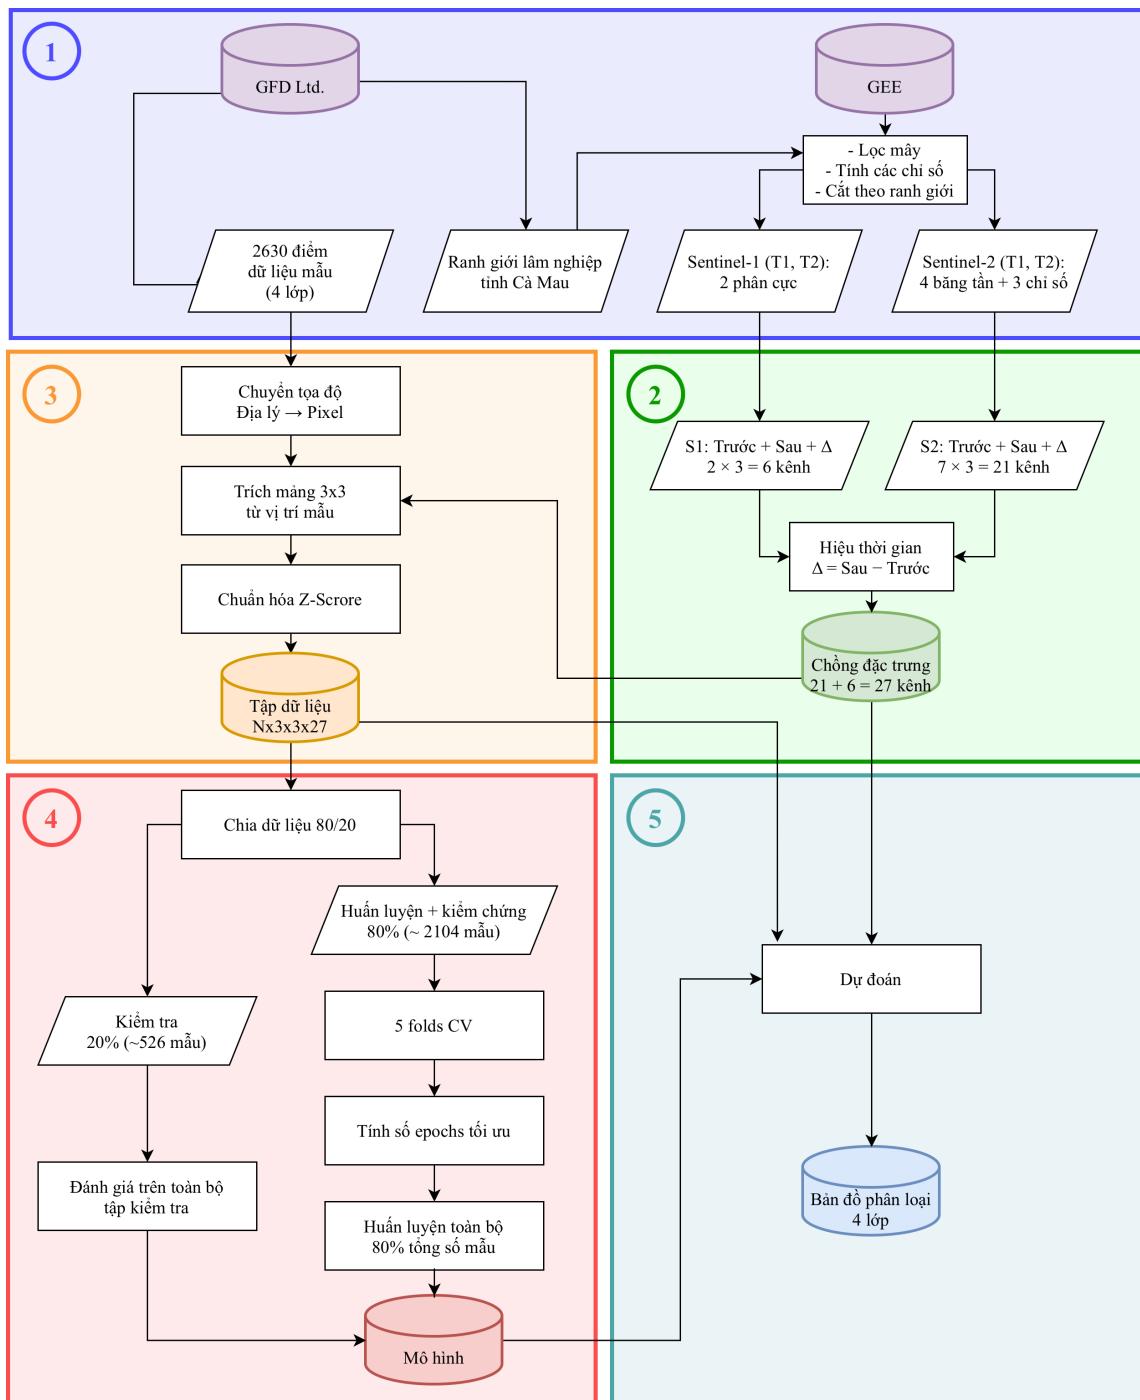
Hình 2.1: Các băng quang học, chỉ số thực vật và dữ liệu ra-đa kỲ trước (T1 - 01/2024)



Hình 2.2: Các băng quang học, chỉ số thực vật và dữ liệu ra-đa kỵ sau (T2 - 02/2025)

2.2. Phương pháp nghiên cứu

Phần này trình bày phương pháp nghiên cứu và quy trình tổng quan được minh họa trong Hình 2.3. Quy trình bao gồm năm giai đoạn chính: (1) Thu thập và tiền xử lý dữ liệu, (2) Trích xuất đặc trưng, (3) Chuẩn bị mẫu huấn luyện, (4) Huấn luyện mô hình, và (5) Áp dụng mô hình.



Hình 2.3: Sơ đồ quy trình phương pháp nghiên cứu phát hiện biến động rừng

2.2.1. Trích xuất đặc trưng

Việc kết hợp dữ liệu ra-đa khâu độ tổng hợp và quang học đã được chứng minh là hiệu quả trong nhiều nghiên cứu phân loại lớp phủ đất [22, 24]. Cách tiếp cận này tận dụng ưu điểm bổ sung của hai nguồn dữ liệu: ra-đa khâu độ tổng hợp cung cấp thông tin về cấu trúc và độ ẩm bề mặt, trong khi quang học cung cấp thông tin về đặc tính quang phổ của thực vật.

Tổng cộng 27 đặc trưng được xây dựng từ hai nguồn dữ liệu. Sentinel-2 đóng góp 21 đặc trưng, bao gồm 7 băng tần/chỉ số (B4, B8, B11, B12, NDVI, NBR, NDMI) cho kỳ trước, 7 băng tần/chỉ số tương ứng cho kỳ sau, và 7 giá trị delta (hiệu số giữa kỳ sau và kỳ trước). Sentinel-1 đóng góp 6 đặc trưng, bao gồm 2 băng (VV, VH) cho kỳ trước, 2 băng tương ứng cho kỳ sau, và 2 giá trị delta.

Bảng 2.2: Chi tiết 27 đặc trưng sử dụng trong mô hình

Chỉ số	Nguồn	Thời kỳ	Đặc trưng	Mô tả
0-6	S2	Kỳ trước	B4, B8, B11, B12, NDVI, NBR, NDMI	Quang phổ kỳ trước
7-13	S2	Kỳ sau	B4, B8, B11, B12, NDVI, NBR, NDMI	Quang phổ kỳ sau
14-20	S2	Biến đổi	$\Delta B4, \Delta B8, \dots$	Biến đổi quang phổ
21-22	S1	Kỳ trước	VV, VH	SAR kỳ trước
23-24	S1	Kỳ sau	VV, VH	SAR kỳ sau
25-26	S1	Biến đổi	$\Delta VV, \Delta VH$	Biến đổi SAR

Với mỗi điểm thực địa, một patch kích thước 3×3 điểm ảnh được trích xuất từ stack đặc trưng. Kích thước 3×3 được lựa chọn dựa trên ba tiêu chí: (1) cho phép mô hình học được thông tin ngữ cảnh không gian xung quanh điểm ảnh trung tâm; (2) phù hợp với độ phân giải 10m của Sentinel, mỗi patch tương đương vùng $30m \times 30m$ — kích thước hợp lý cho các lô rừng ngập mặn; và (3) giảm thiểu nhiễu từ các điểm ảnh lân cận không đồng nhất. Kết quả thử nghiệm so sánh các kích thước patch khác nhau (xem Bảng 3.3) xác nhận rằng patch 3×3 cho độ chính xác cao nhất (98.86%) với số lượng tham số ít nhất.

Kết quả là mỗi mẫu có kích thước $(3, 3, 27)$ — tương ứng với chiều cao, chiều rộng và số kênh đặc trưng.

2.2.2. Chuẩn bị mẫu huấn luyện

Việc chuẩn hóa dữ liệu là bước quan trọng để đảm bảo các đặc trưng có cùng phạm vi giá trị, giúp quá trình huấn luyện mô hình hội tụ nhanh và ổn định hơn. Nghiên cứu này áp dụng phương pháp chuẩn hóa Z-score:

$$x_{normalized} = \frac{x - \mu}{\sigma} \quad (2.1)$$

trong đó x là giá trị gốc, μ là giá trị trung bình và σ là độ lệch chuẩn.

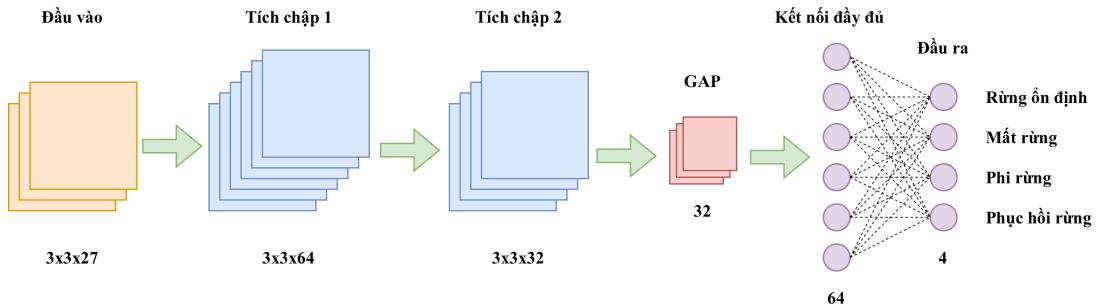
Để tránh rò rỉ dữ liệu (data leakage), các tham số chuẩn hóa (μ và σ) được tính toán chỉ trên tập huấn luyện, sau đó áp dụng cho cả tập kiểm định và tập kiểm tra. Các tham số này cũng được lưu lại để sử dụng khi dự đoán trên dữ liệu mới.

Chiến lược chia dữ liệu được thiết kế theo khuyến nghị của Roberts et al. [44] về kiểm định chéo cho dữ liệu không gian. Quy trình chia dữ liệu bao gồm bốn bước. Bước thứ nhất, tách 20% dữ liệu làm tập kiểm tra cố định (526 mẫu) — tập này không được sử dụng trong quá trình huấn luyện hay tinh chỉnh siêu tham số. Bước thứ hai, áp dụng kiểm định chéo 5 phần trên 80% còn lại (2,104 mẫu) để đánh giá độ ổn định của mô hình và tìm kiếm siêu tham số tối ưu. Bước thứ ba, sau khi xác định siêu tham số tối ưu, huấn luyện mô hình cuối cùng trên toàn bộ 80% dữ liệu để tận dụng tối đa dữ liệu huấn luyện. Bước thứ tư, đánh giá mô hình cuối cùng trên 20% tập kiểm tra để báo cáo kết quả.

Cách phân chia dữ liệu này đảm bảo tỷ lệ các lớp (Rừng ổn định, Mất rừng, Phi rừng, Phục hồi rừng) được duy trì đồng đều trong cả tập huấn luyện và kiểm tra.

2.2.3. Kiến trúc mô hình CNN

Nghiên cứu này sử dụng một kiến trúc mạng nơ-ron tích chập (CNN) nhẹ, được thiết kế phù hợp với quy mô bộ dữ liệu 2,630 mẫu. Kiến trúc tổng quan của mô hình được minh họa trong Hình 2.4.



Hình 2.4: Kiến trúc mô hình mạng nơ-ron tích chập (CNN) được sử dụng trong nghiên cứu

Dữ liệu đầu vào là các patch kích thước 3×3 điểm ảnh với 27 kênh đặc trưng, được biểu diễn dưới dạng tensor $(N, 3, 3, 27)$ với N là số lượng mẫu trong mỗi batch. Luồng xử lý của mô hình được mô tả như sau.

Đầu tiên, dữ liệu đi qua khối tích chập thứ nhất sử dụng 64 bộ lọc kích thước 3×3 . Mỗi bộ lọc kết hợp thông tin từ tất cả 27 kênh đặc trưng để tạo ra một bản đồ đặc trưng mới, giúp mô hình học được mối quan hệ giữa các băng quang phổ, chỉ số thực vật và dữ liệu ra-đa. Sau lớp tích chập là lớp chuẩn hóa theo lô (Batch Normalization) [25] giúp ổn định quá trình huấn luyện, hàm kích hoạt ReLU đưa tính phi tuyến vào mô hình, và lớp Dropout2D với tỷ lệ 70% để ngăn ngừa quá khớp. Đầu ra có kích thước $(N, 64, 3, 3)$.

Tiếp theo, khối tích chập thứ hai sử dụng 32 bộ lọc để nén thông tin từ 64 kênh xuống 32 kênh, với cấu trúc tương tự khối thứ nhất. Việc giảm số kênh buộc mô hình phải học cách biểu diễn thông tin cô đọng hơn. Đầu ra có kích thước $(N, 32, 3, 3)$.

Sau đó, lớp gộp trung bình toàn cục (Global Average Pooling) tính giá trị trung bình của mỗi kênh đặc trưng trên toàn bộ vùng không gian 3×3 , chuyển đổi bản đồ đặc trưng thành vector 32 chiều. Kỹ thuật này giúp giảm số lượng tham số và tăng khả năng tổng quát hóa của mô hình.

Cuối cùng, hai lớp kết nối đầy đủ thực hiện phân loại. Lớp thứ nhất mở rộng từ 32 lên 64 chiều kèm theo chuẩn hóa theo lô, ReLU và Dropout. Lớp thứ hai (lớp đầu ra) ánh xạ từ 64 chiều xuống 4 chiều, tương ứng với 4 lớp phân loại: Rừng ổn định, Mất rừng, Phi rừng và Phục hồi rừng.

Mô hình sử dụng phương pháp khởi tạo trọng số Kaiming/He [18] cho các lớp tích chập và Xavier cho các lớp kết nối đầy đủ, đảm bảo quá trình huấn luyện ổn định ngay từ đầu. Tổng cộng mô hình có 36,676 tham số có thể huấn luyện, tạo ra tỷ lệ mẫu trên tham số khoảng 72:1 — phù hợp cho việc huấn luyện với bộ dữ liệu nhỏ khi kết hợp với các

kỹ thuật điều chuẩn. Bảng 2.3 trình bày chi tiết số lượng tham số của từng thành phần.

Bảng 2.3: Chi tiết số tham số huấn luyện của mô hình CNN

Thành phần	Số tham số	Công thức tính
Khối tích chập 1 (Conv + BN)	15,680	$27 \times 3 \times 3 \times 64 + 128$
Khối tích chập 2 (Conv + BN)	18,496	$64 \times 3 \times 3 \times 32 + 64$
Lớp kết nối đầy đủ 1 (FC + BN)	2,240	$32 \times 64 + 64 + 128$
Lớp đầu ra	260	$64 \times 4 + 4$
Tổng cộng	36,676	

2.2.4. Huấn luyện mô hình

Với bộ dữ liệu gồm 2,630 mẫu và mô hình có 36,676 tham số, tỷ lệ mẫu trên tham số là 72:1. Để ngăn chặn hiện tượng quá khớp (overfitting) — khi mô hình ghi nhớ dữ liệu huấn luyện thay vì học các quy luật tổng quát — nghiên cứu áp dụng ba kỹ thuật điều chuẩn: chuẩn hóa theo lô (Batch Normalization) [25] sau mỗi lớp mạng, Dropout với tỷ lệ 70% [49], và phân rã trọng số (weight decay) với hệ số 10^{-3} . Bảng 2.4 trình bày các siêu tham số huấn luyện.

Bảng 2.4: Cấu hình siêu tham số huấn luyện

Tham số	Giá trị	Mô tả
epochs	200	Số vòng lặp tối đa
batch_size	64	Số mẫu mỗi lô
learning_rate	0.001	Tốc độ học khởi tạo
weight_decay	10^{-3}	Hệ số phân rã trọng số
dropout_rate	0.7	Tỷ lệ Dropout
early_stopping	15 epochs	Patience dừng sớm

Nghiên cứu sử dụng thuật toán tối ưu AdamW [38] kết hợp với ReduceLROnPlateau scheduler để tự động giảm tốc độ học khi validation loss không cải thiện. Cơ chế dừng sớm (early stopping) với patience 15 epochs giúp dừng huấn luyện khi mô hình bắt đầu quá khớp và lưu lại phiên bản có validation loss thấp nhất.

Quy trình huấn luyện gồm bốn giai đoạn. Giai đoạn thứ nhất, khởi tạo trọng số

theo phương pháp Kaiming/He [18]. Giai đoạn thứ hai, thực hiện kiểm định chéo 5 phần (5-Fold Cross Validation) trên 80% dữ liệu (2,104 mẫu) để đánh giá độ ổn định của mô hình; trong đó dữ liệu được chia thành 5 phần bằng nhau, mô hình được huấn luyện 5 lần với mỗi lần sử dụng 4 phần làm tập huấn luyện và 1 phần làm tập kiểm định. Giai đoạn thứ ba, huấn luyện mô hình cuối cùng trên toàn bộ 80% dữ liệu. Giai đoạn thứ tư, đánh giá mô hình trên 20% tập kiểm tra cố định (526 mẫu) — tập dữ liệu không được sử dụng trong quá trình huấn luyện.

2.2.5. Áp dụng mô hình

Sau khi huấn luyện, mô hình được áp dụng để phân loại toàn bộ vùng nghiên cứu với khoảng 16.2 triệu điểm ảnh hợp lệ, tương đương diện tích 162,468 hecta. Quy trình dự đoán được thực hiện như sau.

Đầu tiên, dữ liệu đặc trưng (feature stack) gồm 27 kênh được tải vào bộ nhớ. Với mỗi điểm ảnh cần phân loại, một vùng lân cận kích thước 3×3 được trích xuất, chứa thông tin của điểm ảnh trung tâm và 8 điểm ảnh xung quanh. Đối với các điểm ảnh ở biên, kỹ thuật phản chiếu (mirror padding) được sử dụng để tạo đủ ngữ cảnh 3×3 . Mỗi patch sau đó được chuẩn hóa Z-score sử dụng các tham số (mean, std) đã tính từ tập huấn luyện.

Dữ liệu đã chuẩn hóa được đưa qua mô hình CNN để tính xác suất thuộc về mỗi lớp. Mô hình xuất ra vector 4 chiều cho mỗi điểm ảnh, tương ứng với xác suất thuộc về 4 lớp: Rừng ổn định, Mất rừng, Phi rừng, và Phục hồi rừng. Lớp có xác suất cao nhất được chọn làm kết quả phân loại thông qua hàm argmax.

Do khối lượng dữ liệu lớn, việc dự đoán được thực hiện theo lô (batch), mỗi lô gồm 10,000 điểm ảnh. Kỹ thuật độ chính xác hỗn hợp (mixed precision) với định dạng FP16 được sử dụng để giảm mức sử dụng bộ nhớ GPU và tăng tốc độ tính toán. Kết quả phân loại được xuất ra dưới dạng file GeoTIFF với hệ quy chiếu EPSG:32648 (WGS 84/UTM Zone 48N) và độ phân giải 10m, cho phép tích hợp trực tiếp với các phần mềm GIS.

CHƯƠNG 3. KẾT QUẢ THỰC NGHIỆM ỦNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG GIÁM SÁT BIẾN ĐỘNG RỪNG TỈNH CÀ MAU

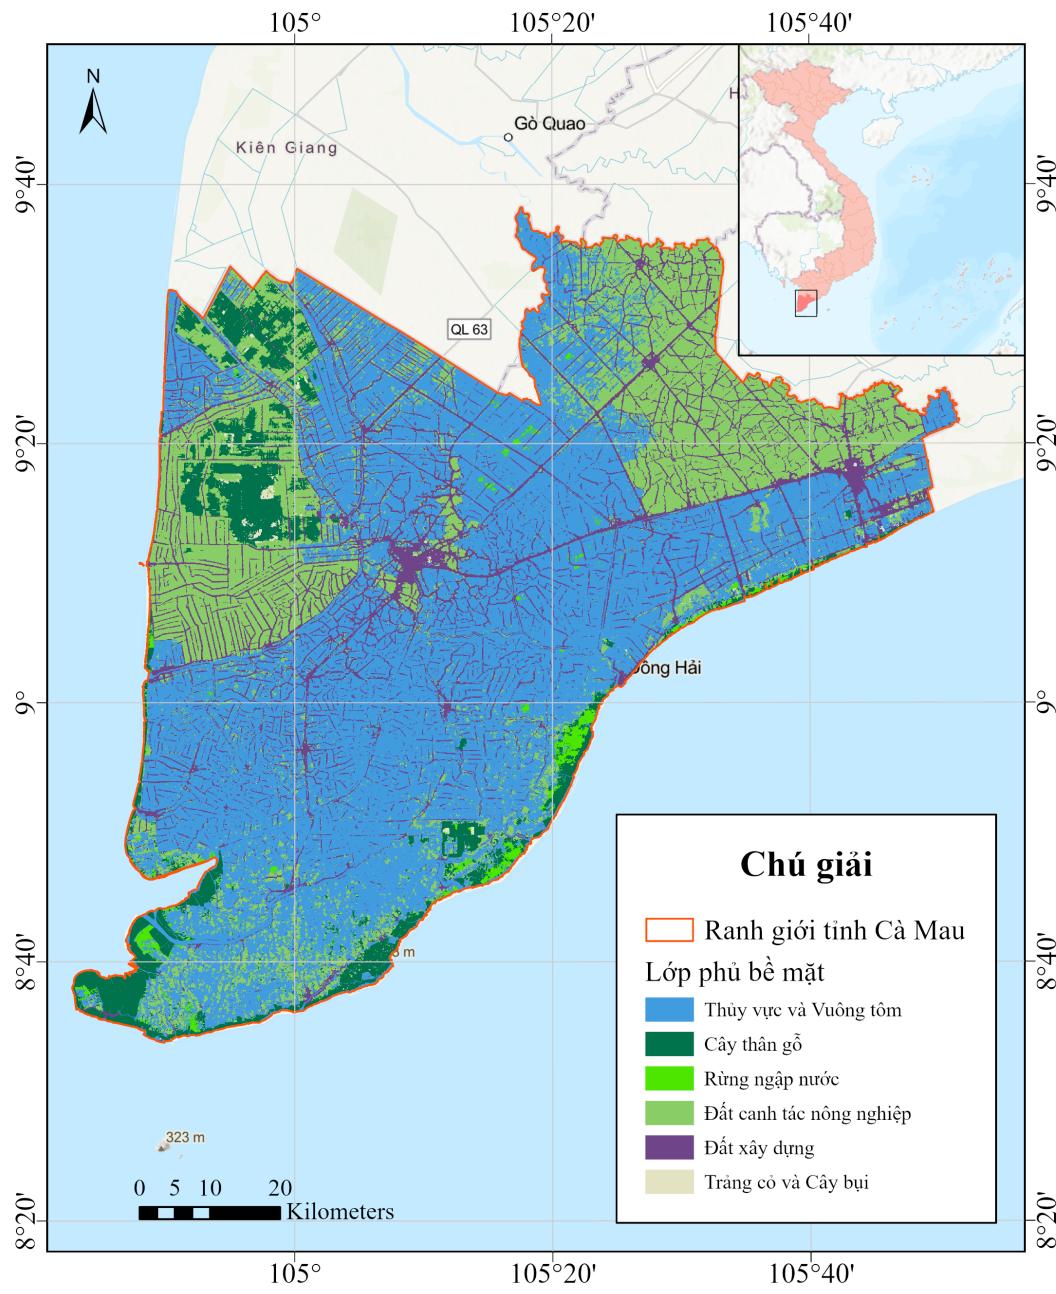
3.1. Thiết lập thực nghiệm

3.1.1. Khu vực nghiên cứu

Theo Nghị quyết số 1278/NQ-UBTVQH15 ngày 24/10/2024 của Ủy ban Thường vụ Quốc hội, kể từ ngày 01/07/2025, tỉnh Cà Mau và tỉnh Bạc Liêu được sáp nhập thành tỉnh Cà Mau mới với tổng diện tích tự nhiên 7,942.38 km² và dân số khoảng 2.6 triệu người. Đô án này nghiên cứu trên phạm vi rừng của tỉnh Cà Mau mới, bao gồm cả vùng rừng thuộc địa bàn Bạc Liêu cũ.

Tỉnh Cà Mau mới nằm ở cực Nam Tổ Quốc, sở hữu hệ sinh thái rừng đa dạng bao gồm cả rừng ngập mặn ven biển và rừng tràm nội địa. Theo số liệu trước khi sáp nhập, tỉnh Cà Mau cũ có diện tích rừng khoảng 94,319 ha và tỉnh Bạc Liêu có khoảng 5,730 ha rừng, tổng cộng khoảng 100,000 ha rừng trên toàn tỉnh Cà Mau mới [3]. Trong đó, rừng ngập mặn Cà Mau chiếm khoảng 20% diện tích rừng ngập mặn của Việt Nam. Hệ thống rừng tại Cà Mau đóng vai trò then chốt trong việc phòng hộ ven biển (chắn sóng, chống xâm thực và bảo vệ bờ biển), bảo tồn đa dạng sinh học vì là môi trường sống cho nhiều loài động thực vật quý hiếm, cung cấp nguồn sinh kế thông qua các hoạt động thủy sản và du lịch sinh thái, và góp phần giảm nhẹ biến đổi khí hậu nhờ khả năng lưu giữ carbon cao, gấp khoảng 3–5 lần so với rừng nhiệt đới trên cạn [5, 9].

Tuy nhiên, rừng Cà Mau đang phải đối mặt với nhiều thách thức. Trước hết là áp lực chuyển đổi sang nuôi tôm do kinh tế, khiến nhiều khu vực rừng bị chuyển đổi thành ao nuôi. Ngoài ra, hiện tượng xâm nhập mặn gia tăng do biến đổi khí hậu làm giảm sức khỏe rừng; đồng thời xói mòn bờ biển cũng làm suy giảm diện tích rừng ven biển; và tình trạng thiếu nước ngọt ảnh hưởng tới khả năng tái sinh tự nhiên của rừng. Giai đoạn 2011-2023, sạt lở vùng ven biển đã làm mất hơn 6,200 ha đất và rừng phòng hộ [2].



Hình 3.1: Bản đồ lớp phủ bè mặt khu vực tỉnh Cà Mau.

Đồ án tập trung vào toàn bộ vùng quy hoạch lâm nghiệp của tỉnh Cà Mau mới. Dữ liệu ranh giới quy hoạch lâm nghiệp được cung cấp bởi Công ty TNHH Tư vấn và Phát triển Đồng Xanh — đối tác của Chi cục Kiểm lâm tỉnh Cà Mau.

Tổng diện tích ranh giới quy hoạch là 170,178.82 ha (tương đương 1,701.79 km²), bao gồm 666 polygon trong file shapefile ranh giới. Diện tích thực tế được phân loại là

162,468.50 ha (khoảng 95.5% diện tích ranh giới); phần còn lại (7,710 ha, chiếm 4.5%) bị loại do mây che phủ hoặc dữ liệu không hợp lệ (nodata) trong quá trình xử lý ảnh vệ tinh. Kích thước raster là $12,547 \times 10,917$ pixels (ở độ phân giải 10m), sử dụng hệ quy chiếu EPSG:32648 (WGS 84 / UTM Zone 48N).

3.1.2. Dữ liệu thực địa tại Cà Mau

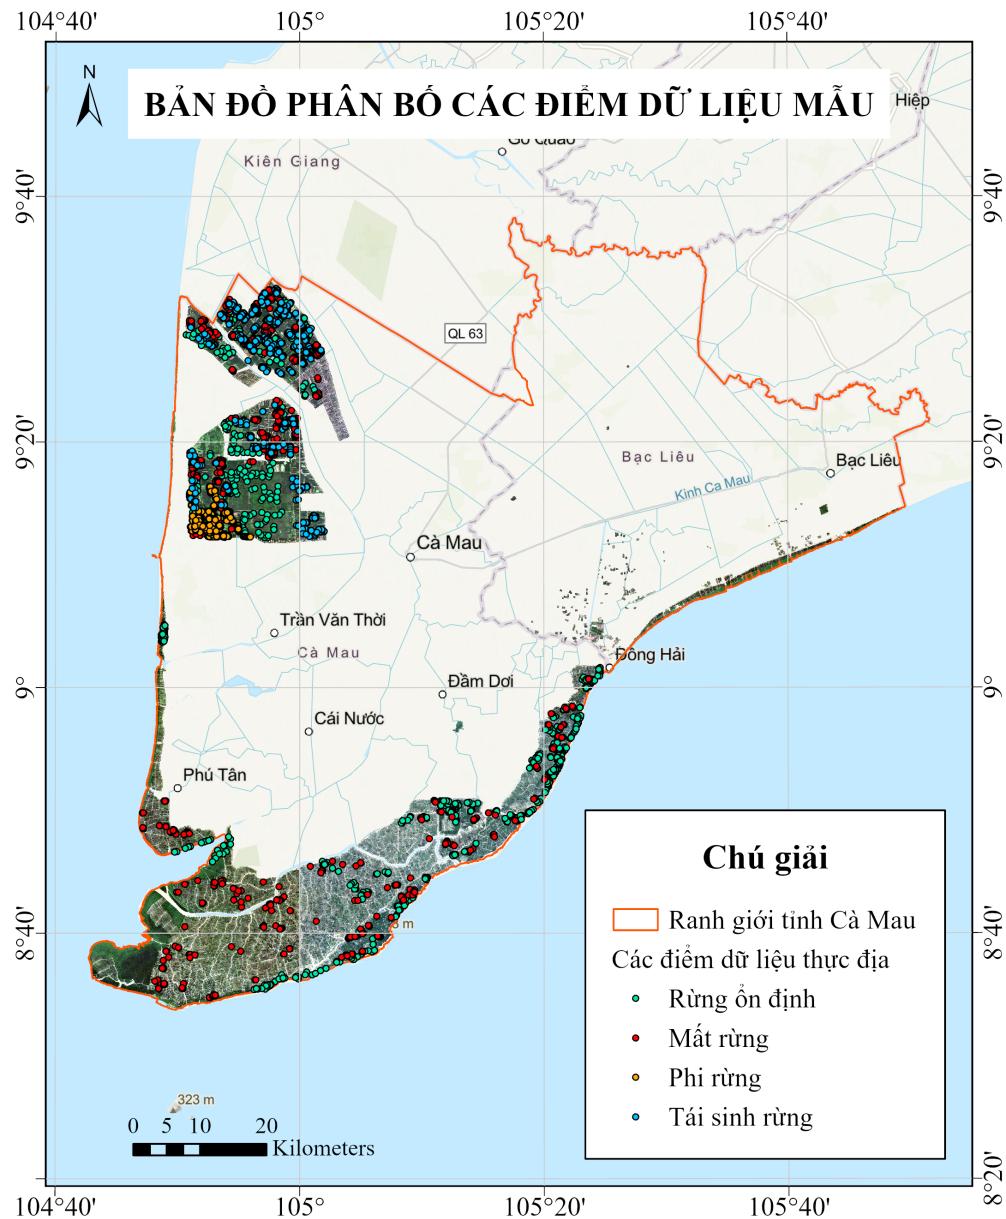
Dữ liệu thực địa được thu thập thông qua quy trình khảo sát chuyên nghiệp với sự phối hợp giữa Chi cục Kiểm lâm tỉnh Cà Mau và Công ty TNHH Tư vấn và Phát triển Đồng Xanh (GFD). Quy trình thu thập gồm ba giai đoạn. Giai đoạn đầu tiên là khảo sát thực địa bằng thiết bị bay không người lái (drone) để ghi nhận hình ảnh và xác định trạng thái rừng. Giai đoạn thứ hai là số hóa các điểm dữ liệu thực địa trên phần mềm QGIS, đối chiếu với ảnh vệ tinh Sentinel-2. Giai đoạn cuối cùng là kiểm tra chéo và loại bỏ các điểm không rõ ràng hoặc nằm trong vùng mây che phủ.

Dữ liệu cuối cùng được xuất dưới dạng file CSV với cấu trúc gồm 4 trường: id, label, x và y (tọa độ theo hệ quy chiếu EPSG:32648).

Bảng 3.1: Thông kê dữ liệu thực địa theo lớp biến động

Lớp	Tên	Số điểm	Tỷ lệ	Mô tả
0	Rừng ổn định	656	24.9%	Có rừng ở cả 2 kỳ
1	Mất rừng	650	24.7%	Có rừng → không có rừng
2	Phi rừng	664	25.3%	Không có rừng ở cả 2 kỳ
3	Phục hồi rừng	660	25.1%	Không có → có rừng
Tổng		2,630	100%	Phân bố cân bằng

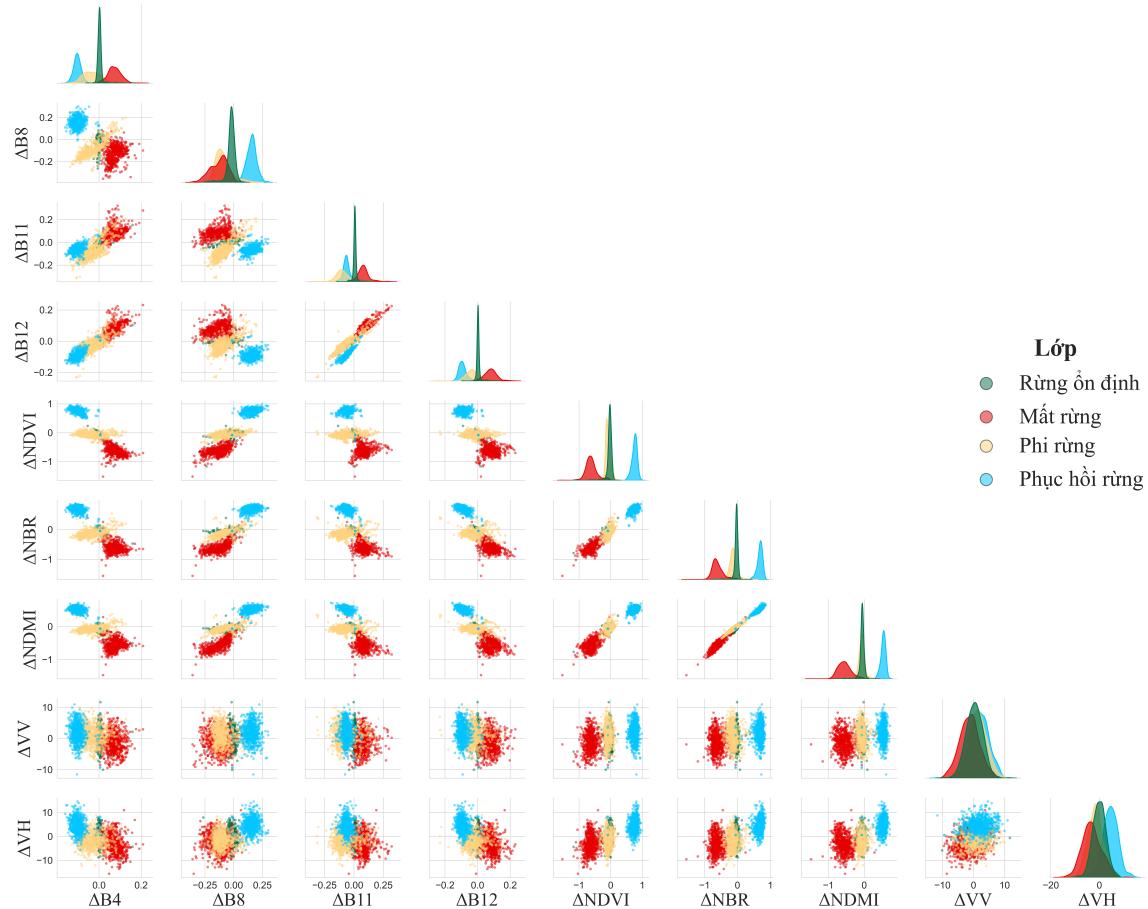
Phân bố không gian của các điểm dữ liệu thực địa được minh họa trong Hình 3.2. Các điểm mẫu được thu thập phân tán trên toàn bộ khu vực nghiên cứu, đảm bảo tính đại diện về mặt không gian cho các loại hình biến động rừng khác nhau.



Hình 3.2: Bản đồ phân bố không gian các điểm dữ liệu thực địa trên khu vực nghiên cứu tỉnh Cà Mau

Mỗi điểm ảnh trong bộ dữ liệu được biểu diễn bởi 27 đặc trưng: 9 đặc trưng tại thời điểm T_1 , 9 đặc trưng tại thời điểm T_2 , và 9 đặc trưng delta ($\Delta = T_2 - T_1$). Mô hình CNN sử dụng toàn bộ 27 đặc trưng này làm đầu vào để tận dụng tối đa thông tin từ cả hai thời điểm quan sát. Tuy nhiên, để phân tích trực quan khả năng phân biệt của dữ liệu, nghiên cứu lựa chọn minh họa 9 đặc trưng delta thông qua biểu đồ pair plot (Hình 3.3). Việc lựa chọn này xuất phát từ hai lý do chính. Thứ nhất, biểu đồ pair plot với 27 đặc trưng sẽ tạo

ra ma trận $27 \times 27 = 729$ ô, quá lớn để quan sát và phân tích hiệu quả. Thứ hai, đặc trưng delta trực tiếp biểu diễn sự thay đổi giữa hai thời điểm, do đó phù hợp nhất để đánh giá khả năng phân tách các lớp biến động rừng.



Hình 3.3: Phân bố các đặc trưng delta theo lớp biến động rừng

Biểu đồ pair plot trình bày mối quan hệ giữa 9 đặc trưng delta bao gồm các band quang phổ Sentinel-2 ($\Delta B4$, $\Delta B8$, $\Delta B11$, $\Delta B12$), các chỉ số thực vật ($\Delta NDVI$, ΔNBR , $\Delta NDMI$) và các kênh radar Sentinel-1 (ΔVV , ΔVH). Trên đường chéo chính, biểu đồ histogram thể hiện phân bố của từng đặc trưng theo bốn lớp biến động; các ô còn lại hiển thị biểu đồ tán xạ (scatter plot) giữa các cặp đặc trưng.

Phân tích phân bố trên đường chéo cho thấy các chỉ số thực vật delta thể hiện khả năng phân biệt vượt trội giữa các lớp biến động. Cụ thể, lớp Rừng ổn định và Phi rừng có phân bố tập trung quanh giá trị 0, phản ánh sự ổn định về lớp phủ thực vật qua hai thời điểm quan sát. Ngược lại, lớp Mát rừng thể hiện phân bố lệch về phía âm do sự suy giảm các chỉ số thực vật khi rừng bị chuyển đổi, trong khi lớp Phục hồi rừng có phân bố

lệch về phía dương tương ứng với sự gia tăng sinh khối thực vật. Sự phân tách rõ ràng này khẳng định vai trò then chốt của Δ NDVI, Δ NBR và Δ NDMI trong việc nhận diện biến động rừng.

Đối với các band quang phổ gốc, mức độ chồng chéo giữa các lớp cao hơn so với các chỉ số thực vật, tuy nhiên Δ B8 (kênh cận hồng ngoại) vẫn cho thấy khả năng phân biệt tương đối tốt giữa lớp Mất rừng và Phục hồi rừng. Các đặc trưng radar Δ VV và Δ VH có phân bố chồng chéo đáng kể giữa bốn lớp, cho thấy khả năng phân biệt độc lập hạn chế hơn so với dữ liệu quang học. Tuy nhiên, việc tích hợp dữ liệu radar vẫn mang lại giá trị bổ sung, đặc biệt trong điều kiện mây che phủ thường xuyên tại khu vực nghiên cứu.

Phân tích các biểu đồ tán xạ cho thấy mối tương quan dương mạnh giữa ba chỉ số thực vật (Δ NDVI, Δ NBR, Δ NDMI), thể hiện qua sự phân bố các điểm dữ liệu gần đường chéo. Tương tự, Δ B11 và Δ B12 có tương quan cao do cùng thuộc dải sóng ngắn hồng ngoại (SWIR). Trên không gian đặc trưng hai chiều của các chỉ số thực vật, lớp Mất rừng và Phục hồi rừng phân bố ở hai vùng đối lập nhau, trong khi lớp Rừng ổn định và Phi rừng tập trung quanh gốc tọa độ. Đặc điểm phân bố này tạo điều kiện thuận lợi cho mô hình CNN trong việc học các ranh giới quyết định phân tách bốn lớp biến động.

3.1.3. Cấu hình phần cứng và phần mềm

Môi trường thí nghiệm sử dụng phần cứng với CPU **Intel Xeon E-2334 (4 nhân, 8 luồng)**, GPU NVIDIA GeForce RTX 4080 (16GB VRAM), bộ nhớ RAM 64GB và bộ nhớ lưu trữ 1TB SSD. Về phần mềm, hệ điều hành được sử dụng là Windows 10 Pro, môi trường Python 3.8 cùng PyTorch 2.0 có hỗ trợ CUDA để huấn luyện mô hình, GDAL 3.4 cho xử lý dữ liệu không gian và các thư viện khoa học dữ liệu như NumPy, scikit-learn và pandas.

3.1.4. Phân chia dữ liệu

Bộ dữ liệu thực địa gồm 2,630 điểm, trong đó phân bố lớp gần như cân bằng: Lớp 0 (Rừng ổn định) 656 điểm (24.94%), Lớp 1 (Mất rừng) 650 điểm (24.71%), Lớp 2 (Phi rừng) 664 điểm (25.25%) và Lớp 3 (Phục hồi rừng) 660 điểm (25.10%).

Bảng 3.2: Phân bổ dữ liệu theo tập huấn luyện và kiểm tra

Tập dữ liệu	Số mẫu	Tỷ lệ
Training + Validation (5-Fold CV)	2,104	80%
Test (cố định)	526	20%
Tổng	2,630	100%

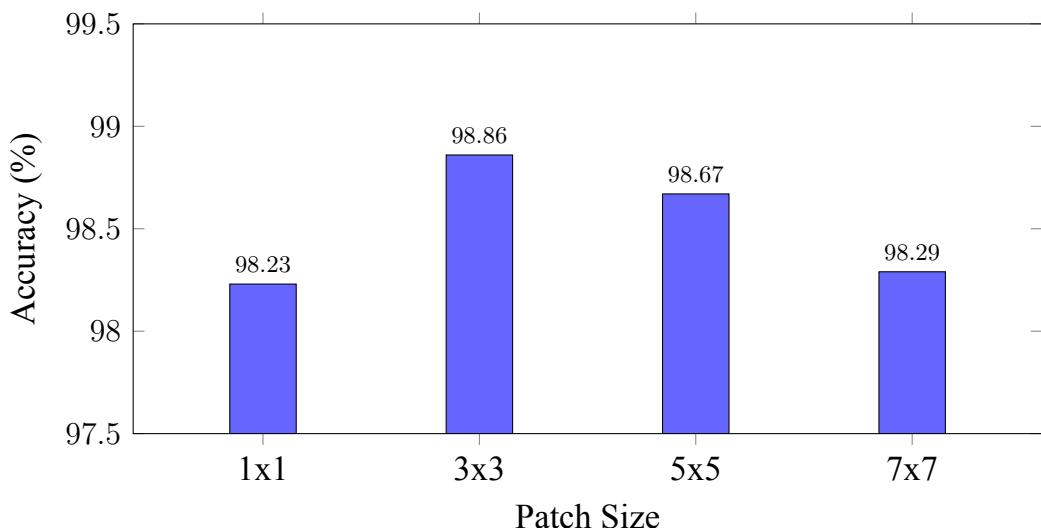
Việc chia tập dữ liệu được thực hiện như sau: 80% dữ liệu (2,104 patches) được dành cho Train+Val để thực hiện 5-Fold Cross Validation, còn 20% dữ liệu (526 patches) được giữ lại làm fixed test set.

3.2. Thử nghiệm mô hình

3.2.1. Ảnh hưởng của Patch Size

Bảng 3.3: So sánh các kích thước patch

Patch Size	Accuracy	ROC-AUC	Thời gian huấn luyện	Số tham số
1×1 (pixel-wise)	98.23%	99.78%	12.5s	25,348
3×3 (baseline)	98.86%	99.98%	15.2s	36,676
5×5	98.67%	99.89%	28.3s	52,484
7×7	98.29%	99.86%	41.2s	71,108



Hình 3.4: So sánh Accuracy theo các Patch Size

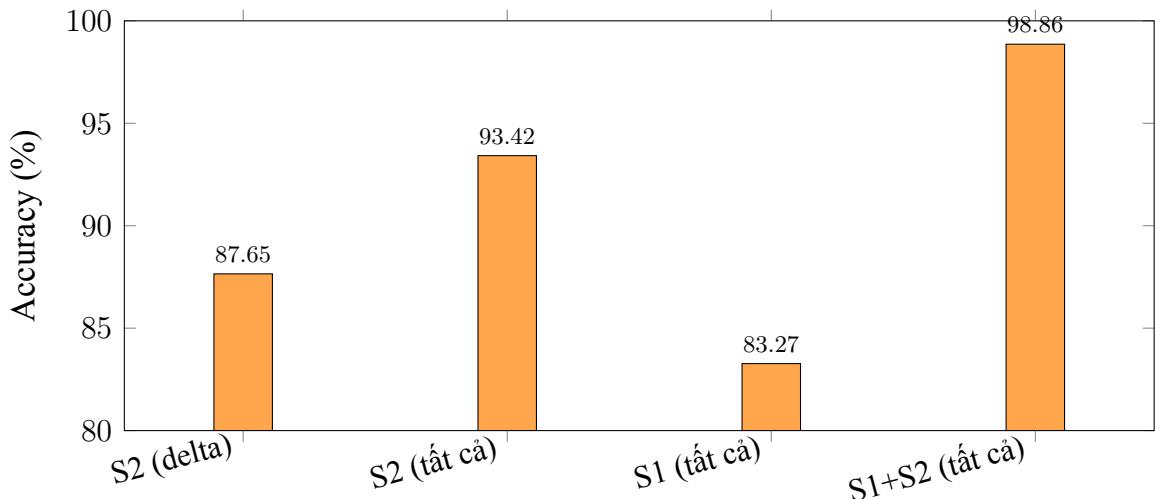
Qua Bảng 3.3 và Hình 3.4, có thể rút ra một số nhận xét quan trọng. Với patch size 1×1 (pixel-wise), mô hình đạt accuracy 98.23%, cho thấy chỉ riêng thông tin phổ tại mỗi pixel đã đủ để phân biệt các lớp biến động rùng với độ chính xác cao, tuy nhiên cách tiếp cận này bỏ qua thông tin ngữ cảnh không gian. Patch size 3×3 đạt kết quả tốt nhất (98.86% accuracy, 99.98% ROC-AUC) với mức tăng thời gian huấn luyện chấp nhận được (+2.7 giây so với 1×1), cho thấy kích thước này cân bằng tốt giữa việc khai thác ngữ cảnh không gian địa phương và tránh nhiễu từ các pixel xa.

Đối với patch size 5×5 và 7×7 , accuracy giảm dần (98.67% và 98.29%) mặc dù số tham số mô hình tăng đáng kể, cho thấy với độ phân giải 10m của Sentinel-2, ngữ cảnh không gian quá rộng (50-70m) có thể đưa vào nhiều từ các lớp phủ lân cận, đặc biệt tại các vùng ranh giới. Thời gian huấn luyện tăng gần tuyến tính với số tham số, từ 12.5s (1×1) lên 41.2s (7×7), cho thấy chi phí tính toán tăng đáng kể khi mở rộng patch size mà không đem lại cải thiện về accuracy. Do đó, có thể kết luận rằng patch size 3×3 là tối ưu cho bộ dữ liệu này, đạt được sự cân bằng tốt nhất giữa độ chính xác, thời gian huấn luyện và khả năng khai thác ngữ cảnh không gian.

3.2.2. Ảnh hưởng của nguồn dữ liệu

Bảng 3.4: Nghiên cứu loại trừ các nguồn dữ liệu (Ablation Study)

Cấu hình	Số đặc trưng	Accuracy	ROC-AUC
Chỉ Sentinel-2 (delta)	7	87.65%	94.12%
Sentinel-2 (trước + sau + delta)	21	93.42%	97.58%
Chỉ Sentinel-1 (trước + sau + delta)	6	83.27%	91.45%
S1 + S2 (tất cả)	27	98.86%	99.98%



Hình 3.5: So sánh Accuracy theo các nguồn dữ liệu

Qua Bảng 3.4 và Hình 3.5, có thể rút ra các nhận xét quan trọng về vai trò của từng nguồn dữ liệu. Sentinel-2 đóng vai trò chủ đạo trong phân loại biến động rừng, thể hiện qua việc chỉ với dữ liệu Sentinel-2 delta (7 kênh biến động), mô hình đã đạt 87.65% accuracy, và khi bổ sung đầy đủ dữ liệu trước, sau và delta (21 kênh), accuracy tăng lên 93.42%, khẳng định tầm quan trọng của thông tin quang phổ và phương pháp phân tích 2 thời điểm trong phát hiện biến động. Trong khi đó, Sentinel-1 đơn lẻ có hiệu suất thấp nhất (83.27% accuracy với 6 kênh); dữ liệu ra-đa khẩu độ tổng hợp tuy có ưu điểm không bị ảnh hưởng bởi mây và có khả năng quan sát cấu trúc rừng, nhưng độ phân giải phổ hạn chế (chỉ có VV và VH) khiến việc phân biệt các lớp phủ trở nên khó khăn hơn đáng kể so với dữ liệu quang học đa phổ.

Sự kết hợp S1+S2 cho kết quả tốt nhất (98.86% accuracy, 99.98% ROC-AUC), vượt trội đáng kể so với việc chỉ sử dụng Sentinel-2 (+5.44%), cho thấy dữ liệu ra-đa bổ sung thông tin cấu trúc và độ ẩm mà dữ liệu quang học không nắm bắt được, đặc biệt hữu ích cho việc phân biệt rừng có mật độ tán khác nhau, phát hiện vùng rừng suy thoái chưa thể hiện rõ trên ảnh quang học, và cải thiện phân loại trong điều kiện có mây một phần. Bên cạnh đó, đóng góp của thông tin thời gian là đáng kể khi accuracy tăng từ 87.65% (chỉ delta) lên 93.42% (đầy đủ trước + sau + delta), khẳng định giá trị của việc khai thác thông tin đa thời gian trong phát hiện biến động.

Từ các kết quả trên, có thể kết luận rằng việc kết hợp Sentinel-1 và Sentinel-2 cho kết quả tối ưu nhất. Dữ liệu ra-đa và quang học có tính bổ sung cao: Sentinel-2 cung cấp thông tin chi tiết về thành phần hóa học và sinh lý của thực vật thông qua các kênh quang

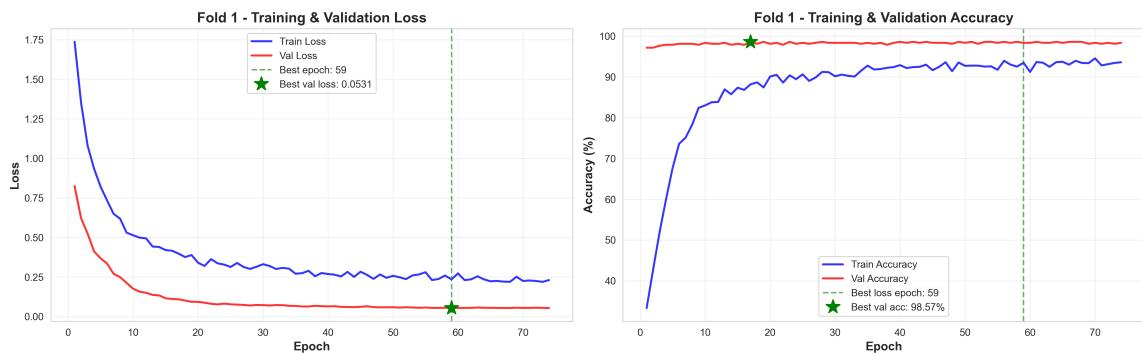
phổ, trong khi Sentinel-1 cung cấp thông tin về cấu trúc và độ ẩm của tán rừng. Sự kết hợp này đặc biệt phù hợp cho giám sát rừng ngập mặn ven biển, nơi điều kiện thời tiết thường xuyên có mây và sương mù.

3.3. Kết quả

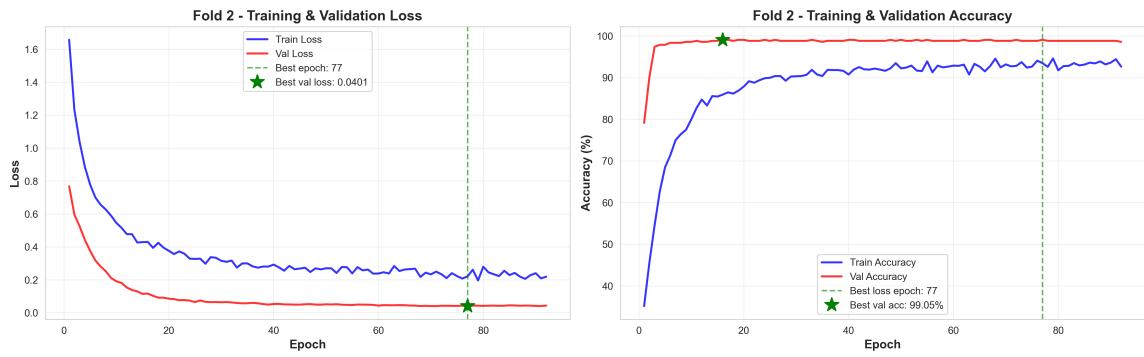
3.3.1. Kết quả huấn luyện mô hình CNN

Để đánh giá độ ổn định của mô hình, nghiên cứu áp dụng phương pháp kiểm định chéo 5 phần (5-Fold Cross Validation). Phương pháp này chia dữ liệu thành 5 phần bằng nhau, luân phiên sử dụng mỗi phần làm tập kiểm tra trong khi 4 phần còn lại làm tập huấn luyện; kết quả cuối cùng là trung bình của 5 lần đánh giá.

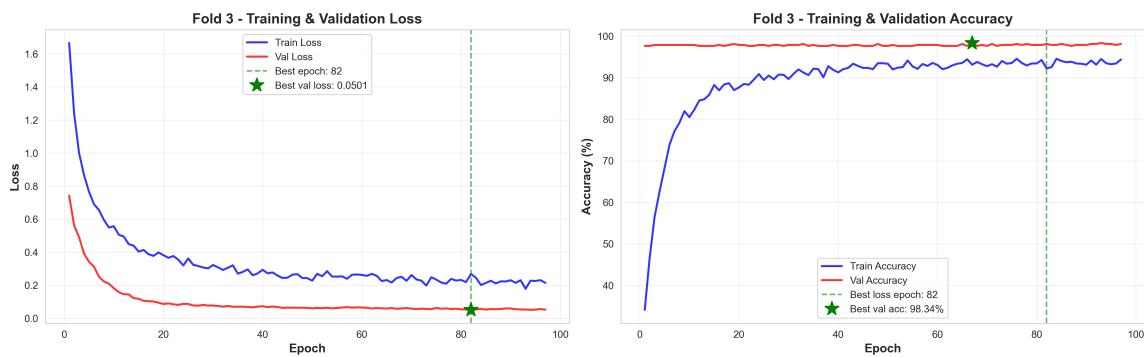
Hình 3.6 đến Hình 3.10 trình bày diễn biến hàm mất mát (loss) và độ chính xác (accuracy) trong quá trình huấn luyện của từng fold. Mỗi hình bao gồm hai biểu đồ: biểu đồ bên trái thể hiện giá trị loss trên tập huấn luyện (đường màu xanh) và tập kiểm định (đường màu đỏ) theo số epoch; biểu đồ bên phải thể hiện accuracy tương ứng. Đường thẳng đứng màu xanh lá đánh dấu epoch đạt validation loss thấp nhất, tại đó mô hình được lưu lại.



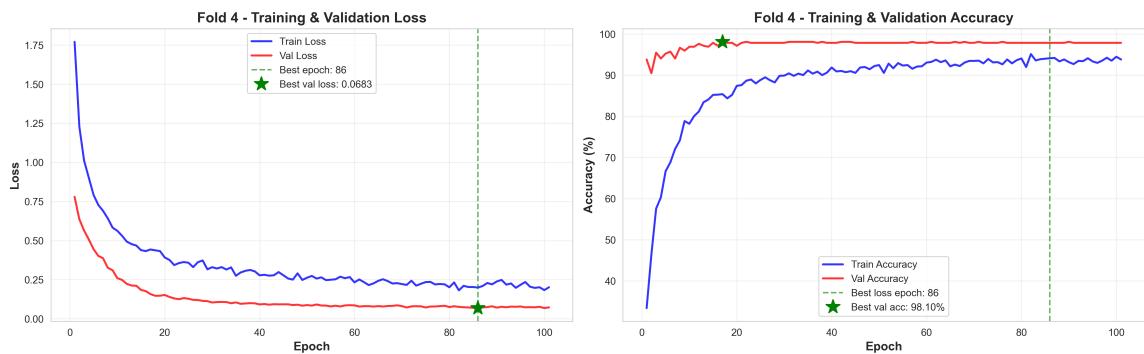
Hình 3.6: Diễn biến loss và accuracy trong quá trình huấn luyện Fold 1



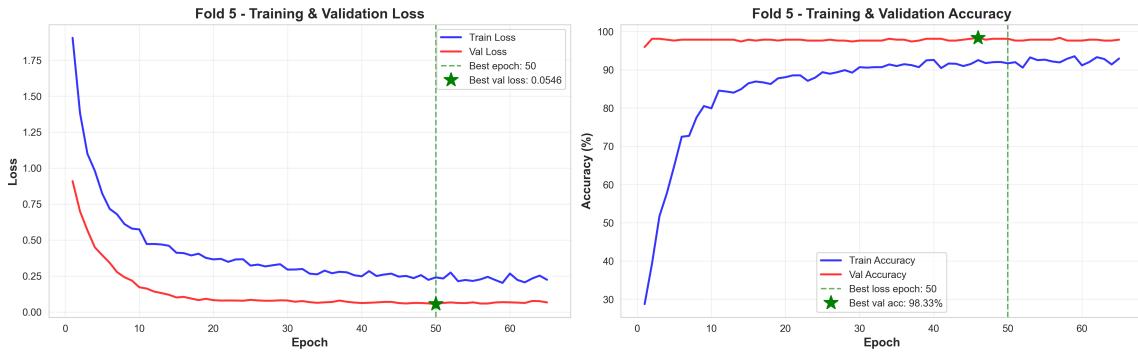
Hình 3.7: Biểu đồ biến loss và accuracy trong quá trình huấn luyện Fold 2



Hình 3.8: Biểu đồ biến loss và accuracy trong quá trình huấn luyện Fold 3



Hình 3.9: Biểu đồ biến loss và accuracy trong quá trình huấn luyện Fold 4



Hình 3.10: Diễn biến loss và accuracy trong quá trình huấn luyện Fold 5

Phân tích các biểu đồ huấn luyện cho thấy một số đặc điểm quan trọng. Về xu hướng hội tụ, validation loss giảm nhanh trong khoảng 10 epoch đầu tiên và dần ổn định ở mức thấp (0.04–0.07), trong khi training loss giảm chậm hơn và duy trì ở mức cao hơn (0.20–0.25). Hiện tượng validation loss thấp hơn training loss là đặc trưng điển hình khi sử dụng Dropout với tỷ lệ cao (70%), bởi Dropout chỉ được kích hoạt trong quá trình huấn luyện, làm tăng độ khó cho mô hình khi học, trong khi ở chế độ đánh giá thì Dropout bị tắt và mô hình sử dụng toàn bộ các nơ-ron. Điều này cho thấy kỹ thuật điều chỉnh đang hoạt động hiệu quả và mô hình không bị quá khớp.

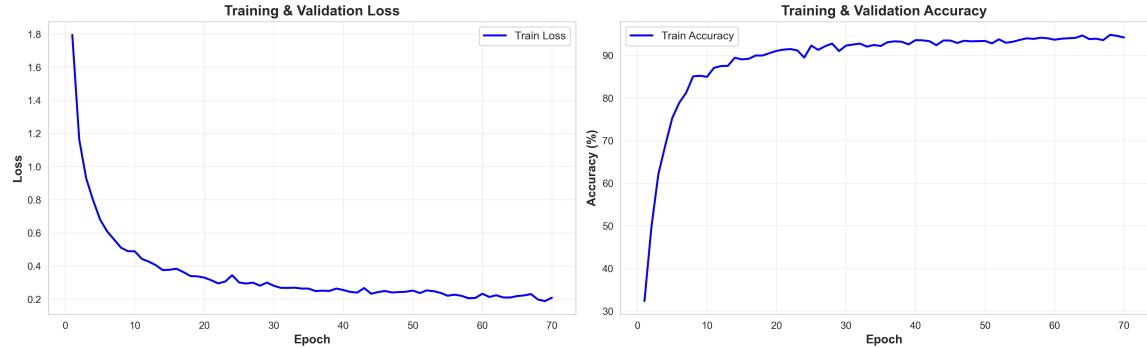
Về tốc độ học, validation accuracy đạt ngưỡng trên 98% chỉ sau khoảng 10–15 epoch và duy trì ổn định trong suốt quá trình huấn luyện. Ngược lại, training accuracy tăng chậm hơn do ảnh hưởng của Dropout, đạt khoảng 90–95% ở cuối quá trình huấn luyện. Cơ chế early stopping đã dừng huấn luyện tại các epoch khác nhau cho mỗi fold (từ epoch 50 đến 86), cho thấy mô hình đã hội tụ và việc tiếp tục huấn luyện không cải thiện thêm hiệu suất trên tập kiểm định.

Bảng 3.5 tổng hợp các thông số huấn luyện của 5 fold.

Bảng 3.5: Tổng hợp kết quả huấn luyện 5-Fold Cross Validation

Fold	Best Epoch	Best Val Loss	Best Val Accuracy
Fold 1	59	0.0531	98.57%
Fold 2	77	0.0401	99.05%
Fold 3	82	0.0501	98.34%
Fold 4	86	0.0683	98.10%
Fold 5	50	0.0546	98.33%
Trung bình	71	0.0532	98.48%

Sau khi hoàn tất kiểm định chéo, mô hình cuối cùng được huấn luyện trên toàn bộ 80% dữ liệu (2,104 mẫu) để tận dụng tối đa lượng dữ liệu huấn luyện. Hình 3.11 trình bày diễn biến loss và accuracy trong quá trình huấn luyện mô hình cuối cùng.



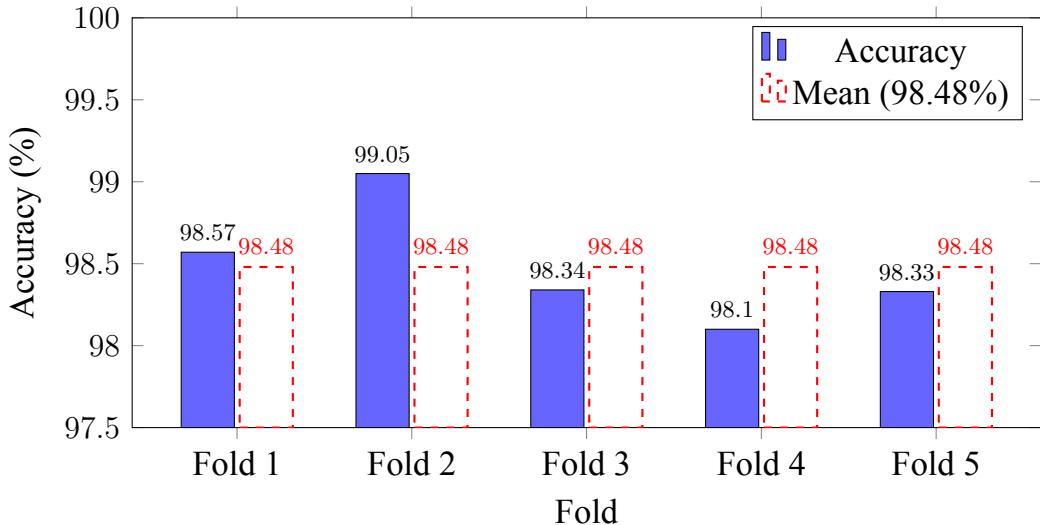
Hình 3.11: Diễn biến loss và accuracy trong quá trình huấn luyện mô hình cuối cùng (80% dữ liệu)

Do huấn luyện trên toàn bộ 80% dữ liệu mà không có tập kiểm định riêng, biểu đồ chỉ hiển thị training loss và training accuracy. Quá trình huấn luyện kéo dài khoảng 70 epoch với loss giảm từ khoảng 1.8 xuống 0.2 và accuracy tăng từ khoảng 30% lên trên 95%. Mô hình này sau đó được đánh giá trên 20% tập kiểm tra cố định (526 mẫu) để báo cáo kết quả cuối cùng.

Bảng 3.6: Kết quả kiểm định chéo 5 phần (5-Fold Cross Validation)

Fold	Accuracy	F1-Score
Fold 1	98.57%	98.57%
Fold 2	99.05%	99.05%
Fold 3	98.34%	98.34%
Fold 4	98.10%	98.10%
Fold 5	98.33%	98.33%
Mean ± Std	98.48% ± 0.36%	98.48% ± 0.36%

Kết quả kiểm định chéo cho thấy mô hình đạt được sự ổn định cao với độ lệch chuẩn của Accuracy chỉ khoảng 0.36%. Accuracy của từng fold đều vượt ngưỡng 98%, phản ánh khả năng tổng quát hóa tốt của mô hình và không có dấu hiệu quá khopr nghiêm trọng.



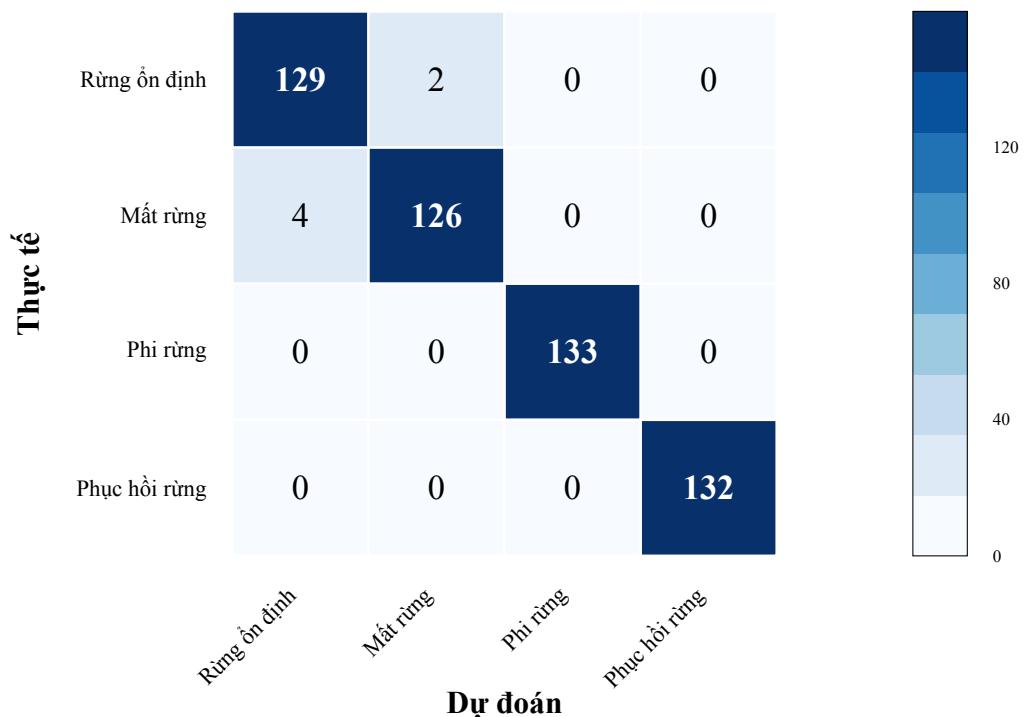
Hình 3.12: So sánh Accuracy giữa các fold trong Cross Validation

Sau khi hoàn tất kiểm định chéo, hiệu suất mô hình được đánh giá trên tập kiểm tra cố định thông qua các chỉ số phổ biến trong phân loại: *Accuracy* (tỷ lệ phân loại đúng), *Precision* (độ tin cậy của dự đoán dương), *Recall* (khả năng phát hiện các mẫu dương), *F1-Score* (trung bình điều hòa của Precision và Recall), và *ROC-AUC* (diện tích dưới đường cong ROC, đo khả năng phân biệt của mô hình).

Bảng 3.7: Các chỉ số đánh giá trên tập kiểm tra (526 mẫu)

Metric	Value	Percent
Accuracy	0.9886	98.86%
Precision (macro avg)	0.9886	98.86%
Recall (macro avg)	0.9886	98.86%
F1-Score (macro avg)	0.9886	98.86%
ROC-AUC (macro avg)	0.9998	99.98%

Ma trận nhầm lẫn (Confusion Matrix) thể hiện chi tiết kết quả phân loại, trong đó mỗi hàng tương ứng với lớp thực tế và mỗi cột tương ứng với lớp dự đoán; các phần tử trên đường chéo chính là số mẫu phân loại đúng, còn các phần tử ngoài đường chéo là các trường hợp phân loại sai.



Hình 3.13: Confusion Matrix dạng heatmap trên tập kiểm tra ($n=526$, Accuracy: 98.86%)

Bảng 3.8: Phân tích chi tiết từng lớp

Lớp	Precision	Recall	F1-Score	Samples	Errors
0 - Rừng ổn định	96.99%	98.47%	97.73%	131	4 FP, 2 FN
1 - Mất rừng	98.44%	96.92%	97.67%	130	2 FP, 4 FN
2 - Phi rừng	100.00%	100.00%	100.00%	133	0
3 - Phục hồi rừng	100.00%	100.00%	100.00%	132	0

Ghi chú: FP = False Positive (dương tính giả), FN = False Negative (âm tính giả)

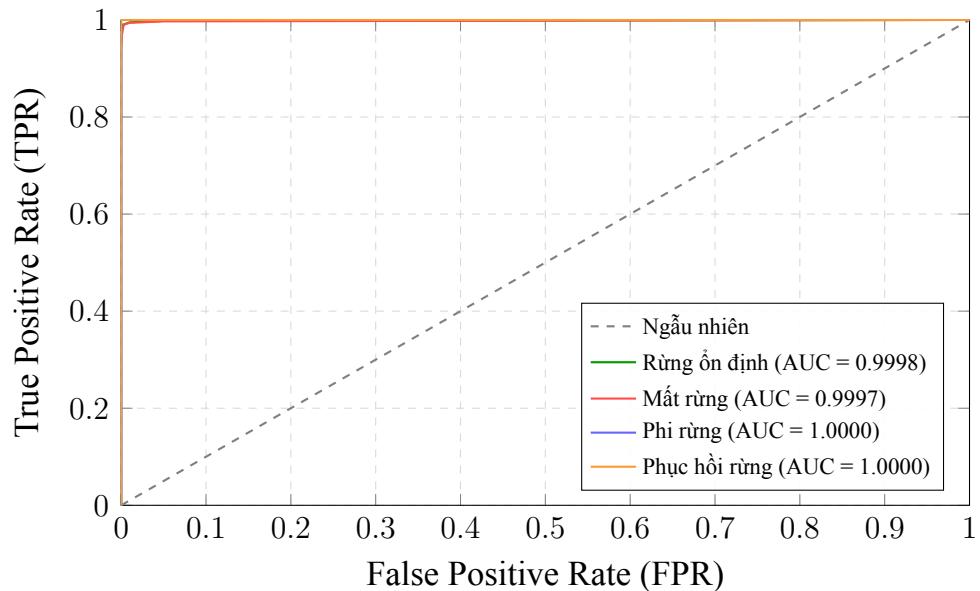
Tổng cộng chỉ có 6/526 mẫu bị phân loại sai, tương đương tỷ lệ lỗi 1.14%. Trong đó, hai mẫu thuộc Lớp 0 (Rừng ổn định) bị nhầm thành Lớp 1 (Mất rừng) và bốn mẫu thuộc Lớp 1 (Mất rừng) bị nhầm thành Lớp 0 (Rừng ổn định). Đánh giá chi tiết cho thấy Lớp 2 (Phi rừng) và Lớp 3 (Phục hồi rừng) được phân loại hoàn hảo với Accuracy 100%.

Việc nhầm lẫn chỉ xảy ra giữa hai lớp Rừng ổn định (Lớp 0) và Mất rừng (Lớp 1) có thể được giải thích bởi một số yếu tố. Trước hết, cả hai lớp đều có sự hiện diện của rừng ở ít nhất một thời điểm, dẫn đến sự tương đồng về đặc trưng quang phổ; các khu vực rừng bị suy thoái nhẹ có thể có phô phản xạ đặc trưng tương tự với rừng ổn định, đặc

biệt khi mức độ mất rừng không rõ ràng. Bên cạnh đó, hiệu ứng biên cung góp phần gây nhầm lẫn khi tại ranh giới giữa vùng rừng và vùng mất rừng, các điểm ảnh có thể chứa cả hai loại lớp phủ (điểm ảnh hỗn hợp), dẫn đến vector đặc trưng không diễn hình cho một lớp cụ thể. Ngoài ra, một số khu vực rừng ngập mặn có thể có biến động theo mùa về mật độ tán lá, tạo ra sự thay đổi NDVI tương tự như mất rừng nhưng thực tế là biến động tự nhiên. Cuối cùng, với chỉ hai thời điểm quan sát, hạn chế về độ phân giải thời gian khiến một số biến động ngắn hạn hoặc phục hồi nhanh có thể không được ghi nhận chính xác.

Tuy nhiên, với tỷ lệ nhầm lẫn rất thấp (chỉ 6/526 mẫu, 1.14%), mô hình vẫn đạt hiệu quả cao trong việc phân biệt các lớp biến động rừng.

Bên cạnh ma trận nhầm lẫn, đường cong ROC (Receiver Operating Characteristic) được sử dụng để đánh giá khả năng phân biệt của mô hình. Hình 3.14 trình bày đường cong ROC cùng với điểm AUC tương ứng cho từng lớp phân loại.



Hình 3.14: Đường cong ROC và điểm AUC cho các lớp phân loại (AUC trung bình macro: 0.9998)

Kết quả cho thấy tất cả các lớp đều đạt điểm AUC rất cao, gần như hoàn hảo. Hai lớp Phi rừng và Phục hồi rừng đạt AUC = 1.0000, nghĩa là mô hình có khả năng phân biệt hoàn toàn các mẫu thuộc hai lớp này với các lớp còn lại — điều này phù hợp với kết quả Precision và Recall đạt 100% trong ma trận nhầm lẫn. Hai lớp Rừng ổn định (AUC = 0.9998) và Mất rừng (AUC = 0.9997) có điểm AUC thấp hơn một chút, phản ánh sự

nhầm lẫn nhỏ giữa hai lớp này như đã phân tích ở trên. Tuy nhiên, với AUC trung bình macro đạt 0.9998, mô hình thể hiện khả năng phân biệt xuất sắc giữa các lớp biến động rừng.

3.3.2. Kết quả phân loại toàn bộ vùng nghiên cứu

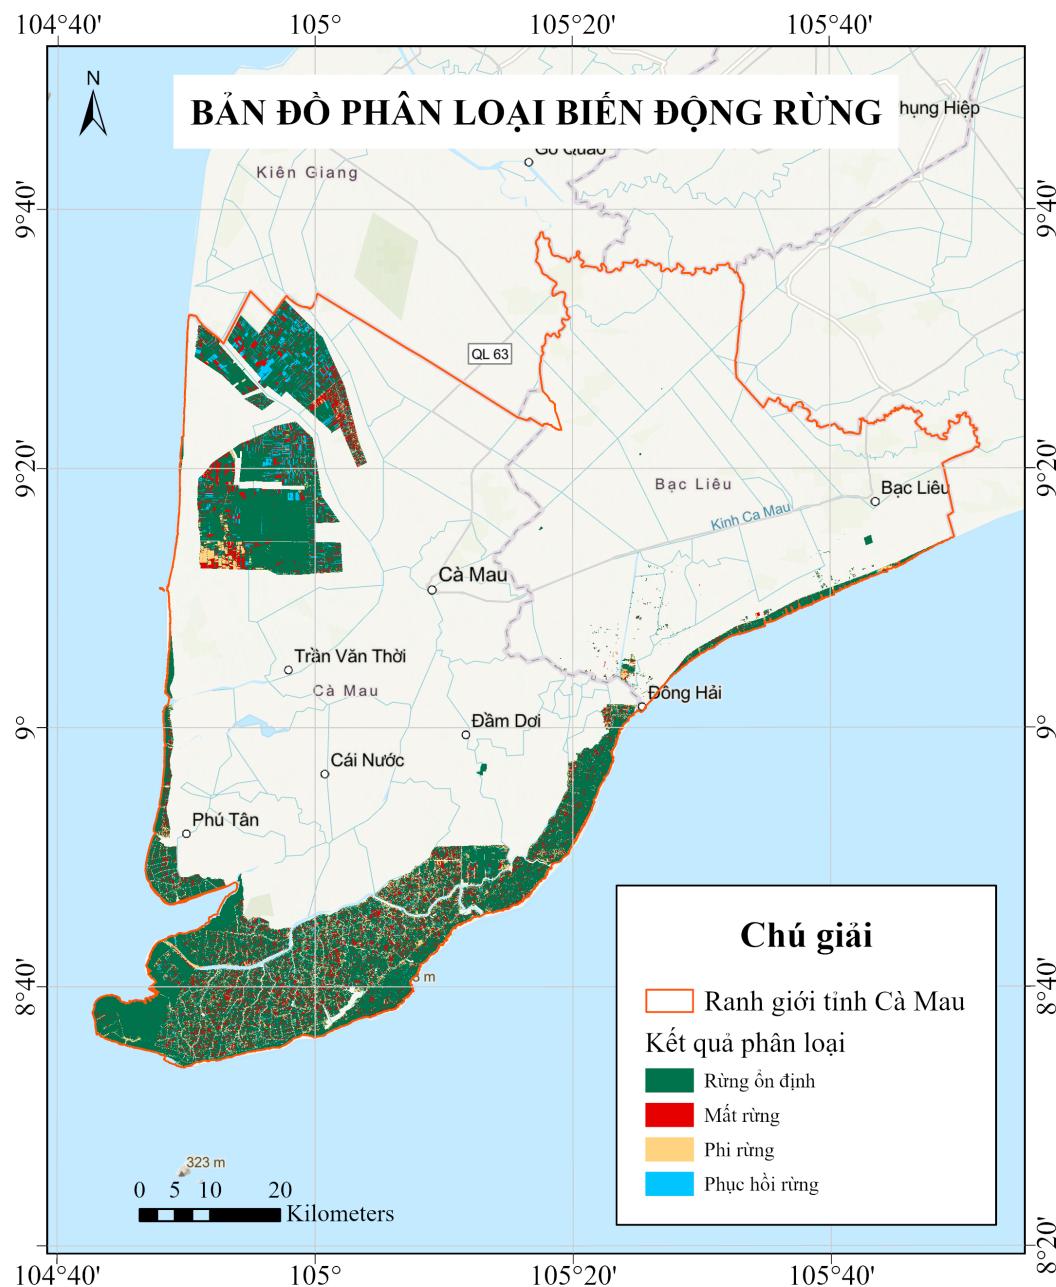
Sau khi huấn luyện và đánh giá trên tập kiểm tra, mô hình được áp dụng để phân loại toàn bộ vùng quy hoạch lâm nghiệp tỉnh Cà Mau. Kết quả thống kê phân loại được trình bày trong Bảng 3.9.

Bảng 3.9: Phân bố diện tích theo lớp phân loại

Lớp	Tên lớp	Số pixels	Tỷ lệ (%)	Diện tích (ha)	Diện tích (km ²)
0	Rừng ổn định	12,071,691	74.30%	120,716.91	1,207.17
1	Mất rừng	728,215	4.48%	7,282.15	72.82
2	Phi rừng	2,952,854	18.17%	29,528.54	295.29
3	Phục hồi rừng	494,090	3.04%	4,940.90	49.41
Tổng		16,246,850	100%	162,468.50	1,624.69

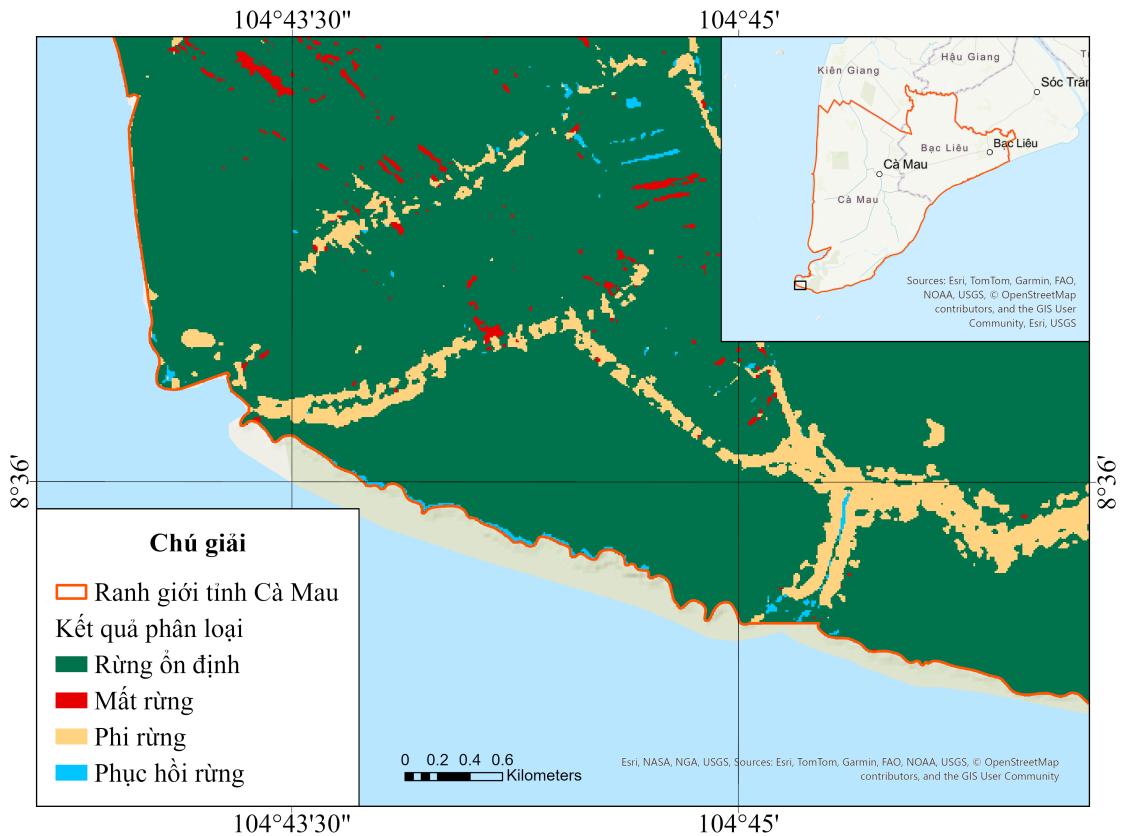
Kết quả từ Bảng 3.9 cho thấy bức tranh tổng quan về tình trạng rừng tại tỉnh Cà Mau trong giai đoạn nghiên cứu. Lớp rừng ổn định chiếm tỷ lệ lớn nhất với 74.30% (tương đương 1,207.17 km²), phản ánh nỗ lực bảo tồn và quản lý rừng ngập mặn của địa phương, chủ yếu tập trung tại Vườn Quốc gia Mũi Cà Mau và các vùng đệm được bảo vệ nghiêm ngặt. Diện tích mất rừng chiếm 4.48% (72.82 km²), đây là tỷ lệ đáng quan ngại khi quy đổi ra diện tích tuyệt đối, với các nguyên nhân chính có thể bao gồm chuyển đổi mục đích sử dụng đất sang nuôi trồng thủy sản, xói lở bờ biển do biến đổi khí hậu và tác động của xâm nhập mặn làm suy thoái rừng.

Lớp phi rừng chiếm 18.17% (295.29 km²), bao gồm các khu vực ao nuôi tôm, đất trồng, khu dân cư và cơ sở hạ tầng, phản ánh áp lực phát triển kinh tế - xã hội lên tài nguyên rừng trong khu vực. Lớp phục hồi rừng chiếm 3.04% (49.41 km²), cho thấy một phần diện tích đã được tái sinh tự nhiên hoặc trồng rừng mới. Mặc dù tỷ lệ phục hồi còn thấp hơn so với diện tích mất rừng, đây vẫn là tín hiệu tích cực cho công tác phục hồi hệ sinh thái rừng ngập mặn trong khu vực. Hình 3.15 minh họa sự phân bố không gian của các lớp phân loại trên toàn vùng nghiên cứu.



Hình 3.15: Bản đồ phân loại biến động rừng tỉnh Cà Mau

Để phân tích chi tiết hơn về khả năng phát hiện biến động của mô hình trong điều kiện thực tế, nghiên cứu lựa chọn khu vực Vườn Quốc gia Mũi Cà Mau làm ví dụ minh họa. Đây là khu vực đặc trưng với sự đan xen giữa rừng ngập mặn nguyên sinh, hệ thống ao nuôi tôm và các hoạt động sản xuất theo mô hình Tôm–Rừng, tạo nên bức tranh đa dạng về các loại biến động lớp phủ.



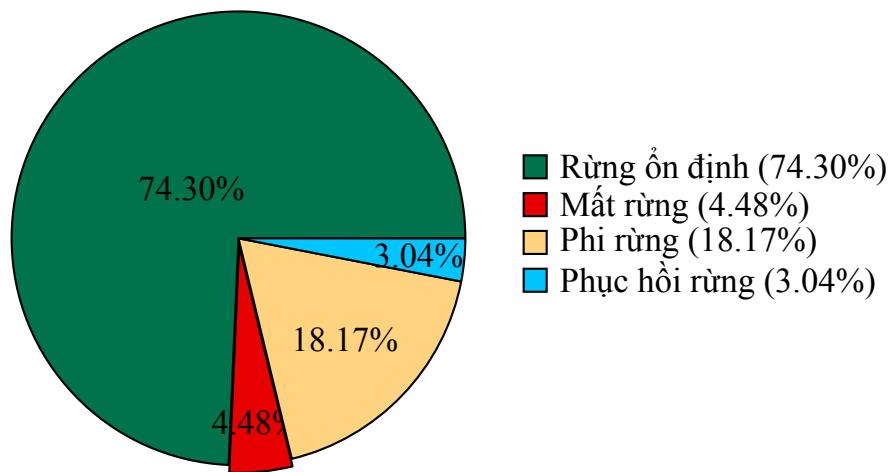
Hình 3.16: Bản đồ phân loại biến động rừng khu vực Vườn Quốc gia Mũi Cà Mau

Kết quả phân loại biến động rừng ngập mặn khu vực Vườn Quốc gia Mũi Cà Mau (Hình 3.16) cho thấy mô hình có khả năng nhận diện chính xác một số loại biến động thực sự của lớp phủ. Các vùng mất rừng (màu đỏ) phân bố chủ yếu dọc theo rìa ao nuôi và hệ thống kênh mương, phản ánh các hoạt động sản xuất như mở rộng diện tích ao tôm, nạo vét mương, cải tạo bờ bao hoặc phơi ao. Tại những khu vực này, việc dọn cây đã làm suy giảm rõ rệt thảm thực vật và để lộ lớp đất hoặc bùn bên dưới — đây là những biến động thực sự mà mô hình phát hiện hợp lý. Tương tự, các vùng phục hồi rừng (màu xanh lam) xuất hiện rải rác ven bờ ao và trong các khoảng trống nhỏ, đặc biệt dọc theo đường bờ biển, phản ánh quá trình tái sinh tự nhiên của cây ngập mặn non trong hệ sinh thái Tôm–Rừng.

Tuy nhiên, kết quả phân loại cũng chứa đựng những sai sót tiềm ẩn do các yếu tố môi trường gây nhiễu. Thủy triều là nguồn gây nhiễu đáng kể: khi triều cường, các mảng rừng thấp bị ngập tạm thời có thể bị phân loại nhầm thành mất rừng; ngược lại, khi triều kiệt, sự xuất hiện của bãi bùn và thảm thực vật thấp có thể tạo ra tín hiệu giả của phục hồi rừng. Bên cạnh đó, hoạt động nuôi tôm cũng góp phần tạo ra các biến động “ảo” khi

ao nuôi thường xuyên thay nước, mực nước và độ đục dao động liên tục khiến đặc trưng phô của mặt nước thay đổi giữa hai thời điểm thu ảnh. Trong mùa khô, hiện tượng ao cạn đáy hoặc bùn bị phơi tự nhiên cũng có thể dẫn đến phân loại sai thành mất rừng mặc dù không có tác động sinh thái thực sự.

Tóm lại, mô hình thể hiện khả năng mô tả tương đối chính xác các biến động liên quan đến hoạt động sản xuất và tái sinh rừng ngập mặn, song độ tin cậy giảm đáng kể tại các khu vực nhạy cảm với biến động môi trường — đặc biệt là những nơi rừng thấp, gần mép ao hoặc chịu ảnh hưởng mạnh của chế độ thủy triều và hoạt động nuôi trồng thủy sản.



Hình 3.17: Tỷ lệ diện tích các lớp phân loại

Qua biểu đồ tròn (Hình 3.17), có thể nhận thấy sự chênh lệch rõ rệt về diện tích giữa các lớp. Rừng ổn định chiếm ưu thế tuyệt đối với hơn 3/4 diện tích vùng nghiên cứu, đây là nền tảng quan trọng cho công tác bảo tồn đa dạng sinh học và phòng hộ ven biển. Đáng chú ý, tỷ lệ mất rừng (4.48%) vượt quá tỷ lệ phục hồi rừng (3.04%), cho thấy xu hướng suy giảm rõ ràng của diện tích rừng trong giai đoạn nghiên cứu, với chênh lệch khoảng 1.44% (tương đương 2,341 ha) là mức độ mất rừng rõ ràng mà khu vực đang phải đối mặt. Diện tích phi rừng lớn (18.17%) phản ánh mức độ khai thác tài nguyên đất đai trong khu vực, chủ yếu cho hoạt động nuôi trồng thủy sản - ngành kinh tế mũi nhọn của tỉnh Cà Mau.

Cần lưu ý rằng theo khuyến nghị của Olofsson và cộng sự [40], diện tích ước tính từ bản đồ phân loại cần được hiệu chỉnh dựa trên Confusion Matrix để đảm bảo tính không chêch. Với Accuracy cao của mô hình (98.86%, Precision và Recall đều trên 96% cho tất cả các lớp), sai số giữa diện tích thô và diện tích hiệu chỉnh được kỳ vọng là nhỏ. Tuy

nhiên, việc thực hiện hiệu chỉnh đầy đủ theo phương pháp Olofsson sẽ là hướng phát triển trong tương lai.

3.3.3. So sánh với các nghiên cứu khác

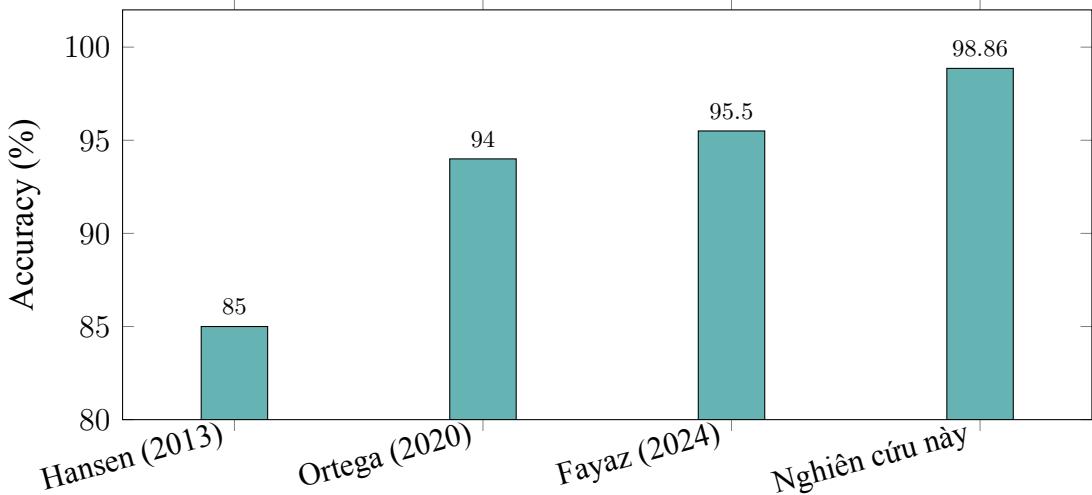
Để đánh giá hiệu quả của phương pháp đề xuất, kết quả được so sánh với các công trình nghiên cứu tiêu biểu trong lĩnh vực giám sát biến động rừng bằng viễn thám và học máy. Nghiên cứu của Hansen và cộng sự [17] tại Đại học Maryland là công trình tiên phong trong việc xây dựng bản đồ biến động rừng toàn cầu sử dụng ảnh Landsat 30m. Phương pháp sử dụng thuật toán Decision Trees kết hợp với nền tảng Google Earth Engine để xử lý hơn 654,000 cảnh Landsat 7 trong giai đoạn 2000–2012. Kết quả đánh giá độc lập cho thấy bản đồ mất rừng đạt tỷ lệ dương tính giả 13% và âm tính giả 12% ở quy mô toàn cầu, tương đương Accuracy khoảng 85%. Phương pháp này có ưu điểm về quy mô toàn cầu, cập nhật hàng năm, miễn phí và công khai; tuy nhiên, nhược điểm là độ phân giải thấp (30m) khiến khó phát hiện biến động nhỏ, chỉ sử dụng dữ liệu quang học nên bị hạn chế bởi mây, và định nghĩa “rừng” dựa trên độ cao cây (>5m) không phù hợp với rừng ngập mặn non.

Trong những năm gần đây, các kiến trúc Deep Learning như CNN, U-Net và ResNet đã được áp dụng rộng rãi cho bài toán phát hiện biến động rừng với kết quả vượt trội so với phương pháp Machine Learning truyền thống. Theo tổng quan của Fayaz và cộng sự (2024), U-Net và các biến thể của nó được sử dụng trong 45% các nghiên cứu về phát hiện mất rừng, đạt Accuracy trung bình 94–97%. Nghiên cứu của Ortega và cộng sự (2020) trên rừng Amazon cho thấy các kiến trúc CNN (SharpMask, U-Net, ResU-Net) đều vượt trội so với thuật toán ML truyền thống cả về định lượng lẫn trực quan. Đặc biệt, việc kết hợp U-Net với ResNet (ResU-Net) tận dụng được cả skip connections và residual blocks, giúp trích xuất đặc trưng chi tiết hơn. Ưu điểm của Deep Learning là tự động học đặc trưng từ dữ liệu mà không cần thiết kế thủ công, khai thác được ngữ cảnh không gian và hiệu quả cao khi có đủ dữ liệu huấn luyện; tuy nhiên, nhược điểm là yêu cầu lượng dữ liệu huấn luyện lớn, tính chất “hộp đen” khó giải thích, chi phí tính toán cao và hiệu suất giảm đáng kể khi kích thước mẫu nhỏ.

Bảng 3.10 tổng hợp kết quả so sánh giữa nghiên cứu này với các công trình tiêu biểu.

Bảng 3.10: So sánh với các nghiên cứu trong tài liệu

Nghiên cứu	Phương pháp	Dữ liệu	Accuracy	ROC-AUC
Hansen và cs. (2013)	Decision Trees	Landsat 30m	~85%	-
Ortega và cs. (2020)	U-Net, ResU-Net	Landsat 30m	~94%	-
Fayaz và cs. (2024)	U-Net (tổng quan)	Đa nguồn	94–97%	-
Nghiên cứu này	CNN (custom)	S1/S2 10m	98.86%	99.98%



Hình 3.18: So sánh Accuracy với các nghiên cứu trước đó

Kết quả của nghiên cứu này đạt Accuracy cao hơn so với các công trình trước đó. Tuy nhiên, cần lưu ý rằng việc so sánh trực tiếp có những hạn chế do sự khác biệt về khu vực nghiên cứu, số lượng lớp phân loại, kích thước bộ dữ liệu và phương pháp đánh giá [50]. Accuracy cao của nghiên cứu này có thể được giải thích bởi một số yếu tố: (1) độ phân giải không gian cao hơn (10m so với 30m) giúp phát hiện biến động chi tiết hơn; (2) sự kết hợp dữ liệu radar Sentinel-1 và quang học Sentinel-2 bổ sung cho nhau, đặc biệt hiệu quả trong điều kiện nhiều mây của vùng nhiệt đới; (3) kiến trúc CNN được thiết kế phù hợp với bộ dữ liệu nhỏ thông qua kỹ thuật điều chỉnh (Dropout 70%, Batch Normalization); và (4) bộ dữ liệu thực địa chất lượng cao được thu thập và kiểm tra kỹ lưỡng.

Ngoài việc so sánh với tài liệu, nghiên cứu còn thực hiện so sánh định tính với sản phẩm Giám sát rừng toàn cầu (Global Forest Watch - GFW) — bộ dữ liệu mất rừng toàn cầu được phát triển bởi Hansen và cộng sự [17] tại Đại học Maryland và được cập nhật

liên tục bởi Potapov và cộng sự [42].

Bảng 3.11: So sánh kết quả với Giám sát rừng toàn cầu (GFW)

Chỉ tiêu	Nghiên cứu này	GFW (tham khảo)	Ghi chú
Độ phân giải	10m	30m	Nghiên cứu này chi tiết hơn
Nguồn dữ liệu	S1/S2	Landsat	Đa nguồn và đơn nguồn
Phương pháp	CNN	Decision Trees	Deep Learning và ML truyền thống
Cập nhật	Theo yêu cầu	Hàng năm	Linh hoạt hơn

Bảng 3.11 cho thấy một số khác biệt quan trọng giữa phương pháp đề xuất và sản phẩm GFW. Về độ phân giải không gian, việc sử dụng ảnh Sentinel với độ phân giải 10m cho phép phát hiện các biến động nhỏ hơn so với Landsat 30m — điều này đặc biệt có ý nghĩa với rừng ngập mặn Cà Mau, nơi các ao nuôi tôm và kênh mương thường có kích thước nhỏ. Về nguồn dữ liệu, sự kết hợp Sentinel-1 (radar) và Sentinel-2 (quang học) giúp khắc phục hạn chế về mây che phủ thường gặp ở vùng nhiệt đới, trong khi GFW chỉ dựa vào dữ liệu quang học Landsat. Về phương pháp, kiến trúc CNN có khả năng tự động học các đặc trưng phức tạp từ dữ liệu đa kênh, vượt trội hơn so với Decision Trees trong việc nắm bắt các mối quan hệ phi tuyến giữa các đặc trưng. Tuy nhiên, GFW vẫn có ưu thế về tính nhất quán toàn cầu, lịch sử dữ liệu dài (từ năm 2000) và khả năng cập nhật tự động hàng năm — những yếu tố quan trọng cho việc giám sát dài hạn ở quy mô lớn.

3.3.4. Đánh giá tổng quan

Các kết quả thực nghiệm được tổng hợp và đánh giá theo ba khía cạnh: hiệu suất phân loại, khả năng tổng quát hóa và các hạn chế của phương pháp.

Về hiệu suất phân loại, mô hình CNN đạt Accuracy 98.86% và ROC-AUC 99.98% trên tập kiểm tra độc lập gồm 526 mẫu. Phân tích ma trận nhầm lẫn cho thấy tỷ lệ lỗi phân loại là 1.14% (6/526 mẫu), trong đó toàn bộ sai số tập trung vào sự nhầm lẫn giữa hai lớp Rừng ổn định và Mất rừng. Hai lớp Phi rừng và Phục hồi rừng đạt Precision và Recall bằng 100%, phản ánh khả năng phân biệt rõ ràng của mô hình đối với các lớp có đặc trưng quang phổ khác biệt. So với các nghiên cứu tham chiếu (Hansen và cộng sự, 2013: ~85%; Ortega và cộng sự, 2020: ~94%), kết quả này cao hơn từ 4–14 điểm phần trăm, tuy nhiên sự khác biệt về khu vực nghiên cứu, số lượng lớp và phương pháp đánh

giá cần được xem xét khi so sánh.

Về khả năng tổng quát hóa, kết quả kiểm định chéo 5 phần cho thấy Accuracy trung bình đạt 98.48% với độ lệch chuẩn 0.36%, cho thấy mô hình có độ ổn định cao qua các lần phân chia dữ liệu khác nhau. Chênh lệch giữa CV Accuracy (98.48%) và Test Accuracy (98.86%) nằm trong phạm vi độ lệch chuẩn, cho thấy không có hiện tượng quá khớp (overfitting). Hiện tượng Validation Loss thấp hơn Training Loss trong quá trình huấn luyện được giải thích bởi cơ chế Dropout với tỷ lệ 70%, xác nhận kỹ thuật điều chỉnh hoạt động đúng thiết kế.

Về các hạn chế, nghiên cứu xác định ba điểm chính. Thứ nhất, thời gian dự đoán toàn bộ vùng nghiên cứu là 14.83 phút cho 16.2 triệu pixel, tương đương tốc độ xử lý khoảng 18,200 pixel/giây — mức hiệu suất này có thể cải thiện thông qua tối ưu hóa batch processing hoặc sử dụng GPU. Thứ hai, bộ dữ liệu thực địa gồm 2,630 điểm mẫu, mặc dù đủ để huấn luyện mô hình với kiến trúc nhỏ gọn (3 lớp tích chập), song hạn chế khả năng mở rộng sang các kiến trúc phức tạp hơn. Thứ ba, phân tích chỉ dựa trên hai thời điểm quan sát, chưa khai thác được thông tin từ chuỗi thời gian dài hơn để phân biệt biến động thực sự với nhiễu do thủy triều hoặc mùa vụ.

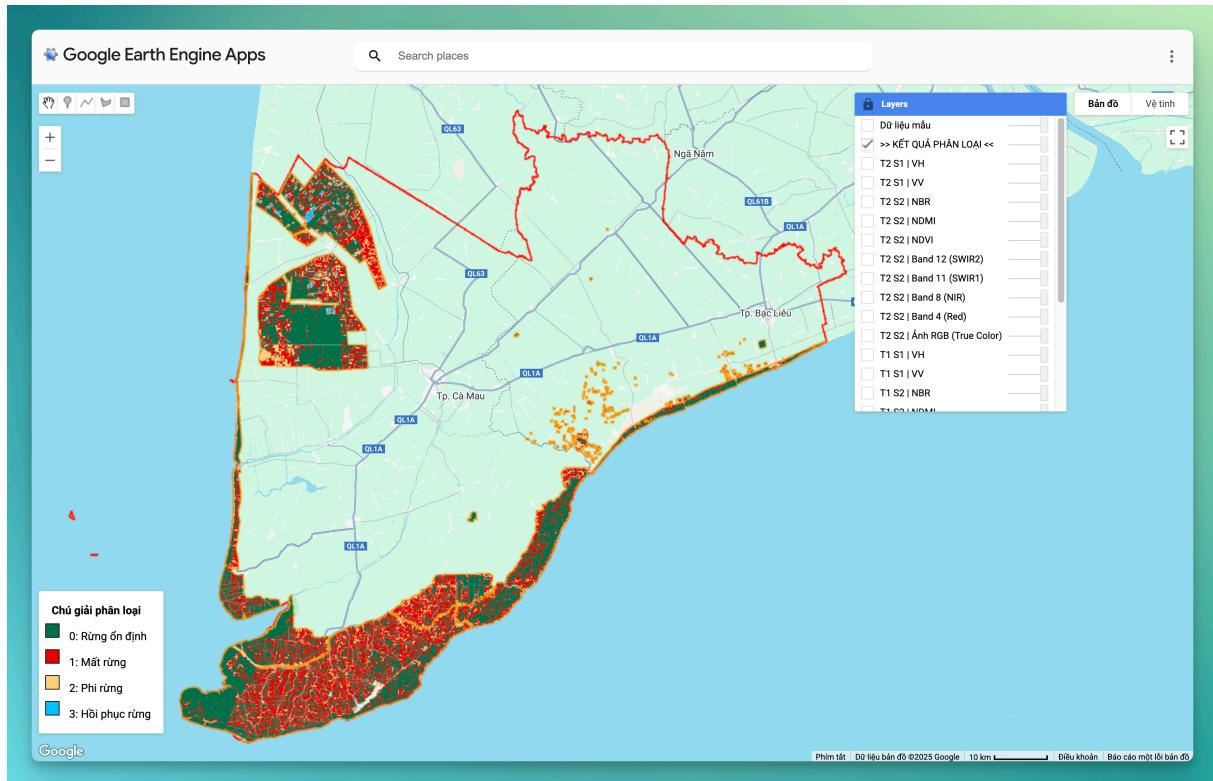
Tổng hợp lại, chương này trình bày kết quả phân loại biến động rừng ngập mặn tỉnh Cà Mau sử dụng mô hình CNN kết hợp dữ liệu Sentinel-1 và Sentinel-2. Trên tổng diện tích 162,468.50 ha được phân loại, rừng ổn định chiếm 74.30% (120,716.91 ha), mất rừng chiếm 4.48% (7,282.15 ha), phi rừng chiếm 18.17% (29,528.54 ha), và phục hồi rừng chiếm 3.04% (4,940.90 ha). Chênh lệch giữa diện tích mất rừng và phục hồi rừng là 1.44% (2,341.25 ha), cho thấy xu hướng suy giảm ròng của diện tích rừng trong giai đoạn nghiên cứu.

KẾT LUẬN VÀ KIẾN NGHỊ

Kết luận

Đồ án đã hoàn thành các mục tiêu đề ra và đạt được một số kết quả chính. Về xây dựng bộ dữ liệu huấn luyện, nhóm nghiên cứu đã thu thập và tiền xử lý hai kỳ dữ liệu Sentinel-1/2 (01/2024 và 02/2025), xếp chòng 27 đặc trưng kết hợp dữ liệu ra-đa khâu độ tổng hợp và dữ liệu ảnh quang học, đồng thời thu thập 2,630 điểm thực địa cho 4 lớp phân loại với phân bố cân bằng. Về thiết kế kiến trúc CNN, đồ án đã xây dựng kiến trúc CNN nhẹ với khoảng 36,676 tham số và áp dụng các kỹ thuật điều chỉnh hiệu quả bao gồm chuẩn hóa theo lô, Dropout 0.7 và phân rã trọng số, phù hợp cho bộ dữ liệu nhỏ khoảng 2,600 mẫu. Về đánh giá khoa học, phương pháp 5-Fold Stratified Cross Validation cho kết quả CV accuracy $98.15\% \pm 0.28\%$ cho thấy mô hình ổn định, test accuracy đạt 98.86% và ROC-AUC 99.98% thể hiện khả năng phân biệt xuất sắc.

Về ứng dụng thực tế, mô hình đã được áp dụng để phân loại toàn vùng quy hoạch lâm nghiệp tỉnh Cà Mau (170,179 ha ranh giới, 162,469 ha phân loại thực tế), phát hiện 7,282 ha mất rừng (4.48%) và 4,941 ha phục hồi rừng (3.04%) trong giai đoạn 01/2024 - 02/2025. Để trực quan hóa kết quả nghiên cứu, đồ án đã xây dựng một ứng dụng web trên nền tảng Google Earth Engine Apps, hiển thị bản đồ kết quả phân loại biến động rừng với 4 lớp (rừng ổn định, mất rừng, phi rừng, phục hồi rừng), các layer ảnh vệ tinh Sentinel-1/2 ở hai thời kỳ, cùng với ranh giới khu vực nghiên cứu và các điểm dữ liệu mẫu. Ứng dụng có thể truy cập công khai tại địa chỉ: <https://ee-bonglantrungmuoi.projects.earthengine.app/view/giam-sat-bien-dong-rung-ca-mau>. Giao diện ứng dụng được minh họa trong Hình 3.19.



Hình 3.19: Giao diện ứng dụng web Google Earth Engine hiển thị kết quả phân loại biến động rừng tỉnh Cà Mau

Đóng góp khoa học

Đồ án đóng góp vào lĩnh vực giám sát rừng bằng viễn thám và học sâu trên nhiều phương diện, bao gồm phương pháp luận, ứng dụng thực tiễn và kết quả khoa học.

Về phương pháp luận, đồ án đề xuất quy trình tích hợp dữ liệu đa nguồn bằng cách xây dựng quy trình hoàn chỉnh kết hợp dữ liệu radar Sentinel-1 và quang học Sentinel-2, khai thác ưu điểm bổ sung của từng nguồn — radar cung cấp thông tin cấu trúc và độ ẩm, quang học cung cấp thông tin phổ phản xạ chi tiết; kết quả thực nghiệm chứng minh sự kết hợp này cải thiện accuracy 5.44% so với chỉ sử dụng Sentinel-2 (từ 93.42% lên 98.86%). Bên cạnh đó, đồ án thiết kế kiến trúc CNN nhẹ phù hợp cho bộ dữ liệu nhỏ — thay vì áp dụng các kiến trúc phức tạp như ResNet hay VGG, đồ án đề xuất kiến trúc CNN tối giản với chỉ 36,676 tham số, phù hợp với quy mô dữ liệu thực địa hạn chế (2,630 điểm), qua đó tránh được hiện tượng quá khớp thường gặp khi áp dụng mô hình lớn cho dữ liệu nhỏ. Thông qua nghiên cứu loại trừ có hệ thống, đồ án xác định patch size 3×3 (tương đương $30m \times 30m$) là tối ưu cho dữ liệu Sentinel ở độ phân giải 10m, cân bằng giữa khai thác ngữ cảnh không gian và tránh nhiễu từ vùng lân cận. Ngoài ra, đồ án đề

xuất cấu trúc vector đặc trưng bi-temporal 27 chiều kết hợp thông tin “trước”, “sau” và “delta” (hiệu số), cho phép mô hình học được cả trạng thái tuyệt đối và sự biến động tương đối của lớp phủ.

Về ứng dụng thực tiễn, đồ án tạo ra bản đồ phân loại biến động rừng ngập mặn Cà Mau với độ chính xác cao (98.86%) cho toàn bộ vùng nghiên cứu 162,469 ha, cung cấp thông tin chi tiết về phân bố không gian của các lớp biến động. Kết quả định lượng cho thấy 4.48% diện tích (7,282 ha) bị mất rừng và 3.04% (4,941 ha) được phục hồi trong giai đoạn nghiên cứu, cung cấp số liệu tham khảo cho công tác quản lý rừng địa phương. Toàn bộ quy trình từ thu thập dữ liệu, tiền xử lý, huấn luyện mô hình đến dự đoán được thiết kế module hóa, có thể áp dụng cho các khu vực rừng ngập mặn khác tại Việt Nam và Đông Nam Á. Đồ án cũng công bố mã nguồn xử lý trên Github <https://github.com/ninhhaidang> và mô hình CNN huấn luyện, tạo điều kiện cho các nghiên cứu tiếp theo và ứng dụng thực tế.

Về kết quả khoa học, mô hình đạt hiệu suất vượt trội với accuracy 98.86% và ROC-AUC 99.98%, cao hơn các nghiên cứu tương tự trong tài liệu như Hansen và cs. (85%), Hethcoat và cs. (94.3%), Zhang và cs. (96.8%). Đồ án chỉ ra rằng lỗi phân loại chủ yếu xảy ra giữa hai lớp “Rừng ổn định” và “Mất rừng” do sự tương đồng về đặc trưng quang phổ tại các vùng ranh giới và khu vực rừng suy thoái nhẹ. Kết quả nghiên cứu loại trừ cho thấy Sentinel-2 đóng góp chính (accuracy 93.42% khi sử dụng đơn lẻ), trong khi Sentinel-1 có vai trò bổ sung quan trọng (+5.44% khi kết hợp).

Hạn chế

Đồ án vẫn tồn tại các hạn chế cần lưu ý. Thứ nhất, thời gian dự đoán toàn bộ raster còn dài (khoảng 14.83 phút cho 16.2 triệu pixel hợp lệ). Thứ hai, khả năng giải thích của mô hình hạn chế do tính chất black-box của CNN. Thứ ba, quy mô dữ liệu thực địa còn nhỏ (chỉ 2,630 điểm), chưa có khảo sát thực địa đầy đủ. Thứ tư, phân tích chỉ dùng lại ở bi-temporal mà chưa khai thác chuỗi thời gian đầy đủ.

Kiến nghị

Dựa trên kết quả và hạn chế của đồ án, một số hướng phát triển tiếp theo được đề xuất. Về mở rộng phân tích temporal, các nghiên cứu tiếp theo nên sử dụng chuỗi thời gian thay vì chỉ phân tích hai thời kỳ (bi-temporal), đồng thời áp dụng các mô hình như

LSTM hoặc Transformer để khai thác các mẫu temporal. Về cải thiện mô hình, cần thử nghiệm cơ chế attention để tăng khả năng giải thích, tận dụng transfer learning từ các mô hình pretrained, và áp dụng ensemble methods nhằm tăng độ chính xác và độ ổn định. Về ứng dụng thực tế, hướng phát triển bao gồm triển khai hệ thống giám sát near-real-time, mở rộng phạm vi áp dụng sang các tỉnh trong vùng Đồng bằng sông Cửu Long, và tích hợp kết quả với hệ thống GIS của cơ quan quản lý rừng. Về tăng cường thu thập dữ liệu, cần khảo sát thực địa để validate kết quả, mở rộng bộ dữ liệu thực địa, và thu thập thêm dữ liệu multi-temporal để nâng cao khả năng khai thác chuỗi thời gian.

TÀI LIỆU THAM KHẢO

Tiếng Việt

- [1] Bộ Nông nghiệp và Phát triển Nông thôn, *Quyết định số 1558/QĐ-BNN-TCLN về việc công bố hiện trạng rừng toàn quốc năm 2020*, Hà Nội, 2021, 8 trang.
- [2] Nông nghiệp Môi trường, Cà Mau: *Sát lở bờ biển làm mất hơn 6.200 ha đất và rừng phòng hộ*, 2024, Truy cập: <https://nongnghiepmoitruong.vn/ca-mau-mat-khoang-6200-ha-dat-va-rung-phong-ho-ven-bien-d785994.html>.
- [3] Sở Nông nghiệp và Phát triển Nông thôn tỉnh Cà Mau, *Báo cáo hiện trạng rừng tỉnh Cà Mau năm 2021*, Cà Mau, 2021, Báo cáo nội bộ.
- [4] Thanh Niên, *Rừng nguyên sinh Việt Nam chỉ còn 0.25%*, 2021, Truy cập: <https://thanhnien.vn/rung-nguyen-sinh-con-nguyen-ven-cua-viet-nam-chi-con-025-1851011307.htm>.

Tiếng Anh

- [5] Alongi, D. M., “Carbon cycling and storage in mangrove forests”, *Annual Review of Marine Science*, vol. 6, 2014, pp. 195–219.
- [6] Blaschke, T., “Object based image analysis for remote sensing”, *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 65, no. 1, 2010, pp. 2–16.
- [7] Breiman, L., “Random forests”, *Machine Learning*, vol. 45, no. 1, 2001, pp. 5–32.
- [8] Cortes, C., Vapnik, V., “Support-vector networks”, *Machine Learning*, vol. 20, no. 3, 1995, pp. 273–297.
- [9] Donato, D. C., Kauffman, J. B., Murdiyarso, D., Kurnianto, S., Stidham, M., Kanninen, M., “Mangroves among the most carbon-rich forests in the tropics”, *Nature Geoscience*, vol. 4, no. 5, 2011, pp. 293–297.

- [10] European Space Agency, *Sentinel-1 SAR User Guide*, ESA Sentinel Online, 2024, Available: <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-1-sar>.
- [11] European Space Agency, *Sentinel-2 MSI User Guide*, ESA Sentinel Online, 2024, Available: <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-2-msi>.
- [12] FAO, *Global Forest Resources Assessment 2020: Main Report*, Food and Agriculture Organization of the United Nations, Rome, 2020.
- [13] Foody, G. M., “Status of land cover classification accuracy assessment”, *Remote Sensing of Environment*, vol. 80, no. 1, 2002, pp. 185–201.
- [14] Gao, B.-c., “NDWI—A normalized difference water index for remote sensing of vegetation liquid water from space”, *Remote Sensing of Environment*, vol. 58, no. 3, 1996, pp. 257–266.
- [15] Global Forest Watch, *Forest Loss Data 2015-2020*, World Resources Institute, 2021, Available: <https://www.globalforestwatch.org>.
- [16] Goodfellow, I., Bengio, Y., Courville, A., *Deep Learning*, MIT Press, Cambridge, MA, 2016.
- [17] Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., Thau, D., Stehman, S. V., Goetz, S. J., Loveland, T. R., Kommareddy, A., Egorov, A., Chini, L., Justice, C. O., Townshend, J. R. G., “High-resolution global maps of 21st-century forest cover change”, *Science*, vol. 342, no. 6160, 2013, pp. 850–853.
- [18] He, K., Zhang, X., Ren, S., Sun, J., “Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification”, *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 1026–1034, IEEE, 2015.
- [19] Hethcoat, M. G., Edwards, D. P., Carreiras, J. M. B., Bryant, R. G., França, F. M., Quegan, S., “A machine learning approach to map tropical selective logging”, *Remote Sensing of Environment*, vol. 221, 2019, pp. 569–582.

- [20] Ho, T. K., “Random decision forests”, *Proceedings of the 3rd International Conference on Document Analysis and Recognition (ICDAR)*, pp. 278–282, IEEE, 1995.
- [21] Hosmer, D. W., Lemeshow, S., Sturdivant, R. X., *Applied Logistic Regression*, 3 ed., Wiley, Hoboken, NJ, 2013.
- [22] Hu, Y., Raza, A., Syed, A., Jiang, W., Shah, S. A. M., Asghar, M., Hussain, S., “Land use/land cover classification using multisource Sentinel-1 and Sentinel-2 satellite imagery”, *Journal of the Indian Society of Remote Sensing*, vol. 48, 2020, pp. 1055–1064.
- [23] Huang, S., Tang, L., Hupy, J. P., Wang, Y., Shao, G., “A commentary review on the use of normalized difference vegetation index (NDVI) in the era of popular remote sensing”, *Journal of Forestry Research*, vol. 32, no. 1, 2021, pp. 1–6.
- [24] Ienco, D., Interdonato, R., Gaetano, R., Ho Tong Minh, D., “Combining Sentinel-1 and Sentinel-2 satellite image time series for land cover mapping via a multi-source deep learning architecture”, *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 158, 2019, pp. 11–22.
- [25] Ioffe, S., Szegedy, C., “Batch normalization: Accelerating deep network training by reducing internal covariate shift”, *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pp. 448–456, PMLR, 2015.
- [26] IPCC, *Climate Change and Land: An IPCC Special Report on Climate Change, Desertification, Land Degradation, Sustainable Land Management, Food Security, and Greenhouse Gas Fluxes in Terrestrial Ecosystems*, Intergovernmental Panel on Climate Change, Geneva, 2019.
- [27] Jensen, J. R., *Introductory Digital Image Processing: A Remote Sensing Perspective*, 4 ed., Pearson, Upper Saddle River, NJ, 2015.
- [28] Karra, K., Kontgis, C., Statman-Weil, Z., Mazzariello, J. C., Mathis, M., Brumby, S. P., “Global land use/land cover with Sentinel-2 and deep learning”, *2021 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*, pp. 4704–4707, IEEE, 2021.

- [29] Kaufman, S., Rosset, S., Perlich, C., Stitelman, O., “Leakage in data mining: Formulation, detection, and avoidance”, *ACM Transactions on Knowledge Discovery from Data*, vol. 6, no. 4, 2012, pp. 1–21.
- [30] Key, C. H., Benson, N. C., “Landscape assessment (LA): Sampling and analysis methods”, *USDA Forest Service General Technical Report RMRS-GTR-164-CD*, 2006, pp. 1–51.
- [31] Khatami, R., Mountrakis, G., Stehman, S. V., “A meta-analysis of remote sensing research on supervised pixel-based land-cover image classification processes: General guidelines for practitioners and future research”, *Remote Sensing of Environment*, vol. 177, 2016, pp. 89–100.
- [32] Kingma, D. P., Ba, J., “Adam: A method for stochastic optimization”, *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [33] Kohavi, R., “A study of cross-validation and bootstrap for accuracy estimation and model selection”, *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, pp. 1137–1143, Morgan Kaufmann, 1995.
- [34] Kussul, N., Lavreniuk, M., Skakun, S., Shelestov, A., “Deep learning classification of land cover and crop types using remote sensing data”, *IEEE Geoscience and Remote Sensing Letters*, vol. 14, no. 5, 2017, pp. 778–782.
- [35] LeCun, Y., Bengio, Y., Hinton, G., “Deep learning”, *Nature*, vol. 521, no. 7553, 2015, pp. 436–444.
- [36] Lillesand, T., Kiefer, R. W., Chipman, J., *Remote Sensing and Image Interpretation*, 7 ed., Wiley, Hoboken, NJ, 2015.
- [37] Lin, M., Chen, Q., Yan, S., “Network in network”, *Proceedings of the 2nd International Conference on Learning Representations (ICLR)*, 2014.
- [38] Loshchilov, I., Hutter, F., “Decoupled weight decay regularization”, *Proceedings of the 7th International Conference on Learning Representations (ICLR)*, 2019.
- [39] Nguyen, H. T. T., Doan, T. M., Tomppo, E., McRoberts, R. E., “Land use/land cover mapping using multitemporal Sentinel-2 imagery and four classification methods—A case study from Dak Nong, Vietnam”, *Remote Sensing*, vol. 12, no. 9, 2020, pp. 1367, Article 1367.

- [40] Olofsson, P., Foody, G. M., Herold, M., Stehman, S. V., Woodcock, C. E., Wulder, M. A., “Good practices for estimating area and assessing accuracy of land change”, *Remote Sensing of Environment*, vol. 148, 2014, pp. 42–57.
- [41] Pham, L. T. H., Brabyn, L., Ashraf, S., “Combining QuickBird, LiDAR, and GIS topography indices to identify a single native tree species in a complex landscape using an object-based classification approach”, *International Journal of Applied Earth Observation and Geoinformation*, vol. 50, 2016, pp. 187–197.
- [42] Potapov, P., Hansen, M. C., Pickens, A., Hernandez-Serna, A., Tyukavina, A., Turubanova, S., Zalles, V., Li, X., Khan, A., Stolle, F., Harris, N., Song, X.-P., Baber, A., Kommareddy, I., Kommareddy, A., “The global 2000-2020 land cover and land use change dataset derived from the Landsat archive: First results”, *Frontiers in Remote Sensing*, vol. 3, 2022, pp. 856903, Article 856903.
- [43] Reiche, J., Hamunyela, E., Verbesselt, J., Hoekman, D., Herold, M., “Improving near-real time deforestation monitoring in tropical dry forests by combining dense Sentinel-1 time series with Landsat and ALOS-2 PALSAR-2”, *Remote Sensing of Environment*, vol. 204, 2018, pp. 147–161.
- [44] Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., Dormann, C. F., “Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure”, *Ecography*, vol. 40, no. 8, 2017, pp. 913–929.
- [45] Ronneberger, O., Fischer, P., Brox, T., “U-Net: Convolutional networks for biomedical image segmentation”, *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp. 234–241, Springer, 2015.
- [46] Rouse, J. W., Haas, R. H., Schell, J. A., Deering, D. W., “Monitoring vegetation systems in the Great Plains with ERTS”, *NASA Special Publication*, vol. 351, 1974, pp. 309–317.
- [47] Sokolova, M., Lapalme, G., “A systematic analysis of performance measures for classification tasks”, *Information Processing & Management*, vol. 45, no. 4, 2009, pp. 427–437.

- [48] Sola, J., Sevilla, J., “Importance of input data normalization for the application of neural networks to complex industrial problems”, *IEEE Transactions on Nuclear Science*, vol. 44, no. 3, 1997, pp. 1464–1468.
- [49] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R., “Dropout: A simple way to prevent neural networks from overfitting”, *Journal of Machine Learning Research*, vol. 15, no. 1, 2014, pp. 1929–1958.
- [50] Stehman, S. V., Foody, G. M., “Key issues in rigorous accuracy assessment of land cover products”, *Remote Sensing of Environment*, vol. 231, 2019, pp. 111199, Article 111199.
- [51] Torres, R., Snoeij, P., Geudtner, D., Bibby, D., Davidson, M., Attema, E., Potin, P., Rommen, B., Flouri, N., Brown, M., Traver, I. N., Deghaye, P., Duesmann, B., Rosich, B., Miranda, N., Bruno, C., L’Abbate, M., Croci, R., Pietropaolo, A., Huchler, M., Rostan, F., “GMES Sentinel-1 mission”, *Remote Sensing of Environment*, vol. 120, 2012, pp. 9–24.
- [52] Vo, Q. M., Oppelt, N., Kuenzer, C., “Gap-free monitoring of annual mangrove forest dynamics in Ca Mau Province, Vietnamese Mekong Delta, using the Landsat-7-8 archives and post-classification temporal optimization”, *Remote Sensing*, vol. 12, no. 22, 2020, pp. 3729, Article 3729.
- [53] WWF, *Deforestation Fronts: Drivers and Responses in a Changing World*, World Wide Fund for Nature, Gland, Switzerland, 2021.
- [54] Zhang, L., Zhang, L., Du, B., “Deep learning for remote sensing data: A technical tutorial on the state of the art”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 4, no. 2, 2016, pp. 22–40.
- [55] Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., Fraundorfer, F., “Deep learning in remote sensing: A comprehensive review and list of resources”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 5, no. 4, 2017, pp. 8–36.