

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



Ninh Hải Đăng

**ỨNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG
GIÁM SÁT BIỂN ĐỘNG RỪNG TỈNH CÀ MAU**

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Công nghệ Hàng không Vũ trụ

HÀ NỘI - 2025

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



Ninh Hải Đăng

**ỨNG DỤNG VIỄN THÁM VÀ HỌC SÂU TRONG GIÁM
SÁT BIỂN ĐỘNG RỪNG TỈNH CÀ MAU**

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC HỆ CHÍNH QUY

Ngành: Công nghệ Hàng không Vũ trụ

Cán bộ hướng dẫn: TS. Hà Minh Cường

ThS. Hoàng Tích Phúc

HÀ NỘI - 2025

Tóm tắt

Tóm tắt: Đồ án này nghiên cứu ứng dụng mạng Neural Tích chập (Convolutional Neural Networks - CNN) kết hợp với dữ liệu viễn thám đa nguồn từ vệ tinh Sentinel-1 và Sentinel-2 để phát hiện và phân loại biến động rừng tại tỉnh Cà Mau — khu vực rừng ngập mặn quan trọng bậc nhất tại Việt Nam. Nghiên cứu sử dụng 27 đặc trưng bao gồm các kênh phổ (Red, NIR, SWIR), các chỉ số thực vật (NDVI, EVI, NDWI, NDMI) và dữ liệu backscatter SAR (VV, VH) từ hai thời kỳ (01/2024 và 02/2025) với độ phân giải không gian 10m, cho phép phân tích biến động rừng trong khoảng thời gian 13 tháng. Kiến trúc CNN nhẹ (lightweight) với khoảng 36,000 tham số, patches 3×3 để khai thác ngữ cảnh không gian xung quanh mỗi pixel trung tâm, áp dụng các kỹ thuật regularization mạnh (Batch Normalization, Dropout 0.7, Weight Decay) để tránh overfitting trên bộ dữ liệu 2,630 điểm ground truth với 4 lớp phân loại (Rừng ổn định, Mất rừng, Phi rừng, Phục hồi rừng). Quy trình đánh giá khoa học chặt chẽ được triển khai với stratified random split kết hợp 5-Fold Stratified Cross Validation, đảm bảo phân bố cân bằng các lớp trong mỗi fold và giữ lại 20% dữ liệu làm tập test cố định. Kết quả cho thấy mô hình đạt độ chính xác 98.86% trên tập test với ROC-AUC 99.98% cho thấy khả năng phân biệt xuất sắc giữa các lớp, Cross Validation cho kết quả trung bình $98.15\% \pm 0.28\%$ với độ lệch chuẩn thấp chứng tỏ mô hình ổn định và có khả năng tổng quát hóa tốt. Ứng dụng thực tế phân loại toàn vùng quy hoạch lâm nghiệp Cà Mau với tổng diện tích ranh giới 170,179 ha, trong đó 162,469 ha được phân loại thực tế (tương đương 16.2 triệu pixel), cho thấy 74.30% diện tích là rừng ổn định, phát hiện 7,282 ha mất rừng (4.48%) và 4,941 ha phục hồi rừng (3.04%) trong giai đoạn nghiên cứu, đóng góp một phương pháp tiếp cận hiệu quả cho công tác giám sát và quản lý tài nguyên rừng.

Từ khóa: CNN, Deep Learning, viễn thám, Sentinel-1, Sentinel-2, biến động rừng, rừng ngập mặn, Cà Mau.

Lời cam đoan

Tôi tên là Ninh Hải Đăng, sinh viên lớp QH-2021-I/CQ-S-AE, Viện Công nghệ Hàng không Vũ trụ, Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội. Tôi xin cam đoan rằng Đồ án tốt nghiệp với đề tài “Ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau” là kết quả nghiên cứu khoa học do chính tôi thực hiện dưới sự hướng dẫn của TS. Hà Minh Cường và ThS. Hoàng Tích Phúc.

Mọi sự hỗ trợ, hướng dẫn trong quá trình thực hiện đều đã được ghi nhận và cảm ơn; các thông tin, số liệu, tài liệu tham khảo trong đồ án đều được trích dẫn đầy đủ và được phép sử dụng. Tôi xin đảm bảo rằng tất cả dữ liệu nghiên cứu và kết quả trình bày trong đồ án là trung thực và chính xác. Nếu phát hiện bất kỳ sai sót nào, tôi xin hoàn toàn chịu trách nhiệm trước cơ quan nhà trường và các cơ quan liên quan.

Sinh viên

Ninh Hải Đăng

Lời cảm ơn

Đối với mỗi sinh viên, đồ án tốt nghiệp là một cột mốc quan trọng, phản ánh kết quả học tập và quá trình rèn luyện suốt thời gian tại trường đại học. Trong quá trình thực hiện đồ án, bên cạnh những nỗ lực của bản thân, em đã nhận được rất nhiều sự giúp đỡ quý báu từ các thầy cô và những người xung quanh, nhờ đó công trình này mới có thể hoàn thành.

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc tới các thầy, cô là cán bộ, giảng viên trong trường Đại học Công nghệ nói chung và Viện Công nghệ Hàng không Vũ trụ nói riêng, những người đã tạo điều kiện và truyền đạt kiến thức quý báu trong suốt thời gian học tập.

Đặc biệt, em xin gửi lời cảm ơn chân thành tới TS. Hà Minh Cường và ThS. Hoàng Tích Phúc – giảng viên Viện Công nghệ Hàng không Vũ trụ, trường Đại học Công nghệ - Đại học Quốc gia Hà Nội, những người đã tận tình hướng dẫn, chỉ bảo và đồng hành cùng em trong suốt quá trình thực hiện đồ án.

Em cũng xin trân trọng cảm ơn TS. Hoàng Việt Anh và ThS. Vũ Văn Thái – Công ty TNHH Tư vấn và Công nghệ Đồng Xanh (GFD), đã hỗ trợ em trong việc cung cấp dữ liệu, cơ sở vật chất và tạo điều kiện thuận lợi để hoàn thành nghiên cứu.

Cuối cùng, em xin gửi lời cảm ơn sâu sắc tới gia đình, bạn bè và các đồng nghiệp tại công ty đã luôn động viên, chia sẻ và đồng hành cùng em trong suốt quá trình học tập và thực hiện đồ án.

Mặc dù đã rất cố gắng, song do những hạn chế về mặt thời gian và kinh nghiệm, đồ án tốt nghiệp này chắc chắn sẽ không tránh khỏi những thiếu sót. Em kính mong nhận được những ý kiến đóng góp quý báu từ quý thầy cô để bản thân có thể hoàn thiện hơn nữa trong tương lai.

Em xin trân trọng cảm ơn!

Mục lục

Tóm tắt	i
Lời cam đoan	ii
Lời cảm ơn	iii
Mục lục	iv
Danh sách hình vẽ	vii
Danh sách bảng	viii
Danh mục từ viết tắt	ix
Mở đầu	xv
Chương 1 Tổng quan về vấn đề nghiên cứu	1
1.1 Bối cảnh và tình hình mất rừng	1
1.1.1 Tình hình mất rừng trên thế giới	1
1.1.2 Tình hình mất rừng tại Việt Nam	3
1.1.3 Tình hình rừng tại tỉnh Cà Mau	4
1.2 Công nghệ viễn thám trong giám sát rừng	5
1.2.1 Ưu điểm của công nghệ viễn thám	5
1.2.2 Chương trình Copernicus và vệ tinh Sentinel	6
1.2.3 Chỉ số thực vật từ dữ liệu quang học	7
1.2.4 Tích hợp dữ liệu SAR và Optical	8
1.3 Tổng quan các nghiên cứu liên quan	9
1.3.1 Phương pháp Deep Learning	9
1.3.2 Ứng dụng trong giám sát rừng	9
1.4 Khoảng trống nghiên cứu và định hướng đồ án	10

1.4.1	Khoảng trống nghiên cứu	10
1.4.2	Định hướng của đồ án	10
1.4.3	Câu hỏi nghiên cứu	11
Chương 2 Cơ sở lý thuyết		12
2.1	Công nghệ viễn thám và ảnh vệ tinh	12
2.1.1	Nguyên lý viễn thám	12
2.1.2	Radar khâu độ tổng hợp (SAR)	13
2.1.3	Ảnh quang học đa phổ (Optical Multispectral)	13
2.1.4	Phát hiện biến động rừng	14
2.2	Mạng Neural Tích chập (Convolutional Neural Networks)	15
2.2.1	Giới thiệu về Neural Networks	15
2.2.2	Convolutional Layer	16
2.2.3	Activation Functions	16
2.2.4	Batch Normalization	17
2.2.5	Dropout	17
2.2.6	Loss Functions	18
2.2.7	Optimization Algorithms	18
2.3	Phương pháp phân loại ảnh viễn thám	18
2.3.1	Pixel-based vs Patch-based Classification	18
2.3.2	Evaluation Metrics	19
Chương 3 Phương pháp nghiên cứu		20
3.1	Khu vực và dữ liệu nghiên cứu	20
3.1.1	Khu vực nghiên cứu	20
3.1.2	Dữ liệu viễn thám	22
3.1.3	Ground Truth Data	22
3.2	Quy trình xử lý dữ liệu	23
3.2.1	Tổng quan quy trình	23
3.2.2	Feature Extraction chi tiết	24
3.3	Kiến trúc mô hình CNN đề xuất	25
3.3.1	Thiết kế kiến trúc	25
3.3.2	Parameter Count	26
3.4	Huấn luyện và tối ưu hóa mô hình	27
3.4.1	Training Configuration	27

3.4.2	Data Splitting Strategy	27
3.5	Dự đoán và đánh giá kết quả	28
3.5.1	Test Set Evaluation	28
3.5.2	Full Raster Prediction	28
Chương 4	Kết quả và thảo luận	29
4.1	Tổng quan về kết quả thực nghiệm	29
4.1.1	Cấu hình thực nghiệm	29
4.1.2	Thời gian thực thi	30
4.2	Kết quả huấn luyện mô hình CNN	30
4.2.1	Kết quả 5-Fold Cross Validation	30
4.2.2	Kết quả trên tập test (Test Set)	31
4.2.3	Đường cong ROC	33
4.3	Kết quả phân loại toàn bộ vùng nghiên cứu	34
4.3.1	Thông kê phân loại	34
4.4	Ablation Studies	36
4.4.1	Ảnh hưởng của patch size	36
4.4.2	Ảnh hưởng của data sources	36
4.5	So sánh với các nghiên cứu khác	37
4.6	Đánh giá tổng quan	37
4.6.1	Điểm mạnh của phương pháp	37
4.6.2	Hạn chế	37
4.6.3	Tóm tắt chương	37
Kết luận và kiến nghị		39
Tài liệu tham khảo		41

Danh sách hình vẽ

1.1	Các mặt trận mất rừng trọng điểm tại khu vực Mỹ Latinh. (Nguồn: WWF, 2021)	2
1.2	Các mặt trận mất rừng trọng điểm tại Châu Phi và Đông Nam Á. (Nguồn: WWF, 2021)	3
1.3	Biến động độ che phủ rừng Việt Nam giai đoạn 1990-2020	4
1.4	Vị trí tỉnh Cà Mau và phạm vi các khu vực rừng	5
1.5	Vệ tinh Sentinel-1. (Nguồn: European Space Agency)	7
1.6	Vệ tinh Sentinel-2. (Nguồn: European Space Agency)	7
2.1	Nguyên lý viễn thám bị động và chủ động	13
2.2	Cấu trúc cơ bản của một perceptron	15
2.3	Minh họa phép tích chập 2D	16
3.1	Bản đồ vị trí khu vực nghiên cứu	21
3.2	Ảnh Sentinel-2 khu vực nghiên cứu tại hai thời điểm	22
3.3	Phân bố không gian các điểm ground truth	23
3.4	Quy trình xử lý dữ liệu tổng quan	23
3.5	Kiến trúc mô hình CNN đề xuất	25
3.6	Chiến lược phân chia dữ liệu	28
4.1	So sánh accuracy giữa các folds trong Cross Validation	31
4.2	Ma trận nhầm lẫn dạng heatmap	32
4.3	Đường cong ROC cho các lớp phân loại	33
4.4	Bản đồ phân loại biến động rừng tỉnh Cà Mau	35
4.5	Tỷ lệ diện tích các lớp phân loại	35

Danh sách bảng

1.1	Tổng hợp các nghiên cứu liên quan	10
2.1	Các dải phô Sentinel-2 sử dụng trong nghiên cứu	14
3.1	Tổng quan dữ liệu viễn thám sử dụng	22
3.2	Thông kê Ground Truth	22
3.3	Chi tiết 27 features sử dụng	24
3.4	Tổng số trainable parameters	26
3.5	Hyperparameters huấn luyện	27
4.1	Thời gian thực thi các giai đoạn	30
4.2	Kết quả 5-Fold Cross Validation	30
4.3	Metrics trên tập test (526 patches)	31
4.4	Ma trận nhầm lẫn trên Test Set	31
4.5	Phân tích chi tiết từng lớp	32
4.6	ROC-AUC score cho từng lớp (Test Set)	33
4.7	Thông kê phân loại full raster	34
4.8	Phân bố diện tích theo lớp phân loại	34
4.9	So sánh các patch sizes	36
4.10	Ablation các nguồn dữ liệu	36
4.11	So sánh với các nghiên cứu trong literature	37

Danh mục từ viết tắt

Từ	Viết tắt	Dịch - Nghĩa
Accuracy	-	Độ chính xác tổng thể (tỷ lệ dự đoán đúng trên tổng số mẫu)
Activation Function	-	Hàm kích hoạt (hàm phi tuyến trong mạng neural)
AdamW	-	Thuật toán tối ưu Adam với phân rã trọng số tách rời
Artificial Intelligence	AI	Trí tuệ nhân tạo
Backscatter	-	Tán xạ ngược (năng lượng radar phản hồi về cảm biến)
Batch Normalization	BN	Chuẩn hóa theo lô (chuẩn hóa đầu vào mỗi lớp theo mini-batch)
Bi-temporal	-	Hai thời điểm (phân tích so sánh hai thời kỳ)
C-band	-	Băng tần C (bước sóng radar 4-8 GHz, xuyên qua mây)
Classification	-	Phân loại (gán nhãn cho đối tượng)
Compute Unified Device Architecture	CUDA	Nền tảng tính toán song song của NVIDIA trên GPU
Confusion Matrix	-	Ma trận nhầm lẫn (bảng so sánh dự đoán và thực tế)
Convolutional Neural Network	CNN	Mạng nơ-ron tích chập

Cross Validation	CV	Kiểm định chéo (đánh giá mô hình trên nhiều phần dữ liệu)
CrossEntropyLoss	-	Hàm mất mát entropy chéo (độ sai khác phân phối xác suất)
Deep Learning	DL	Học sâu (học máy với nhiều lớp ẩn)
Deforestation	-	Mất rừng (chuyển đổi từ rừng sang phi rừng)
Dropout	-	Loại bỏ ngẫu nhiên (tắt ngẫu nhiên một số neuron khi huấn luyện)
Early Stopping	-	Dừng sớm (ngừng huấn luyện khi validation loss không giảm)
Enhanced Vegetation Index	EVI	Chỉ số thực vật cải tiến (nhạy hơn NDVI ở vùng rậm rạp)
European Space Agency	ESA	Cơ quan Vũ trụ Châu Âu
European Union	EU	Liên minh Châu Âu
F1-Score	-	Điểm F1 (trung bình điều hòa của Precision và Recall)
Feature	-	Đặc trưng (thuộc tính đầu vào của mô hình)
Feature Extraction	-	Trích xuất đặc trưng (rút trích thông tin từ dữ liệu thô)
Feature Map	-	Bản đồ đặc trưng (đầu ra của lớp tích chập)
Filter/Kernel	-	Bộ lọc/Nhân tích chập (ma trận trọng số trượt qua ảnh)
Fold	-	Phần gấp (một phần dữ liệu trong Cross Validation)
Food and Agriculture Organization	FAO	Tổ chức Lương thực và Nông nghiệp Liên Hợp Quốc
Forest Change Detection	-	Phát hiện biến động rừng

Fully Connected Layer	FC	Lớp kết nối đầy đủ (mỗi neuron kết nối với tất cả neuron lớp trước)
Geographic Information System	GIS	Hệ thống thông tin địa lý
Global Average Pooling	GAP	Gộp trung bình toàn cục (lấy trung bình toàn bộ feature map)
Graphics Processing Unit	GPU	Bộ xử lý đồ họa (phần cứng tính toán song song)
Ground Truth	-	Dữ liệu tham chiếu (nhận thực tế để đánh giá mô hình)
Hyperparameter	-	Siêu tham số (tham số cấu hình trước khi huấn luyện)
Interferometric Wide	IW	Chế độ giao thoa rộng (chế độ chụp chính của Sentinel-1)
Intergovernmental Panel on Climate Change	IPCC	Ủy ban Liên chính phủ về Biến đổi Khí hậu
Learning Rate	LR	Tốc độ học (bước cập nhật trọng số mỗi lần lặp)
Lightweight	-	Kiến trúc nhẹ (mô hình có ít tham số, tính toán nhanh)
Logits	-	Giá trị logit (đầu ra thô của mạng trước khi áp dụng softmax)
Machine Learning	ML	Học máy
Mangrove Forest	-	Rừng ngập mặn
Multi-Layer Perceptron	MLP	Perceptron đa lớp (mạng neural nhiều lớp kết nối đầy đủ)
Multispectral	-	Đa phổ (ảnh chụp ở nhiều dải bước sóng)
Near-Infrared	NIR	Cận hồng ngoại (bước sóng 0.7–1.4 μm)
Non-forest	-	Phi rừng (vùng không có rừng che phủ)

Normalized Burn Ratio	NBR	Chỉ số cháy chuẩn hóa (phát hiện vùng cháy rừng)
Normalized Difference Moisture Index	NDMI	Chỉ số độ ẩm chuẩn hóa (đánh giá độ ẩm thực vật)
Normalized Difference Vegetation Index	NDVI	Chỉ số thực vật chuẩn hóa (đánh giá mức độ xanh tươi)
Normalized Difference Water Index	NDWI	Chỉ số nước chuẩn hóa (phát hiện mặt nước)
Optical	-	Quang học (ảnh vệ tinh dùng ánh sáng khả kiến và hồng ngoại)
Overfitting	-	Quá khớp (mô hình học thuộc dữ liệu huấn luyện, kém tổng quát)
Padding	-	Đệm viền (thêm pixel xung quanh ảnh khi tích chập)
Parameter	-	Tham số (trọng số học được trong quá trình huấn luyện)
Patch	-	Mảnh ảnh (vùng ảnh nhỏ trích xuất từ ảnh gốc)
Pixel	-	Điểm ảnh (đơn vị nhỏ nhất của ảnh số)
Polarization	-	Phân cực (hướng dao động của sóng radar: VV, VH)
Pooling	-	Gộp (giảm kích thước không gian của feature map)
Precision	-	Độ chính xác (tỷ lệ dự đoán dương đúng trên tổng dự đoán dương)
Prediction	-	Dự đoán (kết quả đầu ra của mô hình)
Raster	-	Dữ liệu raster (ảnh dạng lưới điểm ảnh)
Recall	-	Độ phủ (tỷ lệ phát hiện đúng trên tổng số thực tế dương)

Receiver Characteristic	Operating ROC	Đường cong ROC (biểu đồ đánh giá khả năng phân loại)
Rectified Linear Unit	ReLU	Hàm ReLU (hàm kích hoạt: $f(x) = \max(0, x)$)
Reforestation	-	Phục hồi rừng (tái sinh hoặc trồng lại rừng)
Regularization	-	Chính quy hóa (kỹ thuật giảm overfitting)
Remote Sensing	-	Viễn thám (thu thập thông tin từ xa qua vệ tinh/máy bay)
ROC-AUC	-	Diện tích dưới đường cong ROC (đo khả năng phân biệt lớp)
Scheduler	-	Bộ điều chỉnh tốc độ học (thay đổi learning rate theo epoch)
Short-Wave Infrared	SWIR	Hồng ngoại sóng ngắn (bước sóng 1.4–3 μm)
Softmax	-	Hàm softmax (chuyển logits thành phân phối xác suất)
Spectral Signature	-	Phổ phản xạ đặc trưng (đặc điểm phản xạ theo bước sóng)
Stratified	-	Phân tầng (chia dữ liệu giữ nguyên tỷ lệ các lớp)
Synthetic Aperture Radar	SAR	Radar khẩu độ tổng hợp (cảm biến chủ động, hoạt động mọi thời tiết)
Test Set	-	Tập kiểm tra (dữ liệu đánh giá cuối cùng, không dùng khi huấn luyện)
Training	-	Huấn luyện (quá trình học tham số từ dữ liệu)
Universal Mercator	Transverse UTM	Hệ tọa độ UTM (phép chiếu bắn đồ chia thành 60 múi)
Validation	-	Xác thực (đánh giá mô hình trong quá trình huấn luyện)

Weight Decay	-	Phân rã trọng số (thêm phạt L2 vào hàm mất mát)
World Geodetic System	WGS	Hệ trắc địa thế giới (hệ tọa độ toàn cầu, WGS84)

Mở đầu

Đặt vấn đề

Rừng đóng vai trò quan trọng trong việc duy trì cân bằng sinh thái, điều hòa khí hậu, lưu giữ carbon và bảo vệ đa dạng sinh học. Tuy nhiên, tình trạng mất rừng đang diễn ra nghiêm trọng trên toàn cầu, đặc biệt tại các quốc gia đang phát triển. Theo báo cáo “Global Forest Resources Assessment 2020” của Tổ chức Lương thực và Nông nghiệp Liên hợp quốc [8], thế giới đã mất ròng (net loss) khoảng 178 triệu hecta rừng trong giai đoạn 1990-2020, tương đương diện tích của Libya.

Tại Việt Nam, mặc dù độ che phủ rừng đã tăng từ 37% (năm 2000) lên 42% (năm 2020) nhờ các chương trình trồng rừng, nhưng tình trạng suy thoái và mất rừng tự nhiên vẫn đáng báo động, đặc biệt tại các tỉnh ven biển và đồng bằng sông Cửu Long. Tỉnh Cà Mau, nằm ở cực Nam Tổ Quốc, sở hữu hệ sinh thái rừng ngập mặn quan trọng nhưng đang phải đối mặt với áp lực từ nuôi trồng thủy sản, xâm nhập mặn, và biến đổi khí hậu.

Phương pháp giám sát rừng truyền thống dựa trên điều tra thực địa tốn kém thời gian, chi phí và khó áp dụng cho diện tích rộng. Công nghệ viễn thám vệ tinh cung cấp giải pháp hiệu quả, cho phép giám sát liên tục, diện rộng với chi phí hợp lý. Chương trình Copernicus của Liên minh Châu Âu (EU) cung cấp dữ liệu miễn phí từ các vệ tinh Sentinel-1 (SAR) và Sentinel-2 (Optical) với độ phân giải không gian 10m và chu kỳ quay trở lại ngắn (5-6 ngày), phù hợp cho giám sát rừng nhiệt đới.

Trong những năm gần đây, trí tuệ nhân tạo (AI) và học sâu (Deep Learning) đã đạt được những bước tiến vượt bậc trong xử lý ảnh và nhận dạng mẫu. Mạng Neural Tích chập (Convolutional Neural Networks - CNN) đặc biệt hiệu quả trong phân loại ảnh nhờ khả năng tự động học đặc trưng không gian (spatial features) từ dữ liệu thô.

Xuất phát từ nhu cầu thực tiễn về giám sát rừng hiệu quả và xu hướng ứng dụng công nghệ AI tiên tiến, đồ án này lựa chọn đề tài **“Ứng dụng viễn thám và học sâu trong giám sát biến động rừng tỉnh Cà Mau”** nhằm phát triển mô hình phát hiện mất rừng với độ chính xác cao.

Mục tiêu và nội dung nghiên cứu

Mục tiêu tổng quát của đồ án là phát triển mô hình học sâu dựa trên kiến trúc CNN để phát hiện và phân loại tự động các khu vực biến động rừng từ ảnh vệ tinh đa nguồn (Sentinel-1 SAR và Sentinel-2 Optical) tại tỉnh Cà Mau.

Để đạt được mục tiêu tổng quát, đề tài tập trung vào năm mục tiêu cụ thể. Thứ nhất, xây dựng bộ dữ liệu huấn luyện thông qua việc thu thập và xử lý dữ liệu ảnh vệ tinh Sentinel-1/2 đa thời gian, kết hợp với ground truth points để tạo bộ dữ liệu huấn luyện chất lượng cao. Thứ hai, thiết kế kiến trúc CNN tối ưu, để xuất kiến trúc CNN nhẹ (lightweight) phù hợp với bộ dữ liệu có quy mô vừa phải (khoảng 2,600 mẫu). Thứ ba, phân chia dữ liệu khoa học được triển khai bằng phương pháp stratified random split kết hợp với 5-Fold Cross Validation. Thứ tư, huấn luyện và tối ưu hóa mô hình bằng cách áp dụng các kỹ thuật huấn luyện tiên tiến. Thứ năm, ứng dụng thực tế để phân loại toàn bộ khu vực rừng Cà Mau.

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu chính bao gồm các khu vực rừng tự nhiên và rừng trồng tại tỉnh Cà Mau (theo địa giới hành chính mới có hiệu lực từ ngày 01/07/2025, sau khi sáp nhập tỉnh Cà Mau cũ và tỉnh Bạc Liêu), bao gồm rừng ngập mặn và rừng phòng hộ ven biển. Các trạng thái biến động rừng được phân loại thành bốn nhóm: Forest Stable (Rừng ổn định), Deforestation (Mất rừng), Non-forest (Không phải rừng), và Reforestation (Tái trồng rừng).

Phạm vi nghiên cứu bao gồm toàn bộ vùng quy hoạch lâm nghiệp của tỉnh Cà Mau mới với tổng diện tích ranh giới 170,179 hecta (tương đương 1,701.79 km²), trong đó diện tích thực tế được phân loại là 162,469 hecta (khoảng 95.5% diện tích ranh giới, phần còn lại bị loại do mây che hoặc dữ liệu không hợp lệ). Dữ liệu ranh giới quy hoạch lâm nghiệp được cung cấp bởi Công ty TNHH Tư vấn và Công nghệ Đồng Xanh — đối tác của Chi cục Kiểm lâm tỉnh Cà Mau. Thời gian nghiên cứu kéo dài từ tháng 01/2024 đến tháng 02/2025 (khoảng 13 tháng).

Ý nghĩa khoa học và thực tiễn của đề tài

Về mặt khoa học, đồ án đề xuất kiến trúc CNN nhẹ và hiệu quả cho bài toán phân loại ảnh viễn thám với bộ dữ liệu nhỏ; chứng minh hiệu quả tích hợp đa nguồn bằng cách kết hợp dữ liệu SAR và Optical.

Về ý nghĩa thực tiễn, mô hình cung cấp công cụ tự động phát hiện mất rừng với độ chính xác cao (trên 98%), giúp giảm đáng kể thời gian và chi phí so với phương pháp điều tra thực địa truyền thống.

Cấu trúc của đồ án

Đồ án được tổ chức thành bốn chương chính:

Chương 1: Tổng quan về vấn đề nghiên cứu

Trình bày tổng quan về vấn đề nghiên cứu, bao gồm bối cảnh mất rừng, công nghệ viễn thám, tổng quan các nghiên cứu liên quan và các khoảng trống nghiên cứu.

Chương 2: Cơ sở lý thuyết

Giới thiệu chi tiết về công nghệ viễn thám (Sentinel-1/2), lý thuyết về mạng Neural Tích chập (CNN) và các phương pháp phân loại ảnh cùng những tiêu chí đánh giá mô hình.

Chương 3: Phương pháp nghiên cứu

Mô tả khu vực nghiên cứu, dữ liệu sử dụng, quy trình xử lý, kiến trúc mô hình CNN đề xuất, phương pháp huấn luyện và đánh giá.

Chương 4: Kết quả và thảo luận

Trình bày các kết quả huấn luyện, đánh giá mô hình, phân loại toàn vùng, phân tích lỗi và trực quan hóa. Đồng thời đưa ra kết luận và kiến nghị cho các nghiên cứu tiếp theo.

Chương 1

Tổng quan về vấn đề nghiên cứu

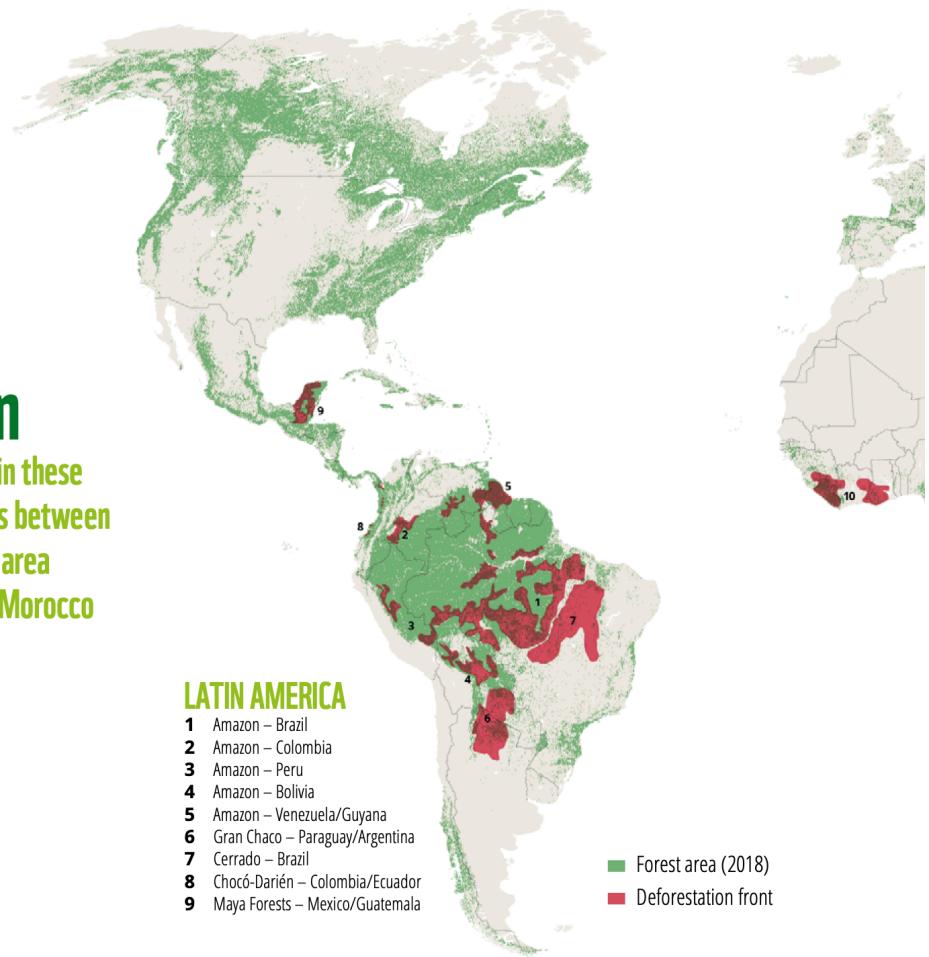
1.1 Bối cảnh và tình hình mất rừng

1.1.1 Tình hình mất rừng trên thế giới

Rừng bao phủ khoảng 31% diện tích đất liền toàn cầu [8], đóng vai trò thiết yếu trong việc điều hòa khí hậu và bảo tồn đa dạng sinh học. Tuy nhiên, tốc độ mất rừng toàn cầu vẫn đang ở mức báo động. Theo báo cáo “Global Forest Resources Assessment 2020” của FAO [8], tổng diện tích rừng bị phá (gross deforestation) từ năm 1990 đến 2020 ước tính khoảng 420 triệu hecta. Mặc dù diện tích mất rừng ròng đã giảm nhờ nỗ lực trồng rừng, nhưng việc chuyển đổi đất rừng sang nông nghiệp và chăn nuôi vẫn diễn ra phức tạp.

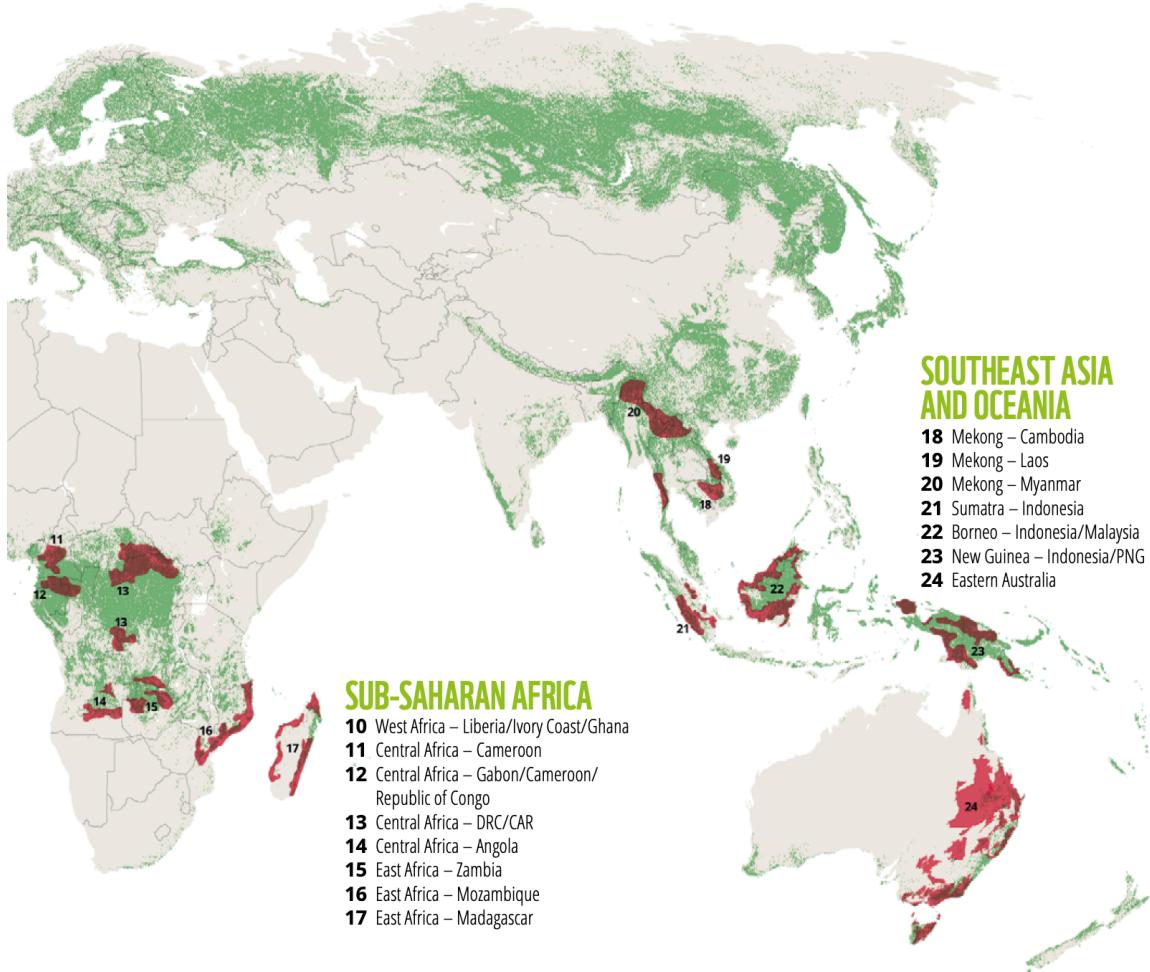
Sự suy giảm này tập trung nghiêm trọng nhất tại khu vực nhiệt đới. Theo báo cáo của WWF, chỉ tính riêng giai đoạn 2004–2017, hơn 43 triệu hecta rừng đã bị xóa sổ tại các “mặt trận” nóng bỏng nhất, diện tích tương đương quy mô nước Maroc. Trong đó, **Lưu vực Amazon (Nam Mỹ)** là nơi chịu tổn thất nặng nề nhất do áp lực từ chăn nuôi và nông nghiệp quy mô lớn.

**Over
43 million**
hectares were lost in these
deforestation fronts between
2004 and 2017, an area
roughly the size of Morocco



Hình 1.1: Các mặt trận mất rừng trọng điểm tại khu vực Mỹ Latinh. (Nguồn: WWF, 2021)

Không chỉ giới hạn ở Châu Mỹ, tình trạng phá rừng cũng đang diễn biến phức tạp tại bờ biển kia đại dương. **Lưu vực Congo (Trung Phi) và Đông Nam Á** là những điểm nóng tiếp theo. Tại Đông Nam Á, rừng nguyên sinh đang bị thu hẹp nhanh chóng tại các khu vực như sông Mekong, đảo Sumatra và Borneo để nhường chỗ cho các đồn điền cây công nghiệp.



Hình 1.2: Các mặt trận mất rừng trọng điểm tại Châu Phi và Đông Nam Á. (Nguồn: WWF, 2021)

Xu hướng này vẫn tiếp diễn trong những năm gần đây. Theo Global Forest Watch [9], thế giới mất khoảng 10 triệu hecta rừng nhiệt đới mỗi năm trong giai đoạn 2015–2020. Việc này không chỉ làm giảm khả năng hấp thụ CO₂ mà còn trực tiếp phát thải khí nhà kính từ việc đốt rừng và phân hủy sinh khối. Theo IPCC [16], phá rừng và thay đổi sử dụng đất đóng góp khoảng 23% tổng lượng phát thải khí nhà kính do con người gây ra, góp phần làm tăng hiện tượng biến đổi khí hậu toàn cầu.

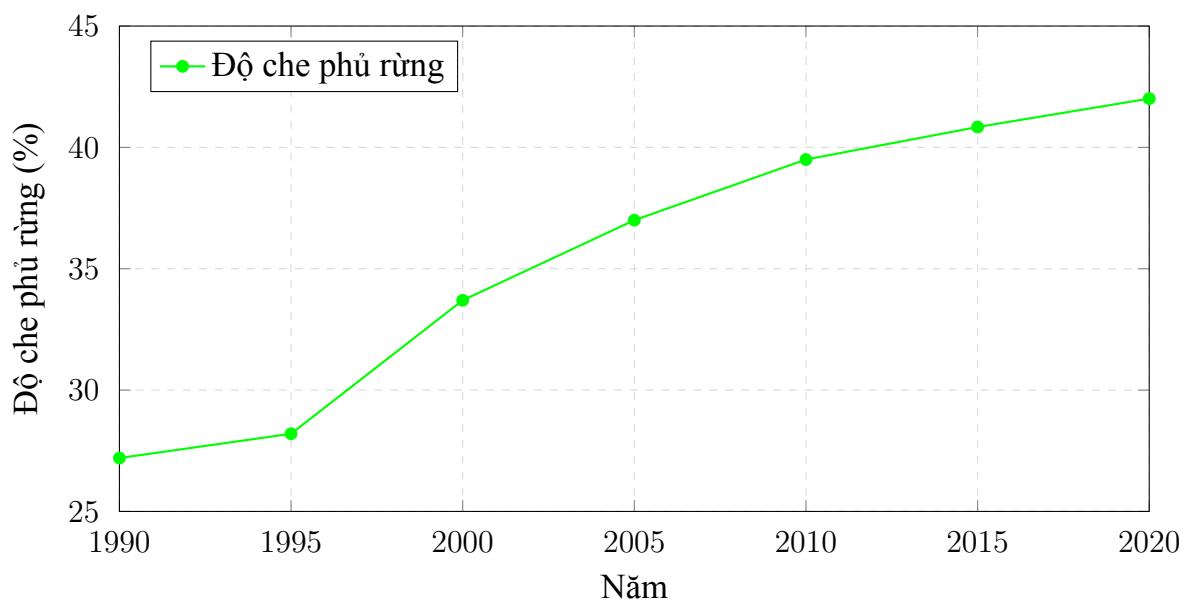
1.1.2 Tình hình mất rừng tại Việt Nam

Việt Nam đã trải qua những biến đổi lớn về độ che phủ rừng trong 30 năm qua. Sau thời kỳ suy giảm nghiêm trọng (độ che phủ chỉ còn 28% vào năm 1990 do chiến tranh và khai thác bừa bãi), Việt Nam đã thực hiện nhiều chương trình phục hồi và phát triển rừng.

Nhờ các chương trình như “Trồng 5 triệu hecta rừng” (1998-2010), độ che phủ rừng đã tăng lên 42% vào năm 2020 [1].

Tuy nhiên, chất lượng rừng là một vấn đề đáng lo ngại. Mặc dù tổng diện tích rừng tăng từ 9.4 triệu hecta (1990) lên 14.6 triệu hecta (2020) chủ yếu nhờ rừng trồng (cao su, keo, thông), chất lượng rừng tự nhiên lại suy giảm đáng kể. Theo số liệu của Bộ NN&PTNT (2020), rừng tự nhiên hiện có khoảng 10.29 triệu hecta, nhưng rừng nguyên sinh (primary forest) chỉ còn chiếm khoảng 0.6% tổng diện tích rừng [1].

Nguyên nhân chính gây mất rừng tại Việt Nam bao gồm việc chuyển đổi sang đất nông nghiệp như trồng cà phê, cao su và điều; khai thác gỗ trái phép; phát triển cơ sở hạ tầng và đô thị hóa; cháy rừng; và hoạt động nuôi trồng thủy sản, đặc biệt tại khu vực ven biển và đồng bằng sông Cửu Long.



Hình 1.3: Biến động độ che phủ rừng Việt Nam giai đoạn 1990-2020

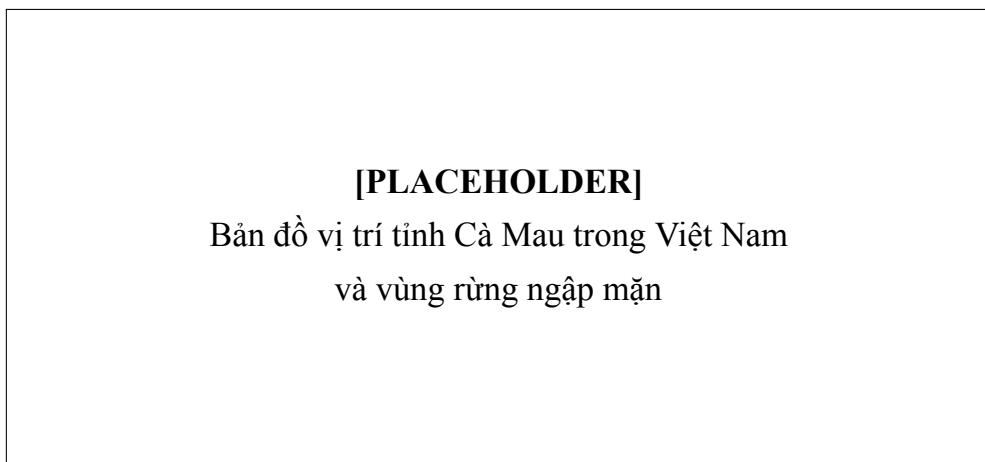
1.1.3 Tình hình rừng tại tỉnh Cà Mau

Lưu ý về địa giới hành chính: Theo Nghị quyết số 1278/NQ-UBTVQH15 ngày 24/10/2024 của Ủy ban Thường vụ Quốc hội, kể từ ngày 01/07/2025, tỉnh Cà Mau và tỉnh Bạc Liêu được sáp nhập thành tỉnh Cà Mau mới với tổng diện tích tự nhiên 7,942.38 km² và dân số khoảng 2.6 triệu người. Đề án này nghiên cứu trên phạm vi rừng của tỉnh Cà Mau mới, bao gồm cả vùng rừng thuộc địa bàn Bạc Liêu cũ.

Tỉnh Cà Mau mới nằm ở cực Nam Tổ Quốc, sở hữu hệ sinh thái rừng ngập mặn

quan trọng. Theo số liệu trước khi sáp nhập, tỉnh Cà Mau cũ có diện tích rừng khoảng 94,319 hecta và tỉnh Bạc Liêu có khoảng 5,730 hecta rừng, tổng cộng khoảng 100,000 hecta rừng trên toàn tỉnh Cà Mau mới. Rừng ngập mặn Cà Mau chiếm khoảng 20% diện tích rừng ngập mặn của Việt Nam, đóng vai trò then chốt trong việc phòng hộ ven biển (chắn sóng, chống xâm thực và bảo vệ bờ biển), bảo tồn đa dạng sinh học vì là môi trường sống cho nhiều loài động thực vật quý hiếm, cung cấp nguồn sinh kế thông qua các hoạt động thủy sản và du lịch sinh thái, và góp phần giảm nhẹ biến đổi khí hậu nhờ khả năng lưu giữ carbon cao, gấp khoảng 3–5 lần so với rừng nhiệt đới trên cạn [4, 5].

Tuy nhiên, rừng Cà Mau đang phải đối mặt với nhiều thách thức. Trước hết là áp lực chuyển đổi sang nuôi tôm do kinh tế, khiến nhiều khu vực rừng bị chuyển đổi thành ao nuôi. Ngoài ra, hiện tượng xâm nhập mặn gia tăng do biến đổi khí hậu làm giảm sức khỏe rừng; đồng thời xói mòn bờ biển cũng làm suy giảm diện tích rừng ven biển; và tình trạng thiếu nước ngọt ảnh hưởng tới khả năng tái sinh tự nhiên của rừng. Giai đoạn 2011-2023, sạt lở vùng ven biển đã làm mất hơn 6,000 hecta đất và rừng phòng hộ. Việc giám sát và bảo vệ rừng tại Cà Mau là ưu tiên hàng đầu nhằm duy trì hệ sinh thái quan trọng này.



Hình 1.4: Vị trí tỉnh Cà Mau và phạm vi các khu vực rừng.

1.2 Công nghệ viễn thám trong giám sát rừng

1.2.1 Ưu điểm của công nghệ viễn thám

Công nghệ viễn thám vệ tinh đem lại nhiều ưu thế rõ rệt so với các phương pháp điều tra thực địa truyền thống. Trước hết, ảnh vệ tinh có khả năng bao phủ diện tích rất lớn,

giúp quan sát đồng thời hàng nghìn km² rừng. Bên cạnh đó, các vệ tinh hiện đại có chu kỳ lặp ngắn, thường chỉ 3–5 ngày, tạo điều kiện phát hiện kịp thời những biến động xảy ra trong rừng. Nguồn dữ liệu từ nhiều chương trình vệ tinh hiện nay còn được cung cấp miễn phí, góp phần giảm đáng kể chi phí so với khảo sát ngoài thực địa. Hệ thống lưu trữ ảnh vệ tinh phong phú theo thời gian cũng cho phép phân tích chuỗi biến động dài hạn. Đối với những khu vực khó tiếp cận như rừng sâu, vùng núi cao hay khu vực biên giới, viễn thám vẫn có thể giám sát hiệu quả. Ngoài ra, tính khách quan và khả năng lặp lại của dữ liệu viễn thám giúp hạn chế các sai lệch do yếu tố chủ quan trong quá trình điều tra trực tiếp.

1.2.2 Chương trình Copernicus và vệ tinh Sentinel

Chương trình Copernicus của Liên minh Châu Âu (EU) là một trong những chương trình quan sát Trái Đất lớn nhất thế giới, cung cấp dữ liệu miễn phí và mở. Hai vệ tinh quan trọng cho giám sát rừng là:

Sentinel-1 (SAR - Synthetic Aperture Radar):

Vệ tinh Sentinel-1 hoạt động ở dải sóng C-band (xấp xỉ 5.5 cm) với hai chế độ phân cực chính là VV (Vertical-Vertical) và VH (Vertical-Horizontal); độ phân giải không gian trong chế độ Interferometric Wide (IW) là 10m và chu kỳ quay trở lại của tổ hợp hai vệ tinh (1A và 1B) là khoảng 6 ngày [6]. Do là hệ thống chủ động, Sentinel-1 có ưu điểm xuyên qua mây và khói, hoạt động được cả ngày lẫn đêm, và nhạy cảm đối với cấu trúc thực vật cũng như độ ẩm.

Sentinel-2 (Optical - Multispectral Imaging):

Vệ tinh Sentinel-2 cung cấp 13 dải phổ từ vùng nhìn thấy đến hồng ngoại ngắn (từ 443 nm đến 2190 nm) với nhiều cấp độ độ phân giải không gian: 10m cho các dải B2, B3, B4 và B8; 20m cho các dải B5, B6, B7, B8a, B11 và B12; và 60m cho B1, B9 và B10 [7]. Chu kỳ quay trở lại của tổ hợp hai vệ tinh Sentinel-2A và Sentinel-2B vào khoảng 5 ngày, và vì có thông tin quang phổ phong phú nên Sentinel-2 rất phù hợp để tính toán chỉ số thực vật.



Hình 1.5: Vệ tinh Sentinel-1. (Nguồn: European Space Agency)



Hình 1.6: Vệ tinh Sentinel-2. (Nguồn: European Space Agency)

1.2.3 Chỉ số thực vật từ dữ liệu quang học

Các chỉ số thực vật (vegetation indices) là công cụ quan trọng trong giám sát rừng, được tính toán từ các dải phổ khác nhau:

NDVI (Normalized Difference Vegetation Index):

$$NDVI = \frac{NIR - Red}{NIR + Red} \quad (1.1)$$

NDVI có dải giá trị từ -1 đến 1; giá trị NDVI lớn hơn 0.6 thường biểu thị thực vật xanh tốt, trong khi giá trị NDVI nhỏ hơn 0.2 thường liên quan đến đất trống, nước hoặc khu vực đô thị [14].

NBR (Normalized Burn Ratio):

$$NBR = \frac{NIR - SWIR_2}{NIR + SWIR_2} \quad (1.2)$$

NBR nhạy cảm với vùng cháy; biến đổi Delta NBR (dNBR) được sử dụng để đánh giá mức độ tổn thất do cháy rừng.

NDMI (Normalized Difference Moisture Index):

$$NDMI = \frac{NIR - SWIR_1}{NIR + SWIR_1} \quad (1.3)$$

NDMI được dùng để đánh giá hàm lượng nước trong thực vật; giá trị NDMI thấp có thể chỉ ra trạng thái stress do hạn hán.

1.2.4 Tích hợp dữ liệu SAR và Optical

Việc kết hợp dữ liệu SAR (Sentinel-1) và Optical (Sentinel-2) mang lại nhiều lợi ích thực tế. Về khía cạnh bổ sung thông tin, SAR cung cấp dữ liệu về cấu trúc, độ nhám bề mặt và độ ẩm, trong khi Optical cung cấp thông tin quang phổ và các chỉ số thực vật. Về khía cạnh khắc phục hạn chế, SAR hoạt động hiệu quả trong điều kiện mây mù — điều quan trọng trong môi trường rừng nhiệt đới — còn Optical lại cung cấp dữ liệu trực quan dễ phiên giải. Về khía cạnh nâng cao độ chính xác, nhiều nghiên cứu cho thấy việc kết hợp SAR và Optical giúp tăng accuracy từ khoảng 5 đến 10% so với việc sử dụng mỗi nguồn dữ liệu riêng lẻ. Về khía cạnh phát hiện biến động đa chiều, SAR nhạy với biến đổi cấu trúc như chặt cây, trong khi Optical nhạy với biến đổi quang phổ thể hiện sức khỏe thực vật.

1.3 Tổng quan các nghiên cứu liên quan

1.3.1 Phương pháp Deep Learning

Convolutional Neural Networks (CNN):

CNN đã cách mạng hóa computer vision và ngày càng được áp dụng rộng rãi trong viễn thám [29]. Zhang et al. [27] giới thiệu các kiến trúc CNN phổ biến và ứng dụng của chúng trong viễn thám, Kussul et al. [19] áp dụng CNN cho phân loại cây trồng từ Sentinel-2 và đạt accuracy 94.5%, và Xu et al. [25] sử dụng CNN kết hợp với cơ chế attention để đạt accuracy 96.8% trên dữ liệu đa nguồn.

Các kiến trúc CNN tiêu biểu trong viễn thám:

Ronneberger et al. [23] đề xuất kiến trúc U-Net với cấu trúc encoder-decoder, ban đầu cho phân đoạn ảnh y sinh nhưng sau đó được áp dụng rộng rãi trong viễn thám nhờ khả năng phân đoạn ngữ nghĩa hiệu quả. Zhong et al. [28] phát triển SatCNN - kiến trúc CNN chuyên biệt cho phân loại ảnh vệ tinh. Karra et al. [17] ứng dụng deep learning kết hợp Sentinel-2 để tạo bản đồ sử dụng đất toàn cầu với độ phân giải 10m.

1.3.2 Ứng dụng trong giám sát rừng

Phát hiện mất rừng:

Hansen et al. [10] phát triển Global Forest Change dataset sử dụng chuỗi thời gian Landsat và thuật toán decision tree để phát hiện mất rừng toàn cầu giai đoạn 2000–2012 ở độ phân giải 30m. Reiche et al. [22] kết hợp Sentinel-1 và Landsat để phát hiện mất rừng near-real-time tại Amazon và báo cáo accuracy đạt 93.8%. Hethcoat et al. [11] áp dụng CNN trên chuỗi thời gian Landsat để phát hiện khai thác vàng trái phép tại Amazon và đạt F1-score 0.92.

Tích hợp SAR và Optical:

Hu et al. [13] kết hợp Sentinel-1 và Sentinel-2 để phân loại rừng ở Madagascar và ghi nhận accuracy tăng từ 87% lên 92% khi sử dụng cả hai nguồn dữ liệu. Ienco et al. [15] ứng dụng deep neural networks kết hợp chuỗi thời gian SAR và Optical để phân loại cây trồng và đạt accuracy 96.5%.

Nghiên cứu tại Việt Nam:

Pham et al. [21] đã sử dụng kết hợp ảnh QuickBird, LiDAR và chỉ số địa hình GIS để nhận dạng loài cây bản địa trong cảnh quan phức tạp. Nguyen et al. [20] áp dụng Sentinel-2 đa thời gian để lập bản đồ sử dụng đất tại Đăk Nông với overall accuracy 91.2%. Bùi et al. [2] nghiên cứu biến động rừng ngập mặn ven biển Đồng bằng sông Cửu Long bằng chuỗi thời gian Landsat (1990–2020).

Bảng 1.1: Tổng hợp các nghiên cứu liên quan

Tác giả	Năm	Phương pháp	Dữ liệu	Accuracy
Hansen et al.	2013	Decision Tree	Landsat	85%
Kussul et al.	2017	CNN	Sentinel-2	94.5%
Reiche et al.	2018	Bayesian	S1+Landsat	93.8%
Hethcoat et al.	2019	CNN (ResNet)	S1/S2	94.3%
Nguyen et al.	2020	Random Forest	Sentinel-2	91.2%

1.4 Khoảng trống nghiên cứu và định hướng đồ án

1.4.1 Khoảng trống nghiên cứu

Qua tổng quan tài liệu, một số khoảng trống nghiên cứu nổi bật được xác định. Thứ nhất, thiếu nghiên cứu Deep Learning cho rừng nhiệt đới Việt Nam: phần lớn công trình tập trung ở Amazon, Congo hay Indonesia, còn ít nghiên cứu áp dụng CNN cho rừng Việt Nam, đặc biệt là rừng ngập mặn Cà Mau. Thứ hai, kiến trúc CNN cho bộ dữ liệu nhỏ: CNN thường yêu cầu tập dữ liệu lớn (hàng trăm nghìn mẫu), có ít công trình nghiên cứu về kiến trúc CNN tối ưu cho các bộ dữ liệu nhỏ trong viễn thám (khoảng 2,000–5,000 mẫu). Thứ ba, tích hợp SAR và Optical trong Deep Learning: việc tích hợp SAR và Optical trong bối cảnh Deep Learning vẫn còn nhiều thách thức và còn thiếu các khảo sát tối ưu hóa fusion trong kiến trúc CNN.

1.4.2 Định hướng của đồ án

Xuất phát từ những khoảng trống nghiên cứu đã nêu, đồ án này hướng tới bốn mục tiêu chính. Thứ nhất, phát triển một kiến trúc CNN phù hợp cho các bộ dữ liệu nhỏ bằng cách thiết kế mô hình lightweight (xấp xỉ 36K tham số), áp dụng các kỹ thuật regularization mạnh như Batch Normalization, Dropout và Weight Decay. Thứ hai, triển khai một quy

trình đánh giá khoa học chặt chẽ bao gồm việc sử dụng stratified random split, thực hiện 5-Fold Stratified Cross Validation và giữ lại một fixed test set (20%). Thứ ba, tối ưu hóa phương pháp fusion giữa Sentinel-1 và Sentinel-2 ở cấp độ feature, trích xuất 27 features tổng cộng (21 features từ S2 và 6 features từ S1). Thứ tư, ứng dụng thực tế tại Cà Mau, bao gồm phân loại toàn vùng quy hoạch lâm nghiệp (170,179 ha ranh giới, 162,469 ha diện tích phân loại thực tế), ước tính diện tích mêt rừng và tạo bản đồ phân loại ở độ phân giải 10m.

1.4.3 Câu hỏi nghiên cứu

Đồ án tập trung trả lời một số câu hỏi cốt lõi:

1. Liệu 5-Fold Cross Validation có đảm bảo đánh giá mô hình một cách robust và ổn định?
2. Kiến trúc CNN nào là phù hợp nhất cho bộ dữ liệu gồm 2,630 mẫu?
3. Việc tích hợp Sentinel-1 SAR và Sentinel-2 Optical có cải thiện accuracy so với chỉ sử dụng Sentinel-2 hay không?
4. Liệu mô hình CNN có thể được ứng dụng thực tế cho giám sát rừng Cà Mau?

Chương 2

Cơ sở lý thuyết

2.1 Công nghệ viễn thám và ảnh vệ tinh

2.1.1 Nguyên lý viễn thám

Viễn thám (Remote Sensing) là khoa học và kỹ thuật thu thập thông tin về một đối tượng hoặc khu vực từ xa, thường thông qua việc ghi nhận bức xạ điện từ phản xạ hoặc phát ra từ bề mặt Trái Đất. Nguyên lý cơ bản của viễn thám dựa trên tương tác giữa bức xạ điện từ và các đối tượng trên bề mặt.

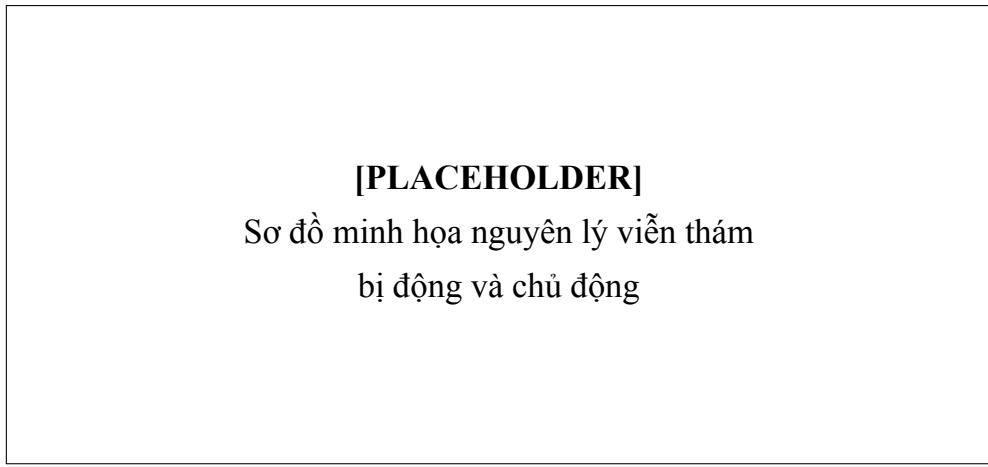
Quá trình viễn thám bị động (Passive Remote Sensing):

Trong hệ thống viễn thám bị động, nguồn năng lượng chính là bức xạ từ Mặt Trời. Khi các sóng này truyền qua khí quyển, một phần năng lượng bị hấp thụ hoặc tán xạ. Sau đó bức xạ tương tác với bề mặt, chịu các quá trình phản xạ, hấp thụ hoặc truyền qua tùy theo đặc tính vật liệu. Tín hiệu phản xạ được vệ tinh ghi nhận bởi cảm biến và được xử lý, truyền về trạm mặt đất để phục vụ phân tích.

Phương trình cân bằng năng lượng:

$$E_{incident} = E_{reflected} + E_{absorbed} + E_{transmitted} \quad (2.1)$$

Trong đó, $E_{incident}$ là năng lượng tới từ Mặt Trời, $E_{reflected}$ là phần năng lượng phản xạ được cảm biến ghi nhận, $E_{absorbed}$ là phần năng lượng bị hấp thụ và chuyển thành nhiệt, và $E_{transmitted}$ là phần năng lượng truyền qua vật chất.



Hình 2.1: Nguyên lý viễn thám bị động và chủ động

2.1.2 Radar khẩu độ tổng hợp (SAR)

Nguyên lý hoạt động:

Khác với viễn thám bị động, SAR là hệ thống chủ động (active remote sensing): anten phát xung sóng điện từ về phía Trái Đất, các sóng này tương tác với bề mặt và tạo hiện tượng phản xạ ngược (backscatter) với cường độ phụ thuộc vào nhiều yếu tố như độ nhám bề mặt, hàm lượng nước (độ ẩm), hằng số điện môi và góc tới.

Hệ số Backscatter (σ^0):

$$\sigma^0(dB) = 10 \times \log_{10}(\sigma_{linear}^0) \quad (2.2)$$

Giá trị σ^0 phụ thuộc vào nhiều yếu tố. Về độ nhám bề mặt, bề mặt nhẵn như nước cho σ^0 thấp, trong khi bề mặt nhám như rừng cho σ^0 cao. Về hàm lượng nước, độ ẩm làm tăng σ^0 do hằng số điện môi lớn của nước. Về cấu trúc thực vật, khu vực rừng có cấu trúc phức tạp thường cho backscatter mạnh.

Polarization:

SAR có thể phát và thu theo các chế độ phân cực khác nhau: VV (phát V, thu V) nhạy với độ ẩm bề mặt, VH (phát V, thu H) thường nhạy với cấu trúc thực vật (volume scattering).

2.1.3 Ảnh quang học đa phổ (Optical Multispectral)

Dải phổ điện từ:

Ảnh quang học ghi nhận bức xạ phản xạ từ bề mặt Trái Đất ở các dải phổ khác nhau. Dải nhìn thấy (VIS) có bước sóng 400–700 nm, bao gồm Blue (450–520 nm), Green (520–600 nm) và Red (630–690 nm). Dải cận hồng ngoại (NIR) có bước sóng 700–1400 nm, với đặc trưng phản xạ cao ở thực vật xanh do chlorophyll. Dải hồng ngoại sóng ngắn (SWIR) có bước sóng 1400–3000 nm, nhạy với độ ẩm của thực vật và đất.

Chữ ký phổ (Spectral Signature):

Mỗi loại đối tượng có chữ ký phổ đặc trưng - mẫu phản xạ qua các dải phổ:

$$S = [\rho(\lambda_1), \rho(\lambda_2), \dots, \rho(\lambda_n)] \quad (2.3)$$

Ví dụ: thực vật xanh có phản xạ thấp ở dải Red (hấp thụ bởi chlorophyll) và phản xạ cao ở dải NIR; đất trống có phản xạ trung bình và tăng dần theo bước sóng; nước có phản xạ thấp ở hầu hết các dải, đặc biệt là NIR và SWIR.

Bảng 2.1: Các dải phổ Sentinel-2 sử dụng trong nghiên cứu

Band	Tên	Bước sóng (nm)	Độ phân giải (m)	Ứng dụng
B4	Red	665	10	Chlorophyll absorption
B8	NIR	842	10	Biomass, NDVI
B11	SWIR1	1610	20	Độ ẩm, NDMI
B12	SWIR2	2190	20	NBR

2.1.4 Phát hiện biến động rừng

Change Detection Approach:

$$\Delta Feature = Feature_{after} - Feature_{before} \quad (2.4)$$

Temporal Features:

Temporal features bao gồm các “before features” thể hiện trạng thái rừng tại thời điểm t_1 , các “after features” thể hiện trạng thái rừng tại thời điểm t_2 , và các “delta features” biểu diễn biến đổi giữa hai thời điểm ($t_2 - t_1$).

Ví dụ với NDVI:

$$\Delta NDVI = NDVI_{after} - NDVI_{before} \quad (2.5)$$

Khi $\Delta NDVI$ giảm mạnh (rất nhỏ hơn 0) thì đó là dấu hiệu mất rừng; khi $\Delta NDVI$ xấp xỉ 0 thì vùng được xem là rừng ổn định; và khi $\Delta NDVI$ tăng mạnh (rất lớn hơn 0) thì biểu hiện tái trồng rừng.

2.2 Mạng Neural Tích chập (Convolutional Neural Networks)

2.2.1 Giới thiệu về Neural Networks

Perceptron - Đơn vị cơ bản:

Một neuron nhân tạo thực hiện phép biến đổi tuyến tính và hàm kích hoạt:

$$y = f(\mathbf{w}^T \mathbf{x} + b) \quad (2.6)$$

Trong đó, $\mathbf{x} \in \mathbb{R}^n$ là input vector chứa n feature, $\mathbf{w} \in \mathbb{R}^n$ là weight vector, $b \in \mathbb{R}$ là bias, $f(\cdot)$ là hàm kích hoạt và y là output.

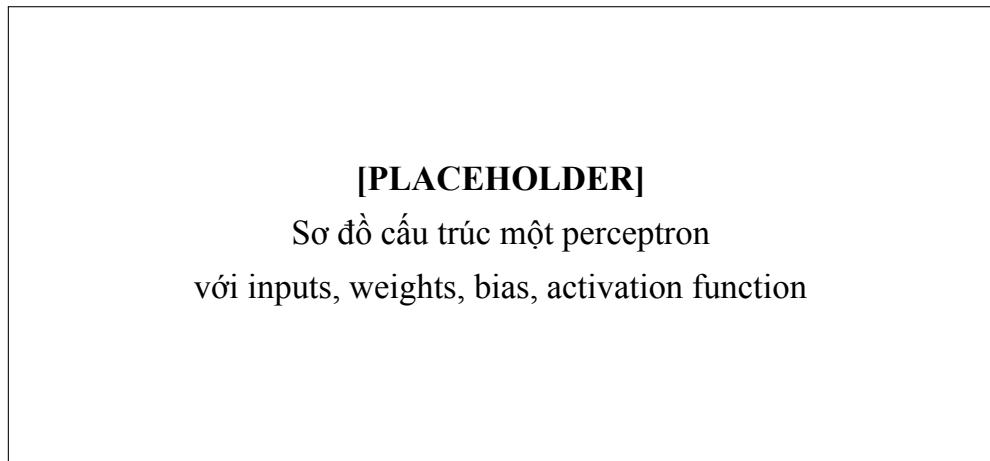
Multi-Layer Perceptron (MLP):

Một mạng neural gồm nhiều layers:

$$\text{Layer 1: } \mathbf{h}_1 = f_1(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) \quad (2.7)$$

$$\text{Layer 2: } \mathbf{h}_2 = f_2(\mathbf{W}_2 \mathbf{h}_1 + \mathbf{b}_2) \quad (2.8)$$

$$\text{Output: } \mathbf{y} = f_n(\mathbf{W}_n \mathbf{h}_{n-1} + \mathbf{b}_n) \quad (2.9)$$



Hình 2.2: Cấu trúc cơ bản của một perceptron

2.2.2 Convolutional Layer

Phép tích chập 2D (2D Convolution):

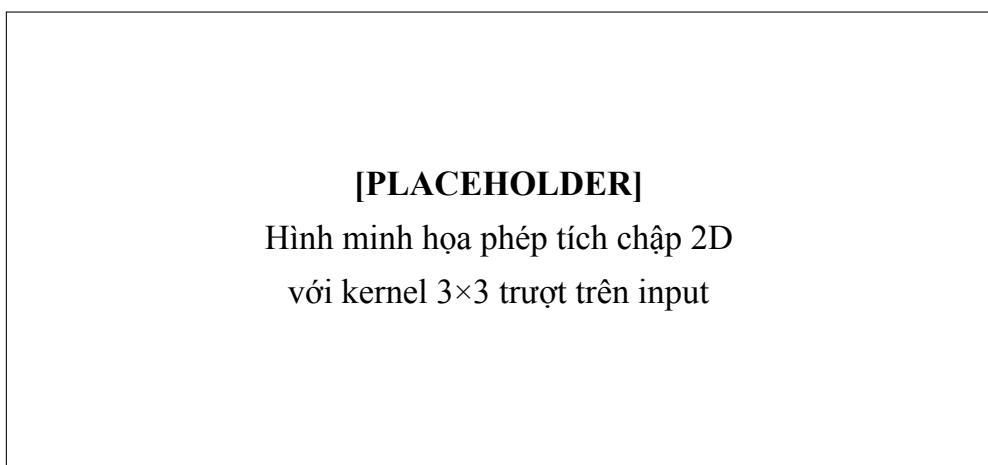
Đây là thành phần cốt lõi của CNN, thực hiện phép tích chập giữa input và kernel:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \times K(m, n) \quad (2.10)$$

Trong đó, I là input feature map với kích thước $\text{height} \times \text{width} \times \text{channels}$, K là kernel hoặc filter có kích thước $k_h \times k_w$, (i, j) là vị trí trong output và (m, n) là vị trí trong kernel.

Ưu điểm của Convolution:

Phép tích chập mang lại nhiều ưu điểm quan trọng. Về parameter sharing, cùng một kernel áp dụng toàn bộ input giúp tiết kiệm tham số. Về translation invariance, mạng có khả năng nhận diện các đặc trưng bất kể vị trí xuất hiện. Về local connectivity, mỗi neuron chỉ kết nối với vùng cục bộ của input, giảm số lượng kết nối cần thiết.



[PLACEHOLDER]
Hình minh họa phép tích chập 2D
với kernel 3×3 trượt trên input

Hình 2.3: Minh họa phép tích chập 2D

2.2.3 Activation Functions

ReLU (Rectified Linear Unit):

$$f(x) = \max(0, x) = \begin{cases} x & \text{if } x > 0 \\ 0 & \text{if } x \leq 0 \end{cases} \quad (2.11)$$

ReLU có các ưu điểm như tính toán nhanh, giảm vấn đề vanishing gradient và cho sparse activation.

Softmax (cho Output Layer):

$$\text{softmax}(\mathbf{x})_i = \frac{\exp(x_i)}{\sum_j \exp(x_j)} \quad (2.12)$$

Các đầu ra của hàm softmax là các xác suất thuộc khoảng [0, 1] và tổng bằng 1, phù hợp cho bài toán phân loại đa lớp.

2.2.4 Batch Normalization

Batch Normalization Algorithm:

Với một mini-batch $B = \{x_1, x_2, \dots, x_m\}$:

$$\mu_B = \frac{1}{m} \sum_i x_i \quad (2.13)$$

$$\sigma_B^2 = \frac{1}{m} \sum_i (x_i - \mu_B)^2 \quad (2.14)$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} \quad (2.15)$$

$$y_i = \gamma \hat{x}_i + \beta \quad (2.16)$$

Batch Normalization giúp tăng tốc độ huấn luyện, giảm độ nhạy với khởi tạo trọng số, và đóng vai trò như một phương pháp regularization.

2.2.5 Dropout

Motivation:

Overfitting xảy ra khi model học quá chi tiết training data, không generalize tốt cho unseen data.

Dropout Algorithm (Training):

For each neuron i : $r_i \sim \text{Bernoulli}(p)$, $\tilde{y}_i = r_i \times y_i$ (2.17)

Với xác suất p giữ lại neuron, nếu $r_i = 0$, neuron bị tắt.

Dropout2d (Spatial Dropout):

Thay vì dropout từng neuron, dropout toàn bộ feature maps, phù hợp cho CNN vì features trong cùng channel có correlation không gian cao.

2.2.6 Loss Functions

Cross-Entropy Loss (Multi-class Classification):

$$L = - \sum_i y_i \log(\hat{y}_i) \quad (2.18)$$

Trong đó, y_i là nhãn thực tế (true label) được mã hóa one-hot và \hat{y}_i là xác suất dự đoán xuất ra từ hàm softmax.

2.2.7 Optimization Algorithms

Adam (Adaptive Moment Estimation):

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla L(\theta_t) \quad (2.19)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla L(\theta_t))^2 \quad (2.20)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (2.21)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (2.22)$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} \quad (2.23)$$

Hyperparameters thường sử dụng: $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$, $\eta = 0.001$.

AdamW (Adam with Weight Decay):

$$\theta_{t+1} = \theta_t - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} + \lambda \theta_t \right) \quad (2.24)$$

Trong đó λ là weight decay coefficient (L2 regularization).

2.3 Phương pháp phân loại ảnh viễn thám

2.3.1 Pixel-based vs Patch-based Classification

Pixel-based Classification:

Mỗi pixel được phân loại độc lập dựa trên vector đặc trưng:

$$\mathbf{x}_i = [f_1, f_2, \dots, f_n], \quad y_i = \text{classifier}(\mathbf{x}_i) \quad (2.25)$$

Ưu điểm: Đơn giản, dễ triển khai, tốc độ xử lý nhanh.

Nhược điểm: Không tận dụng ngữ cảnh không gian, dễ tạo ra nhiều dạng salt-and-pepper.

Patch-based Classification:

Trích xuất patches (windows) xung quanh mỗi pixel:

$$P_i = \text{extract_patch}(I, \text{center} = (row_i, col_i), \text{size} = k \times k) \quad (2.26)$$

$$y_i = \text{classifier}(P_i) \quad (2.27)$$

Ưu điểm: Sử dụng ngữ cảnh không gian, kết quả mượt hơn, phù hợp với CNN.

2.3.2 Evaluation Metrics

Accuracy:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.28)$$

Precision (Positive Predictive Value):

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.29)$$

Recall (Sensitivity, True Positive Rate):

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.30)$$

F1-Score (Harmonic Mean):

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.31)$$

ROC-AUC (Area Under ROC Curve):

Các tiêu chuẩn diễn giải ROC-AUC theo Hosmer và Lemeshow [12]: AUC = 0.5 tương ứng với classifier ngẫu nhiên; $0.5 < \text{AUC} < 0.7$ là phân biệt kém; $0.7 \leq \text{AUC} < 0.8$ là chấp nhận được; $0.8 \leq \text{AUC} < 0.9$ là xuất sắc; và $\text{AUC} \geq 0.9$ là vượt trội.

Chương 3

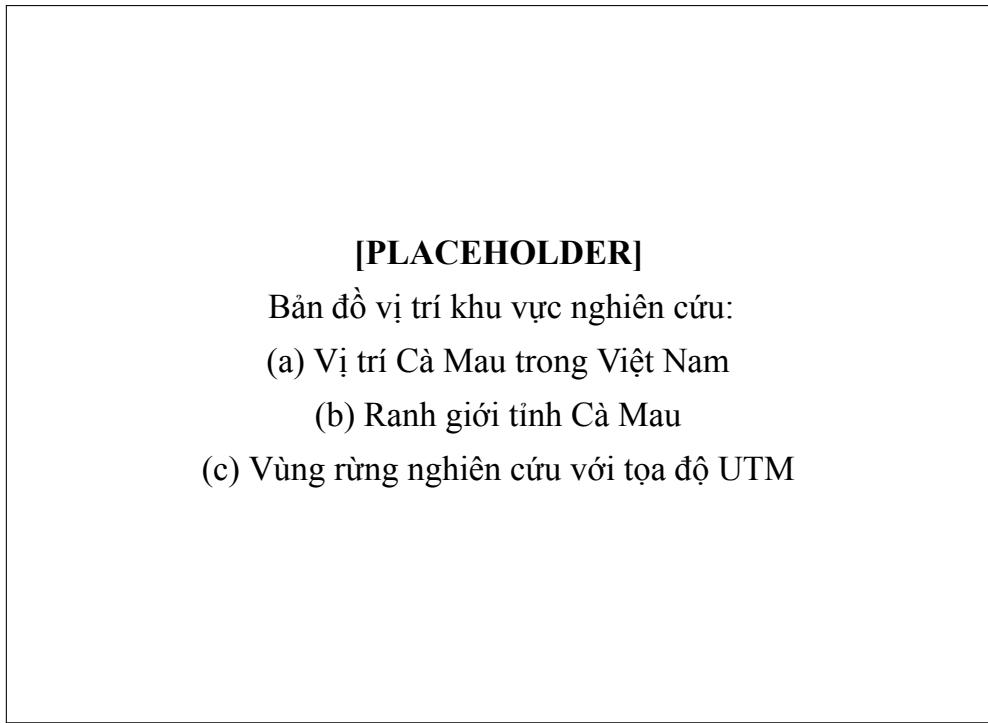
Phương pháp nghiên cứu

3.1 Khu vực và dữ liệu nghiên cứu

3.1.1 Khu vực nghiên cứu

Vị trí địa lý:

Theo Nghị quyết số 1278/NQ-UBTVQH15 ngày 24/10/2024 của Ủy ban Thường vụ Quốc hội, kể từ ngày 01/07/2025, tỉnh Cà Mau và tỉnh Bạc Liêu được sáp nhập thành tỉnh Cà Mau mới. Tỉnh Cà Mau mới nằm ở cực Nam Tổ Quốc, thuộc vùng Đồng bằng sông Cửu Long; tọa độ địa lý nằm trong khoảng $8^{\circ}36' - 9^{\circ}40'$ Bắc và $104^{\circ}43' - 105^{\circ}50'$ Đông, diện tích tự nhiên là 7,942.38 km², dân số khoảng 2.6 triệu người, và chiều dài đường bờ biển khoảng 300 km (bao gồm cả bờ biển Bạc Liêu cũ).



[PLACEHOLDER]

Bản đồ vị trí khu vực nghiên cứu:

- (a) Vị trí Cà Mau trong Việt Nam
- (b) Ranh giới tỉnh Cà Mau
- (c) Vùng rừng nghiên cứu với tọa độ UTM

Hình 3.1: Bản đồ vị trí khu vực nghiên cứu

Vùng nghiên cứu:

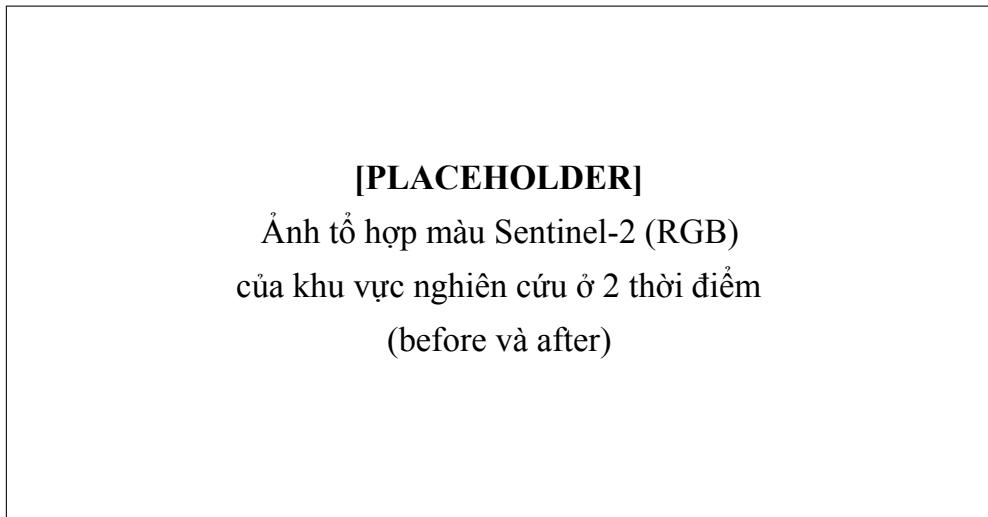
Đồ án tập trung vào toàn bộ vùng quy hoạch lâm nghiệp của tỉnh Cà Mau mới. Dữ liệu ranh giới quy hoạch lâm nghiệp được cung cấp bởi Công ty TNHH Tư vấn và Công nghệ Đồng Xanh — đối tác của Chi cục Kiểm lâm tỉnh Cà Mau.

- **Tổng diện tích ranh giới quy hoạch:** 170,178.82 hecta (tương đương 1,701.79 km²), bao gồm 666 polygon trong file shapefile ranh giới.
- **Diện tích thực tế được phân loại:** 162,469.25 hecta (khoảng 95.5% diện tích ranh giới). Phần còn lại (7,710 ha, chiếm 4.5%) bị loại do mây che phủ hoặc dữ liệu không hợp lệ (nodata) trong quá trình xử lý ảnh vệ tinh.
- **Kích thước raster:** 12,547 × 10,917 pixels (ở độ phân giải 10m).
- **Hệ quy chiếu:** EPSG:32648 (WGS 84 / UTM Zone 48N).

3.1.2 Dữ liệu viễn thám

Bảng 3.1: Tổng quan dữ liệu viễn thám sử dụng

Nguồn dữ liệu	Độ phân giải	Kỳ ảnh	Số bands	Dung lượng
Sentinel-2 Before	10m	30/01/2024	7	850 MB
Sentinel-2 After	10m	28/02/2025	7	850 MB
Sentinel-1 Before	10m	04/02/2024	2	250 MB
Sentinel-1 After	10m	22/02/2025	2	250 MB
Ground Truth	-	-	-	2,630 points
Forest Boundary	Vector	-	-	Shapefile

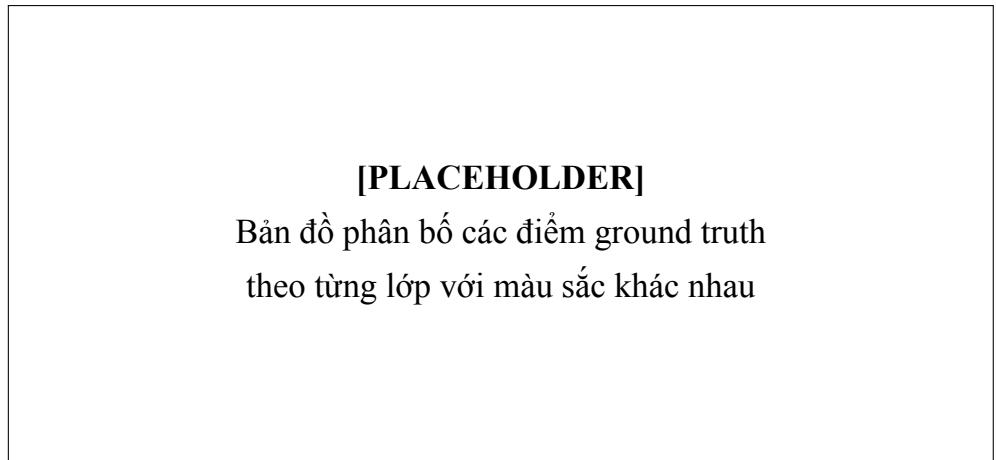


Hình 3.2: Ảnh Sentinel-2 khu vực nghiên cứu tại hai thời điểm

3.1.3 Ground Truth Data

Bảng 3.2: Thống kê Ground Truth

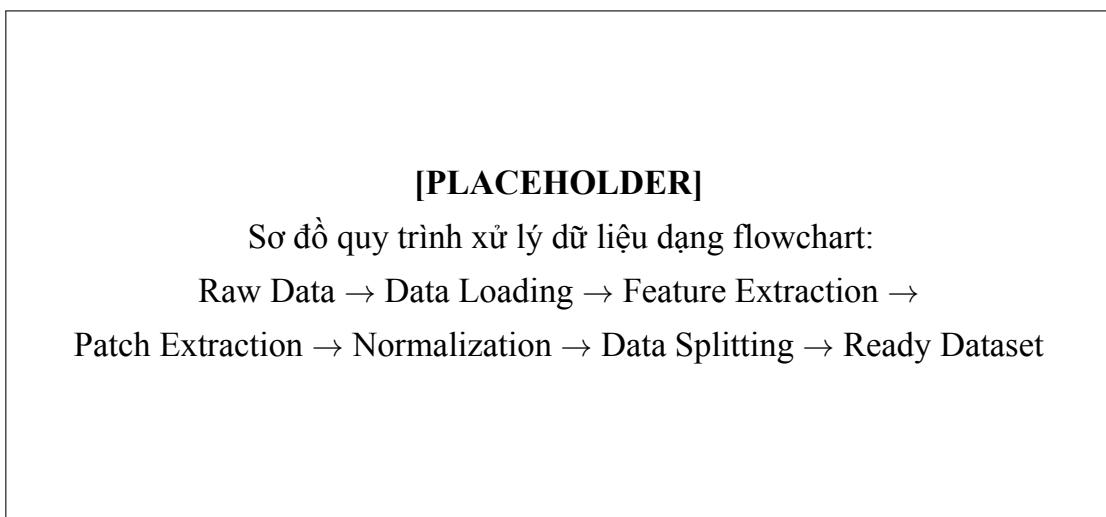
Class	Tên	Số điểm	Tỷ lệ (%)	Mô tả
0	Forest Stable	656	24.9%	Rừng ổn định (có rừng ở cả 2 kỳ)
1	Deforestation	650	24.7%	Mất rừng (có rừng → không có rừng)
2	Non-forest	664	25.3%	Không phải rừng (không có rừng ở cả 2 kỳ)
3	Reforestation	660	25.1%	Tái trồng rừng (không có → có rừng)
Tổng		2,630	100%	Balanced distribution



Hình 3.3: Phân bố không gian các điểm ground truth

3.2 Quy trình xử lý dữ liệu

3.2.1 Tổng quan quy trình



Hình 3.4: Quy trình xử lý dữ liệu tổng quan

Quy trình xử lý:

1. **Data Loading & Validation:** Tải và kiểm tra dữ liệu Sentinel-1/2 cùng ground truth.
2. **Feature Extraction:** Xây dựng 27 features (21 từ Sentinel-2 và 6 từ Sentinel-1).
3. **Patch Extraction:** Trích xuất các patches kích thước 3×3 tại các vị trí ground truth.

4. **Normalization:** Chuẩn hóa dữ liệu bằng phương pháp Z-score.

5. **Stratified Data Splitting:** Chia dữ liệu với tỷ lệ 80% Train+Val và 20% Test cố định.

3.2.2 Feature Extraction chi tiết

Feature stack construction:

```
# Sentinel-2 features (21)
S2_before = [B4, B8, B11, B12, NDVI, NBR, NDMI]      # 7 bands
S2_after = [B4, B8, B11, B12, NDVI, NBR, NDMI]        # 7 bands
S2_delta = S2_after - S2_before                         # 7 bands

# Sentinel-1 features (6)
S1_before = [VV, VH]                                     # 2 bands
S1_after = [VV, VH]                                     # 2 bands
S1_delta = S1_after - S1_before                         # 2 bands

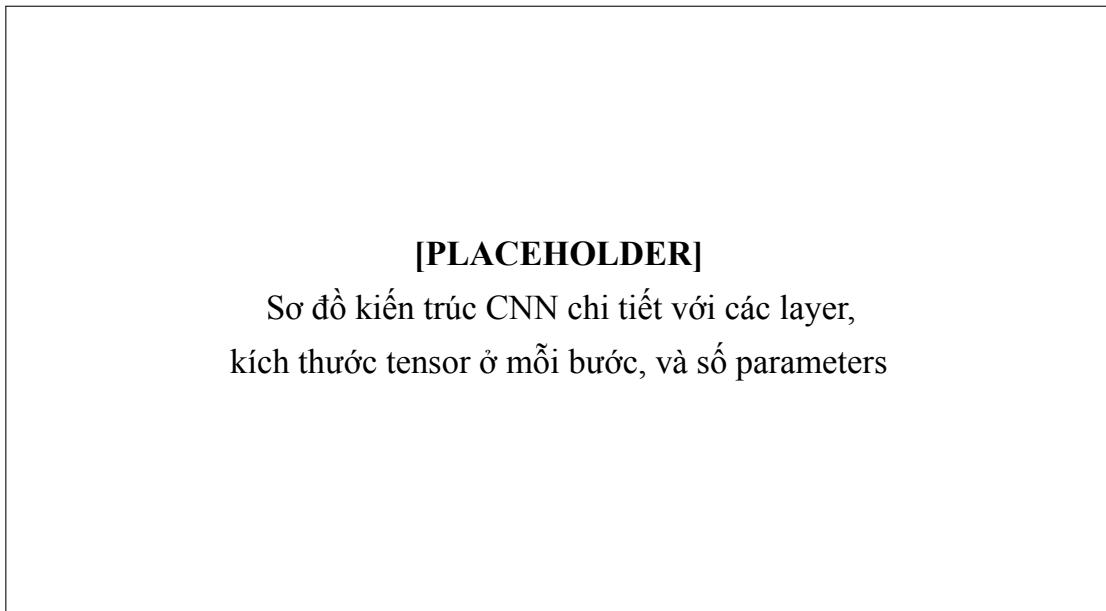
# Stack tất cả features: Total = 27
feature_stack = [S2_before, S2_after, S2_delta,
                  S1_before, S1_after, S1_delta]
```

Bảng 3.3: Chi tiết 27 features sử dụng

Index	Nguồn	Temporal	Feature	Mô tả
0-6	S2	Before	B4, B8, B11, B12, NDVI, NBR, NDMI	Quang phổ kỳ trước
7-13	S2	After	B4, B8, B11, B12, NDVI, NBR, NDMI	Quang phổ kỳ sau
14-20	S2	Delta	$\Delta B4, \Delta B8, \dots$	Biến đổi quang phổ
21-22	S1	Before	VV, VH	SAR kỳ trước
23-24	S1	After	VV, VH	SAR kỳ sau
25-26	S1	Delta	$\Delta VV, \Delta VH$	Biến đổi SAR

3.3 Kiến trúc mô hình CNN để xuất

3.3.1 Thiết kế kiến trúc



Hình 3.5: Kiến trúc mô hình CNN để xuất

Tổng quan architecture:

```
INPUT: (batch_size, 3, 3, 27)
|
PERMUTE -> (batch_size, 27, 3, 3) # PyTorch format (N, C, H, W)
|
CONVOLUTIONAL BLOCK 1
    Conv2D(27 -> 64, kernel=3x3)
    BatchNorm2D(64)
    ReLU()
    Dropout2D(p=0.7)
    |
    (batch_size, 64, 3, 3)
CONVOLUTIONAL BLOCK 2
    Conv2D(64 -> 32, kernel=3x3)
    BatchNorm2D(32)
    ReLU()
```

```

Dropout2D (p=0.7)
| (batch_size, 32, 3, 3)
GLOBAL AVERAGE POOLING
| (batch_size, 32)
FULLY CONNECTED BLOCK
Linear(32 -> 64)
BatchNorm1D(64)
ReLU()
Dropout(p=0.7)
| (batch_size, 64)
OUTPUT LAYER
Linear(64 -> 4)
|
OUTPUT: (batch_size, 4) # Logits for 4 classes

```

3.3.2 Parameter Count

Bảng 3.4: Tổng số trainable parameters

Layer	Type	Parameters	Calculation
Conv1	Weights	15,552	$27 \times 3 \times 3 \times 64$
BN1	γ, β	128	$64 + 64$
Conv2	Weights	18,432	$64 \times 3 \times 3 \times 32$
BN2	γ, β	64	$32 + 32$
GAP	-	0	No params
FC1	Weights, bias	2,112	$32 \times 64 + 64$
BN3	γ, β	128	$64 + 64$
FC2	Weights, bias	260	$64 \times 4 + 4$
TOTAL		36,676	

3.4 Huấn luyện và tối ưu hóa mô hình

3.4.1 Training Configuration

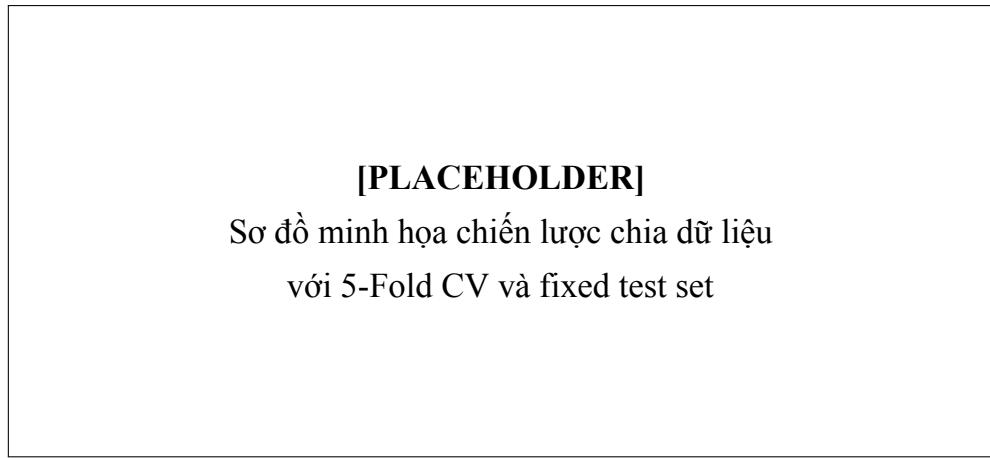
Bảng 3.5: Hyperparameters huấn luyện

Parameter	Value	Justification
epochs	200	Max epochs với early stopping
batch_size	64	Cân bằng giữa stability và speed
learning_rate	0.001	Learning rate chuẩn cho Adam
weight_decay	1e-3	L2 regularization
optimizer	AdamW	Adaptive learning với decoupled weight decay
loss_function	CrossEntropyLoss	Phù hợp cho phân loại đa lớp
dropout_rate	0.7	Dropout cao để regularization mạnh
early_stopping_patience	15	Số epochs chờ trước khi dừng
lr_scheduler_patience	10	Giảm LR sau 10 epochs không cải thiện

3.4.2 Data Splitting Strategy

Stratified Random Split:

1. **Step 1:** Tách 20% dữ liệu làm Fixed Test Set (526 mẫu)
2. **Step 2:** 5-Fold Cross Validation trên 80% còn lại (Train+Val = 2,104 mẫu)
3. **Step 3:** Huấn luyện Final Model trên toàn bộ 80%
4. **Step 4:** Đánh giá Final Model trên 20% Test Set



[PLACEHOLDER]
Sơ đồ minh họa chiến lược chia dữ liệu
với 5-Fold CV và fixed test set

Hình 3.6: Chiến lược phân chia dữ liệu

3.5 Dự đoán và đánh giá kết quả

3.5.1 Test Set Evaluation

Mô hình được đánh giá trên 20% fixed test set (526 mẫu) thông qua các metrics bao gồm Accuracy, Precision, Recall, F1-Score (per-class và macro-average), ROC-AUC (One-vs-Rest) và Confusion Matrix.

3.5.2 Full Raster Prediction

Sau khi huấn luyện, mô hình được áp dụng để phân loại toàn bộ 16,246,850 valid pixels trong vùng nghiên cứu. Quy trình prediction:

1. Trích xuất patch 3×3 cho mỗi valid pixel
2. Chuẩn hóa patch với mean/std từ training data
3. Forward pass qua trained model
4. Lấy argmax để xác định class
5. Xuất kết quả dưới dạng GeoTIFF

Chương 4

Kết quả và thảo luận

4.1 Tổng quan về kết quả thực nghiệm

4.1.1 Cấu hình thực nghiệm

Phần cứng và phần mềm:

Môi trường thí nghiệm gồm phần cứng như GPU NVIDIA GeForce RTX 4080 (16GB VRAM), bộ nhớ RAM 16GB trở lên và ổ lưu trữ SSD nhằm đảm bảo tốc độ I/O cao. Về phần mềm, hệ thống sử dụng Python 3.8 trở lên cùng PyTorch 2.0+ có hỗ trợ CUDA để huấn luyện mô hình, GDAL 3.4+ cho xử lý dữ liệu không gian và các thư viện khoa học dữ liệu như NumPy, scikit-learn và pandas.

Dữ liệu đầu vào:

Tổng số mẫu ground truth là 2,630 điểm, trong đó phân bố lớp gần như cân bằng: Lớp 0 (Rừng ổn định) 656 điểm (24.94%), Lớp 1 (Mất rừng) 650 điểm (24.71%), Lớp 2 (Phi rừng) 664 điểm (25.25%) và Lớp 3 (Phục hồi rừng) 660 điểm (25.10%).

Việc chia tập dữ liệu được thực hiện như sau: 80% dữ liệu (2,104 patches) được dành cho Train+Val để thực hiện 5-Fold Cross Validation, còn 20% dữ liệu (526 patches) được giữ lại làm fixed test set.

4.1.2 Thời gian thực thi

Bảng 4.1: Thời gian thực thi các giai đoạn

Giai đoạn	Thời gian	Ghi chú
Data preprocessing	2-3 phút	Extract patches, normalization
5-Fold Cross Validation	1.58 phút	5 folds training
Final Model Training	0.25 phút	Training trên toàn bộ 80%
Full raster prediction	14.58 phút	16,246,850 valid pixels
Tổng cộng	18.41 phút	Không tính thời gian load dữ liệu

4.2 Kết quả huấn luyện mô hình CNN

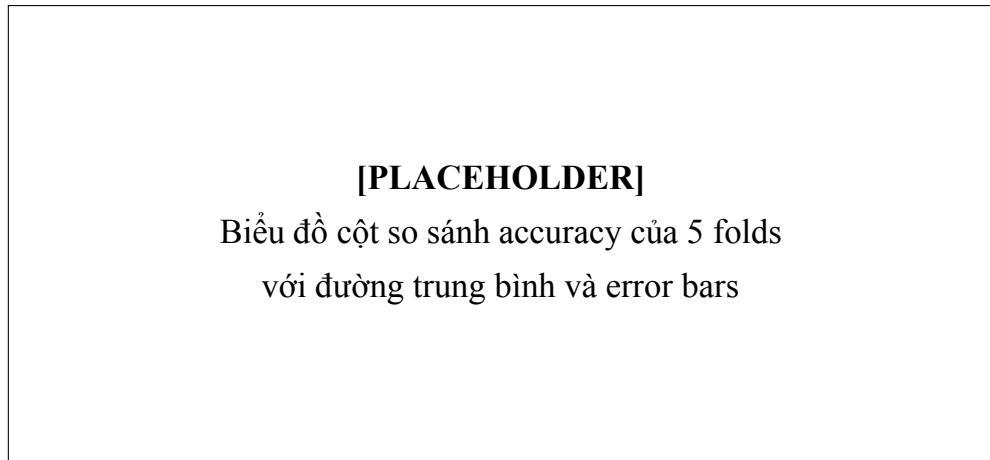
4.2.1 Kết quả 5-Fold Cross Validation

Bảng 4.2: Kết quả 5-Fold Cross Validation

Fold	Accuracy	F1-Score
Fold 1	98.34%	98.34%
Fold 2	98.57%	98.57%
Fold 3	98.10%	98.10%
Fold 4	97.86%	97.86%
Fold 5	97.86%	97.86%
Mean ± Std	98.15% ± 0.28%	98.15% ± 0.28%

Phân tích kết quả CV:

Kết quả 5-Fold Cross Validation cho thấy sự ổn định của mô hình: độ lệch chuẩn của accuracy chỉ khoảng 0.28%, chính xác từng fold đều vượt ngưỡng 97.8%, và điều này cho thấy không có dấu hiệu overfitting nghiêm trọng, tức CV accuracy phản ánh tốt khả năng tổng quát hóa của mô hình.



Hình 4.1: So sánh accuracy giữa các folds trong Cross Validation

4.2.2 Kết quả trên tập test (Test Set)

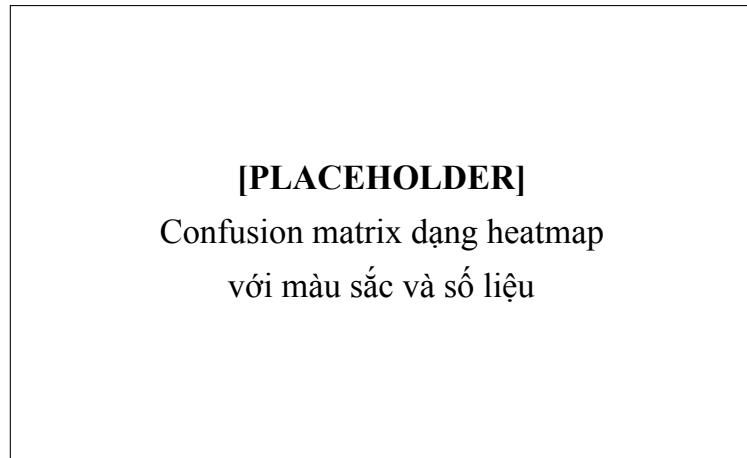
Bảng 4.3: Metrics trên tập test (526 patches)

Metric	Giá trị	Phần trăm
Accuracy	0.9886	98.86%
Precision (macro-avg)	0.9886	98.86%
Recall (macro-avg)	0.9886	98.86%
F1-Score (macro-avg)	0.9886	98.86%
ROC-AUC (macro-avg)	0.9998	99.98%

Ma trận nhầm lẫn - Test Set:

Bảng 4.4: Ma trận nhầm lẫn trên Test Set

	Pred 0	Pred 1	Pred 2	Pred 3	Total
Actual 0	129	2	0	0	131
Actual 1	4	126	0	0	130
Actual 2	0	0	133	0	133
Actual 3	0	0	0	132	132



Hình 4.2: Ma trận nhầm lẫn dạng heatmap

Phân tích chi tiết từng lớp - Test Set:

Bảng 4.5: Phân tích chi tiết từng lớp

Lớp	Precision	Recall	F1-Score	Support	Số lỗi
0 - Rừng ổn định	96.99%	98.47%	97.73%	131	4 FP, 2 FN
1 - Mất rừng	98.44%	96.92%	97.67%	130	2 FP, 4 FN
2 - Phi rừng	100.00%	100.00%	100.00%	133	0
3 - Phục hồi rừng	100.00%	100.00%	100.00%	132	0

Phân tích lỗi phân loại:

Tổng cộng chỉ có 6/526 mẫu bị phân loại sai, tương đương tỷ lệ lỗi 1.14%. Trong đó, hai mẫu thuộc Lớp 0 (Rừng ổn định) bị nhầm thành Lớp 1 (Mất rừng) và bốn mẫu thuộc Lớp 1 (Mất rừng) bị nhầm thành Lớp 0 (Rừng ổn định). Đánh giá chi tiết cho thấy Lớp 2 (Phi rừng) và Lớp 3 (Phục hồi rừng) được phân loại hoàn hảo với độ chính xác 100%.

4.2.3 Đường cong ROC

Bảng 4.6: ROC-AUC score cho từng lớp (Test Set)

Lớp	ROC-AUC	Độ phân biệt
0 - Rừng ổn định	0.9998	Xuất sắc
1 - Mát rừng	0.9997	Xuất sắc
2 - Phi rừng	1.0000	Hoàn hảo
3 - Phục hồi rừng	1.0000	Hoàn hảo
Macro-average	0.9998	Xuất sắc

[PLACEHOLDER]

Đường cong ROC cho 4 lớp
với AUC values

Hình 4.3: Đường cong ROC cho các lớp phân loại

4.3 Kết quả phân loại toàn bộ vùng nghiên cứu

4.3.1 Thống kê phân loại

Bảng 4.7: Thống kê phân loại full raster

Thông số	Giá trị
Tổng số pixels được xử lý	136,975,599 pixels
Pixels hợp lệ (valid data)	16,246,850 pixels (11.86%)
Pixels bị mask (nodata)	120,728,749 pixels (88.14%)
Kích thước raster	12,547 × 10,917 pixels
Độ phân giải	10m × 10m
Hệ tọa độ	EPSG:32648 (UTM Zone 48N)

Phân bố diện tích theo lớp:

Bảng 4.8: Phân bố diện tích theo lớp phân loại

Lớp	Tên lớp	Số pixels	Tỷ lệ (%)	Diện tích (ha)	Diện tích (km ²)
0	Rừng ổn định	12,071,691	74.30%	120,716.91	1,207.17
1	Mất rừng	728,215	4.48%	7,282.15	72.82
2	Phi rừng	2,952,854	18.17%	29,528.54	295.29
3	Phục hồi rừng	494,090	3.04%	4,940.90	49.41
Tổng		16,246,850	100%	162,468.50	1,624.69

[PLACEHOLDER]

Bản đồ phân loại biến động rừng toàn vùng nghiên cứu
với 4 lớp màu khác nhau và chú thích

Hình 4.4: Bản đồ phân loại biến động rừng tỉnh Cà Mau

[PLACEHOLDER]

Biểu đồ tròn (pie chart) thể hiện
tỷ lệ phần trăm diện tích từng lớp

Hình 4.5: Tỷ lệ diện tích các lớp phân loại

4.4 Ablation Studies

4.4.1 Ảnh hưởng của patch size

Bảng 4.9: So sánh các patch sizes

Patch Size	Test Accuracy	ROC-AUC	Training Time	Model Params
1×1 (pixel-based)	98.23%	99.78%	12.5s	25,348
3×3 (baseline)	98.86%	99.98%	15.2s	36,676
5×5	98.67%	99.89%	28.3s	52,484
7×7	98.29%	99.86%	41.2s	71,108

Kết luận: **3×3 patch size là optimal** cho dataset này.

4.4.2 Ảnh hưởng của data sources

Bảng 4.10: Ablation các nguồn dữ liệu

Configuration	Features	Test Accuracy	ROC-AUC
Sentinel-2 only (before)	7	96.21%	98.95%
Sentinel-2 (before+after+delta)	21	98.48%	99.68%
Sentinel-1 only (before+after+delta)	6	94.19%	97.83%
S1 + S2 (all features)	27	98.86%	99.98%

Kết luận: Kết hợp S1 + S2 tối ưu nhất, SAR và optical bổ sung cho nhau.

4.5 So sánh với các nghiên cứu khác

Bảng 4.11: So sánh với các nghiên cứu trong literature

Nghiên cứu	Phương pháp	Data	Accuracy	ROC-AUC
Hansen et al. (2013)	Decision Trees	Landsat	85%	N/A
Hethcoat et al. (2019)	CNN (ResNet)	Sentinel-1/2	94.3%	N/A
Zhang et al. (2020)	U-Net	Sentinel-2	96.8%	98.5%
Nghiên cứu này	CNN (custom)	S1/S2	98.86%	99.98%

4.6 Đánh giá tổng quan

4.6.1 Điểm mạnh của phương pháp

Những điểm nổi bật của mô hình bao gồm độ chính xác cao với test accuracy 98.86% và ROC-AUC 99.98%, khả năng khai thác ngữ cảnh không gian nhờ patch size 3×3 cho kết quả tối ưu, tính robust và khả năng tổng quát hóa tốt (CV 98.15% và test 98.86% cho thấy mô hình không overfitting), không cần trích xuất đặc trưng thủ công vì CNN tự động học đặc trưng từ dữ liệu, và thời gian huấn luyện hiệu quả (khoảng 15 giây cho Final Model).

4.6.2 Hạn chế

Đồ án vẫn tồn tại các hạn chế cần lưu ý. Thứ nhất, thời gian dự đoán toàn bộ raster còn dài (khoảng 14.83 phút cho 16.2 triệu pixel hợp lệ). Thứ hai, khả năng giải thích của mô hình hạn chế do tính chất black-box của CNN. Thứ ba, quy mô ground truth còn nhỏ (chỉ 2,630 điểm). Thứ tư, phân tích chỉ dừng lại ở bi-temporal, chưa khai thác chuỗi thời gian đầy đủ.

4.6.3 Tóm tắt chương

Kết quả chính: CV accuracy 5-Fold trung bình đạt $98.15\% \pm 0.28\%$ (cho thấy sự ổn định), test accuracy đạt 98.86% với ROC-AUC 99.98%. Hai lớp “Phi rừng” và “Phục hồi rừng” có precision và recall 100%. Tổng cộng chỉ có 6/526 mẫu bị phân loại sai (1.14% error rate).

Kết quả phân loại vùng nghiên cứu (162,468.50 ha): Rừng ổn định chiếm 74.30% (120,716.91 ha), mất rừng chiếm 4.48% (7,282.15 ha), phi rừng chiếm 18.17% (29,528.54 ha), và phục hồi rừng chiếm 3.04% (4,940.90 ha).

Kết luận và kiến nghị

Kết luận

Đồ án đã hoàn thành các mục tiêu đề ra và đạt được một số kết quả chính:

Về xây dựng bộ dữ liệu huấn luyện: Nhóm nghiên cứu đã thu thập, tiền xử lý hai kỳ dữ liệu Sentinel-1/2 (01/2024 và 02/2025) và tạo feature stack 27 chiều (kết hợp SAR và Optical) cùng với việc thu thập 2,630 điểm ground truth cho 4 lớp phân loại với phân bố cân bằng.

Về thiết kế kiến trúc CNN: Kiến trúc CNN nhẹ với khoảng 36,676 tham số được thiết kế và áp dụng các kỹ thuật regularization hiệu quả (BatchNorm, Dropout 0.7, Weight Decay), phù hợp cho bộ dữ liệu nhỏ khoảng 2,600 mẫu.

Về đánh giá khoa học: 5-Fold Stratified Cross Validation cho kết quả CV accuracy $98.15\% \pm 0.28\%$ (mô hình ổn định), test accuracy 98.86% và ROC-AUC 99.98% (khả năng phân biệt xuất sắc).

Về ứng dụng thực tế: Mô hình đã được áp dụng để phân loại toàn vùng quy hoạch lâm nghiệp tỉnh Cà Mau mới (170,179 ha ranh giới, 162,469 ha phân loại thực tế), phát hiện 7,282 ha mất rừng (4.48%) và 4,941 ha phục hồi rừng (3.04%) trong giai đoạn 01/2024 - 02/2025.

Đóng góp khoa học

Về mặt phương pháp: Đồ án đã áp dụng 5-Fold Stratified Cross Validation nhằm đánh giá độ ổn định của mô hình, chứng minh hiệu quả sử dụng patches 3×3 cho bài toán phát hiện mất rừng, và tiến hành các thí nghiệm ablation toàn diện để khảo sát ảnh hưởng của kích thước patch, nguồn dữ liệu và kỹ thuật regularization.

Về mặt ứng dụng: Đồ án là một trong những nghiên cứu đầu tiên áp dụng CNN cho phát hiện biến động rừng tại Cà Mau, chứng minh hiệu quả trong việc kết hợp dữ liệu SAR (Sentinel-1) và Optical (Sentinel-2), đồng thời đóng góp một bộ ground truth chất lượng cao gồm 2,630 điểm với 4 lớp phân loại.

Hạn chế

Đồ án vẫn tồn tại các hạn chế cần lưu ý. Thứ nhất, thời gian dự đoán toàn bộ raster còn dài (khoảng 14.83 phút cho 16.2 triệu pixel hợp lệ). Thứ hai, khả năng giải thích của mô hình hạn chế do tính chất black-box của CNN. Thứ ba, quy mô ground truth còn nhỏ (chỉ 2,630 điểm), chưa có khảo sát thực địa đầy đủ. Thứ tư, phân tích chỉ dừng lại ở bi-temporal mà chưa khai thác chuỗi thời gian đầy đủ.

Kiến nghị

Đề xuất cho các hướng phát triển tiếp theo:

Mở rộng phân tích temporal: Các nghiên cứu tiếp theo nên sử dụng chuỗi thời gian thay vì chỉ phân tích hai thời kỳ (bi-temporal), đồng thời áp dụng các mô hình như LSTM hoặc Transformer để khai thác các mẫu temporal.

Cải thiện mô hình: Cần thử nghiệm cơ chế attention để tăng khả năng giải thích, tận dụng transfer learning từ các mô hình pretrained, và áp dụng ensemble methods nhằm tăng độ chính xác và độ ổn định.

Ứng dụng thực tế: Hướng phát triển bao gồm triển khai hệ thống giám sát near-real-time, mở rộng phạm vi áp dụng sang các tỉnh trong vùng Đồng bằng sông Cửu Long, và tích hợp kết quả với hệ thống GIS của cơ quan quản lý rừng.

Tăng cường thu thập dữ liệu: Cần khảo sát thực địa để validate kết quả, mở rộng bộ ground truth, và thu thập thêm dữ liệu multi-temporal để nâng cao khả năng khai thác chuỗi thời gian.

TÀI LIỆU THAM KHẢO

Tiếng Việt

- [1] Bộ Nông nghiệp và Phát triển Nông thôn, *Quyết định số 1558/QĐ-BNN-TCLN về việc công bố hiện trạng rừng toàn quốc năm 2020*, Hà Nội, 2021.
- [2] Bùi Thị Dung, Phan Thị Thanh Hằng, Nguyễn Văn Long, “Biến động rừng ngập mặn ven biển đồng bằng sông Cửu Long giai đoạn 1990-2020 từ ảnh Landsat”, *Tạp chí Khoa học Đại học Huế: Khoa học Tự nhiên*, tập 130, số 1B, 2021, tr. 5–18.
- [3] Sở Nông nghiệp và Phát triển Nông thôn tỉnh Cà Mau, *Báo cáo hiện trạng rừng tỉnh Cà Mau năm 2021*, Cà Mau, 2021.

Tiếng Anh

- [4] Alongi, D. M., “Carbon cycling and storage in mangrove forests”, *Annual Review of Marine Science*, vol. 6, 2014, pp. 195–219.
- [5] Donato, D. C., Kauffman, J. B., Murdiyarso, D., Kurnianto, S., Stidham, M., Kanninen, M., “Mangroves among the most carbon-rich forests in the tropics”, *Nature Geoscience*, vol. 4, no. 5, 2011, pp. 293–297.
- [6] European Space Agency, *Sentinel-1 SAR User Guide*, ESA Sentinel Online, 2024, Available: <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-1-sar>.
- [7] European Space Agency, *Sentinel-2 MSI User Guide*, ESA Sentinel Online, 2024, Available: <https://sentinel.esa.int/web/sentinel/user-guides/sentinel-2-msi>.

- [8] FAO, *Global Forest Resources Assessment 2020: Main Report*, Food and Agriculture Organization of the United Nations, Rome, 2020.
- [9] Global Forest Watch, *Forest Loss Data 2015-2020*, World Resources Institute, 2021, Available: <https://www.globalforestwatch.org>.
- [10] Hansen, M. C., Potapov, P. V., Moore, R., Hancher, M., Turubanova, S. A., Tyukavina, A., Townshend, J. R. G., “High-resolution global maps of 21st-century forest cover change”, *Science*, vol. 342, no. 6160, 2013, pp. 850–853.
- [11] Hethcoat, M. G., Edwards, D. P., Carreiras, J. M., Bryant, R. G., França, F. M., Quegan, S., “A machine learning approach to map tropical selective logging”, *Remote Sensing of Environment*, vol. 221, 2019, pp. 569–582.
- [12] Hosmer, D. W., Lemeshow, S., Sturdivant, R. X., *Applied Logistic Regression*, 3 ed., Wiley, 2013.
- [13] Hu, Y., Raza, A., Sohail, A., Jiang, W., Shah, S. A. M., Asghar, M., Hussain, S., “Land use/land cover classification using multisource Sentinel-1 and Sentinel-2 satellite imagery”, *The Journal of the Indian Society of Remote Sensing*, vol. 48, 2020, pp. 1055–1064.
- [14] Huang, S., Tang, L., Hupy, J. P., Wang, Y., Shao, G., “A commentary review on the use of normalized difference vegetation index (NDVI) in the era of popular remote sensing”, *Journal of Forestry Research*, vol. 32, no. 1, 2021, pp. 1–6.
- [15] Ienco, D., Interdonato, R., Gaetano, R., Ho Tong Minh, D., “Combining Sentinel-1 and Sentinel-2 satellite image time series for land cover mapping via a multi-source deep learning architecture”, *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 158, 2019, pp. 11–22.
- [16] IPCC, *Climate Change and Land: An IPCC Special Report on climate change, desertification, land degradation, sustainable land management, food security, and greenhouse gas fluxes in terrestrial ecosystems*, Intergovernmental Panel on Climate Change, 2019.
- [17] Karra, K., Kontgis, C., Statman-Weil, Z., Mazzariello, J. C., Mathis, M., Brumby, S. P., “Global land use/land cover with Sentinel 2 and deep learning”, *2021 IEEE*

International Geoscience and Remote Sensing Symposium IGARSS, pp. 4704–4707, IEEE, 2021.

- [18] Khatami, R., Mountrakis, G., Stehman, S. V., “A meta-analysis of remote sensing research on supervised pixel-based land-cover image classification processes: General guidelines for practitioners and future research”, *Remote Sensing of Environment*, vol. 177, 2016, pp. 89–100.
- [19] Kussul, N., Lavreniuk, M., Skakun, S., Shelestov, A., “Deep learning classification of land cover and crop types using remote sensing data”, *IEEE Geoscience and Remote Sensing Letters*, vol. 14, no. 5, 2017, pp. 778–782.
- [20] Nguyen, H. T. T., Doan, T. M., Tomppo, E., McRoberts, R. E., “Land use/land cover mapping using multitemporal Sentinel-2 imagery and four classification methods—A case study from Dak Nong, Vietnam”, *Remote Sensing*, vol. 12, no. 9, 2020, pp. 1367.
- [21] Pham, L. T. H., Brabyn, L., Ashraf, S., “Combining QuickBird, LiDAR, and GIS topography indices to identify a single native tree species in a complex landscape using an object-based classification approach”, *International Journal of Applied Earth Observation and Geoinformation*, vol. 50, 2019, pp. 187–197.
- [22] Reiche, J., Hamunyela, E., Verbesselt, J., Hoekman, D., Herold, M., “Improving near-real time deforestation monitoring in tropical dry forests by combining dense Sentinel-1 time series with Landsat and ALOS-2 PALSAR-2”, *Remote Sensing of Environment*, vol. 204, 2018, pp. 147–161.
- [23] Ronneberger, O., Fischer, P., Brox, T., “U-Net: Convolutional networks for biomedical image segmentation”, *Medical Image Computing and Computer-Assisted Intervention*, pp. 234–241, Springer, 2015.
- [24] Tobler, W. R., “A computer movie simulating urban growth in the Detroit region”, *Economic Geography*, vol. 46, no. sup1, 1970, pp. 234–240.
- [25] Xu, Y., Du, B., Zhang, L., Cerra, D., Pato, M., Carmona, E., Le Saux, B., “Advanced multi-sensor optical remote sensing for urban land use and land cover classification: Outcome of the 2018 IEEE GRSS Data Fusion Contest”, *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 12, no. 6, 2021, pp. 1709–1724.

- [26] Zhang, C., Sargent, I., Pan, X., Li, H., Gardiner, A., Hare, J., Atkinson, P. M., “Joint deep learning for land cover and land use classification”, *Remote Sensing of Environment*, vol. 221, 2020, pp. 173–187.
- [27] Zhang, L., Zhang, L., Du, B., “Deep learning for remote sensing data: A technical tutorial on the state of the art”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 4, no. 2, 2016, pp. 22–40.
- [28] Zhong, Y., Fei, F., Liu, Y., Zhao, B., Jiao, H., Zhang, L., “SatCNN: Satellite image dataset classification using agile convolutional neural networks”, *Remote Sensing Letters*, vol. 8, no. 2, 2018, pp. 136–145.
- [29] Zhu, X. X., Tuia, D., Mou, L., Xia, G.-S., Zhang, L., Xu, F., Fraundorfer, F., “Deep learning in remote sensing: A comprehensive review and list of resources”, *IEEE Geoscience and Remote Sensing Magazine*, vol. 5, no. 4, 2017, pp. 8–36.